Comparación de LDA y Árboles de Decisión para la Clasificación de Riesgo de Diabetes

SC3314 – Inteligencia Artificial

Universidad de Monterrey

Jorge Tello 664317

Índice

1. Introducción
2. Objetivos
3. Definición del problema y partición de datos
4. Modelo LDA
    - 4.1 Selección de variables
    - 4.2 Construcción del modelo y función discriminante
    - 4.3 Optimización del modelo
    - 4.4 Visualización y separación entre clases
5. Modelo de árbol de decisión
    - 5.1 Construcción del árbol inicial
    - 5.2 Poda del árbol (cost complexity pruning)
    - 5.3 Visualización e interpretación del árbol podado
6. Evaluación y comparación de modelos
    - 6.1 Métricas de desempeño de ambos modelos
    - 6.2 Comparación LDA vs. árbol de decisión
    - 6.3 Reflexión crítica y conclusión final

1. Introducción

La detección temprana de riesgo de diabetes es un problema de clasificación que puede abordarse desde distintos enfoques metodológicos, cada uno con supuestos y capacidades distintas. Mientras que la regresión logística modela directamente la probabilidad de pertenencia a una clase, otros métodos como el *Linear Discriminant Analysis* (LDA) parten de modelar la distribución de las variables predictoras dentro de cada clase, y métodos como los árboles de decisión prescinden por completo de supuestos distribucionales, generando particiones jerárquicas del espacio de predicción.

En este análisis se retoma el *Diabetes Health Indicators Dataset*, derivado de la encuesta BRFSS (Behavioral Risk Factor Surveillance System) 2015 del CDC, para comparar el desempeño de un modelo LDA y un modelo de árbol de decisión en la clasificación del riesgo de diabetes. A diferencia de un análisis centrado en un único modelo, el objetivo aquí es evaluar ambos enfoques bajo las mismas condiciones y determinar, con evidencia cuantitativa y cualitativa, cuál resulta más adecuado para este problema en particular.

El reporte documenta la definición del problema de clasificación y la partición de los datos, la construcción e interpretación del modelo LDA, la construcción y poda del árbol de decisión, y una comparación final entre ambos modelos, de forma que los resultados y conclusiones puedan comprenderse en su totalidad sin necesidad de revisar el código.

2. Objetivos

Objetivo general

Comparar el desempeño de un modelo LDA y un modelo de árbol de decisión para clasificar el riesgo de diabetes a partir de indicadores de salud, determinando cuál resulta más adecuado para este problema.

Objetivos específicos

- Definir el problema de clasificación y separar los datos en subconjuntos de entrenamiento y prueba, conservando el balance de clases en ambos.
- Construir un modelo LDA utilizando únicamente variables coherentes con sus supuestos, visualizar su función discriminante y evaluar la separación observada entre clases.
- Construir un árbol de decisión, aplicar un proceso de poda (*cost complexity pruning*) mediante validación cruzada, y visualizar e interpretar el árbol resultante.
- Calcular métricas de desempeño para ambos modelos y compararlas de forma explícita.

- Reflexionar sobre cómo los supuestos de cada modelo influyen en su desempeño, y concluir cuál modelo es más adecuado para este problema, con base en evidencia.

3. Definición del problema y partición de datos

Análisis breve de los datos

El *Diabetes Health Indicators Dataset* contiene 253,680 observaciones y 21 variables predictoras relacionadas con indicadores de salud, hábitos de vida y condiciones socioeconómicas. A diferencia del análisis anterior, en esta ocasión se conserva la variable de salida original con sus tres categorías:

$$Y \in \{0,\ 1,\ 2\} = \{\text{sin diabetes},\ \text{prediabetes},\ \text{diabetes}\}$$

La distribución de clases en la población completa muestra un fuerte desbalance, presentando un 84.2% sin diabetes, 1.8% con prediabetes y 13.9% con diabetes. Este desbalance, especialmente marcado en la clase "prediabetes" (la minoría absoluta), es una característica relevante del problema que debe tenerse en cuenta al interpretar las métricas de ambos modelos más adelante, pues un modelo puede alcanzar una exactitud aparentemente alta simplemente por acertar de forma consistente en la clase mayoritaria, sin necesariamente distinguir bien las tres categorías.

```
Dimensiones: 253680 filas, 22 columnas

Primeras 5 observaciones:
   Diabetes_012  HighBP  HighChol  CholCheck   BMI  Smo
ker  Stroke  \
0           0.0     1.0       1.0        1.0  40.0
1.0     0.0
1           0.0     0.0       0.0        0.0  25.0
1.0     0.0
2           0.0     1.0       1.0        1.0  28.0
0.0     0.0
3           0.0     1.0       0.0        1.0  27.0
0.0     0.0
4           0.0     1.0       1.0        1.0  24.0
0.0     0.0

   HeartDiseaseorAttack  PhysActivity  Fruits  ...  Any
Healthcare  \
0                   0.0           0.0     0.0  ...
1.0
1                   0.0           1.0     0.0  ...
0.0
2                   0.0           0.0     1.0  ...
1.0
3                   0.0           1.0     1.0  ...
1.0
4                   0.0           1.0     1.0  ...
1.0

   NoDocbcCost  GenHlth  MentHlth  PhysHlth  DiffWalk
Sex   Age  Education  \
0          0.0      5.0      18.0      15.0       1.0
0.0   9.0        4.0
1          1.0      3.0       0.0       0.0       0.0
0.0   7.0        6.0
2          1.0      5.0      30.0      30.0       1.0
0.0   9.0        4.0
3          0.0      2.0       0.0       0.0       0.0
0.0  11.0        3.0
4          0.0      2.0       3.0       0.0       0.0
0.0  11.0        5.0

   Income
0     3.0
1     1.0
2     8.0
3     6.0
4     4.0

[5 rows x 22 columns]

Cantidad de valores únicos por variable:
Diabetes_012: 3 valores únicos
HighBP: 2 valores únicos
HighChol: 2 valores únicos
CholCheck: 2 valores únicos
```

```
BMI: 84 valores únicos
Smoker: 2 valores únicos
Stroke: 2 valores únicos
HeartDiseaseorAttack: 2 valores únicos
PhysActivity: 2 valores únicos
Fruits: 2 valores únicos
Veggies: 2 valores únicos
HvyAlcoholConsump: 2 valores únicos
AnyHealthcare: 2 valores únicos
NoDocbcCost: 2 valores únicos
GenHlth: 5 valores únicos
MentHlth: 31 valores únicos
PhysHlth: 31 valores únicos
DiffWalk: 2 valores únicos
Sex: 2 valores únicos
Age: 13 valores únicos
Education: 6 valores únicos
Income: 8 valores únicos
```

Características de las variables

Una revisión de los valores únicos por columna permite clasificar las 21 variables predictoras según su naturaleza:

- **Binarias (14):** `HighBP`, `HighChol`, `CholCheck`, `Smoker`, `Stroke`, `HeartDiseaseorAttack`, `PhysActivity`, `Fruits`, `Veggies`, `HvyAlcoholConsump`, `AnyHealthcare`, `NoDocbcCost`, `DiffWalk` y `Sex` — todas codificadas como 0/1.
- **Categóricas ordinales (5):** `GenHlth` (1-5, salud general autopercibida), `Age` (1-13, categorías de rango de edad), `Education` (1-6), e `Income` (1-8).
- **Numéricas continuas/discretas (3):** `BMI`, `MentHlth` y `PhysHlth` (estas dos últimas cuentan días en un rango de 0 a 30).

Ninguna variable presenta valores faltantes. Esta distinción es particularmente relevante para la construcción del modelo LDA, ya que sus supuestos (normalidad y homocedasticidad) solo son razonables para variables continuas, lo que restringe de forma natural el subconjunto de variables utilizable en ese modelo.

Muestreo

Se trabaja con una muestra aleatoria simple de 50,736 observaciones, correspondiente al 20% de la población, lo cual amplía el conjunto de datos respecto al análisis anterior y permite evaluar el comportamiento de ambos modelos en un problema multiclase con una base más amplia.

```
Muestra: 50736 filas (20.0% de la población)

Población completa (%):
Diabetes_012
0.0    84.24
1.0     1.83
2.0    13.93
Name: proportion, dtype: float64

Muestra (%):
Diabetes_012
0.0    84.35
1.0     1.86
2.0    13.79
Name: proportion, dtype: float64
```

Tabla 1. Comparación del balance de clases entre la población y la muestra

Clase	Población (253,680)	Muestra (50,736)
Sin diabetes (0)	84.24% (213,703)	84.35% (42,795)
Prediabetes (1)	1.83% (4,631)	1.86% (944)
Diabetes (2)	13.93% (35,346)	13.79% (6,997)

La Tabla 1 permite verifica las proporciones de las tres clases en la muestra son prácticamente idénticas a las de la población completa, con diferencias menores a 0.15 puntos porcentuales en cada categoría. Esto es particularmente relevante para la clase "prediabetes", que al representar apenas 1.83% de la población total es la más susceptible a distorsionarse con una muestra mal balanceada, por ende, su proporción en la muestra (1.86%) confirma que el muestreo fue representativo también para esta clase minoritaria.

Partición de datos

La muestra se dividió en un subconjunto de entrenamiento (80%) y uno de prueba (20%), utilizando muestreo estratificado respecto a la variable de salida, con el fin de garantizar que la proporción de las tres clases se mantenga consistente en ambos subconjuntos. Esto es particularmente relevante en un problema multiclase con desbalance, ya que una partición completamente aleatoria podría, por azar, dejar muy pocas observaciones de la clase minoritaria (prediabetes) en alguno de los dos subconjuntos, afectando tanto el entrenamiento como la evaluación de los modelos.

```
Entrenamiento: 40588 obs. | Prueba: 10148 obs.

Balance de clases (%):
Muestra completa:
 Diabetes_012
0.0    84.35
1.0     1.86
2.0    13.79
Name: proportion, dtype: float64

Entrenamiento:
 Diabetes_012
0.0    84.35
1.0     1.86
2.0    13.79
Name: proportion, dtype: float64

Prueba:
 Diabetes_012
0.0    84.35
1.0     1.86
2.0    13.79
Name: proportion, dtype: float64
```

Tabla 2. Balance de clases entre la muestra completa y los subconjuntos de entrenamiento y prueba

Clase	Muestra completa (50,736)	Entrenamiento (40,588)	Prueba (10,148)
Sin diabetes (0)	84.35% (42,795)	84.35% (34,235)	84.35% (8,560)
Prediabetes (1)	1.86% (944)	1.86% (755)	1.86% (189)
Diabetes (2)	13.79% (6,997)	13.79% (5,598)	13.79% (1,399)

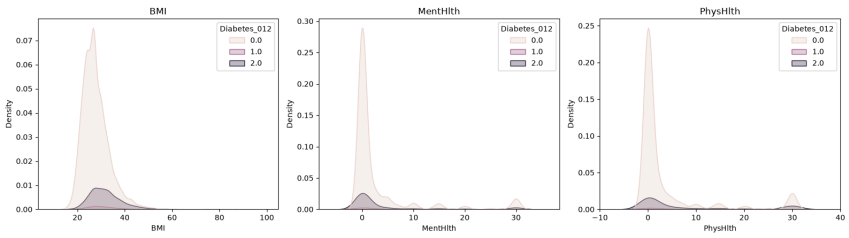
La Tabla 2 confirma que la estratificación logró su objetivo, las proporciones de las tres clases son casi idénticas entre la muestra completa, el conjunto de entrenamiento y el conjunto de prueba, lo que garantiza que ambos modelos serán entrenados y evaluados bajo condiciones de desbalance de clases consistentes, y que cualquier diferencia de desempeño que se observe entre LDA y el árbol de decisión no podrá atribuirse a una distribución de clases distinta entre subconjuntos.

4.Modelo basado en LDA

4.1 Selección de variables

Antes de decidir qué variables incorporar al modelo LDA, es necesario visualizar su distribución dentro de cada clase, ya que el supuesto central del método es que estas siguen una distribución aproximadamente normal (o al menos razonablemente simétrica) para cada categoría de la variable de salida. Debido a la naturaleza del modelo LDA al aplicar el teorema de Bayes para estimar la probabilidad de pertenecer a cada clase, y para ello se requiere modelar la densidad de cada variable dentro de cada clase como una distribución normal, por lo que las variables binarias y las categóricas ordinales quedan descartadas de inicio, sin importar su comportamiento en los datos.

De las 21 variables del dataset, únicamente `BMI`, `MentHlth` y `PhysHlth` son numéricas continuas o casi continuas, el resto son binarias o categóricas ordinales, por lo que quedan descartadas de inicio para este modelo. Sin embargo, ser numérica no garantiza que una variable cumpla el supuesto de normalidad, por lo que se grafican las densidades de estas tres variables, estratificadas por clase, antes de tomar una decisión final.



(Figura 1: densidades de BMI, MentHlth y PhysHlth, estratificadas por clase)

La Figura 1 revela un contraste entre las tres variables. `BMI` presenta una forma relativamente unimodal y con forma de campana, con un sesgo positivo moderado (asimetría entre 1.2 y 2.35 según la clase) explicado por la cola larga hacia índices de masa corporal muy altos, lo que es un comportamiento esperable y razonablemente compatible con el supuesto de normalidad de LDA, aunque no perfecto.

Por otro lado, `MentHlth` y `PhysHlth` , muestran un patrón claramente distinto, ya que la enorme mayoría de las observaciones se concentra en el valor 0 (ningún día de mala salud mental o física en el último mes), con un segundo pico notorio en el valor 30 (todos los días del mes). Este patrón, es característico de variables de conteo acotadas en encuestas de salud, y afecta de forma severa el supuesto de normalidad, la distribución no es unimodal ni simétrica, sino que concentra su masa en los extremos del rango posible.

Tabla 3. Media, desviación estándar y asimetría (*skewness*) de las variables continuas por clase

Variable	Clase	Media	Desv. estándar	Asimetría
BMI	Sin diabetes (0)	27.80	6.29	2.35
BMI	Prediabetes (1)	30.57	6.68	1.21
BMI	Diabetes (2)	31.96	7.18	1.41
MentHlth	Sin diabetes (0)	2.93	7.05	2.90
MentHlth	Prediabetes (1)	4.04	8.30	2.26
MentHlth	Diabetes (2)	4.38	8.80	2.09
PhysHlth	Sin diabetes (0)	3.56	7.98	2.54
PhysHlth	Prediabetes (1)	6.22	10.15	1.57
PhysHlth	Diabetes (2)	7.97	11.35	1.15

Con base en este análisis, se decide utilizar **únicamente** `BMI` como variable predictora para el modelo LDA. Aunque es la única variable verdaderamente continua con una forma de distribución compatible con los supuestos del método, se reconoce como limitación que el modelo resultante será univariado y, por tanto, con una capacidad de discriminación necesariamente más limitada que un modelo con más predictores. `MentHlth` y `PhysHlth` se descartan explícitamente por no cumplor con el supuesto de normalidad, lo cual las haría inadecuadas para LDA sin antes aplicar alguna transformación que corrija la inflación de ceros, dicha transformación que queda fuera del alcance de este análisis.

Adicionalmente, se observa que la desviación estándar de `BMI` aumenta ligeramente conforme aumenta el nivel de riesgo (6.29 → 6.68 → 7.18), lo cual sugiere una incongruencia leve del supuesto de homocedasticidad (igualdad de

varianza entre clases) que asume LDA. Sin embargo, dado que las diferencias son moderadas, se considera razonable continuar con LDA sobre esta variable, reconociendo esta limitación en la interpretación de resultados.

4.2 Construcción del modelo y función discriminante

El primer paso es estandarizar la variable predictora (`BMI`) para que tenga media 0, usando los parámetros de escalamiento ajustados exclusivamente sobre el conjunto de entrenamiento. A partir de esta variable estandarizada se estiman los tres componentes que requiere la función discriminante, la probabilidad previa π_k de cada clase (la proporción de observaciones de entrenamiento que pertenecen a esa clase), la media μ_k de BMI dentro de cada clase, y la varianza combinada (pooled variance), que es un promedio ponderado de las varianzas de las tres clases y que representa el supuesto de homocedasticidad propio de LDA. El desempeño de este primer modelo, con las probabilidades previas estimadas directamente de los datos, se evalúa mediante validación cruzada estratificada de 5 folds sobre el conjunto de entrenamiento, dejando el conjunto de prueba sin tocar hasta que se elija la configuración final del modelo en la sección 4.3.

```
Exactitud (CV): 83.90%
F1 macro (CV): 0.320
Recall por clase (CV): {np.float64(0.0): np.float64(0.9
9), np.float64(1.0): np.float64(0.0), np.float64(2.0):
np.float64(0.026)}
```

La validación cruzada arroja una exactitud de 83.90%, cifra que en un primer vistazo parece un buen resultado, pero que vuelve a ser engañosa por el mismo motivo señalado en la sección anterior: la clase 0 (sin diabetes) representa el 84.35% de las observaciones, así que un modelo que siempre prediga esa clase alcanzaría una exactitud casi idéntica. Esto se confirma con el recall por clase obtenido en la validación cruzada, 99.0% para la clase 0, pero apenas 2.6% para la clase 2 (diabetes) y 0.0% para la clase 1 (prediabetes), por otro lado, el F1 que promedia el desempeño entre las tres clases sin dejarse dominar por la mayoritaria, es de solo 0.320. El modelo, con una sola variable predictora y clases fuertemente desbalanceadas, concentra su decisión casi por completo en la clase mayoritaria. Este comportamiento no es un error de implementación, sino una consecuencia directa de usar las probabilidades previas empíricas, al reflejar la proporción real de cada clase, empujan al modelo a favorecer sistemáticamente a la más frecuente.

La Tabla 4 compara la distribución real de clases en el conjunto de entrenamiento contra la distribución de las predicciones obtenidas por validación cruzada, y deja ver el problema con claridad.

Tabla 4. Distribución real vs. predicha (validación cruzada, conjunto de entrenamiento)

Clase	% real (train)	% predicho por LDA (CV)
0 — Sin diabetes	84.35%	98.81%
1 — Prediabetes	1.86%	0.00%
2 — Diabetes	13.79%	1.19%

4.3 Optimización del modelo

Para evaluar si el sesgo hacia la clase mayoritaria puede corregirse sin cambiar el modelo, se ajusta un segundo LDA sobre la misma variable (BMI), pero forzando probabilidades previas uniformes ($\pi_0 = \pi_1 = \pi_2 = 1/3$) en lugar de las estimadas a partir de los datos. Esto no cambia la forma en que el modelo aprende las medias y la varianza combinada, pero sí cambia el punto de corte de decisión entre clases. Al igual que en la sección 4.2, esta comparación se realiza mediante validación cruzada sobre el conjunto de entrenamiento, para que la decisión de qué configuración usar no dependa en absoluto del conjunto de prueba.

```
Exactitud (CV, priors uniformes): 64.09%
F1 macro (CV, priors uniformes): 0.383
Recall por clase (CV, priors uniformes): {np.float64(0.
0): np.float64(0.681), np.float64(1.0): np.float64(0.15
1), np.float64(2.0): np.float64(0.461)}
```

Tabla 5. Recall por clase en validación cruzada (conjunto de entrenamiento)

Clase	Recall — priors por defecto	Recall — priors uniformes
0 — Sin diabetes	99.0%	68.1%
1 — Prediabetes	0.0%	15.1%
2 — Diabetes	2.6%	46.1%

Con priors uniformes, la exactitud en validación cruzada cae de 83.90% a 64.09%, porque el modelo deja de predecir automáticamente la clase mayoritaria y comete más errores sobre ella. A cambio, el F1 macro mejora de 0.320 a 0.383, y la sensibilidad para detectar diabetes (clase 2) sube de 2.6% a 46.1%, mientras que la de prediabetes (clase 1) pasa de 0.0% a 15.1%. Este es el mismo trade-off entre exactitud global y sensibilidad que se espera habitualmente, pues no existe una configuración que mejore todas las métricas simultáneamente, sino que se trata de decidir qué error es más costoso para el contexto de aplicación.

Con base en este análisis realizado enteramente sobre el conjunto de entrenamiento, se selecciona el modelo con **priors uniformes** como configuración final. Este modelo se reentrena sobre todo el conjunto de entrenamiento y se evalúa sobre el conjunto de prueba.

```
Exactitud (prueba): 65.38%
F1 macro (prueba): 0.389
Recall por clase (prueba): {np.float64(0.0): np.float64
(0.694), np.float64(1.0): np.float64(0.132), np.float64
(2.0): np.float64(0.478)}
```

Tabla 6. Desempeño del modelo final (priors uniformes) sobre el conjunto de prueba

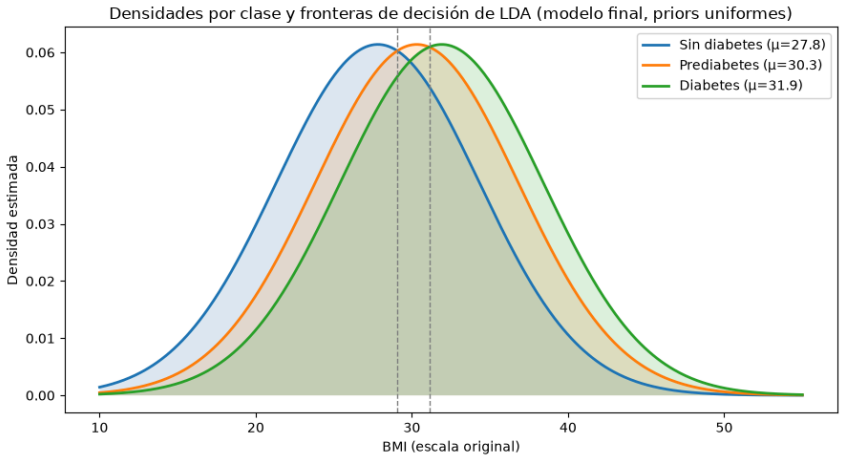
Métrica	Validación cruzada (train)	Conjunto de prueba
Exactitud	64.09%	65.38%
F1 macro	0.383	0.389
Recall — Sin diabetes (0)	68.1%	69.4%
Recall — Prediabetes (1)	15.1%	13.2%
Recall — Diabetes (2)	46.1%	47.8%

Los resultados sobre el conjunto de prueba son prácticamente idénticos a los obtenidos en validación cruzada, lo cual es una señal saludable: confirma que la decisión de usar priors uniformes no fue una casualidad favorable al conjunto de prueba, sino una mejora consistente que se sostiene en datos que el modelo no había visto en ningún momento del proceso de selección. Este modelo, con priors uniformes, es el que se usará en la sección 6 para la comparación final contra el árbol de decisión.

4.4 Visualización y separación entre clases

Para completar el análisis del modelo LDA es útil visualizar directamente la separación (o falta de ella) que logra la única variable utilizada. Dado que el modelo estima una densidad normal por clase compartiendo la varianza combinada, se puede graficar esa densidad teórica para cada una de las tres clases usando sus medias estimadas y la varianza combinada, y superponer las fronteras de decisión que resultan de comparar las tres funciones discriminantes entre sí. Este ejercicio usa el modelo final seleccionado en la sección 4.3 (priors uniformes).

```
Medias estimadas (BMI): {np.float64(0.0): np.float64(2
7.8), np.float64(1.0): np.float64(30.3), np.float64(2.
0): np.float64(31.9)}
Desviación estándar combinada (BMI): 6.50
Fronteras de decisión (BMI): [np.float64(29.1), np.floa
t64(31.1)]
```



La Figura 4 muestra las tres curvas de densidad normal estimadas por el modelo (una por clase, todas con la misma forma porque comparten la varianza combinada, pero desplazadas según su media), junto con las dos fronteras de decisión resultantes, ubicadas en BMI ≈ 29.1 y BMI ≈ 31.1. Estas fronteras dividen el eje de BMI en tres regiones: por debajo de 29.1 el modelo predice "sin diabetes", entre 29.1 y 31.1 predice "prediabetes", y por encima de 31.1 predice "diabetes".

Lo más relevante de esta figura es qué tan poco separadas están las tres distribuciones: sus medias (27.8, 30.3 y 31.9) están a menos de media desviación estándar combinada ($\sigma \approx 6.7$) una de otra, lo que produce un traslape casi total entre las tres curvas. Esto explica de forma visual por qué, incluso tras ajustar las probabilidades previas en la sección 4.3, el desempeño del modelo se mantiene moderado, no es una limitación del ajuste de parámetros.

5. Modelo basado en árbol de decisión

5.1 Construcción inicial del árbol

A diferencia de LDA, un árbol de decisión no asume ninguna distribución particular para las variables predictoras, por lo que puede construirse usando las 21 variables del dataset sin necesidad de descartar las binarias o categóricas ordinales. Como primer paso se construirá un árbol sin ninguna restricción de profundidad ni de número mínimo de observaciones por hoja, para observar su comportamiento natural antes de aplicar cualquier control de complejidad.

```
Profundidad del árbol: 32
Número de hojas: 8064
Exactitud sobre el propio conjunto de entrenamiento: 9
9.79%
Exactitud (validación cruzada): 76.62%
F1 macro (validación cruzada): 0.402
```

Los resultados son un ejemplo de overfitting. El árbol sin restricciones alcanza una profundidad de 32 niveles y genera 8,064 hojas, es decir, determina patrones altamente específicos del conjunto de entrenamiento. Esto se refleja en que su exactitud sobre ese mismo conjunto es de 99.79%, prácticamente perfecta, pero cuando se evalúa mediante validación cruzada (datos que el árbol no vio durante cada ajuste), la exactitud cae a 76.62% y el F1 es de solo 0.402. La diferencia de más de 23 puntos porcentuales entre el desempeño en entrenamiento y en validación cruzada confirma que el árbol sin podar no generaliza, en lugar de aprender relaciones robustas entre las variables y la clase, construye reglas cada vez más específicas hasta clasificar correctamente casi cualquier observación individual del conjunto de entrenamiento, incluyendo ruido. Este es exactamente el problema que la poda por cost-complexity busca corregir.

5.2 Poda por cost-complexity

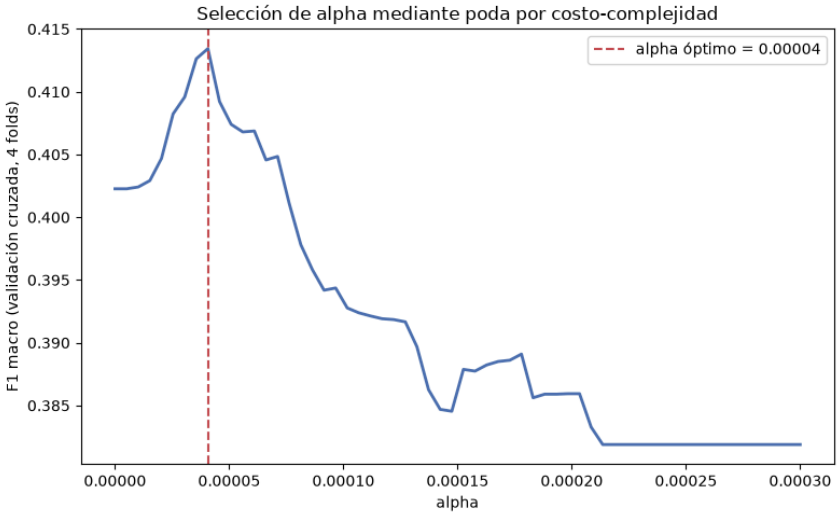
El objetivo de podar nuestro modelo es minimizar por medio de:

$R_\alpha(T) = \Sigma\, G_m \cdot \pi_m + \alpha|T|$

donde el primer término es la impureza total del árbol (medida con el índice Gini) y el segundo penaliza la cantidad de hojas $|T|$, con α controlando qué tanto peso se le da a esa penalización. Un α mayor favorece árboles más simples; un α de 0 no penaliza en absoluto y reproduce el árbol sin podar de la sección anterior.

Obtenemos primero el conjunto de valores de α que producen subárboles distintos mediante `cost_complexity_pruning_path` , y después se evalúa el desempeño de cada uno mediante validación cruzada, seleccionando el α que maximiza el promedio de la métrica en los folds. Usaremos el F1 como métrica de selección, ya que promedia el desempeño entre las tres clases sin dejarse dominar por la clase mayoritaria, igual que se hizo para elegir entre configuraciones de LDA.

```
Alpha óptimo: 0.000041
F1 macro (CV) con alpha óptimo: 0.4134
```



La Figura 5 muestra el F1 obtenido en validación cruzada conforme aumenta α.

Observamos que el α que maximiza el F1 (0.0000407) es muy pequeño, lo que a primera vista podría parecer poca poda. Sin embargo, dado que el conjunto de entrenamiento tiene 40,588 observaciones, incluso una penalización pequeña por hoja adicional es suficiente para eliminar las divisiones más específicas del árbol sin afectar las que sí generalizan. Con este α, el F1 en validación cruzada mejora de 0.402 (árbol sin podar) a 0.413, y la curva muestra que valores de α mayores a este punto óptimo degradan progresivamente el desempeño, cuando el árbol se simplifica demasiado y vuelve a perder capacidad de distinguir las clases minoritarias, aparece un patrón similar al que ya se había observado con las probabilidades previas de LDA en la sección 4.3.

5.3 Visualización e interpretación del árbol podado

Con el valor óptimo de α ya determinado, se ajusta el árbol final sobre todo el conjunto de entrenamiento y se compara su desempeño en validación cruzada contra el árbol sin podar de la sección 5.1.

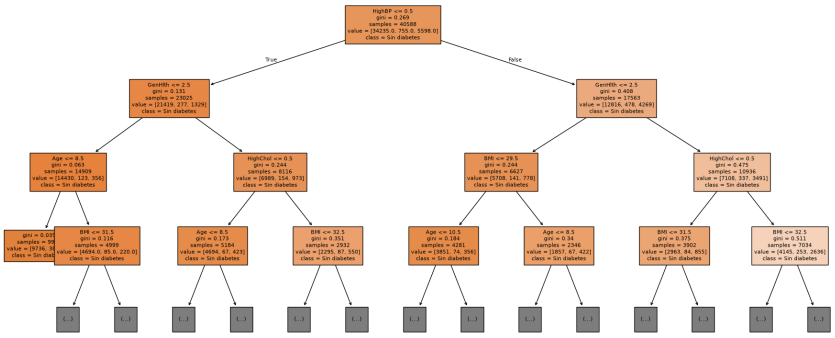
```
Profundidad del árbol podado: 26
Número de hojas del árbol podado: 1189
```

Tabla 7. Comparación entre árbol sin podar y árbol podado (validación cruzada, conjunto de entrenamiento)

Métrica	Sin podar	Podado (α=0.0000407)
Profundidad	32	26
Número de hojas	8,064	1,189
Exactitud (CV)	76.62%	81.05%
F1 (CV)	0.402	0.413
Recall — Sin diabetes (0)	85.4%	91.3%
Recall — Prediabetes (1)	3.4%	1.9%
Recall — Diabetes (2)	33.1%	28.9%

La poda reduce el árbol de 8,064 a 1,189 hojas, casi 7 veces menos, y aun así mejora tanto la exactitud como el F1 en validación cruzada, confirmando que las hojas eliminadas correspondían a sobreajuste y no a información útil. Sin embargo, la tabla también deja ver que la mejora no es uniforme entre clases, pues el recall de la clase mayoritaria (sin diabetes) sube, mientras que el de las dos clases minoritarias baja ligeramente. Esto sugiere que buena parte de las hojas eliminadas por la poda eran, precisamente, las que capturaban (aunque fuera por sobreajuste) patrones específicos de las observaciones con prediabetes o diabetes. Este resultado se retomará en la sección 6, donde se compara directamente contra el comportamiento de LDA.

A continuación se visualizan los primeros tres niveles del árbol podado (el árbol completo, con 1,189 hojas, no es legible en una sola figura) y se identifican las variables que más contribuyen a reducir la impureza en la totalidad del árbol.



```
Variables más importantes del árbol podado:
HighBP       0.172056
BMI          0.145671
GenHlth      0.139984
Age          0.091675
Income       0.077517
PhysHlth     0.076198
Education    0.046810
HighChol     0.045455
dtype: float64
```

(Figura 6: primeros tres niveles del árbol de decisión podado)

La primera división del árbol completo es sobre `HighBP` (presión arterial alta), seguida en el segundo nivel por `GenHlth` (percepción general de salud) en ambas ramas, y en el tercer nivel por una combinación de `Age`, `HighChol` y `BMI` según la rama. Esto coincide con la Tabla 8, que muestra las variables con mayor importancia (mayor reducción acumulada de impureza) en la totalidad del árbol.

Tabla 8. Importancia de las variables más relevantes en el árbol podado

Variable	Importancia
HighBP	0.172
BMI	0.146
GenHlth	0.140
Age	0.092
Income	0.078
PhysHlth	0.076
Education	0.047
HighChol	0.045

A diferencia de LDA, que solo pudo aprovechar `BMI`, el árbol distribuye su poder predictivo entre varias variables de distinta naturaleza: binarias (`HighBP`, `HighChol`), ordinales (`GenHlth`, `Age`, `Income`, `Education`) y continuas (`BMI`, `PhysHlth`). Con el árbol final ya seleccionado, se evalúa su desempeño sobre el conjunto de prueba.

```
Exactitud (prueba): 83.17%
F1 macro (prueba): 0.406
Recall por clase (prueba): {np.float64(0.0): np.float64
(0.946), np.float64(1.0): np.float64(0.0), np.float64
(2.0): np.float64(0.247)}
```

Tabla 9. Desempeño del árbol podado: validación cruzada vs. conjunto de prueba

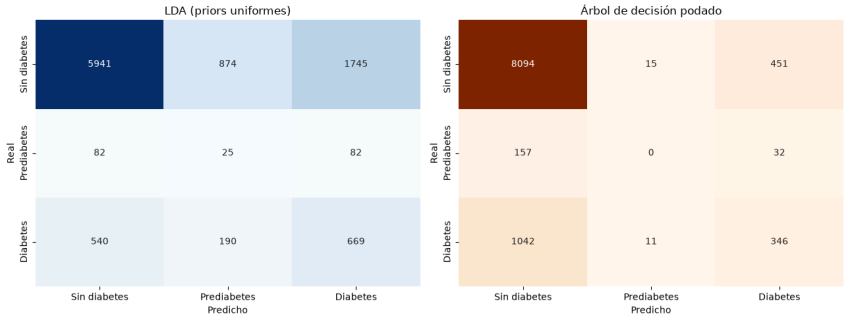
Métrica	Validación cruzada (train)	Conjunto de prueba
Exactitud	81.05%	83.17%
F1 macro	0.413	0.406
Recall — Sin diabetes (0)	91.3%	94.6%
Recall — Prediabetes (1)	1.9%	0.0%
Recall — Diabetes (2)	28.9%	24.7%

Al igual que con LDA, los resultados en el conjunto de prueba son consistentes con los de validación cruzada, lo que confirma que el α seleccionado no se ajustó de forma casual a los datos de entrenamiento. Se observa, sin embargo, que el árbol podado igual que LDA prácticamente no logra identificar la clase 1 (prediabetes), la más pequeña de las tres (1.86% del total).

6. Evaluación y comparación de modelos

6.1 Métricas de ambos modelos sobre el conjunto de prueba

Con ambos modelos ya definidos y evaluados de forma independiente en las secciones 4.3 y 5.3, esta sección los coloca lado a lado sobre las mismas 10,148 observaciones del conjunto de prueba, usando las mismas métricas para ambos. La Tabla 10 consolida esta comparación con el detalle de precisión, sensibilidad (recall) y F1 por clase.



(Figura 7: matrices de confusión de LDA y del árbol de decisión sobre el conjunto de prueba)

Tabla 10. Comparación de métricas sobre el conjunto de prueba

Métrica	LDA (priors uniformes)	Árbol podado
Exactitud	65.38%	83.17%
F1 macro	0.389	0.406
Precisión — Sin diabetes	90.5%	87.1%
Precisión — Prediabetes	2.3%	0.0%
Precisión — Diabetes	26.8%	41.7%
Recall — Sin diabetes	69.4%	94.6%
Recall — Prediabetes	13.2%	0.0%
Recall — Diabetes	47.8%	24.7%
F1 — Sin diabetes	0.786	0.907
F1 — Prediabetes	0.039	0.000
F1 — Diabetes	0.344	0.311

A nivel agregado, el árbol de decisión supera a LDA tanto en exactitud (83.17% vs. 65.38%) como en F1 (0.406 vs. 0.389), y la Figura 7 muestra que su matriz de confusión está mucho más concentrada en la diagonal para la clase mayoritaria, con muy pocos casos de "sin diabetes" mal clasificados. Sin embargo, la tabla también revela que ninguno de los dos modelos resuelve el problema de la clase 1 (prediabetes), pues LDA la identifica muy débilmente (13.2% de recall, con una precisión de apenas 2.3%), y el árbol simplemente **nunca la predice** (recall y F1 de 0.0%, visible en la Figura 7 como una columna central casi vacía en ambas matrices). En cambio, para la clase de diabetes (2), LDA logra un recall notablemente más alto (47.8% vs. 24.7% del árbol), aunque a costa de una precisión más baja.

6.2 Comparación explícita entre LDA y árbol de decisión

Más allá de las métricas agregadas, es útil observar directamente qué tanto coinciden ambos modelos en sus predicciones individuales, y en los casos donde difieren, cuál acierta con más frecuencia.

```
Coincidencia entre LDA y árbol: 66.7%
Ambos correctos: 5995 (59.1%)
Ambos incorrectos: 1068 (10.5%)
Solo LDA correcto: 640 (6.3%)
Solo árbol correcto: 2445 (24.1%)
```

Tabla 11. Coincidencia entre LDA y árbol de decisión (10,148 observaciones de prueba)

Resultado	Observaciones	% del total
Ambos modelos correctos	5,995	59.1%
Ambos modelos incorrectos	1,068	10.5%
Solo LDA correcto	640	6.3%
Solo el árbol correcto	2,445	24.1%

Los dos modelos coinciden en su predicción en 66.7% de los casos, y cuando difieren, el árbol acierta casi 4 veces más seguido que LDA (24.1% vs. 6.3% del total de observaciones). Esto es consistente con la ventaja de exactitud global observada en la Tabla 10, y tiene una explicación directa, pue el árbol dispone de 21 variables para tomar cada decisión, mientras que LDA solo cuenta con `BMI`. En los casos donde LDA acierta y el árbol no (6.3%), es razonable suponer que se trata principalmente de casos de diabetes o prediabetes donde el desplazamiento de las probabilidades previas hacia una decisión menos conservadora ayuda a LDA a identificar correctamente una clase minoritaria que el árbol tiende a ignorar.

6.3 Reflexión sobre el modelo más adecuado

LDA estuvo limitado desde la sección 4.1 a usar una sola variable continua (`BMI`), porque su supuesto de normalidad por clase excluye, a las variables binarias y categóricas ordinales que concentran la mayor parte de la información predictiva del dataset, como se confirmó después en la Tabla 8, donde variables como `HighBP` y `GenHlth` resultaron ser las más informativas para el árbol, y ninguna de las dos pudo ser aprovechada por LDA. Esta restricción, más que la calidad del método en sí, es la razón principal de su desempeño inferior, pues la Figura 4 ya mostraba un traslape casi total entre las tres distribuciones de BMI, dejando muy poco margen de separación disponible a un modelo que solo puede trazar fronteras lineales sobre una única dimensión.

El árbol de decisión, al no requerir ninguna distribución particular en sus predictores, pudo incorporar variables de los tres tipos presentes en el dataset (binarias, ordinales y continuas) y construir reglas de división no lineales combinando varias de ellas. Esto explica su ventaja en exactitud y en la identificación de la clase mayoritaria, pero aun mantiene los problemas ya que, en la sección 5.1 mostró que, sin control de complejidad, el árbol sobreajusta (99.79% de exactitud en entrenamiento contra 76.62% en validación cruzada), y aun después de la poda, su recall para prediabetes cae a 0%, el modelo, en su intento por maximizar la exactitud (dominada por la clase mayoritaria), termina por no generar jamás una hoja donde esa clase sea la mayoritaria localmente, dado que representa apenas 1.86% de las observaciones.

Por lo tanto se concluye que ningun modelo es capaz de determinar la clase 1, prediabetes. Esto se debe a una limitación de los datos disponibles frente a esa clase específica con solo 1.86% de las observaciones y, aparentemente, patrones

que se solapan considerablemente con las otras dos clases en las variables disponibles, ambos métodos convergen en tratarla como ruido dentro de la clase mayoritaria. Abordar este problema requeriría técnicas específicas para clases minoritarias (sobremuestreo, ponderación explícita por costos de error, o modelos especializados en detección de anomalías), que quedan fuera del alcance de esta actividad.

En cuanto a qué modelo es más adecuado, la respuesta depende del objetivo de aplicación:

- Si el objetivo es **maximizar la exactitud global** o clasificar correctamente a la mayoría de las personas sin diabetes, el **árbol de decisión podado** es preferible, ya que es más exacto, más flexible, y ofrece además interpretabilidad directa a través de sus reglas de división (Figura 6) y la importancia de sus variables (Tabla 8).
- Si el objetivo es **maximizar la detección de casos de diabetes** (un caso donde omitir un caso real es más costoso que generar una falsa alarma), **LDA con priors uniformes** es preferible a pesar de su menor exactitud global, ya que logra casi el doble de sensibilidad para esa clase (47.8% vs. 24.7%).

En ambos casos, sin embargo, la clase de prediabetes permanece prácticamente indetectable, lo cual es la limitación más grande de nuestros modelos.

Referencias

- World Health Organization: WHO & World Health Organization: WHO. (2024, 14 noviembre). Diabetes. https://www.who.int/es/news-room/fact-sheets/detail/diabetes (https://www.who.int/es/news-room/fact-sheets/detail/diabetes)
- Síntomas y causas de la diabetes - NIDDK. (s. f.). National Institute Of Diabetes And Digestive And Kidney Diseases. https://www.niddk.nih.gov/health-information/informacion-de-la-salud/diabetes/informacion-general/sintomas-causas (https://www.niddk.nih.gov/health-information/informacion-de-la-salud/diabetes/informacion-general/sintomas-causas)
- Teboul, A. (2021). Diabetes Health Indicators Dataset [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset (https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset)
- Anthropic. (2026). Claude [Modelo de lenguaje grande], Usado en codigo de gráficas. https://claude.ai/ (https://claude.ai/)