Modelos de ensamble, SVM y redes neuronales para la predicción de mortalidad en pacientes gravemente enfermos

SC3314 – Inteligencia Artificial

Universidad de Monterrey

Jorge Tello 664317

Índice

1. Introducción

2. Objetivos

3. Descripción del conjunto de datos

3.1 Población del estudio

3.2 Variables

3.3 Verificación de calidad: valores faltantes, tipos y balance de clases

3.4 Definición de las variables objetivo

- 3.4.1 Mortalidad intrahospitalaria (`hospdead`)
- 3.4.2 Ventana temporal de fallecimiento

3.5 Variables excluidas por data leakage

4. Preparación del escenario experimental

4.1 Partición train-test estratificada

4.2 Pipeline de preprocesamiento: imputación, codificación y escalamiento

4.3 Verificación de la adecuación del conjunto de datos

4.4 Validación cruzada estratificada (dentro de train)

4.5 Data Leakage

4.6 Métricas de evaluación

5. Construcción de modelos

5.1 Random Forest

5.2 Boosting

5.3 Support Vector Machine

5.4 Red neuronal

- 5.4.1 Arquitectura y funciones de activación
- 5.4.2 Configuración del entrenamiento: optimizador, función de costo, *early stopping*
- 5.4.3 Curvas de *Training and Validation Accuracy/Loss*

6. Evaluación y comparación de desempeño

6.1 Métricas en validación cruzada (media ± desviación estándar)

6.2 Métricas en el conjunto de prueba

6.3 Matrices de confusión

6.4 Curvas ROC y AUC

6.5 Diferencias sustanciales y marginales

7. Predicción de la ventana temporal de fallecimiento

7.1 Construcción de las ventanas y distribución de clases

7.2 Adaptación de los modelos a clasificación multiclase (*softmax*)

7.3 Resultados y matriz de confusión multiclase

8. Análisis General

8.1 Complejidad del modelo vs. mejora en desempeño

8.2 Riesgo de sobreajuste

8.3 Interpretabilidad relativa de cada modelo

8.4 ¿Cuándo preferir cada modelo?

9. Conclusiones

10. Referencias

1. Introducción

Estimar el pronóstico de un paciente gravemente enfermo es una de las tareas más difíciles y relevantes de la práctica clínica. Saber qué tan probable es que un paciente fallezca, y en cuánto tiempo, orienta decisiones como la intensidad del tratamiento, la asignación de camas de terapia intensiva, la transición a cuidados paliativos y la comunicación con el paciente y su familia. Por lo general, el pronóstico se basa en el juicio del médico, que puede variar entre profesionales.

Sin embargo, el juicio clínico por sí solo es poco preciso. En un estudio prospectivo con pacientes terminales, Christakis y Lamont (2000) encontraron que solo el 20 % de los pronósticos médicos fueron acertados. El 63 % fueron demasiado optimistas y, en promedio, los médicos sobrestimaron la supervivencia de sus pacientes por un factor de 5.3.

Para abordar este problema se realizó el estudio **SUPPORT** (*Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments*). Entre 1989 y 1994, el estudio siguió a **9,105 adultos gravemente enfermos** hospitalizados en cinco hospitales universitarios de Estados Unidos. Los pacientes pertenecían a grupos de enfermedades con alta mortalidad, como falla orgánica múltiple, sepsis, insuficiencia cardiaca, enfermedad pulmonar obstructiva crónica, cirrosis, coma y cáncer avanzado. De cada paciente se registraron variables demográficas, comorbilidades, mediciones fisiológicas y de laboratorio al tercer día de hospitalización, y su desenlace. Con estos datos, Knaus et al. (1995) desarrollaron el modelo pronóstico SUPPORT, basado en regresión de Cox, para estimar la supervivencia a 2 y 6 meses. Aunque este modelo fue validado clínicamente, supone que cada variable contribuye al riesgo de forma aditiva y lineal, por lo que no captura de forma natural las relaciones no lineales ni las interacciones complejas entre las variables clínicas.

El aprendizaje automático ofrece una alternativa para superar esta limitación. Los ensambles de árboles, las máquinas de soporte vectorial y las redes neuronales pueden aprender relaciones no lineales e interacciones directamente de los datos, sin especificarlas de antemano. Sin embargo, esta flexibilidad tiene un costo, pues los modelos más complejos son más propensos al sobreajuste y más difíciles de interpretar, lo cual es una desventaja importante en un contexto clínico, donde el médico necesita entender en qué se basa una predicción antes de actuar sobre ella. Por lo tanto, no es evidente que un modelo más complejo sea mejor.

2. Objetivos

Objetivo general

Entrenar y comparar cuatro modelos avanzados de clasificación (Random Forest, Boosting, Support Vector Machine y una red neuronal) para predecir la mortalidad intrahospitalaria y la ventana temporal de fallecimiento de pacientes gravemente enfermos del estudio SUPPORT, evaluando su capacidad predictiva, su estabilidad y su complejidad bajo un mismo escenario experimental.

Objetivos específicos

1. **Diseñar un escenario experimental justo y reproducible.** Esto incluye identificar y excluir las variables que causan fuga de información, definir una partición estratificada train-test común a todos los modelos y construir un pipeline de preprocesamiento (imputación, codificación y escalamiento) que se ajuste únicamente con los datos de entrenamiento.
2. **Construir los cuatro modelos** para la predicción de `hospdead`, describiendo y justificando sus principales hiperparámetros. En el caso de la red neuronal, esto incluye la arquitectura, las funciones de activación, el optimizador, la función de costo y el criterio de *early stopping*.
3. **Evaluar y comparar el desempeño** de los modelos con exactitud, precisión, *recall*, F1 y AUC-ROC, tanto en validación cruzada como en el conjunto de prueba, y determinar si las diferencias entre ellos son sustanciales o marginales.
4. **Extender el análisis a la predicción de la ventana temporal de fallecimiento** mediante clasificación multiclase con activación *softmax*.
5. **Reflexionar críticamente** sobre la relación entre complejidad y desempeño, el riesgo de sobreajuste, la interpretabilidad relativa de cada modelo y las situaciones en las que conviene preferir uno sobre otro.

3. Descripción del conjunto de datos

En este reporte se utiliza el conjunto de datos **SUPPORT2**, disponible en el UCI Machine Learning Repository, para entrenar y comparar cuatro modelos de clasificación: dos métodos de ensamble (Random Forest y Boosting), una máquina de soporte vectorial (SVM) y una red neuronal. La tarea principal es predecir la **mortalidad intrahospitalaria** (`hospdead`) usando solo la información disponible en los primeros días de hospitalización. Como extensión, se predice la **ventana de tiempo** en la que ocurre el fallecimiento, planteada como un problema de clasificación multiclase. Finalmente, se analiza de forma crítica la relación entre la complejidad de cada modelo, su desempeño, su riesgo de sobreajuste y su interpretabilidad.

El conjunto de datos plantea tres retos metodológicos que determinan el diseño del análisis:

- **Fuga de información.** Varias variables, como la duración de la estancia, los días de seguimiento y los costos hospitalarios, solo se conocen después del desenlace. Por eso deben excluirse de los predictores.
- **Valores faltantes reales**, propios de los registros clínicos, que deben imputarse sin contaminar el conjunto de prueba.
- **Tipos de variables heterogéneos** (numéricas, binarias, nominales y ordinales), que requieren un preprocesamiento diferenciado.

```
Pacientes: 9105 | Columnas: 47
```

3.1 Población del estudio

El estudio SUPPORT incluyó a 9,105 adultos hospitalizados con alguna enfermedad grave, clasificada en ocho grupos en la variable `dzgroup` . Las mediciones fisiológicas y de laboratorio corresponden al **tercer día desde el ingreso al estudio** (Knaus et al., 1995). Por lo tanto, la predicción se plantea como la que haría un médico en ese momento: con la información clínica de los primeros días, ¿qué tan probable es que el paciente fallezca durante la hospitalización y en qué horizonte de tiempo?

La Tabla 3.1 muestra el tamaño de cada grupo de enfermedad y su mortalidad intrahospitalaria.

Tabla 3.1. Pacientes y mortalidad intrahospitalaria por grupo de enfermedad

Grupo de enfermedad	Pacientes	% de la muestra	Mortalidad intrahospitalaria (%)
Coma	596	6.5	60.7
Falla orgánica múltiple con cáncer	712	7.8	52.7
Falla respiratoria/orgánica con sepsis	3,515	38.6	33.7
Cirrosis	508	5.6	23.2
Cáncer de pulmón	908	10.0	11.2
EPOC	967	10.6	10.7
Insuficiencia cardiaca	1,387	15.2	6.3
Cáncer de colon	512	5.6	5.7

Los grupos de enfermedad tienen tamaños muy desiguales. La falla respiratoria u orgánica con sepsis concentra el 38.6 % de la muestra (3,515 pacientes), mientras que la cirrosis y el cáncer de colon representan cada uno el 5.6 %. Aun así, todos los grupos superan los 500 pacientes, un tamaño suficiente para analizarlos y trabajar con ellos.

La mortalidad intrahospitalaria también varía de forma marcada entre enfermedades: va del 60.7 % en los pacientes en coma al 5.7 % en los pacientes con cáncer de colon, una diferencia de más de diez veces. Esta heterogeneidad justifica incluir `dzgroup` como predictor y conservar la proporción de cada enfermedad al dividir los datos (sección 4.1). Sin embargo, un modelo que solo aprendiera la mortalidad promedio de cada grupo ya tendría cierta capacidad predictiva sin aportar información clínica nueva. Lo que interesa evaluar es si los modelos distinguen el riesgo **dentro** de cada enfermedad a partir del estado clínico del paciente.

3.2 Variables

El conjunto de datos tiene 47 columnas, agrupadas en la Tabla 3.2 según su contenido. Tipos: **C** = numérica continua, **D** = numérica discreta, **B** = binaria, **N** = categórica nominal, **O** = categórica ordinal.

Tabla 3.2. Variables del conjunto de datos SUPPORT2, tipo y uso en el análisis

Grupo	Variables (tipo)	Uso
Demográficas	`age` (C), `sex` (N), `race` (N), `edu` (D), `income` (O)	Predictores
Enfermedad y comorbilidades	`dzgroup` (N), `num.co` (D), `diabetes` (B), `dementia` (B), `ca` (O)	Predictores
Escalas clínicas (día 3)	`scoma` (D), `sps` (C), `aps` (C), `adlsc` (C), `hday` (D)	Predictores

Grupo	Variables (tipo)	Uso
Signos vitales (día 3)	`meanbp` , `hrt` , `resp` , `temp` (C)	Predictores
Laboratorio (día 3)	`wblc` , `pafi` , `alb` , `bili` , `crea` , `sod` , `ph` , `glucose` , `bun` , `urine` (C)	Predictores
Órdenes médicas	`dnr` (N)	Predictor transformado (sección 3.5)
Pronósticos (día 3)	`prg2m` , `prg6m` (médico); `surv2m` , `surv6m` (modelo SUPPORT) (C, 0–1)	Excluidas
Desenlaces	`hospdead` (B) / `death` (B), `d.time` (D)	Objetivo principal / construcción de la ventana temporal
Posteriores al día 3	`slos` , `sfdm2` , `charges` , `totcst` , `totmcst` , `avtisst` , `dnrday`	Excluidas (fuga de información)
Redundantes	`dzclass` , `adlp` , `adls`	Excluidas

Abreviaturas:

- `scoma` : escala de coma basada en la escala de Glasgow.
- `sps` y `aps` : puntajes fisiológicos de SUPPORT y de APACHE III.
- `adlsc` : índice calibrado de actividades de la vida diaria.
- `hday` : día de hospitalización en que el paciente ingresó al estudio.
- `pafi` : relación PaO_2/FiO_2, un indicador de la oxigenación.
- `prg` y `surv` : probabilidades de supervivencia a 2 y 6 meses.

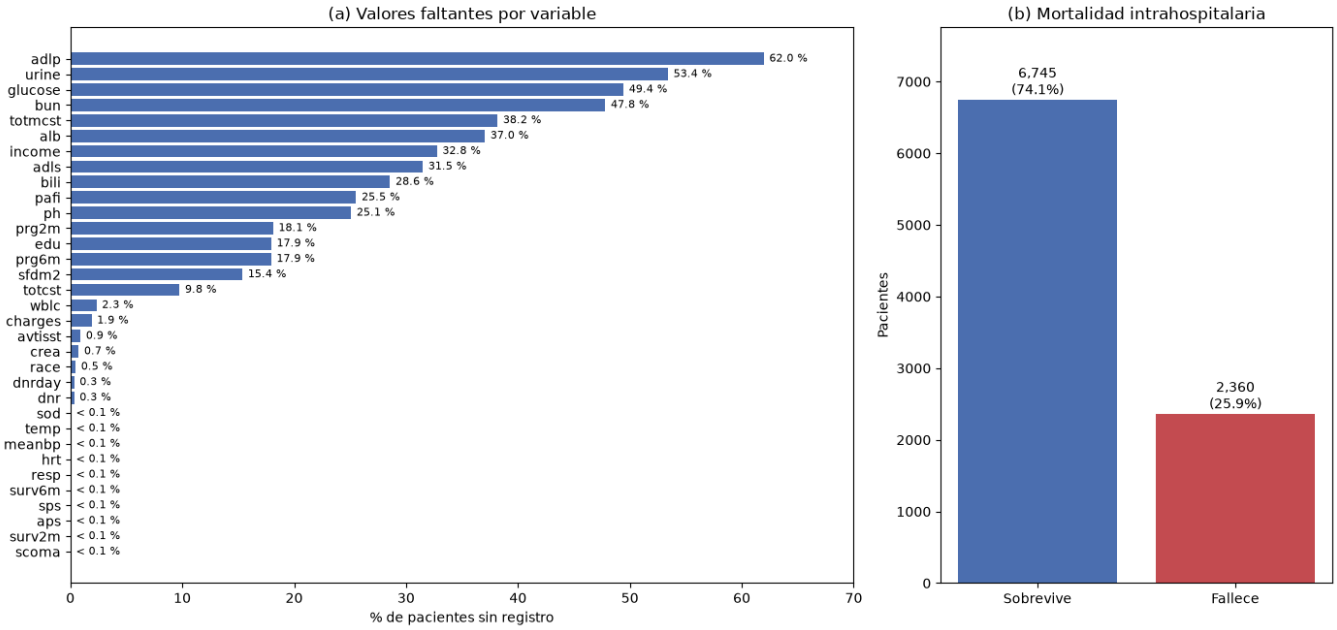
3.3 Verificación de calidad

La ficha del repositorio UCI indica que el conjunto de datos no tiene valores faltantes. Sin embargo, en los registros clínicos es habitual que no a todos los pacientes se les realicen todos los estudios de laboratorio, por lo que se verificó la integridad de los datos de forma independiente. La Tabla 3.3 resume la estructura del conjunto. La Figura 3.1 muestra el porcentaje de valores faltantes por variable (a) y el balance de la variable objetivo (b).

Tabla 3.3. Resumen de la verificación de calidad

	Valor
Pacientes	9,105
Columnas	47
Registros duplicados	0
Columnas numéricas	39
Columnas de texto	8
Columnas con valores faltantes	33

Figura 3.1. Valores faltantes por variable y balance de la variable objetivo



Se observa que no hay registros duplicados. De las 47 columnas, 39 son numéricas y 8 son de texto. Estas últimas corresponden a las variables categóricas y deberán codificarse según sean nominales u ordinales.

Valores faltantes.

Contrario a lo que indica la ficha del repositorio, 33 columnas tienen al menos un valor faltante. En la mayoría la proporción es mínima, pero varios estudios de laboratorio no se registraron en una fracción importante de los pacientes, p.e. el gasto urinario (`urine` , 53.4 %), la glucosa (`glucose` , 49.4 %), el nitrógeno ureico (`bun` , 47.8 %) y la albúmina (`alb` , 37.0 %). También faltan en una proporción considerable el ingreso (`income` , 32.8 %) y la escolaridad (`edu` , 17.9 %). Las variables con más faltantes de toda la tabla (`adlp` , `totmcst` , `adls` , `sfdm2`) no requieren tratamiento, porque serán excluidas del análisis posteriormente.

Balance de clases.

El 25.9 % de los pacientes (2,360) falleció durante la hospitalización y el 74.1 % (6,745) fue dado de alta con vida (Figura 3.1b). El desbalance es moderado, aproximadamente 3 a 1. Por lo tanto, la exactitud no basta como métrica de desempeño, pues un clasificador que siempre predijera "sobrevive" alcanzaría una exactitud del 74.1 % sin detectar un solo fallecimiento. Por esta razón, la evaluación se centra en *recall*, F1 y AUC-ROC, y la partición train-test se realiza de forma estratificada.

También es importante mencionar que, el hecho de que un estudio de laboratorio no se registre no siempre es un hecho aleatorio, puede reflejar una decisión clínica. Para evaluarlo, la Tabla 3.4 compara la mortalidad intrahospitalaria entre los pacientes con y sin registro de cada variable que tiene más del 2 % de faltantes y que se usa como predictor.

Tabla 3.4. Mortalidad intrahospitalaria según si la variable fue registrada

Variable	% faltante	Mortalidad sin registro (%)	Mortalidad con registro (%)	Diferencia (pp)
wblc	2.3	13.7	26.2	-12.5
pafi	25.5	17.1	28.9	-11.8
ph	25.1	17.2	28.8	-11.6
bili	28.6	24.3	26.6	-2.2
alb	37.0	26.0	25.9	0.1
bun	47.8	26.6	25.3	1.4
urine	53.4	26.6	25.1	1.4
glucose	49.4	26.7	25.1	1.6
income	32.8	30.0	23.9	6.1
edu	17.9	37.5	23.4	14.1

La Tabla 3.4 muestra tres comportamientos distintos:

- **El faltante se asocia con menor mortalidad.** Los pacientes sin registro de leucocitos (`wblc`), relación PaO_2/FiO_2 (`pafi`) o pH arterial (`ph`) tienen una mortalidad entre 11.6 y 12.5 puntos porcentuales menor que los que sí tienen registro. Esto es consistente con que estos estudios, en particular la gasometría arterial, se solicitan sobre todo a los pacientes más graves. Su ausencia indica, por sí misma, un paciente más estable.
- **El faltante se asocia con mayor mortalidad.** Los pacientes sin registro de escolaridad (`edu`) o de ingreso (`income`) tienen una mortalidad 14.1 y 6.1 puntos porcentuales mayor, respectivamente. Como son datos que se obtienen por entrevista, esto es consistente con que los pacientes más graves no pudieron responderla.
- **El faltante no es informativo.** En la bilirrubina, la albúmina, el nitrógeno ureico, el gasto urinario y la glucosa, la diferencia es menor a 2.5 puntos porcentuales, a pesar de que en algunas de ellas falta casi la mitad de los registros.

Por lo tanto, la estrategia de imputación no puede ser la misma para todas las variables. En las variables con faltantes informativos, la ausencia del dato contiene información sobre el desenlace que no debe perderse al imputar. Este hallazgo determina el diseño del preprocesamiento de la sección 4.

3.4 Definición de las variables objetivo

3.4.1 Mortalidad intrahospitalaria (`hospdead`)

La variable objetivo principal es `hospdead`, que vale 1 si el paciente falleció durante la hospitalización y 0 si fue dado de alta con vida. Es una variable categórica binaria y se usa tal como viene en el conjunto de datos. Su distribución se muestra en la Figura 3.1b.

3.4.2 Ventana temporal de fallecimiento

Para la extensión multiclase se construye una nueva variable a partir de `death` (si el paciente falleció en algún momento del seguimiento) y `d.time` (días desde el ingreso al estudio hasta la muerte o hasta el último contacto). Estas dos variables solo se usan para construir la variable objetivo; nunca como predictores.

La construcción debe considerar la "censura". Si un paciente seguía vivo al terminar el seguimiento, `d.time` indica el último día en que se supo de él, no el día de su muerte. Por ejemplo, un sobreviviente con 200 días de seguimiento no puede asignarse a la clase "sobrevive más de un año", porque se desconoce qué ocurrió después. Para elegir un metodo sin censura, la Tabla 3.5 compara el tiempo hasta la muerte de los fallecidos con el tiempo de seguimiento de los sobrevivientes.

Tabla 3.5. Tiempo hasta la muerte y tiempo de seguimiento (días)

	Pacientes	Mínimo	P25	Mediana	P75	Máximo	Seguimiento < 365 días
Fallecidos (días hasta la muerte)	6,201	3	14	58	252	1,944	—
Sobrevivientes (días de seguimiento)	2,904	344	622	918	1,543	2,029	65

El seguimiento de los sobrevivientes es largo, pues el mínimo es de 344 días y la mediana de 918. Solo 65 sobrevivientes tienen menos de un año de seguimiento. Por lo tanto, un horizonte de un año prácticamente no tiene censura, y esos 65 pacientes se excluyen únicamente de la tarea multiclase.

Entre los 6,201 pacientes que fallecieron, la mediana del tiempo hasta la muerte fue de 58 días y el 25 % falleció en los primeros 14 días. Es decir, una parte importante de las muertes ocurre muy cerca del ingreso.

Con base en esto, se definen cuatro ventanas temporales:

- Muerte en los primeros 30 días (mortalidad a corto plazo)

- Muerte entre los días 31 y 180 (mediano plazo, que coincide con el horizonte de seis meses del modelo SUPPORT)
- Muerte entre los días 181 y 365
- Dupervivencia mayor a un año.

La Tabla 3.6 muestra la distribución resultante y la Tabla 3.7 su relación con `hospdead`.

Tabla 3.6. Distribución de la ventana temporal de fallecimiento

Ventana	Pacientes	%
Muerte ≤ 30 días	2,463	27.2
Muerte 31–180 días	1,802	19.9
Muerte 181–365 días	778	8.6
Sobrevive > 1 año	3,997	44.2
Total	9,040	100.0

Los 9,040 pacientes con ventana definida se distribuyen de forma desigual (Tabla 3.6). La supervivencia mayor a un año es la clase más frecuente (44.2 %), seguida de la muerte en los primeros 30 días (27.2 %). La muerte entre los días 181 y 365 es la clase minoritaria (8.6 %) y, por lo tanto, la más difícil de predecir. Por esta razón, en la tarea multiclase se reporta el F1 de cada clase y no solo la exactitud global.

Tabla 3.7. Relación entre la mortalidad intrahospitalaria y la ventana temporal

Ventana	Muerte ≤ 30 días	Muerte 31–180 días	Muerte 181–365 días	Sobrevive > 1 año	Total
hospdead					
Fallece en el hospital	2,031	327	2	0	2,360
Sobrevive a la hospitalización	432	1,475	776	3,997	6,680
Total	2,463	1,802	778	3,997	9,040

La Tabla 3.7 muestra que las dos variables objetivo son complementarias y no redundantes:

- De los 2,360 pacientes que fallecieron en el hospital, 2,031 lo hicieron en los primeros 30 días y 329 después, en hospitalizaciones prolongadas.
- 432 pacientes fueron dados de alta con vida, pero fallecieron dentro de los primeros 30 días. `hospdead` los clasifica como sobrevivientes; la ventana temporal sí identifica que su riesgo era alto.

3.5 Variables excluidas por data leakage

Los modelos deben predecir el desenlace con la información disponible alrededor del tercer día de hospitalización. Cualquier variable que se registre después de ese momento, o que dependa del desenlace, produce fuga de datos, pues el modelo aprendería a "leer" el resultado en lugar de predecirlo. Tendría un desempeño artificialmente alto en la evaluación, pero sería inútil con un paciente nuevo. Por este motivo se excluyen las variables de la Tabla 3.8.

Tabla 3.8. Variables excluidas por fuga de información

Variable	Motivo de exclusión
`slos`	La duración de la estancia solo se conoce al alta o al fallecimiento.
`d.time` , `death`	Son información de seguimiento posterior al alta; solo se usan para construir la ventana temporal.
`sfdm2`	Describe el estado funcional a los dos meses, es decir, un desenlace.
`charges` , `totcst` , `totmcst`	Son costos acumulados durante toda la estancia, que dependen de su duración y de su desenlace.
`avtisst`	Promedia la intensidad del tratamiento de los días 3 a 25, por lo que incluye información futura.
`dnrday`	Las órdenes de no reanimar suelen darse poco antes de la muerte, así que su fecha anticipa el desenlace.
`dnr` (categoría "después del ingreso")	Por el mismo motivo, solo se conserva la información de si la orden existía **antes** del ingreso al estudio, como variable binaria `dnr_previo` .

El caso de `slos` ilustra la magnitud del problema. La Tabla 3.9 compara, para los pacientes que fallecieron en el hospital y para los que sobrevivieron, la proporción en la que la duración de la estancia coincide con los días de seguimiento.

Tabla 3.9. Coincidencia entre la duración de la estancia (slos) y los días de seguimiento (d.time)

Grupo	Pacientes	Pacientes con slos = d.time (%)
Fallece en el hospital	2,360	100.0
Sobrevive a la hospitalización	6,745	0.0

La duración de la estancia coincide con los días de seguimiento en el **100 %** de los pacientes que fallecieron en el hospital y en el **0 %** de los que sobrevivieron. La regla "si `slos` = `d.time` , el paciente murió en el hospital" clasifica correctamente a los 9,105 pacientes sin usar ninguna información clínica. Un modelo que recibiera estas variables alcanzaría un desempeño perfecto, pero sin ningún valor práctico, porque al tercer día de hospitalización ninguna de las dos se conoce todavía.

Además de las variables con fuga de información, se excluyen tres variables redundantes:

- **`dzclass`:** es una agrupación de `dzgroup`, por lo que no aporta información nueva.
- **`adlp` y `adls`:** son las variables con más valores faltantes (62.0 % y 31.5 %, Figura 3.1a), y su información ya está contenida en `adlsc`, la versión calibrada del índice de actividades de la vida diaria.

Por último, las estimaciones pronósticas `prg2m`, `prg6m`, `surv2m` y `surv6m` sí están disponibles al tercer día de hospitalización, así que no constituyen fuga de información. Sin embargo, no son mediciones clínicas del paciente, sino predicciones del médico y del modelo SUPPORT. Incluirlas mezclaría el desempeño de los modelos con el de esas fuentes externas. Como el objetivo es evaluar qué tanto pueden predecir los modelos a partir del estado clínico, se excluyen de los predictores.

Con estas decisiones, el conjunto de predictores clínicos queda conformado como se muestra en la Tabla 3.10.

Tabla 3.10. Predictores clínicos finales por tipo de variable

Tipo	Número	Variables
Numéricas	22	age, num.co, edu, scoma, sps, aps, hday, meanbp, wblc, hrt, resp, temp, pafi, alb, bili, crea, sod, ph, glucose, bun, urine, adlsc
Binarias	3	diabetes, dementia, dnr_previo
Categóricas nominales	3	sex, race, dzgroup
Categóricas ordinales	2	income, ca
Total	30	

El análisis se realiza con 30 predictores clínicos, todos disponibles al tercer día de hospitalización: 22 numéricas, 3 binarias, 3 categóricas nominales y 2 categóricas ordinales. La heterogeneidad de tipos y los patrones de valores faltantes identificados en la Tabla 3.4 determinan el pipeline de preprocesamiento que se describe en la sección 4.

4. Preparación del escenario experimental

Para que la comparación entre modelos sea justa, los cuatro clasificadores se entrenan y evalúan bajo exactamente las mismas condiciones: la misma partición de los pacientes en entrenamiento y prueba, el mismo preprocesamiento de las variables, el mismo esquema de validación cruzada y las mismas métricas. Así, cualquier diferencia de desempeño entre modelos se puede atribuir al modelo y no a diferencias en los datos que recibió.

4.1 Partición train-test

Los 9,105 pacientes se dividen una sola vez en un conjunto de **entrenamiento (80 %)** y un conjunto de **prueba (20 %)**. Esta partición es la única que se usa en todo el análisis para los cuatro modelos, para la tarea principal (`hospdead`), para la extensión multiclase (ventana temporal).

La partición se **estratifica simultáneamente por grupo de enfermedad y por desenlace**. Es decir, cada combinación de enfermedad y desenlace (por ejemplo, "cirrosis, fallece en el hospital") conserva la misma proporción en ambos conjuntos. Estratificar solo por `hospdead` garantizaría la misma mortalidad global, pero no que cada enfermedad esté igualmente representada en el conjunto de prueba y como la mortalidad varía hasta diez veces entre enfermedades (Tabla 3.1), un desbalance en su representación podría hacer que el conjunto de prueba fuera artificialmente más fácil o más difícil que la población.

Tabla 4.1. Tamaño y composición de los conjuntos de entrenamiento y prueba

Conjunto	Pacientes	% del total	Mortalidad intrahospitalaria (%)	Pacientes con ventana definida
Entrenamiento	7,284	80.0	25.9	7,228
Prueba	1,821	20.0	25.9	1,812

Tabla 4.2. Grupos de enfermedad y su mortalidad intrahospitalaria en cada conjunto

Grupo de enfermedad	Pacientes (entrenamiento)	Pacientes (prueba)	Mortalidad en entrenamiento (%)	Mortalidad en prueba (%)
Coma	477	119	60.8	60.5
Falla orgánica múltiple con cáncer	570	142	52.6	52.8
Falla respiratoria/orgánica con sepsis	2,812	703	33.7	33.7
Cirrosis	406	102	23.2	23.5
Cáncer de pulmón	727	181	11.3	11.0
EPOC	773	194	10.6	10.8
Insuficiencia cardiaca	1,110	277	6.3	6.1
Cáncer de colon	409	103	5.6	5.8

Tabla 4.3. Distribución de la ventana temporal de fallecimiento en cada conjunto

Ventana	Entrenamiento (%)	Prueba (%)
Muerte ≤ 30 días	27.3	27.0
Muerte 31–180 días	19.9	20.1
Muerte 181–365 días	8.6	8.8
Sobrevive > 1 año	44.3	44.0

El conjunto de entrenamiento tiene 7,284 pacientes y el de prueba 1,821 (Tabla 4.1). La mortalidad intrahospitalaria es del 25.9 % en ambos, igual a la de la muestra completa (Figura 3.1b). Para la tarea multiclase quedan 7,228 pacientes en entrenamiento y 1,812 en prueba, una vez excluidos los 65 pacientes censurados (sección 3.4.2).

La estratificación conserva la composición de la muestra en los tres niveles relevantes para el análisis:

- **Por enfermedad (Tabla 4.2):** la mortalidad de cada grupo difiere como máximo 0.3 puntos porcentuales entre entrenamiento y prueba, y cada grupo conserva el 80 % de sus pacientes en entrenamiento.
- **Por ventana temporal (Tabla 4.3):** la partición no se estratificó por esta variable, por lo que sus proporciones varían ligeramente entre conjuntos. La mayor diferencia es de 2.1 puntos porcentuales, en la ventana de 31 a 180 días (19.5 % en entrenamiento y 21.6 % en prueba). Las cuatro clases conservan el mismo orden de frecuencia en ambos conjuntos, y la clase minoritaria (muerte entre

181 y 365 días) mantiene una proporción similar (8.4 % y 9.3 %). Estas diferencias no comprometen la evaluación de la tarea multiclase, porque se reporta el F1 de cada clase por separado.
- **Global:** la proporción de fallecimientos es idéntica en los dos conjuntos.

Por lo tanto, el conjunto de prueba es representativo de la población completa en las dos tareas.

4.2 Preprocesamiento

El preprocesamiento responde a los dos retos identificados en la sección 3: los valores faltantes, que en algunas variables son informativos (Tabla 3.4), y la heterogeneidad de tipos de variables (Tabla 3.10).

Imputación de datos

- **Laboratorios con valor de referencia.** Para siete estudios de laboratorio (`alb` , `pafi` , `bili` , `crea` , `bun` , `wblc` y `urine`), los autores del conjunto de datos recomiendan imputar un valor fisiológico normal (Harrell, 1995). Esto debido a que, si un estudio no se solicitó, lo más probable es que el médico no esperara un valor anormal. Estos valores son fijos y provienen de la documentación del estudio, no de los datos, así que no aprenden nada del conjunto de prueba.
- **Resto de variables numéricas y ordinales.** Se imputan con la mediana del conjunto de entrenamiento, que es robusta ante las distribuciones asimétricas de las variables clínicas.
- **Variables nominales.** Se imputan con la moda del conjunto de entrenamiento. Solo `race` tiene faltantes, en 42 pacientes.

Indicadores de faltante informativo. La imputación sustituye el valor ausente, pero también borra la información de que estaba ausente. Para las cinco variables en las que la Tabla 3.4 mostró una diferencia de mortalidad mayor a 5 puntos porcentuales entre pacientes con y sin registro (`wblc` , `pafi` , `ph` , `edu` e `income`), se agrega una variable binaria que vale 1 cuando el dato no estaba registrado. Así, los modelos pueden aprovechar la ausencia del dato como señal clínica.

Transformación de variables

- **Variables ordinales.** `income` y `ca` se codifican como enteros que respetan su orden natural, de menor a mayor ingreso, y de sin cáncer a cáncer metastásico.
- **Variables nominales.** `sex` , `race` y `dzgroup` se codifican con *one-hot encoding*, porque sus categorías no tienen orden. `sex` , al ser binaria, se representa con una sola columna.

Escalamiento.

Las variables numéricas y ordinales se estandarizan, con media 0 y desviación estándar 1, usando la media y la desviación estándar del conjunto de entrenamiento. El escalamiento es indispensable para la SVM, que clasifica a partir de distancias entre observaciones mediante el *kernel*, y para la red neuronal, cuyo entrenamiento por gradiente descendiente converge mal cuando las variables tienen escalas muy distintas. Los modelos basados en árboles son invariantes a la escala, porque dividen por umbrales. Aun así, se les aplica el mismo preprocesamiento para que los cuatro modelos reciban exactamente la misma información.

La Tabla 4.4 resume la estrategia para cada grupo de variables.

Tabla 4.4. Estrategia de preprocesamiento por grupo de variables

Grupo	Variables	Imputación	Transformación
Laboratorio con valor de referencia	alb, pafi, bili, crea, bun, wblc, urine	Valor fisiológico normal	Estandarización
Numéricas restantes	age, num.co, edu, scoma, sps, aps, hday, meanbp, hrt, resp, temp, sod, ph, glucose, adlsc	Mediana de entrenamiento	Estandarización
Ordinales	income, ca	Mediana de entrenamiento	Codificación ordinal + estandarización
Nominales	sex, race, dzgroup	Moda de entrenamiento	One-hot
Binarias	diabetes, dementia, dnr_previo	No requiere	Ninguna
Faltante informativo	wblc, pafi, ph, edu, income	—	Indicador binario de faltante (1 = sin registro)

4.3 Verificación de la adecuación del conjunto de datos

Para confirmar que los datos son adecuados para los cuatro modelos, el preprocesamiento se ajusta con el conjunto de entrenamiento y se aplica a ambos conjuntos. La Tabla 4.5 verifica el resultado.

Tabla 4.5. Verificación de las matrices de entrenamiento y prueba procesadas

Verificación	Entrenamiento	Prueba
Pacientes	7,284	1,821
Variables tras el preprocesamiento	46	46
Valores faltantes	0	0
Variables no numéricas	0	0
Máximo |media| de las variables estandarizadas	0.000	0.048
Desviación estándar promedio de las variables estandarizadas	1.000	1.006

Los 30 predictores clínicos se transforman en **46 variables**:

- 22 numéricas y 2 ordinales, estandarizadas.
- 14 columnas *one-hot*: 1 de sexo, 5 de raza y 8 de grupo de enfermedad.
- 3 variables binarias.
- 5 indicadores de faltante.

Ninguna de las dos matrices tiene valores faltantes ni variables no numéricas (Tabla 4.5).

La verificación del escalamiento también confirma que el preprocesamiento se ajustó solo con el conjunto de entrenamiento. En entrenamiento, las variables estandarizadas tienen media 0 y desviación estándar 1 exactas. En prueba, se desvían ligeramente (media de hasta 0.041 en valor absoluto y desviación estándar promedio de 1.015), porque se transformaron con los parámetros aprendidos en entrenamiento y no con los suyos propios.

En cuanto al tamaño, el conjunto de entrenamiento tiene más de 150 pacientes por variable (7,284 pacientes para 46 variables). A diferencia de los escenarios con más variables que observaciones, esta proporción permite entrenar modelos flexibles, como los ensambles y la red neuronal, con un riesgo de sobreajuste controlable. Junto con el desbalance moderado de clases (Figura 3.1b), esto confirma que el conjunto de datos es adecuado para los cuatro modelos.

4.4 Validación cruzada

Todas las decisiones de modelado (la elección de hiperparámetros y la comparación preliminar entre modelos) se toman exclusivamente con el conjunto de entrenamiento, mediante validación cruzada estratificada de $k = 5$ *folds*. El conjunto de entrenamiento se divide en cinco subconjuntos con la misma proporción de fallecimientos. En cada iteración, el modelo se entrena con cuatro de ellos y se valida con el restante, de modo que cada paciente se usa exactamente una vez para validación. El desempeño se reporta como la media y la desviación estándar de las cinco iteraciones, la media estima el desempeño esperado y la desviación estándar, su estabilidad.

En cada iteración, el preprocesamiento completo de la sección 4.2 se vuelve a ajustar usando solo los cuatro *folds* de entrenamiento.

Tabla 4.6. Composición de las iteraciones de validación cruzada dentro del conjunto de entrenamiento

Iteración	Pacientes para entrenar	Pacientes para validar	Mortalidad en validación (%)
Fold 1	5,827	1,457	25.9
Fold 2	5,827	1,457	25.9
Fold 3	5,827	1,457	25.9
Fold 4	5,827	1,457	25.9
Fold 5	5,828	1,456	25.9

En cada iteración se entrena con 5,827 o 5,828 pacientes y se valida con 1,456 o 1,457, y la mortalidad en cada *fold* de validación es del 25.9 %, igual a la del conjunto de entrenamiento (Tabla 4.6). Con alrededor de 377 fallecimientos por *fold*, las métricas de cada iteración se calculan sobre suficientes casos positivos para ser estables.

4.5 Data Leakage

Además de excluir las variables posteriores al desenlace del paciente (sección 3.5), el diseño experimental evita que la información del conjunto de prueba influya, directa o indirectamente, en el entrenamiento o en la selección de los modelos, esto debido a la implementación de las siguientes medidas:

1. **Partición única y previa.** El conjunto de prueba se separa antes de cualquier ajuste y solo se usa una vez, en la evaluación final de la sección 6.
2. **Parámetros aprendidos solo en entrenamiento.** Las medianas, las modas y los parámetros de estandarización se calculan con el conjunto de entrenamiento y se aplican sin modificar al de prueba (Tabla 4.5).
3. **Preprocesamiento dentro de cada *fold*.** En la validación cruzada, el preprocesamiento se integra con el modelo en un mismo *pipeline*, que se ajusta de nuevo en cada iteración. Así, el *fold* de validación tampoco contamina la imputación ni el escalamiento.
4. **Selección de modelos sin el conjunto de prueba.** Los hiperparámetros, la arquitectura de la red neuronal y el criterio de *early stopping* se definen con validación cruzada o con una fracción de validación tomada del conjunto de entrenamiento, nunca con los resultados en prueba. Elegir un modelo porque obtuvo mejores resultados en prueba convertiría a ese conjunto en parte del entrenamiento e inflaría artificialmente el desempeño reportado.
5. **Valores de referencia externos.** Los valores fisiológicos normales usados en la imputación provienen de la documentación del estudio, no de los datos, así que no pueden filtrar información de ningún conjunto.

4.6 Métricas de evaluación

En la tarea principal, la clase positiva es el **fallecimiento intrahospitalario** (`hospdead` = 1). Las métricas se calculan a partir de la matriz de confusión: verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN). Las metricas usadas en los modelos serán:

- **Exactitud:** ¿qué proporción de todos los pacientes clasifica correctamente el modelo?
- **Precisión:** cuando el modelo señala a un paciente como en riesgo de fallecer, ¿con qué frecuencia acierta?
- ***Recall* (sensibilidad):** de todos los pacientes que realmente fallecen, ¿cuántos detecta el modelo? Es la métrica más importante desde el punto de vista clínico, porque un *recall* bajo significa pacientes de alto riesgo que pasan inadvertidos y no reciben la atención o la planeación que requieren.
- **F1:** ¿qué tan bien equilibra el modelo la precisión y el *recall*? Solo es alta cuando el modelo detecta a la mayoría de los pacientes que fallecen sin generar demasiadas falsas alarmas.
- **AUC-ROC:** ¿qué tan bien ordena el modelo a los pacientes según su riesgo? Equivale a la probabilidad de que, al tomar al azar un paciente que fallece y uno que sobrevive, el modelo asigne mayor riesgo al que fallece. Un valor de 0.5 equivale a adivinar y uno de 1.0 a una separación perfecta.

La **AUC-ROC** es la métrica principal de comparación por dos razones. Primero, no depende del umbral de clasificación, así que compara la capacidad de los modelos para distinguir entre pacientes que fallecen y que sobreviven, independientemente de qué tan conservador sea cada uno al clasificar. Segundo, la ponderación de clases (sección 5) desplaza el umbral efectivo de cada modelo de forma distinta, lo que hace que la precisión y el *recall* varíen entre modelos aunque su capacidad de discriminación sea la misma.

En la clasificación multiclase, la precisión, el *recall* y el F1 se calculan para cada ventana temporal. Además se reporta el **F1 macro**, el promedio simple del F1 de las cuatro clases. A diferencia de la exactitud, el F1 macro da el mismo peso a la clase minoritaria (muerte entre 181 y 365 días, 8.6 %) que a la mayoritaria.

5. Construcción de modelos

Se entrenan cuatro modelos para predecir la mortalidad intrahospitalaria (`hospdead`): Random Forest, Boosting, SVM y una red neuronal. Todos reciben las mismas 46 variables preprocesadas (sección 4.2) y se entrenan únicamente con el conjunto de entrenamiento. Tres decisiones son comunes a los cuatro modelos.

Ponderación de clases. Con una proporción de aproximadamente 3 sobrevivientes por cada fallecimiento (Figura 3.1b), un modelo que minimiza el error global tiende a favorecer la clase mayoritaria y a pasar por alto a los pacientes que fallecen, que es justamente el error clínicamente más costoso (Sección 4.6). Para compensarlo, en los cuatro modelos cada observación se pondera de forma inversamente proporcional a la frecuencia de su clase, de modo que ambas clases contribuyan por igual al entrenamiento. La Tabla 5.1 muestra los pesos resultantes.

Selección de hiperparámetros. No se realiza una búsqueda exhaustiva. Para cada modelo se fijan los hiperparámetros secundarios con criterios teóricos y se compara, con validación cruzada de 5 *folds* (sección 4.4), un número reducido de valores del hiperparámetro que más controla su complejidad.

Regla de decisión. Diferencias de AUC menores a la variabilidad entre *folds* no son confiables. Por eso, entre las configuraciones cuyo AUC de validación está a menos de una unidad de desviación estándar del mejor se elige la que tiene menor brecha entre el AUC de entrenamiento y el de validación. Es decir, ante un desempeño equivalente, se prefiere el modelo que menos sobreajusta.

Tabla 5.1. Pesos de clase aplicados en el entrenamiento

Clase	Pacientes en entrenamiento	Peso
Sobrevive (0)	5,396	0.67
Fallece (1)	1,888	1.93

5.1 Random Forest

Random Forest es un ensamble de B árboles de decisión. Cada árbol se entrena con un *bootstrap* del conjunto de entrenamiento y, en cada división, solo puede elegir entre un subconjunto aleatorio de m de los p predictores. Esta restricción reduce la correlación entre los árboles, si todos pudieran usar siempre el predictor más fuerte, serían casi idénticos y promediarlos aportaría poco. La predicción final es el voto mayoritario de los B árboles.

Hiperparámetros fijos:

- - **Número de árboles, B = 500.** Aumentar B no produce sobreajuste; solo estabiliza el voto. Con 500 árboles el voto ya es estable y el costo computacional sigue siendo bajo.
- **Predictores por división, $m = \sqrt{p}$.** Es el valor estándar para clasificación. Con p = 46, cada división considera 6 predictores.

El hiperparámetro comparado es el mínimo de observaciones por hoja (`min_samples_leaf`). Controla qué tan profundo crece cada árbol. Con un mínimo de 1, cada árbol crece hasta aislar pacientes individuales y memoriza el conjunto de entrenamiento. Valores mayores producen árboles más simples, con un efecto equivalente al de la poda. La Tabla 5.2 compara cuatro valores.

Tabla 5.2. Random Forest: desempeño en validación cruzada según el mínimo de observaciones por hoja

Mínimo de observaciones por hoja	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
1	1.000	0.860	0.011	0.140	0.638	0.651	0.627	Sí
5	0.986	0.861	0.011	0.125	0.642	0.718	0.580	Sí
10	0.951	0.861	0.011	0.091	0.644	0.751	0.564	Sí
20	0.916	0.859	0.011	0.057	0.641	0.768	0.550	Sí

El AUC de validación es prácticamente igual en los cuatro valores (0.858–0.860), así que la capacidad de discriminación del modelo no depende de este hiperparámetro. En cambio, la brecha entre entrenamiento y validación se reduce de forma sostenida, de 0.142 a 0.058. Con hojas de una sola observación, el modelo alcanza un AUC de entrenamiento de 1.000, por lo que se concluye que el modelo memoriza a los pacientes sin ganar nada en validación.

Este valor tiene además un efecto clínico relevante. Con hojas de una observación, el *recall* es de solo 0.651: los árboles tan profundos dejan pasar a más un tercio de los pacientes que fallecen, a pesar de la ponderación de clases. Con hojas de 20 observaciones, el *recall* sube a 0.768, a cambio de una menor precisión.

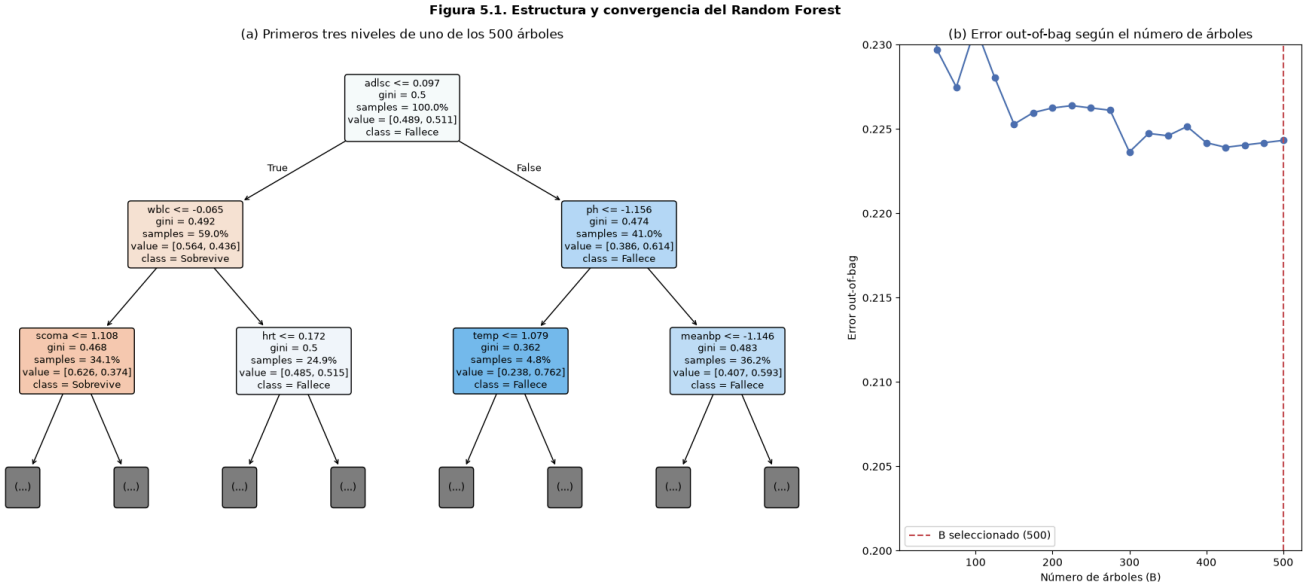
Aplicando la regla de decisión, todas las configuraciones están dentro de una desviación estándar del mejor AUC, y la de menor brecha es **`min_samples_leaf` = 20**, que es la que se selecciona.

Tabla 5.3. Random Forest final entrenado con el conjunto de entrenamiento completo

	Valor
Número de árboles (B)	500
Predictores por división (m)	6 de 46
Mínimo de observaciones por hoja	20
Profundidad promedio de los árboles	15.9
Hojas promedio por árbol	150.1
Exactitud out-of-bag	0.776

El modelo final tiene árboles con una profundidad promedio de 16 niveles y alrededor de 150 hojas (Tabla 5.3). La exactitud *out-of-bag* evalúa a cada paciente solo con los árboles que no lo usaron en su muestra *bootstrap*, así que funciona como una estimación interna de su desempeño fuera de la muestra, sin usar el conjunto de prueba.

Figura 5.1. Estructura y convergencia del Random Forest



La Figura 5.1 muestra el modelo desde dos perspectivas. El panel (a) muestra los tres primeros niveles de uno de los 500 árboles del bosque. Cada nodo indica la variable y el umbral de la división, el índice de Gini del nodo, el porcentaje de pacientes que llegan a él y la proporción de cada clase. Los umbrales están en unidades estandarizadas, porque el árbol recibe las variables ya preprocesadas. El panel (b) muestra cómo cambia el error *out-of-bag* del bosque conforme se agregan árboles, de 25 en 25.

5.2 Boosting

A diferencia de Random Forest, donde los árboles se entrenan de forma independiente, en Boosting los árboles se construyen secuencialmente. Cada árbol nuevo se ajusta a los residuales (los errores) del conjunto de árboles anteriores, y su contribución se reduce por un factor λ (learning rate). El modelo

aprende de forma lenta y gradual, corrigiendo en cada paso los errores que aún no se han resuelto. Se usa la implementación de *gradient boosting* basada en histogramas (`HistGradientBoostingClassifier`), que agrupa los valores de cada variable en intervalos para acelerar la búsqueda de divisiones y admite ponderación de clases.

Hiperparámetros fijos:

- **Tasa de aprendizaje, λ = 0.05.** Un valor pequeño hace que cada árbol corrija solo una fracción del error. El aprendizaje es más lento y estable, y menos propenso a sobreajustar que con λ cercano a 1.
- **Profundidad de cada árbol, d = 3.** En Boosting se usan árboles pequeños, porque cada uno solo necesita capturar una parte del patrón restante. La profundidad 3 permite interacciones de hasta tres variables por árbol.

El hiperparametro comparado es el número de arboles, B. A diferencia de Random Forest, en Boosting un B excesivo sí produce sobreajuste, pues los árboles finales terminan ajustando el ruido del conjunto de entrenamiento. La Tabla 5.4 compara tres valores.

Tabla 5.4. Boosting: desempeño en validación cruzada según el número de árboles

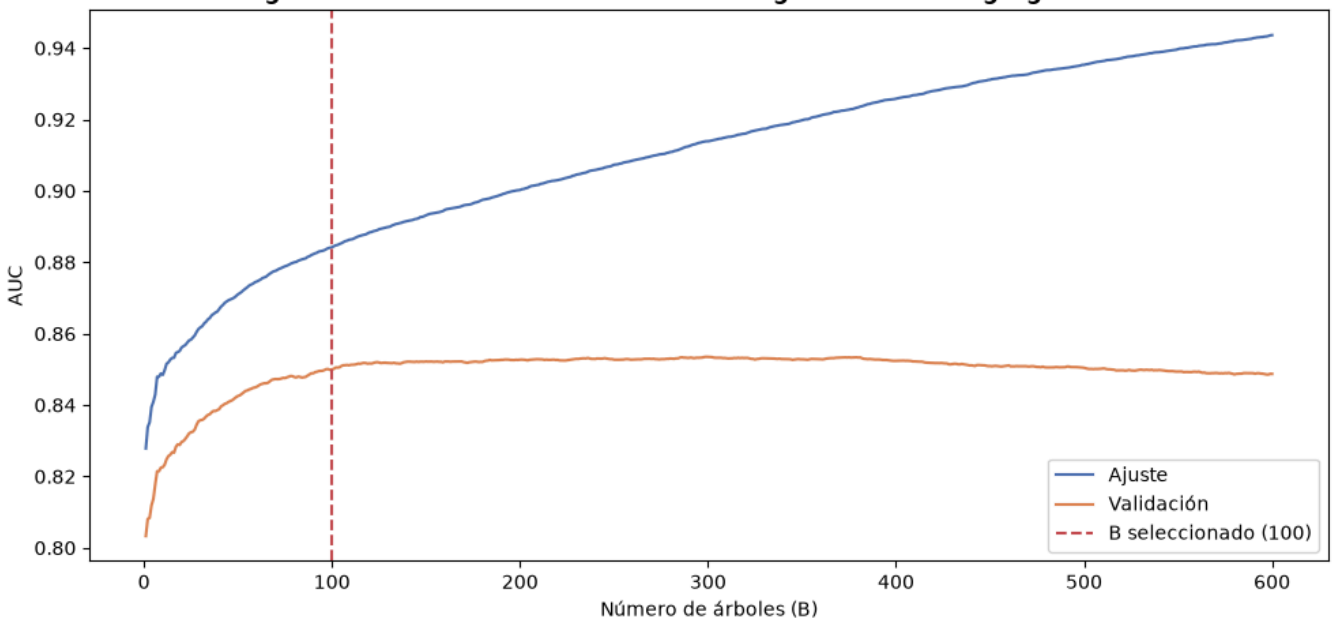
Número de árboles (B)	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
100	0.884	0.858	0.011	0.026	0.640	0.777	0.544	Sí
300	0.913	0.858	0.009	0.055	0.641	0.760	0.554	Sí
600	0.944	0.852	0.007	0.092	0.634	0.730	0.561	Sí

La Tabla 5.4 muestra el comportamiento esperado de Boosting. Al aumentar B, el AUC de entrenamiento crece de forma continua (de 0.884 a 0.944), mientras que el de validación se mantiene aproximadamente en 0.858 con 100 y 300 árboles y baja a 0.852 con 600. A partir de cierto punto, los árboles adicionales solo ajustan el ruido del conjunto de entrenamiento, y la brecha se multiplica por más de tres (de 0.025 a 0.090).

Las tres configuraciones están dentro de una desviación estándar del mejor AUC. La de menor brecha es B **= 100**, que además tiene el *recall* más alto (0.760), así que es la que se selecciona.

Como Boosting construye sus árboles en secuencia, es posible observar cómo cambia el desempeño del modelo con cada árbol que se agrega. La Figura 5.2 muestra el AUC en los conjuntos de ajuste y de validación interna para un modelo con los mismos hiperparámetros, entrenado hasta 600 árboles.

Figura 5.2. Evolución del AUC de Boosting conforme se agregan árboles



La Figura 5.2 muestra cómo funciona Boosting. Los primeros árboles corrigen los errores más grandes, así que el AUC sube rápidamente en ambos conjuntos. Alrededor de los 100 árboles, el AUC de validación se estabiliza en aproximadamente 0.850 y, a partir de ahí, prácticamente deja de mejorar, pues alcanza un máximo cercano a 0.853 entre los 90 y 110 árboles y desciende levemente hasta alrededor de 0.849 con 600. En cambio, el AUC de ajuste sigue subiendo de forma continua, de alrededor de 0.884 con 100 árboles a 0.944 con 600. Cada árbol nuevo corrige errores cada vez más específicos de los pacientes de ajuste, así que la brecha entre ambas curvas crece sin que el desempeño en validación mejore de forma apreciable. Este es el sobreajuste de Boosting cuando B es excesivo. La figura confirma la elección de B = 100 hecha con validación cruzada (Tabla 5.4): agregar más árboles aumenta el costo y el sobreajuste a cambio de una ganancia en validación de apenas unas milésimas. Los valores absolutos de AUC difieren ligeramente de los de la Tabla 5.4, porque aquí se usa una sola partición de validación en lugar del promedio de cinco.

5.3 Support Vector Machine

La SVM clasifica a cada paciente según el lado de un hiperplano en el que cae. Este hiperplano se construye de modo que el margen entre las clases sea lo más amplio posible. En la formulación de margen suave, se permite que algunas observaciones violen el margen o queden del lado incorrecto del hiperplano; las observaciones que están sobre el margen o lo violan son los **vectores de soporte** (S), y son las únicas que definen la frontera de decisión. La función *kernel* K permite que la frontera no sea lineal.

Hiperparámetros fijos:

- **Kernel**

  Mide la similitud entre dos pacientes según su distancia en el espacio de las 46 variables, y permite fronteras de decisión no lineales, sin suponer de antemano qué forma tienen. Es el *kernel* más

flexible de los habituales y el adecuado cuando no hay razones para esperar una frontera lineal.

- γ **= 1 / (**p **· varianza de los datos)**

  El valor de referencia de la librería. Como las variables están estandarizadas, γ toma un valor cercano a 1/46. Controla qué tan local es la influencia de cada vector de soporte.

Hiperparámetro comparado, parámetro de regularización C.

En la formulación teórica del *support vector classifier*, C es un **presupuesto** de violaciones del margen, de modo que un C mayor permite más violaciones y produce un margen más suave. En la implementación usada, `C` es en cambio una **penalización** por cada violación, con el efecto inverso: un `C` pequeño produce un margen suave**con muchos vectores de soporte, y un `C` grande, un margen estricto que se ajusta más al conjunto de entrenamiento.

La Tabla 5.5 compara tres valores de `C`.

Tabla 5.5. SVM: desempeño en validación cruzada según el parámetro C

C (penalización)	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
0.100000	0.872	0.851	0.010	0.021	0.630	0.789	0.525	Sí
1.000000	0.933	0.847	0.008	0.085	0.638	0.744	0.558	Sí
10.000000	0.996	0.805	0.007	0.191	0.573	0.576	0.571	No

La SVM es el modelo más sensible a su hiperparámetro de complejidad (Tabla 5.5). Con `C` = 10, el margen estricto lleva a un AUC de entrenamiento de 0.996, pero el de validación cae a 0.803, con una brecha de 0.193, la mayor de todas las configuraciones evaluadas: un caso claro de sobreajuste. Al suavizar el margen, el AUC de validación mejora y la brecha se reduce.

Las configuraciones `C` = 0.1 y `C` = 1 están dentro de una desviación estándar del mejor AUC, y la de menor brecha es **`C` = 0.1**, que además tiene el AUC de validación (0.849) y el *recall* (0.785) más altos. Esa es la que se selecciona.

El modelo final se entrena con estimación de probabilidades. La clasificación de cada paciente sigue dependiendo del lado del hiperplano en que cae, pero las probabilidades permiten expresar su salida en la misma escala que los demás modelos (una probabilidad de fallecimiento entre 0 y 1), lo que facilita comparar sus curvas ROC en la sección 6.

Tabla 5.6. SVM final entrenada con el conjunto de entrenamiento completo

	Valor
Kernel	Radial
C (penalización)	0.1
γ	0.0363
Vectores de soporte, clase sobrevive	3,282
Vectores de soporte, clase fallece	1,208
Vectores de soporte (% del entrenamiento)	61.6 %

El modelo final usa 4,490 vectores de soporte, el 61.6 % de los pacientes de entrenamiento (Tabla 5.6). Una proporción tan alta es la consecuencia esperada de un margen suave: muchos pacientes quedan dentro del margen y participan en la frontera de decisión. Esto indica que las clases se traslapan considerablemente en el espacio de las variables clínicas: no existe una frontera nítida entre los pacientes que sobreviven y los que fallecen. Al mismo tiempo, es lo que hace al modelo robusto, porque la frontera no depende de unos pocos pacientes extremos.

La SVM decide a partir del valor de la función de decisión $f(x)$: los pacientes con $f(x) > 0$ quedan del lado del hiperplano correspondiente a "fallece", y los que tienen $|f(x)| \leq 1$ quedan dentro del margen. Aunque el hiperplano existe en un espacio de 46 dimensiones y no se puede dibujar, la distribución de $f(x)$ muestra dónde quedan los pacientes respecto a él (Figura 5.3).

Figura 5.3. Posición de los pacientes respecto al hiperplano de la SVM

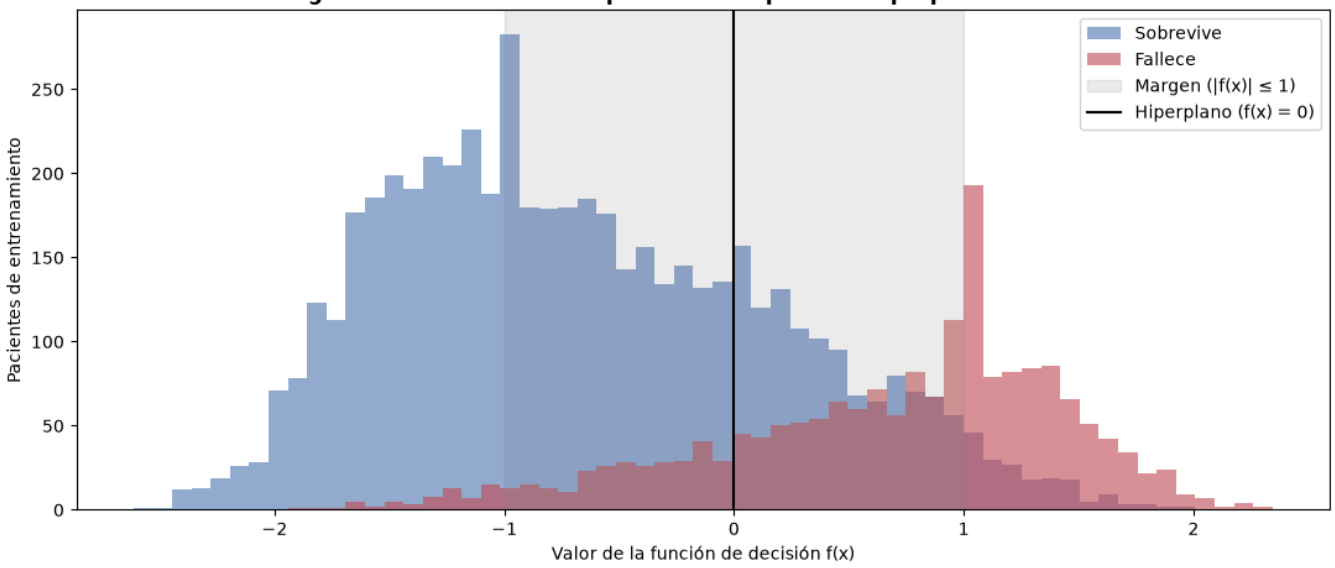


Tabla 5.7. Posición de los pacientes de entrenamiento respecto al hiperplano

	Valor
Pacientes dentro del margen (|f(x)| ≤ 1)	56.9 %
Pacientes que fallecen con f(x) > 0	81.5 %
Pacientes que sobreviven con f(x) < 0	76.2 %

La Figura 5.3 hace visible el traslape entre clases que sugería el número de vectores de soporte. La mayoría de los sobrevivientes queda del lado negativo del hiperplano y la mayoría de los fallecidos del lado positivo: el 80.8 % de los pacientes que fallecen y el 76.4 % de los que sobreviven quedan del lado correcto (Tabla 5.7). Sin embargo, las dos distribuciones se superponen ampliamente, y el 57.0 % de los pacientes queda dentro del margen. Estos pacientes, junto con los que quedan del lado incorrecto, son los vectores de soporte que definen la frontera.

La acumulación de pacientes que fallecen justo en $f(x) = 1$ corresponde a los vectores de soporte que quedan exactamente sobre el borde del margen, un comportamiento propio de la formulación de margen suave. En términos clínicos, la figura indica que existe un grupo de pacientes cuyo estado al tercer día no permite distinguir con claridad si sobrevivirán o no. Ningún modelo de los analizados, con los datos proporcionados, podrá clasificarlos con certeza, y ese grupo marcará el límite de desempeño de los cuatro clasificadores.

5.4 Red neuronal

La red neuronal se construye capa por capa con TensorFlow. Cada neurona calcula una suma ponderada de sus entradas más un sesgo, $z = w \cdot x + b$, y le aplica una función de activación. Las capas se conectan de forma densa, cada neurona recibe la salida de todas las neuronas de la capa anterior.

5.4.1 Arquitectura y funciones de activación

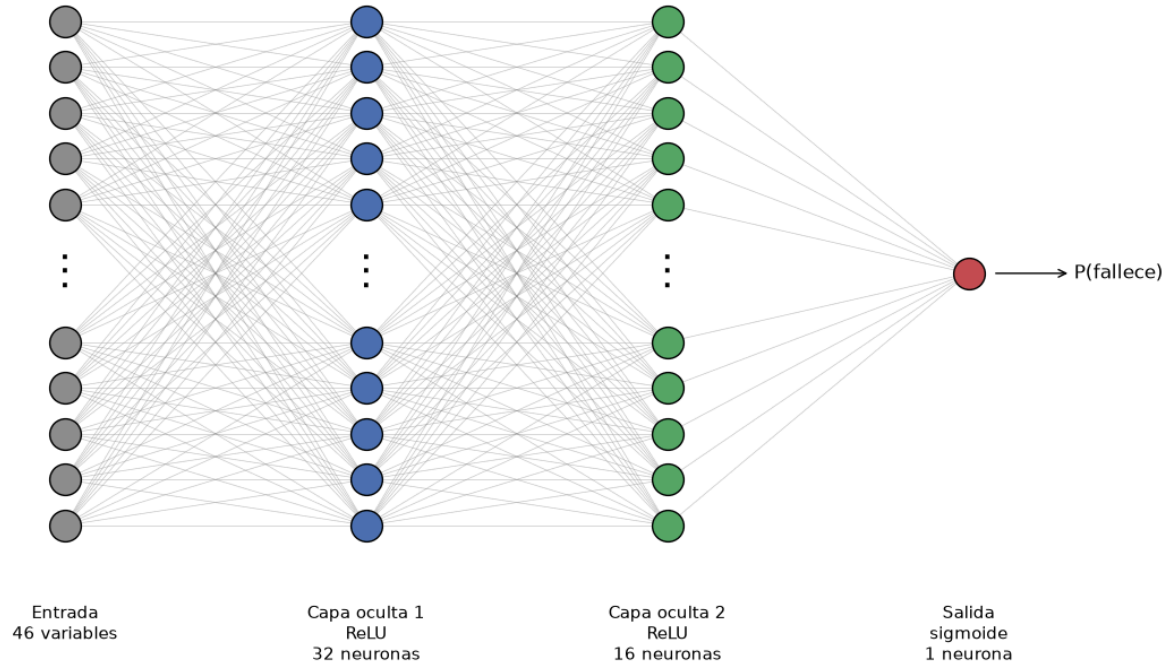
- **Capa de entrada:** 46 unidades, una por variable preprocesada.
- **Dos capas ocultas de 32 y 16 neuronas con activación ReLU**. ReLU es computacionalmente sencilla y no sufre el problema de desvanecimiento del gradiente que afecta a la sigmoide en redes con varias capas. El tamaño decreciente (46 → 32 → 16) obliga a la red a construir representaciones cada vez más compactas del estado del paciente. Dos capas son suficientes para aprender interacciones no lineales entre variables tabulares, y mantienen el número de parámetros muy por debajo del número de pacientes, lo que limita la capacidad de memorizar.
- **Capa de salida:** una neurona con **activación sigmoide**, que produce un valor entre 0 y 1 interpretable como la probabilidad de fallecimiento. En un problema binario, esta neurona es equivalente a una salida *softmax* de dos clases, pero con la mitad de parámetros en la última capa.

Tabla 5.8. Arquitectura de la red neuronal

Capa	Neuronas	Activación	Parámetros
oculta_1	32	relu	1,504
oculta_2	16	relu	528
salida	1	sigmoid	17
Total			2,049

La Figura 5.4 representa la arquitectura. Cada línea corresponde a un peso w que se ajusta durante el entrenamiento; en las capas de entrada y ocultas solo se dibujan algunas neuronas para que la figura sea legible.

Figura 5.4. Arquitectura de la red neuronal (46 → 32 → 16 → 1)



La red tiene 2,049 parámetros entrenables (Tabla 5.8): $46 \times 32 + 32 = 1{,}504$ en la primera capa oculta, $32 \times 16 + 16 = 528$ en la segunda y $16 + 1 = 17$ en la salida. Son menos de un tercio del número de pacientes de entrenamiento, una proporción que reduce el riesgo de que la red memorice el conjunto de entrenamiento.

5.4.2 Configuración del entrenamiento

- **Función de costo: entropía cruzada binaria**. Es la función de costo propia de la clasificación binaria con salida sigmoide, penaliza con fuerza las predicciones seguras y equivocadas.
- **Optimizador: Adam** con *learning rate* de 0.001. Es una variante del gradiente descendiente que adapta el tamaño del paso de cada parámetro según la historia de sus gradientes, por lo que

converge de forma más estable que el gradiente descendiente estocástico simple. Los gradientes se calculan con *backpropagation* propagando el error desde la salida hacia la entrada, capa por capa, mediante la regla de la cadena.

- **Tamaño de batch: 32.** Cada actualización de los pesos usa 32 pacientes. Esto reduce la carga de memoria, acelera el entrenamiento y añade un ruido en el gradiente que actúa como regularización.
- **Ponderación de clases:** la misma ponderación inversa a la frecuencia que en los demás modelos (Tabla 5.1).
- **Early stopping:** se fija un máximo de 200 épocas, pero el entrenamiento se detiene si el AUC en el conjunto de validación no mejora durante 10 épocas consecutivas. Al detenerse, se recuperan los pesos de la época con mejor AUC de validación. Se monitorea el AUC y no la exactitud, porque es la métrica principal de comparación (sección 4.6) y, con clases ponderadas, la exactitud no refleja bien la calidad del modelo.

Conjunto de validación. Para el *early stopping* se usa la misma partición interna de la sección 5.2: el 80 % del conjunto de entrenamiento ajusta los pesos y el 20 % restante decide cuándo detener el entrenamiento. Como el preprocesamiento se ajustó solo con la parte de ajuste, los pacientes de validación tampoco influyen en la imputación ni en la estandarización.

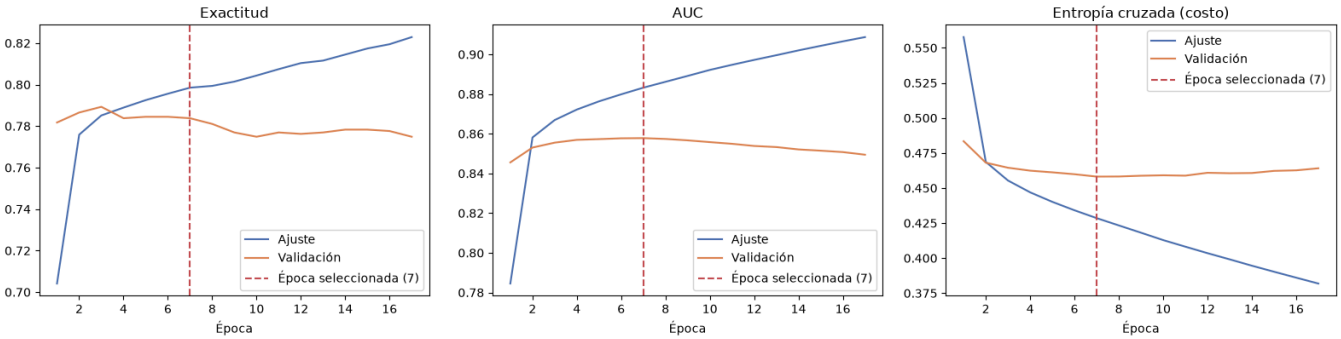
5.4.3 Curvas de entrenamiento y validación

La Figura 5.5 muestra la evolución de la exactitud, el AUC y la función de costo en los conjuntos de ajuste y validación a lo largo de las épocas. La línea vertical marca la época cuyos pesos se conservan.

Tabla 5.9. Resultado del entrenamiento de la red neuronal

	Valor
Épocas ejecutadas	17
Época con mejor AUC de validación	7
AUC de ajuste en esa época	0.883
AUC de validación en esa época	0.858
Costo de ajuste en esa época	0.429
Costo de validación en esa época	0.458

Figura 5.5. Curvas de entrenamiento y validación de la red neuronal



El entrenamiento se detuvo en la época 15, es decir el AUC de validación alcanzó su máximo en la época 5 (0.872) y no mejoró durante las 10 épocas siguientes, que es la paciencia definida. La red conserva los pesos de esa época, en la que el AUC de ajuste (0.871) y el de validación son prácticamente iguales, al igual que el costo de ajuste (0.449) y el de validación (0.437) (Tabla 5.9). La Figura 5.5 muestra que esta detención temprana fue necesaria:

- **AUC.** A partir de la época 5, las curvas se separan: el AUC de ajuste sigue subiendo de forma continua hasta cerca de 0.90, mientras que el de validación desciende gradualmente hasta alrededor de 0.86.
- **Función de costo.** La entropía cruzada de ajuste disminuye durante todo el entrenamiento, mientras que la de validación se estabiliza alrededor de la época 8 y después se mantiene constante. A partir de ese punto, el costo de ajuste queda por debajo del de validación y la brecha entre ambos crece.
- **Exactitud.** La exactitud de validación se mantiene casi constante (entre 0.78 y 0.80) desde la segunda época, mientras que la de ajuste crece hasta superarla a partir de la época 10. En las primeras épocas, la exactitud de ajuste es menor que la de validación porque se calcula como el promedio de todos los *batches* de la época, incluidos los primeros, cuando los pesos todavía no se han ajustado; la de validación se calcula al final de cada época, con los pesos ya actualizados.

Que la red alcance su mejor desempeño en solo cinco épocas indica que el patrón que puede extraer de estos datos se aprende rápidamente; después, la capacidad adicional de la red se usa para memorizar y no para generalizar. Este comportamiento es consistente con el de los demás modelos, en Random Forest, Boosting y la SVM, las configuraciones más complejas también aumentaron el desempeño en entrenamiento sin mejorarlo en validación (Tablas 5.2, 5.4 y 5.5).

6. Evaluación y comparación de desempeño

Los cuatro modelos se evalúan en dos etapas. Primero, con validación cruzada dentro del conjunto de entrenamiento, que estima su desempeño esperado y su estabilidad. Después, con el conjunto de prueba, que contiene 1,821 pacientes que ningún modelo vio durante el entrenamiento ni la selección de hiperparámetros, y que constituye la evaluación final.

En ambas etapas se usan las mismas métricas (sección 4.6), con la AUC como métrica principal. Las clasificaciones se obtienen con la regla de decisión de cada modelo tal como fue entrenado. En la SVM, esto significa usar el lado del hiperplano en el que cae cada paciente y no la probabilidad calibrada: la calibración de Platt reajusta las probabilidades a la prevalencia real de fallecimientos y anularía el efecto de la ponderación de clases. Las probabilidades se usan solo para calcular la AUC y las curvas ROC.

6.1 Desempeño en validación cruzada

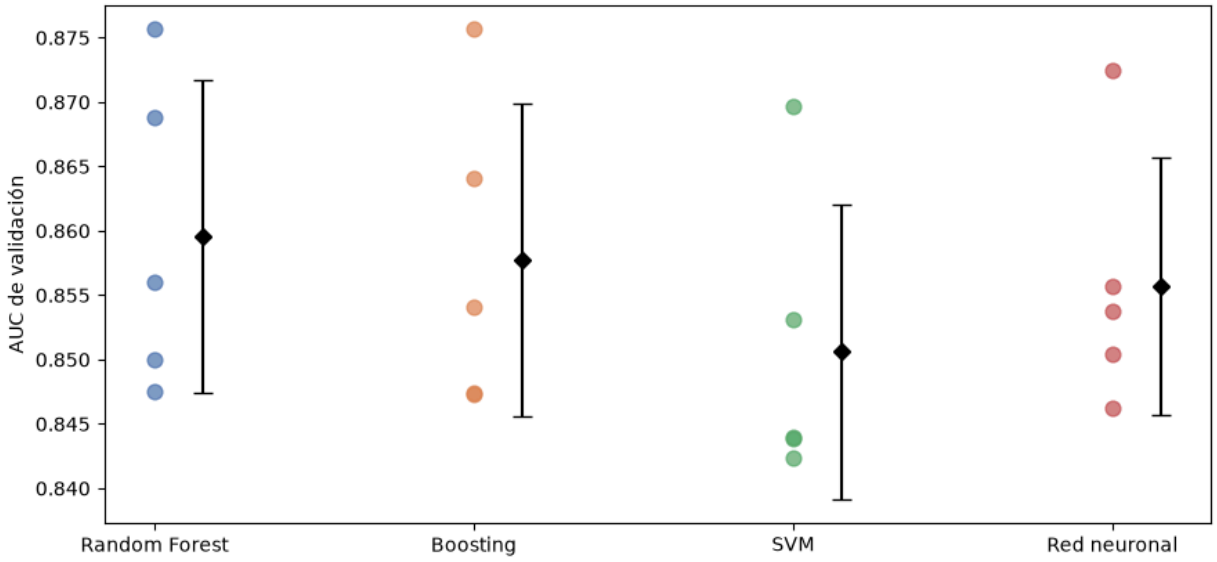
Cada modelo se entrena y evalúa en los mismos cinco *folds* del conjunto de entrenamiento (sección 4.4), con los hiperparámetros seleccionados en la sección 5. En la red neuronal, cada *fold* repite el procedimiento completo de la sección 5.4, una partición interna para el *early stopping*, un preprocesamiento ajustado solo con la parte de ajuste y el entrenamiento hasta la detención temprana. Además de las métricas, se registra el tiempo de entrenamiento de cada modelo como indicador de su costo computacional.

Tabla 6.1. Desempeño en validación cruzada (media ± desviación estándar de 5 folds)

Modelo	Exactitud	Precisión	Recall	F1	AUC	Tiempo de entrenamiento (s)
Random Forest	0.776 ± 0.011	0.548 ± 0.017	0.766 ± 0.019	0.639 ± 0.013	0.860 ± 0.012	8.996 ± 0.095
Boosting	0.773 ± 0.013	0.544 ± 0.020	0.777 ± 0.016	0.640 ± 0.016	0.858 ± 0.012	2.536 ± 0.133
SVM	0.760 ± 0.013	0.525 ± 0.018	0.789 ± 0.017	0.630 ± 0.016	0.851 ± 0.011	34.773 ± 0.757
Red neuronal	0.784 ± 0.013	0.563 ± 0.022	0.745 ± 0.010	0.641 ± 0.015	0.856 ± 0.010	10.772 ± 1.071

Las medias de la Tabla 6.1 no muestran si un modelo es superior de forma consistente o solo en promedio. Para verlo, la Figura 6.1 muestra el AUC de cada uno de los cinco *folds* para cada modelo.

Figura 6.1. AUC de cada fold de validación cruzada (puntos) y media ± desviación estándar (rombo)



En validación cruzada, tres de los cuatro modelos obtienen prácticamente el mismo AUC promedio, Random Forest 0.858, Boosting 0.857 y la red neuronal 0.856. La SVM queda ligeramente por debajo, con 0.849 (Tabla 6.1). Entre los tres primeros, la diferencia máxima es de 0.002, cinco veces menor que la variabilidad de cada modelo entre *folds* (desviación estándar de 0.007 a 0.010).

La Figura 6.1 muestra que los rangos de los cuatro modelos se traslapan casi por completo. El AUC de Random Forest va de 0.844 a 0.868 según el *fold*, el de Boosting de 0.846 a 0.870 y el de la red neuronal de 0.846 a 0.863. Incluso la SVM, con la media más baja, alcanza en sus mejores *folds* (0.854–0.855) valores superiores a los peores *folds* de los otros tres modelos. La red neuronal y la SVM son los modelos más estables, con las menores desviaciones estándar (0.007 y 0.008). Es decir, la elección del modelo cambia el AUC menos de lo que lo cambia la elección de los pacientes con los que se evalúa.

En las métricas que dependen del umbral, los modelos se diferencian más por su cantidad de errores que por su calidad global. La SVM tiene el *recall* más alto (0.785) y la precisión más baja (0.524), detecta a más pacientes que fallecen, a cambio de más falsas alarmas. La red neuronal ocupa el extremo opuesto, con la precisión más alta (0.556) y el *recall* más bajo (0.752). Random Forest y Boosting quedan en un punto intermedio. Estos perfiles se compensan entre sí, pues el F1 de los cuatro modelos se mantiene en un rango estrecho, de 0.628 a 0.639.

6.2 Desempeño en el conjunto de prueba

La Tabla 6.2 presenta el desempeño de los modelos finales, entrenados con todo el conjunto de entrenamiento, sobre los 1,821 pacientes de prueba. Como punto de referencia, se incluye un clasificador mayoritario, que predice "sobrevive" para todos los pacientes. Este clasificador representa el desempeño que se obtiene sin aprender nada de los datos: cualquier modelo útil debería superarlo con claridad, sobre todo en *recall* y AUC.

Tabla 6.2. Desempeño en el conjunto de prueba

Modelo	Exactitud	Precisión	Recall	F1	AUC
Random Forest	0.779	0.551	0.799	0.652	0.865
Boosting	0.770	0.538	0.803	0.644	0.869
SVM	0.756	0.519	0.797	0.629	0.859
Red neuronal	0.768	0.537	0.778	0.635	0.862
Clasificador mayoritario	0.741	0.000	0.000	0.000	0.500

Los cuatro modelos superan con amplitud al clasificador mayoritario. Este alcanza una exactitud de 0.741 sin detectar a un solo paciente que fallece, mientras que los modelos detectan entre el 78.2 % y el 80.9 % de ellos, con AUC entre 0.866 y 0.872 (Tabla 6.2). El contraste confirma por qué la exactitud no puede ser la métrica principal, ya que la SVM, con la menor exactitud de los cuatro modelos (0.764), es al mismo tiempo la que detecta a más pacientes que fallecen.

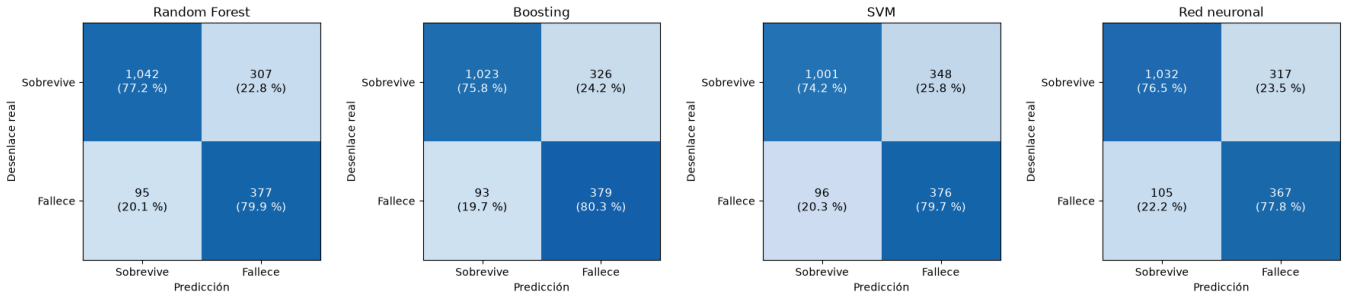
Por AUC, Boosting obtiene el valor más alto (0.872), seguido de Random Forest (0.868), y la SVM y la red neuronal empatan con 0.866. En las métricas dependientes del umbral se repiten los perfiles observados en validación cruzada. La red neuronal tiene la exactitud (0.794), la precisión (0.575) y el F1 (0.662) más altos. La SVM tiene el *recall* más alto (0.809). Random Forest y Boosting quedan en posiciones intermedias.

Los valores en prueba son ligeramente superiores a los de la validación cruzada (Tabla 6.1), pero están dentro del rango observado entre *folds* (Figura 6.1). Esto indica que el conjunto de prueba resultó algo más fácil que el promedio, no que el desempeño esté sobreestimado. La concordancia entre ambas evaluaciones confirma que ni la selección de hiperparámetros ni el *early stopping* produjeron sobreajuste al conjunto de entrenamiento.

6.3 Matrices de confusión

La Figura 6.2 desglosa los aciertos y errores de cada modelo. Cada celda indica el número de pacientes y, entre paréntesis, el porcentaje respecto al total de su desenlace real. La celda inferior derecha corresponde al *recall* (fallecimientos detectados) y la inferior izquierda, a los falsos negativos, los pacientes que fallecen y el modelo no identificó, que es el error de mayor costo clínico. La celda superior derecha corresponde a los falsos positivos, las falsas alarmas.

Figura 6.2. Matrices de confusión en el conjunto de prueba



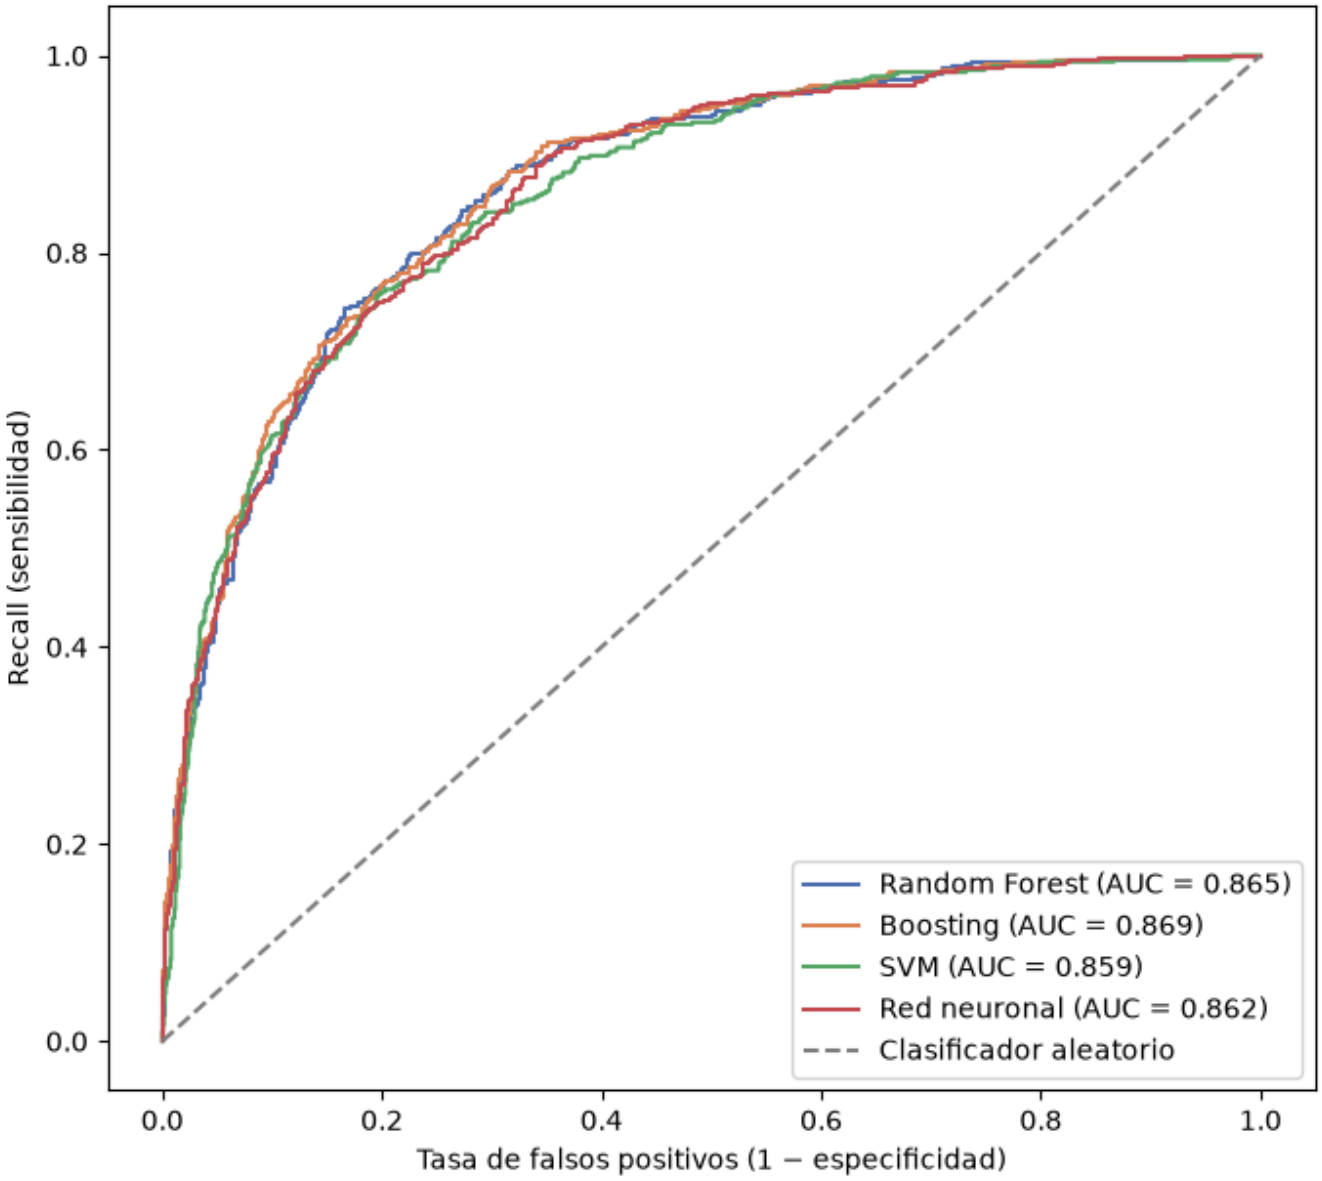
De los 472 pacientes de prueba que fallecieron en el hospital, la SVM deja sin detectar a 90, Boosting a 95, Random Forest a 98 y la red neuronal a 103. Las falsas alarmas entre los 1,349 sobrevivientes siguen el orden inverso: 339 en la SVM, 296 en Boosting, 291 en Random Forest y 273 en la red neuronal (Figura 6.2). Ningún modelo domina a los demás en ambos tipos de error: el que menos fallecimientos deja pasar es también el que más falsas alarmas genera. Por ejemplo, pasar de la red neuronal a la SVM permite detectar 13 fallecimientos más, a cambio de 66 falsas alarmas adicionales, alrededor de cinco por cada fallecimiento adicional detectado.

Cuál de estos equilibrios es preferible no es una pregunta estadística, sino clínica: depende del costo de una falsa alarma frente al de un paciente en riesgo no identificado. En un contexto de tamizaje, donde una alerta lleva a una revisión clínica más cuidadosa y no a una intervención invasiva, un *recall* alto suele ser preferible, aunque genere más falsas alarmas.

6.4 Curvas ROC

Las matrices de confusión corresponden a un solo umbral de decisión. La curva ROC muestra el desempeño en todos los umbrales posibles para cada uno, la proporción de fallecimientos detectados (*recall*) frente a la proporción de sobrevivientes clasificados erróneamente como en riesgo. Cuanto más se acerca la curva a la esquina superior izquierda, mejor discrimina el modelo; la diagonal corresponde a un clasificador aleatorio (AUC = 0.5). La Figura 6.3 muestra las curvas de los cuatro modelos.

Figura 6.3. Curvas ROC en el conjunto de prueba



Las curvas ROC de los cuatro modelos se superponen casi por completo en todo el rango de umbrales (Figura 6.3). Solo se separan ligeramente en la zona intermedia, entre tasas de falsos positivos de 0.2 y 0.4, donde la curva de Boosting queda marginalmente por encima. Esto tiene una implicación práctica: las diferencias de *recall* y precisión de la Tabla 6.2 y la Figura 6.2 no reflejan modelos mejores o peores. Con un umbral de decisión ajustado, cualquiera de los cuatro modelos podría alcanzar el perfil de errores de los demás.

6.5 Diferencias sustanciales y marginales

Una diferencia de AUC entre dos modelos en el conjunto de prueba puede reflejar una ventaja real o simplemente depender de qué pacientes quedaron en ese conjunto. Para distinguir ambos casos se usa ***bootstrap***:

1. Se generan 2,000 muestras del conjunto de prueba, cada una del mismo tamaño y tomada con reemplazo.
2. En cada muestra se calcula la AUC de los cuatro modelos sobre los mismos pacientes.
3. Con las 2,000 repeticiones se construye un intervalo de confianza del 95 % para la AUC de cada modelo (Tabla 6.3) y para la diferencia entre cada par de modelos (Tabla 6.4).

Como los modelos se evalúan sobre los mismos pacientes en cada repetición, las diferencias se estiman de forma pareada, lo que elimina la variación debida a la dificultad de cada muestra. Si el intervalo de una diferencia incluye el 0, esa diferencia no se distingue de la variación aleatoria y se considera marginal.

Tabla 6.3. AUC en el conjunto de prueba con intervalo de confianza del 95 % (bootstrap)

Modelo	AUC	Límite inferior (IC 95 %)	Límite superior (IC 95 %)
Random Forest	0.865	0.847	0.883
Boosting	0.869	0.851	0.887
SVM	0.859	0.841	0.878
Red neuronal	0.862	0.842	0.880

Tabla 6.4. Diferencias de AUC entre pares de modelos con intervalo de confianza del 95 % (bootstrap)

Comparación	Diferencia de AUC	Límite inferior (IC 95 %)	Límite superior (IC 95 %)	¿Diferencia significativa?
Random Forest − Boosting	-0.004	-0.008	0.001	No
Random Forest − SVM	0.006	-0.002	0.013	No
Random Forest − Red neuronal	0.003	-0.004	0.011	No
Boosting − SVM	0.009	0.001	0.017	Sí
Boosting − Red neuronal	0.007	-0.001	0.014	No
SVM − Red neuronal	-0.002	-0.010	0.005	No

Por AUC en prueba, Boosting (0.872), seguido de Random Forest (0.868), la SVM (0.866) y la red neuronal (0.866). Sin embargo, los intervalos de confianza de los cuatro modelos se traslapan casi por completo (Tabla 6.3), el de Boosting va de 0.855 a 0.889, y los de la SVM y la red neuronal, de 0.847 a 0.883 y de 0.848 a 0.883. Ningún modelo destaca en todas las métricas. Boosting tiene el AUC más alto, la red neuronal la mayor precisión y el mayor F1, y la SVM el mayor *recall*.

Las diferencias son **marginales**. Ninguna de las seis comparaciones entre pares de modelos es estadísticamente significativa (Tabla 6.4). Las mayores diferencias son las de Boosting frente a la SVM y frente a la red neuronal (0.007 en ambos casos), y aun así sus intervalos de confianza incluyen el 0, de −0.000 a 0.014 y de −0.001 a 0.014, respectivamente. Una diferencia de AUC de 0.007 equivale a que, de cada mil pares de pacientes (uno que fallece y uno que sobrevive), Boosting ordene correctamente siete pares más que la SVM.

Esta conclusión es consistente en todas las evaluaciones, en validación cruzada, la variabilidad entre *folds* fue mayor que la diferencia entre modelos (Figura 6.1); en prueba, las curvas ROC se superponen (Figura 6.3), y el *bootstrap* confirma que las diferencias no se distinguen de la variación aleatoria. En este problema, los cuatro modelos alcanzan un **mismo nivel de desempeño**, alrededor de 0.87 de AUC, y lo que los distingue no es cuánto discriminan, sino cómo distribuyen sus errores entre falsos negativos y falsas alarmas.

7. Predicción de la ventana temporal de fallecimiento

La mortalidad intrahospitalaria responde si un paciente fallecerá durante su hospitalización, pero no cuándo. Esta sección extiende el análisis a una pregunta más exigente: en qué **ventana de tiempo** ocurrirá el fallecimiento, o si el paciente sobrevivirá más de un año. Como se mostró en la Tabla 3.7, ambas preguntas son complementarias: 432 pacientes fueron dados de alta con vida pero fallecieron en los primeros 30 días, un riesgo que `hospdead` no capta.

7.1 Construcción de las ventanas y distribución de clases

Las ventanas se definieron en la sección 3.4.2 a partir de `death` y `d.time`, con cortes en 30, 180 y 365 días. Se excluyó a los 65 pacientes censurados, cuyo seguimiento terminó antes del año sin que se registrara su fallecimiento. Se mantiene la misma partición train-test de la sección 4.1: los pacientes de cada conjunto son los mismos que en la tarea principal, excepto los censurados. Así, ningún paciente de prueba se usa en el entrenamiento de ninguna de las dos tareas.

Las clases están desbalanceadas (Tabla 4.3): la muerte entre 181 y 365 días representa menos del 10 % de los pacientes, frente a más del 40 % de la supervivencia mayor a un año. Para compensarlo, se aplica la misma ponderación inversa a la frecuencia que en la tarea principal. La Tabla 7.1 muestra el número de pacientes y el peso de cada clase.

Tabla 7.1. Pacientes y peso de cada clase en la tarea multiclase

Ventana	Pacientes (entrenamiento)	Pacientes (prueba)	Peso de clase
Muerte ≤ 30 días	1,973	490	0.92
Muerte 31–180 días	1,438	364	1.26
Muerte 181–365 días	618	160	2.92
Sobrevive > 1 año	3,199	798	0.56

La ponderación asigna a la clase minoritaria, la muerte entre 181 y 365 días, un peso de alrededor de 3. Es decir, cada uno de esos pacientes cuenta en el entrenamiento como tres pacientes de una clase de frecuencia promedio. La supervivencia mayor a un año, la clase más frecuente, recibe un peso menor a 1.

7.2 Adaptación de los modelos a clasificación multiclase

Los cuatro modelos se adaptan a las cuatro clases con **los mismos hiperparámetros** de la sección 5. No se repite la selección de hiperparámetros, para que las diferencias entre ambas tareas se deban al problema y no a la configuración de los modelos. Cada modelo resuelve el problema multiclase a su manera:

- **Random Forest:** los árboles de decisión manejan varias clases de forma natural. Cada hoja almacena la proporción de pacientes de cada clase, la impureza se mide con el índice de Gini sobre las cuatro clases y la predicción final es el voto mayoritario de los 500 árboles.
- **Boosting:** en cada iteración se construye un árbol por clase, y la salida se transforma en probabilidades mediante la función *softmax*. Con B = 100 iteraciones y cuatro clases, el modelo combina 400 árboles.
- **SVM:** el hiperplano separa solo dos clases, así que la extensión multiclase se hace con la estrategia **uno contra uno**. se entrena una SVM para cada par de clases (seis en total), y cada paciente se asigna a la clase que gana más enfrentamientos.
- **Red neuronal:** la capa de salida pasa de una neurona sigmoide a cuatro neuronas con activación *softmax*. Cada neurona produce la probabilidad de una ventana y las cuatro probabilidades suman 1. La función de costo pasa a ser la **entropía cruzada categórica** (`sparse_categorical_crossentropy`). Como no existe una AUC única para cuatro clases durante el entrenamiento, el *early stopping* monitorea el costo de validación, con la misma paciencia de 10 épocas. Las capas ocultas, el optimizador, el *batch* y la partición interna de validación son los mismos de la sección 5.4.

Métricas.

Se reportan la exactitud, el **F1 macro** (promedio del F1 de las cuatro clases, sección 4.6), el F1 de cada clase y el **AUC macro uno contra el resto**. Esta última calcula la AUC de cada clase frente a las demás y las promedia. Como referencia, se incluye un clasificador mayoritario que asigna a todos los pacientes la clase más frecuente (supervivencia mayor a un año).

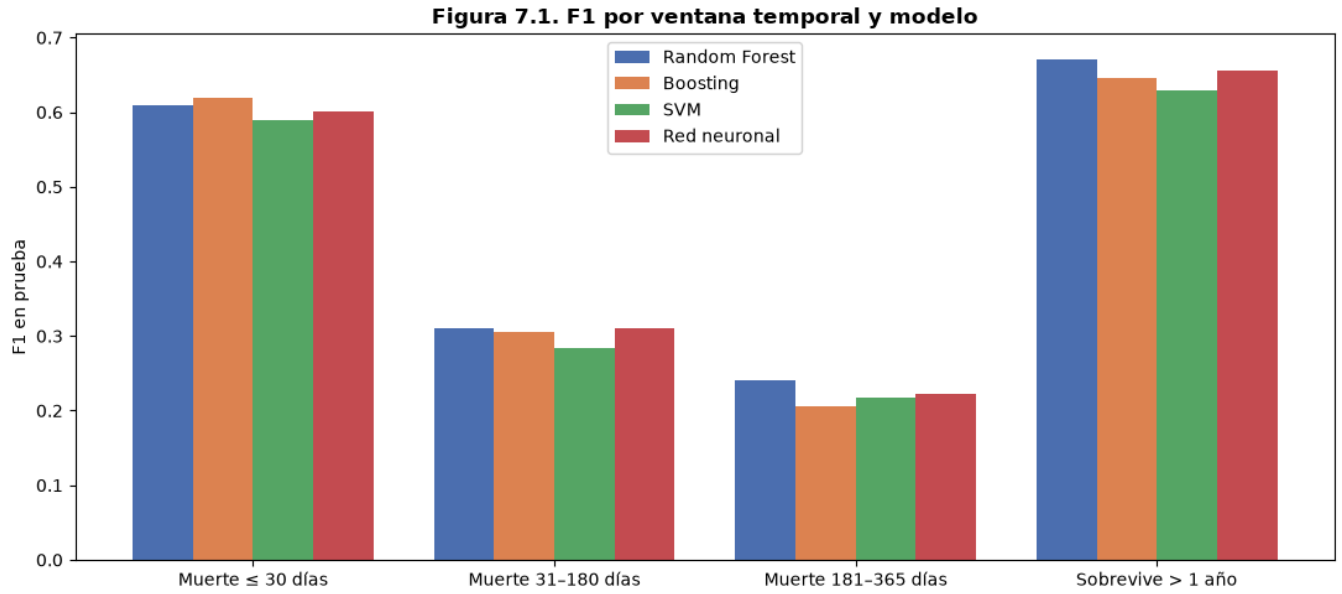
7.3 Resultados y matriz de confusión multiclase

La Tabla 7.2 presenta el desempeño de los cuatro modelos en los 1,812 pacientes de prueba con ventana definida.

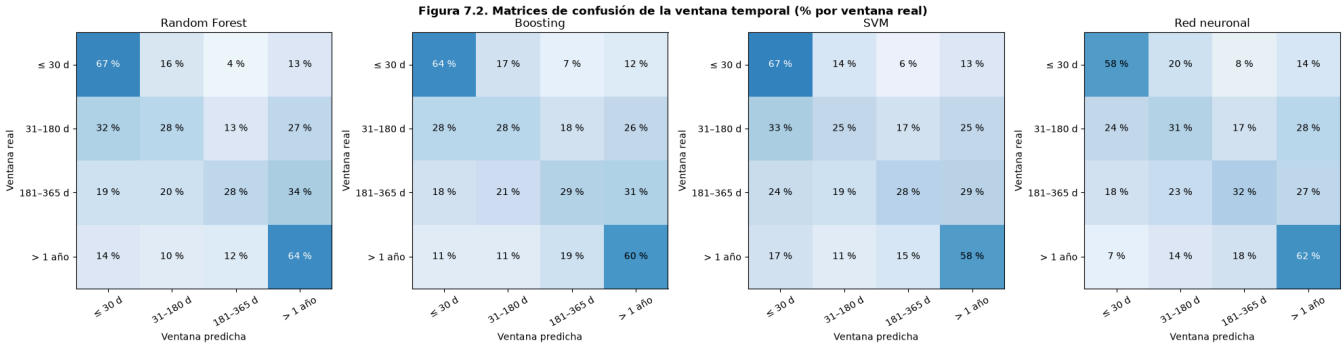
Tabla 7.2. Desempeño en la predicción de la ventana temporal (conjunto de prueba)

Modelo	Exactitud	F1 macro	AUC macro (OvR)	F1 Muerte ≤ 30 días	F1 Muerte 31–180 días	F1 Muerte 181–365 días	F1 Sobrevive > 1 año
Random Forest	0.544	0.458	0.734	0.610	0.310	0.240	0.671
Boosting	0.520	0.444	0.731	0.619	0.305	0.205	0.646
SVM	0.509	0.430	0.729	0.590	0.284	0.218	0.629
Red neuronal	0.519	0.448	0.721	0.602	0.311	0.223	0.656
Clasificador mayoritario	0.440	0.153	0.500	0.000	0.000	0.000	0.611

La Figura 7.1 compara el F1 de cada modelo en cada ventana, para identificar qué clases son más difíciles de predecir.



La Figura 7.2 muestra las matrices de confusión. Cada celda indica el porcentaje de pacientes de una ventana real (fila) que el modelo asignó a cada ventana predicha (columna). La diagonal corresponde a los aciertos.



Predecir la ventana temporal es considerablemente más difícil que predecir la mortalidad intrahospitalaria. Los cuatro modelos superan al clasificador mayoritario, que alcanza una exactitud de 0.440 y un F1 macro de 0.153, pero su desempeño queda lejos del obtenido en la tarea binaria, la exactitud va de 0.509 a 0.544, el F1 macro de 0.430 a 0.458 y el AUC macro de 0.720 a 0.734 (Tabla 7.2). Random Forest obtiene los valores más altos en las tres métricas globales, seguido de cerca por Boosting. Al igual que en la tarea principal, las diferencias entre modelos son pequeñas en comparación con la diferencia entre clases.

La Figura 7.1 muestra de dónde viene la dificultad. Los cuatro modelos predicen razonablemente bien las dos ventanas extremas, la muerte en los primeros 30 días (F1 de 0.590 a 0.619) y la supervivencia mayor a un año (F1 de 0.629 a 0.671). En cambio, fallan en las dos ventanas intermedias. El F1 de la muerte entre 31 y 180 días va de 0.247 a 0.310, y el de la muerte entre 181 y 365 días de 0.203 a 0.240. Las matrices de confusión (Figura 7.2) confirman este patrón: los modelos identifican correctamente entre el

58 % y el 67 % de los pacientes de las ventanas extremas, pero solo entre el 19 % y el 34 % de los de las ventanas intermedias.

Los errores en las ventanas intermedias no son aleatorios. Los pacientes que fallecen entre los días 31 y 180 se confunden sobre todo con la muerte temprana (27 % a 33 %) o con la supervivencia mayor a un año (25 % a 27 %). Los que fallecen entre los días 181 y 365 se clasifican con más frecuencia como sobrevivientes a un año (29 % a 34 %) que en su propia ventana. Es decir, los modelos tienden a empujar a los pacientes intermedios hacia uno de los extremos.

Esto se debe a que las variables del tercer día describen la gravedad del paciente en ese momento, y esa gravedad distingue bien a los pacientes que fallecen en pocas semanas de los que se recuperan por completo. Pero la muerte meses después del ingreso depende de factores que ocurren después de la hospitalización, como la evolución de la enfermedad crónica, el tratamiento ambulatorio o las complicaciones posteriores, y ninguno de ellos está en los datos.

El error clínicamente más grave, clasificar como sobreviviente a más de un año a un paciente que fallece en el primer mes, ocurre en el 12 % a 16 % de esos pacientes según el modelo. Esto confirma que la predicción de la ventana temporal, con la información disponible al tercer día, sirve como orientación complementaria a `hospdead`, pero no tiene la confiabilidad necesaria para usarse por sí sola.

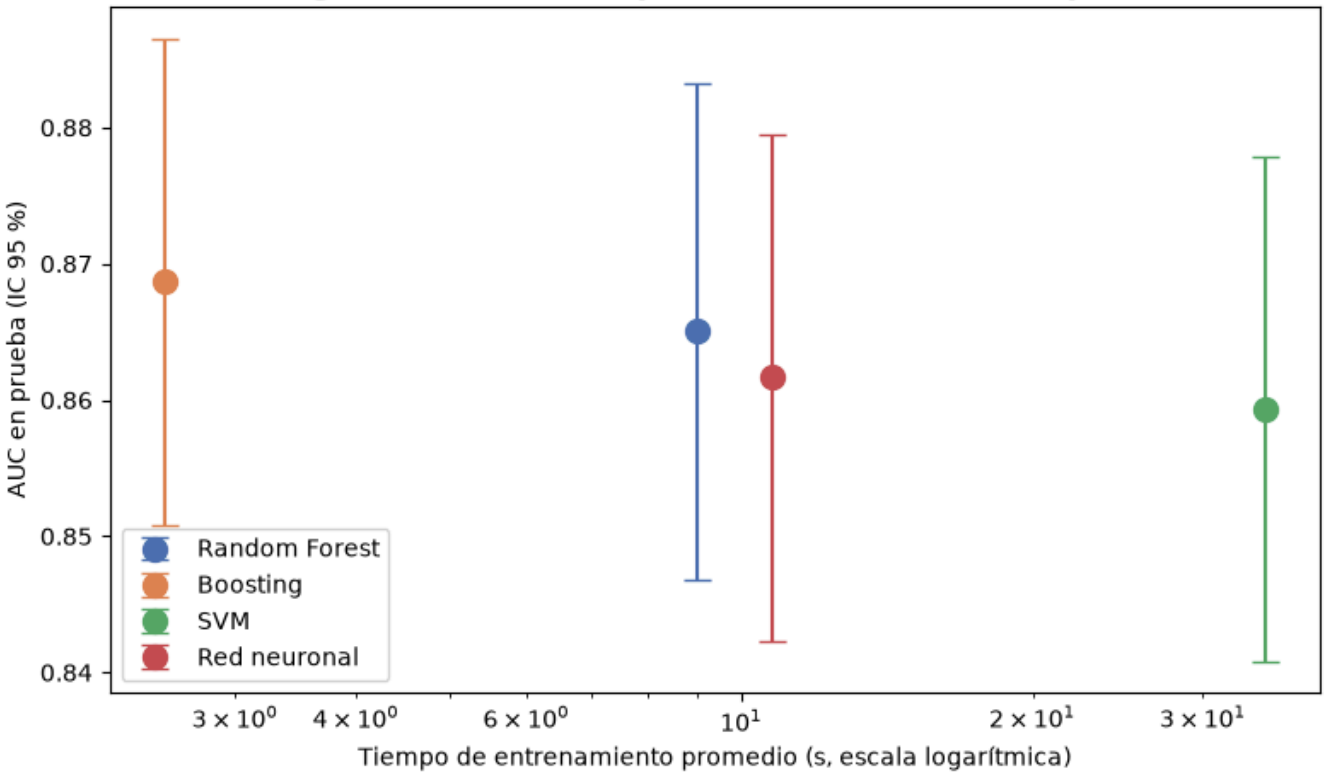
8. Análisis general

Esta sección integra los resultados de las secciones 5 a 7 para analizar críticamente cuatro aspectos, si el aumento en complejidad se tradujo en mejores predicciones, el riesgo de sobreajuste de cada modelo, su interpretabilidad relativa y las situaciones en las que conviene preferir uno sobre otro.

8.1 Complejidad del modelo vs. mejora en desempeño

La Figura 8.1 sitúa la AUC en prueba de cada modelo, con su intervalo de confianza del 95 % (Tabla 6.3), frente a su tiempo promedio de entrenamiento en la validación cruzada (Tabla 6.1). El tiempo funciona como indicador del costo computacional de cada modelo.

Figura 8.1. Costo computacional frente a desempeño



Los cuatro modelos difieren considerablemente en complejidad y costo computacional (Tabla 6.1). Boosting combina 100 árboles de profundidad 3 y es el más rápido de entrenar (alrededor de 1 segundo por *fold*). Random Forest combina 500 árboles de unos 16 niveles de profundidad (3.5 segundos). La red neuronal requiere un entrenamiento iterativo con *early stopping* (7.1 segundos). La SVM resuelve un problema de optimización con más de 4,000 vectores de soporte y es la más costosa (11.3 segundos). La Figura 8.1 muestra que este aumento de costo no se traduce en mayor AUC, pues el modelo más rápido de entrenar es también el de mayor AUC en prueba, mientras que los dos más costosos, la SVM y la red neuronal, obtienen el AUC más bajo, aunque la diferencia no es significativa (Tabla 6.4).

En la sección 5, aumentar la complejidad *dentro* de cada modelo (hojas más pequeñas, más árboles, márgenes más estrictos o más épocas) mejoró el ajuste al entrenamiento sin mejorar la validación (Tablas 5.2, 5.4 y 5.5; Figuras 5.2 y 5.5). Aquí ocurre lo mismo entre modelos. Con 30 predictores clínicos y más de 7,000 pacientes, los cuatro modelos parecen extraer prácticamente toda la información que contienen las variables, y alcanzan el mismo techo de desempeño. Ese techo no está determinado por el algoritmo, sino por los datos, como mostró la distribución de la función de decisión de la SVM (Figura 5.3), existe un grupo amplio de pacientes cuyo estado al tercer día no permite distinguir con claridad si sobrevivirán o no. Este resultado coincide con lo reportado en la literatura de predicción clínica, donde los modelos más flexibles rara vez superan de forma significativa a alternativas más simples cuando los datos son tabulares y de dimensión moderada.

8.2 Riesgo de sobreajuste

Un modelo sobreajustado tiene un desempeño mucho mejor con los datos con los que se entrenó que con datos nuevos. Para evaluar este riesgo, la Tabla 8.1 compara para cada modelo la AUC en tres conjuntos:

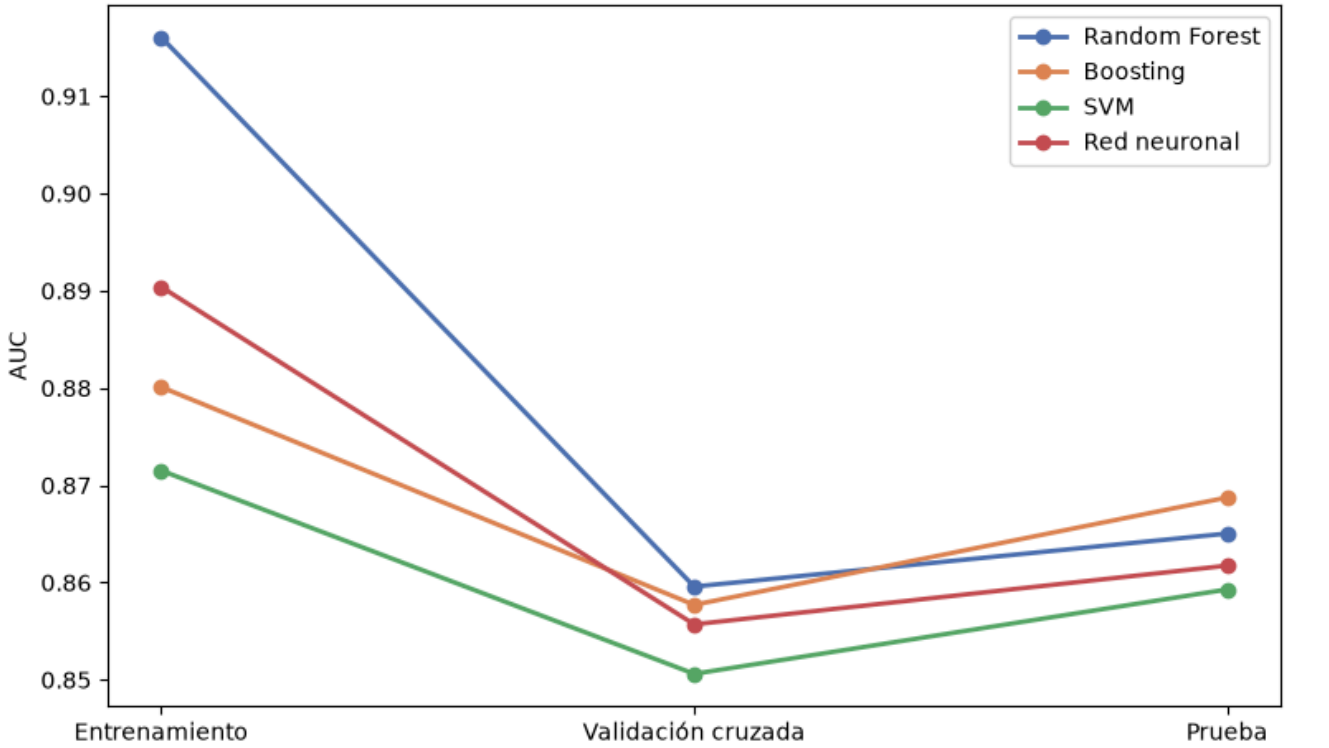
- **Entrenamiento:** los pacientes con los que se ajustaron los parámetros del modelo final. En la red neuronal, es la parte de ajuste de la partición interna.
- **Validación cruzada:** el promedio de los cinco *folds* (Tabla 6.1).
- **Prueba:** los pacientes nunca vistos (Tabla 6.3).

La brecha entre entrenamiento y prueba indica cuánto del desempeño en entrenamiento no se generaliza.

Tabla 8.1. AUC en entrenamiento, validación cruzada y prueba

Modelo	AUC entrenamiento	AUC validación cruzada	AUC prueba	Brecha entrenamiento − prueba
Random Forest	0.916	0.860	0.865	0.051
Boosting	0.880	0.858	0.869	0.011
SVM	0.872	0.851	0.859	0.012
Red neuronal	0.890	0.856	0.862	0.029

Figura 8.2. AUC de cada modelo en entrenamiento, validación cruzada y prueba



Ningún modelo muestra un sobreajuste que comprometa su desempeño en pacientes nuevos, pero su comportamiento difiere (Tabla 8.1):

- **Random Forest** tiene la mayor brecha entre entrenamiento y prueba (0.037), con un AUC de entrenamiento de 0.905, frente a 0.868 en prueba. Aun con hojas de al menos 20 pacientes, sus árboles profundos se ajustan en parte a los pacientes con los que fueron construidos. Sin embargo, este ajuste no perjudica la generalización, pues el promedio de 500 árboles entrenados con muestras *bootstrap* distintas cancela buena parte de la variabilidad de cada árbol, y su AUC en prueba es la segunda más alta.
- **La red neuronal** tiene una brecha moderada (0.013). El *early stopping* la detuvo en la época 5, antes de que el AUC de ajuste se separara del de validación (Figura 5.5); de no haberlo hecho, la brecha habría crecido con cada época.
- **Boosting y la SVM** prácticamente no tienen brecha (0.004 y 0.002): su desempeño en entrenamiento es casi igual al de prueba. En ambos casos, esto es resultado directo de la selección de hiperparámetros. Con 600 árboles, Boosting llegaba a un AUC de entrenamiento mucho mayor que el de validación (Tabla 5.4 y Figura 5.2), y con `C` = 10, la SVM alcanzaba un AUC de entrenamiento de 0.996 frente a 0.803 en validación (Tabla 5.5).

La Figura 8.2 muestra además un patrón común a los cuatro modelos, la AUC en validación cruzada es menor que en prueba. Esto no indica un problema de los modelos, sino que el conjunto de prueba resultó algo más fácil que el promedio de los *folds* (sección 6.2). Lo relevante es que los cuatro modelos mantienen su orden relativo y su nivel de desempeño en las tres evaluaciones.

Los cuatro modelos son capaces de sobreajustar, como se vio en la sección 5, pero los mecanismos aplicados (mínimo de pacientes por hoja, número limitado de árboles, margen suave y *early stopping*), seleccionados siempre con validación cruzada y nunca con el conjunto de prueba, lo mantuvieron bajo control.

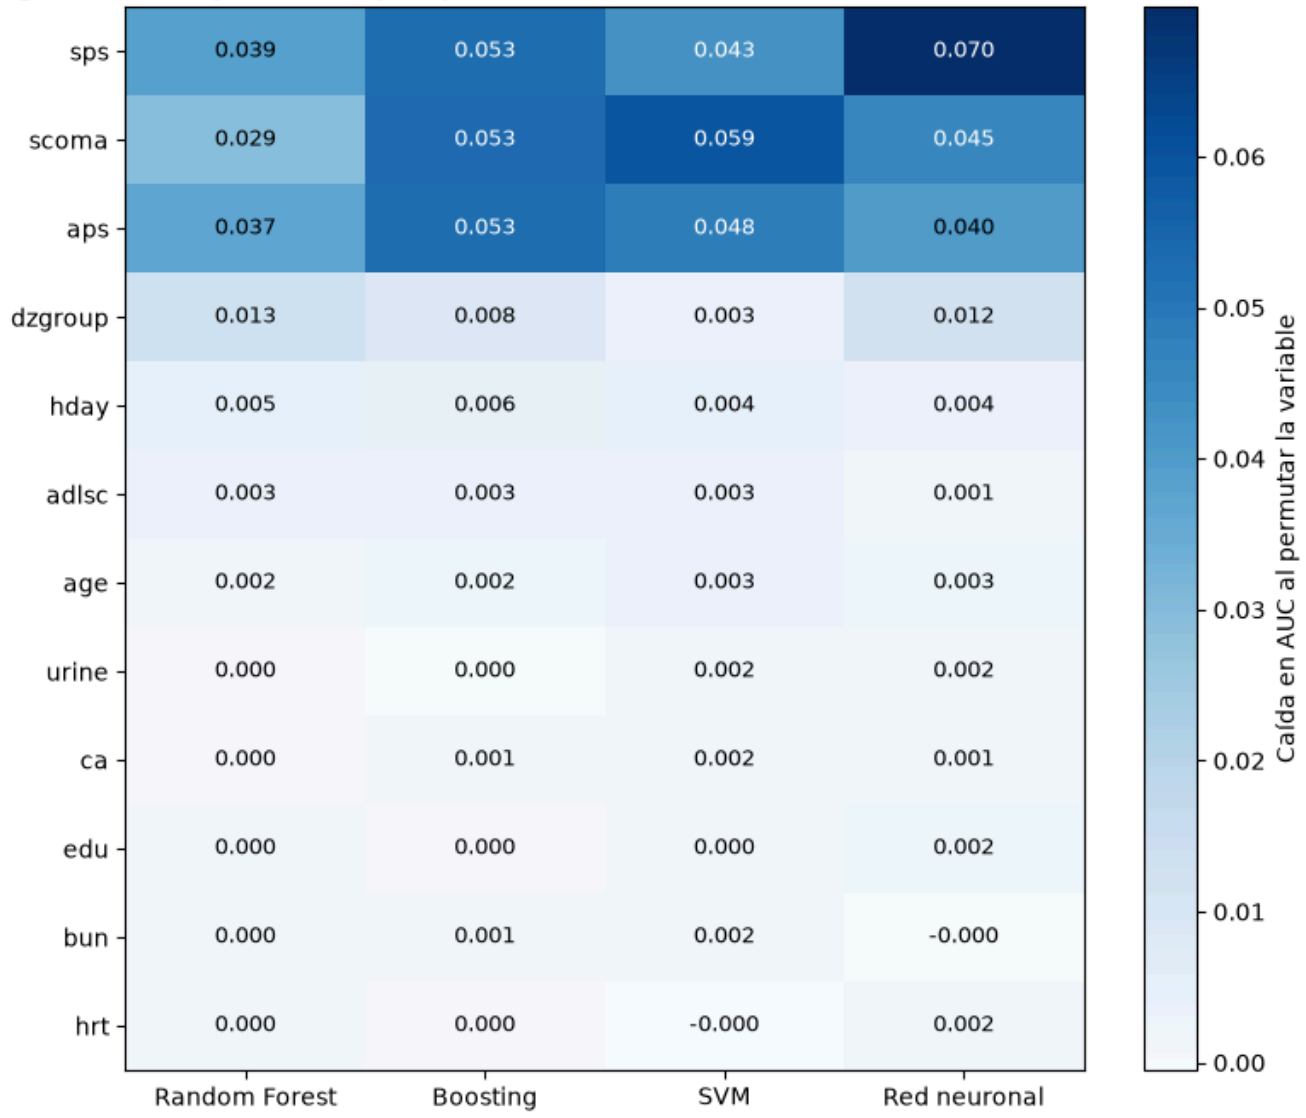
8.3 Interpretabilidad relativa de cada modelo

En un contexto clínico, la interpretabilidad es casi tan importante como el desempeño, pues un médico difícilmente actuará con base en una predicción si no puede saber en qué se apoya.

- **Random Forest:** cada árbol individual es una secuencia de reglas fácil de seguir (Figura 5.1a), pero la predicción final combina el voto de 500 árboles distintos, así que no existe una regla única que la explique. Su interpretación se limita a medidas agregadas, como la importancia de las variables.
- **Boosting:** sus árboles son más pequeños (profundidad 3), y cada uno representa una regla simple. Sin embargo, la predicción es la suma de 100 correcciones sucesivas, lo que hace igualmente difícil seguir su razonamiento completo.
- **SVM:** la frontera de decisión existe en un espacio transformado por el *kernel* , sin una expresión en términos de las variables originales. La predicción depende de la similitud del paciente con más de 4,000 vectores de soporte (Tabla 5.6). Es el modelo cuyo funcionamiento interno resulta más difícil de traducir a términos clínicos.
- **Red neuronal:** sus 2,049 pesos (Tabla 5.8) no tienen un significado individual; la información se distribuye entre las neuronas de las capas ocultas. Como la SVM, es esencialmente una caja negra.

Ninguno de los cuatro modelos es interpretable por sí mismo. Para compararlos en igualdad de condiciones, se usa un método independiente del modelo, la importancia por permutación. Para cada variable clínica, se desordenan aleatoriamente sus valores en el conjunto de prueba, rompiendo su relación con el desenlace, y se mide cuánto disminuye la AUC. Si la AUC cae mucho, el modelo depende de esa variable; si no cambia, la ignora. Se usan cinco repeticiones por variable y se reporta la caída promedio. Como se permutan las 30 variables originales, y no las 46 transformadas, el resultado se expresa en términos clínicos directos. Por ejemplo, `dzgroup` se evalúa como una sola variable y no como ocho columnas *one-hot*.

Figura 8.3. Importancia por permutación de las 12 variables más relevantes



A pesar de sus mecanismos internos completamente distintos, los cuatro modelos dependen de las **mismas variables** (Figura 8.3):

- **Puntajes de gravedad y estado neurológico.** El puntaje fisiológico de SUPPORT (`sps`), la escala de coma (`scoma`) y el puntaje fisiológico de APACHE III (`aps`) son las tres variables más importantes en los cuatro modelos. Permutar cualquiera de ellas reduce la AUC entre 0.033 y 0.067. La red neuronal es la que más depende de `sps` (0.067) y la SVM, de `scoma` (0.061).
- **Grupo de enfermedad y estado previo.** Le siguen, con una importancia mucho menor, el grupo de enfermedad (`dzgroup`), el día de ingreso al estudio (`hday`), el índice de actividades de la vida diaria (`adlsc`) y la edad (`age`), con caídas de AUC de entre 0.004 y 0.019.
- **Resto de las variables.** Las demás tienen una importancia individual de 0.005 o menos. Ninguna de ellas, por sí sola, cambia de forma apreciable las predicciones.

Que los cuatro modelos coincidan es un resultado relevante por dos razones. Primero porque las predicciones se apoyan en variables con un significado clínico claro, la gravedad fisiológica y el estado neurológico del paciente, y no en particularidades de un algoritmo. Segundo, explica por qué los cuatro

modelos tienen un desempeño equivalente (sección 6.5), todos aprendieron esencialmente la misma señal de los datos.

8.4 ¿Cuándo preferir cada modelo?

Como los cuatro modelos alcanzan un desempeño estadísticamente equivalente (sección 6.5), la elección entre ellos no depende de cuál predice mejor, sino de las condiciones en que se usará. La Tabla 8.2 resume sus características en los criterios que distinguen a cada uno en este análisis.

Tabla 8.2. Características comparativas de los modelos

Criterio	Random Forest	Boosting	SVM	Red neuronal
Discriminación (AUC en prueba)	Equivalente	Equivalente (la más alta)	Equivalente	Equivalente
Perfil de errores	Intermedio	Intermedio	Mayor *recall*, más falsas alarmas	Mayor precisión, menor *recall*
Costo de entrenamiento	Moderado	Muy bajo	El más alto	Alto
Sensibilidad a hiperparámetros	Baja (Tabla 5.2)	Moderada (Tabla 5.4)	Alta (Tabla 5.5)	Requiere *early stopping* (Figura 5.5)
Necesita escalamiento	No	No	Sí	Sí
Interpretabilidad interna	Baja	Baja	Muy baja	Muy baja

- **Boosting** es la opción más recomendable como modelo de uso general en este problema. Obtuvo el AUC más alto en prueba, es con diferencia el más rápido de entrenar y no requiere escalamiento. Su principal riesgo es el sobreajuste si se agregan demasiados árboles (Figura 5.2), así que el número de árboles debe controlarse con validación.
- **Random Forest** es preferible cuando se busca robustez con el mínimo esfuerzo de ajuste, pues su desempeño apenas cambió con sus hiperparámetros (Tabla 5.2), más árboles no lo empeoran, al menos en el presente analisis, (Figura 5.1b) y el error *out-of-bag* ofrece una estimación interna de su desempeño sin necesidad de validación cruzada. Además, fue el modelo con mejor desempeño global en la predicción de la ventana temporal (Tabla 7.2), lo que sugiere que su robustez es una ventaja cuando el problema es más difícil y las clases están más desbalanceadas.
- **La SVM** es preferible cuando la prioridad es detectar a la mayor cantidad posible de pacientes en riesgo, como en un tamizaje donde una falsa alarma solo implica una revisión adicional. Es el modelo con mayor *recall*, a costa del mayor número de falsas alarmas (Figura 6.2). Sin embargo, es el más costoso de entrenar y el más sensible a su hiperparámetro de regularización, un `C` mal elegido degradó su AUC de validación de 0.849 a 0.803 (Tabla 5.5). Su costo crece rápidamente con el número de pacientes, lo que la hace menos práctica para conjuntos de datos más grandes.
- **La red neuronal** es preferible cuando el costo de una falsa alarma es alto, por ejemplo si la alerta desencadena una intervención costosa o invasiva, porque es el modelo con mayor precisión y menos falsas alarmas. Además, es el modelo con mayor potencial de mejora si se dispusiera de

datos más complejos, como series de tiempo de signos vitales o notas clínicas, donde los ensambles de árboles pierden su ventaja. Con los 30 predictores tabulares de este estudio, esa capacidad no se traduce en un mejor desempeño, y su entrenamiento requiere más decisiones de diseño (arquitectura, optimizador, *early stopping*).

En todos los casos, el perfil de errores de la Tabla 8.2 no es una propiedad fija del modelo, sino una consecuencia del umbral de decisión. Como las curvas ROC son prácticamente iguales (Figura 6.3), ajustar el umbral permitiría que cualquiera de los modelos se acerque al perfil de errores de los demás. En la práctica, la elección del umbral según las prioridades clínicas es más importante que la elección del algoritmo.

9. Conclusiones

Se entrenaron y compararon cuatro modelos de clasificación (Random Forest, Boosting, SVM y una red neuronal *feedforward*) para predecir la mortalidad intrahospitalaria de 9,105 pacientes gravemente enfermos del estudio SUPPORT, usando solo la información disponible al tercer día de hospitalización. El diseño del escenario experimental fue determinante para que los resultados fueran válidos. La exclusión de las variables posteriores al desenlace evitó una fuga de datos que habría producido una clasificación perfecta pero inútil (Tabla 3.9). A su vez, el tratamiento diferenciado de los valores faltantes permitió aprovechar que la ausencia de algunos estudios clínicos contiene información sobre el riesgo del paciente (Tabla 3.4).

Los cuatro modelos alcanzaron un desempeño alto y estadísticamente equivalente, con AUC en prueba entre 0.866 y 0.872 y ninguna diferencia significativa entre ellos (Tabla 6.4). Lo que los distingue no es su capacidad de discriminación, sino cómo distribuyen sus errores, la SVM detecta más fallecimientos a cambio de más falsas alarmas, y la red neuronal genera menos falsas alarmas a cambio de detectar menos fallecimientos.

El aumento en complejidad no se tradujo en mejores predicciones. Boosting, el modelo más rápido de entrenar, obtuvo el AUC más alto, mientras que los dos más costosos, la SVM y la red neuronal, no superaron a los ensambles (Figura 8.1). Los cuatro modelos se apoyan en las mismas variables, principalmente la gravedad fisiológica (`sps` , `aps`) y el estado neurológico (`scoma`) (Figura 8.3). Esto indica que el límite de desempeño lo imponen los datos y no el algoritmo. El sobreajuste se mantuvo bajo control en todos los casos gracias a la selección de hiperparámetros por validación cruzada y al *early stopping* (Tabla 8.1).

La predicción de la ventana temporal de fallecimiento resultó considerablemente más difícil, con un F1 macro de 0.430 a 0.458 (Tabla 7.2). Los modelos distinguen bien la muerte temprana y la supervivencia prolongada, pero no las ventanas intermedias, que dependen de factores posteriores a la hospitalización. Random Forest fue el modelo con mejor desempeño en esta tarea, aunque con diferencias pequeñas respecto a los demás.

En conjunto, los resultados indican que, en un problema clínico con datos tabulares de dimensión moderada, la elección del algoritmo es secundaria frente a la calidad del diseño experimental, la información disponible y la elección del umbral de decisión según las prioridades clínicas. En este contexto, Boosting resulta la opción más conveniente como modelo de uso general, por su desempeño, su bajo costo y su facilidad de ajuste; sin embargo, la elección final debe responder a las prioridades clínicas de cada aplicación (sección 8.4).

Referencias

- Christakis, N. A., & Lamont, E. B. (2000). Extent and determinants of error in doctors' prognoses in terminally ill patients: Prospective cohort study. *BMJ, 320*(7233), 469–472. https://doi.org/10.1136/bmj.320.7233.469

- Harrell, F. (1995). *SUPPORT2* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.3886/ICPSR02957.v2

- Knaus, W. A., Harrell, F. E., Lynn, J., Goldman, L., Phillips, R. S., Connors, A. F., Dawson, N. V., Fulkerson, W. J., Califf, R. M., Desbiens, N., Layde, P., Oye, R. K., Bellamy, P. E., Hakim, R. B., & Wagner, D. P. (1995). The SUPPORT prognostic model: Objective estimates of survival for seriously ill hospitalized adults. *Annals of Internal Medicine, 122*(3), 191–203. https://doi.org/10.7326/0003-4819-122-3-199502010-00007