Comparación de modelos de clasificación para la predicción de mortalidad en pacientes gravemente enfermos

SC3314 – Inteligencia Artificial

Universidad de Monterrey

Jorge Tello 664317

Índice

1. Introducción

2. Objetivos

3. Descripción del conjunto de datos

3.1 Población del estudio

3.2 Variables

3.3 Verificación de calidad: valores faltantes, tipos y balance de clases

3.4 Definición de las variables objetivo

- 3.4.1 Mortalidad intrahospitalaria (`hospdead`)
- 3.4.2 Ventana temporal de fallecimiento

3.5 Variables excluidas por data leakage

4. Preparación del escenario experimental

4.1 Partición train-test estratificada

4.2 Pipeline de preprocesamiento: imputación, codificación y escalamiento

4.3 Verificación de la adecuación del conjunto de datos

4.4 Validación cruzada estratificada (dentro de train)

4.5 Data Leakage

4.6 Métricas de evaluación

5. Construcción de modelos

5.1 Regresión logística

5.2 Linear Discriminant Analysis

5.3 Random Forest

5.4 Boosting

5.5 Support Vector Machine

5.6 Red neuronal

6. Comparación de modelos en validación cruzada

6.1 Métricas de desempeño (media ± desviación estándar)

6.2 Estabilidad entre particiones

6.3 Estadístico F y pruebas t pareadas

6.4 Costo computacional e interpretabilidad

7. Selección del modelo final

8. Evaluación del modelo final en el conjunto de prueba

8.1 Métricas de desempeño con intervalo de confianza

8.2 Matriz de confusión y curva ROC

8.3 Interpretación de los resultados

8.4 Variables que sostienen la predicción

9. Predicción de la ventana temporal de fallecimiento

9.1 Adaptación de los modelos a clasificación multiclase (*softmax*)

9.2 Comparación en validación cruzada y selección del modelo

9.3 Evaluación en el conjunto de prueba

10. Comparación con el modelo pronóstico SUPPORT y la estimación médica

11. Tablero interactivo

12. Conclusión y reflexión final

12.1 Aprendizajes sobre la problemática

12.2 Modelo más adecuado

12.3 Limitaciones

12.4 Trabajo futuro

12.5 Reflexión Final

13. Referencias

1. Introducción

Estimar el pronóstico de un paciente gravemente enfermo es una de las tareas más difíciles y relevantes de la práctica clínica. Saber qué tan probable es que un paciente fallezca, y en cuánto tiempo, ayuda a la toma de decisiones como la intensidad del tratamiento, la asignación de terapia intensiva, la transición a cuidados paliativos y la comunicación con el paciente y su familia. Por lo general, el pronóstico se basa en el juicio del médico, que puede variar entre profesionales.

Sin embargo, el juicio clínico por sí solo es poco preciso. En un estudio prospectivo con pacientes terminales, Christakis y Lamont (2000) encontraron que solo el 20 % de los pronósticos médicos fueron acertados. El 63 % fueron demasiado optimistas y, en promedio, los médicos sobrestimaron la supervivencia de sus pacientes por un factor de 5.3.

Para abordar este problema se realizó el estudio **SUPPORT** (*Study to Understand Prognoses and Preferences for Outcomes and Risks of Treatments*). Entre 1989 y 1994, el estudio siguió a **9,105 adultos gravemente enfermos** hospitalizados en cinco hospitales universitarios de Estados Unidos. Los pacientes pertenecían a grupos de enfermedades con alta mortalidad, como falla orgánica múltiple, sepsis, insuficiencia cardiaca, enfermedad pulmonar obstructiva crónica, cirrosis, coma y cáncer avanzado. De cada paciente se registraron variables demográficas, comorbilidades, mediciones fisiológicas y de laboratorio al tercer día de hospitalización, y su desenlace. Con estos datos, Knaus et al. (1995) desarrollaron el modelo pronóstico SUPPORT, basado en regresión de Cox, para estimar la supervivencia a 2 y 6 meses. Aunque este modelo fue validado clínicamente, supone que cada variable contribuye al riesgo de forma aditiva y lineal, por lo que no captura de forma natural las relaciones no lineales ni las interacciones complejas entre las variables clínicas.

El aprendizaje automático ofrece una alternativa para superar esta limitación. Los ensambles de árboles, SVM y redes neuronales pueden aprender relaciones no lineales e interacciones directamente de los datos, sin especificarlas de antemano. Sin embargo, esta flexibilidad tiene un costo, pues los modelos más complejos son más propensos al sobreajuste y más difíciles de interpretar, lo cual es una desventaja importante en un contexto clínico, donde el médico necesita entender en qué se basa una predicción antes de actuar sobre ella. Por lo tanto, no es evidente que un modelo más complejo sea mejor.

Por esta razón, los modelos flexibles se comparan con dos clasificadores lineales clásicos, la **regresión logística** y el **Linear Discriminant Analisis** (LDA). Ambos comparten con el modelo SUPPORT el supuesto de que las variables contribuyen al riesgo de forma aditiva, pero a cambio son fáciles de interpretar, pues cada coeficiente indica cómo cambia el riesgo cuando cambia una variable. Si los modelos flexibles no los superan de forma significativa, la ganancia en desempeño no justificaría la pérdida de interpretabilidad. Así, el análisis busca responder qué tan bien puede anticiparse el desenlace de un paciente grave con la información de sus primeros días de hospitalización, y qué modelo ofrece el mejor equilibrio entre desempeño, estabilidad e interpretabilidad para ese propósito.

2. Objetivos

Objetivo general

Desarrollar y comparar seis modelos de clasificación (regresión logística, LDA, Random Forest, Boosting, Support Vector Machine y una red neuronal) para predecir la mortalidad intrahospitalaria y la ventana temporal de fallecimiento de pacientes gravemente enfermos del estudio SUPPORT, seleccionar un modelo final con base en evidencia cuantitativa y cualitativa, y evaluar su desempeño en un conjunto de prueba independiente.

Objetivos específicos

1. **Diseñar un escenario experimental justo y reproducible.** Esto incluye identificar y excluir las variables que causan fuga de información, definir una partición estratificada train-test común a todos los modelos y construir un pipeline de preprocesamiento (imputación, codificación y escalamiento) que se ajuste únicamente con los datos de entrenamiento.
2. **Construir los seis modelos** para la predicción de `hospdead`, describiendo y justificando sus principales hiperparámetros. En el caso de la red neuronal, esto incluye la arquitectura, las funciones de activación, el optimizador, la función de costo y el criterio de *early stopping*.
3. **Comparar el desempeño** de los modelos en validación cruzada con exactitud, precisión, *recall*, F1 y AUC-ROC, y determinar mediante el estadístico F y pruebas t pareadas si las diferencias entre ellos son estadísticamente significativas.
4. **Seleccionar un modelo final** considerando su desempeño, su estabilidad, su interpretabilidad y su coherencia con el problema clínico, y **evaluarlo una sola vez en el conjunto de prueba**, interpretando sus métricas en lenguaje accesible.
5. **Extender el análisis a la predicción de la ventana temporal de fallecimiento** mediante clasificación multiclase con activación *softmax*.
6. **Contextualizar y comunicar los resultados**, comparándolos con las estimaciones del modelo SUPPORT y de los médicos tratantes, y mediante un tablero interactivo que, a partir de las características de un paciente, estime su riesgo y el rango de fechas en que es más probable el desenlace.

3. Descripción del conjunto de datos

En este reporte se utiliza el conjunto de datos **SUPPORT2**, disponible en el UCI Machine Learning Repository, para entrenar y comparar seis modelos de clasificación: dos clasificadores lineales (regresión logística y LDA), dos métodos de ensamble (Random Forest y Boosting), SVM y una red neuronal. La tarea principal es predecir la **mortalidad intrahospitalaria** (`hospdead`) usando solo la información disponible en los primeros días de hospitalización. A partir de la comparación se selecciona un modelo final, que se evalúa en un conjunto de prueba independiente. Como extensión, se predice la **ventana de tiempo** en la que ocurre el fallecimiento, planteada como un problema de clasificación multiclase.

El conjunto de datos plantea tres retos metodológicos que determinan el diseño del análisis:

- **Fuga de datos.** Varias variables, como la duración de la estancia, los días de seguimiento y los costos hospitalarios, solo se conocen después del desenlace. Por eso deben excluirse de los predictores.
- **Valores faltantes reales**, propios de los registros clínicos, que deben imputarse sin contaminar el conjunto de prueba.
- **Tipos de variables heterogéneos** (numéricas, binarias, nominales y ordinales), que requieren un preprocesamiento diferenciado.

```
Pacientes: 9105 | Columnas: 47
```

3.1 Población del estudio

Como se mencionó anteriormente, el estudio SUPPORT incluyó a 9,105 adultos hospitalizados con alguna enfermedad grave, clasificada en ocho grupos en la variable `dzgroup` . Las mediciones fisiológicas y de laboratorio corresponden al **tercer día desde el ingreso al estudio** (Knaus et al., 1995). Por lo tanto, la predicción se plantea como la que haría un médico en ese momento, con base a ello, se plantea lo siguiente: "Con la información clínica de los primeros días, ¿qué tan probable es que el paciente fallezca durante la hospitalización y en qué horizonte de tiempo?"

La Tabla 3.1 muestra el tamaño de cada grupo de enfermedad y su mortalidad intrahospitalaria.

Tabla 3.1. Pacientes y mortalidad intrahospitalaria por grupo de enfermedad

Grupo de enfermedad	Pacientes	% de la muestra	Mortalidad intrahospitalaria (%)
Coma	596	6.5	60.7
Falla orgánica múltiple con cáncer	712	7.8	52.7
Falla respiratoria/orgánica con sepsis	3,515	38.6	33.7
Cirrosis	508	5.6	23.2
Cáncer de pulmón	908	10.0	11.2
EPOC	967	10.6	10.7
Insuficiencia cardiaca	1,387	15.2	6.3
Cáncer de colon	512	5.6	5.7

Los grupos de enfermedad tienen tamaños muy desiguales. La falla respiratoria u orgánica con sepsis concentra el 38.6 % de la muestra (3,515 pacientes), mientras que la cirrosis y el cáncer de colon representan cada uno el 5.6 %. Aun así, todos los grupos superan los 500 pacientes, un tamaño suficiente para analizarlos y trabajar con ellos.

La mortalidad intrahospitalaria también varía de forma marcada entre enfermedades, se observa que va del 60.7 % en los pacientes en coma al 5.7 % en los pacientes con cáncer de colon, una diferencia de más de diez veces. Esta heterogeneidad justifica incluir `dzgroup` como predictor y conservar la proporción de cada enfermedad al dividir los datos (sección 4.1). Sin embargo, un modelo que solo aprendiera la mortalidad promedio de cada grupo ya tendría cierta capacidad predictiva sin aportar información clínica nueva. Lo que nos interesa evaluar en este estudio es si los modelos distinguen el riesgo **dentro** de cada enfermedad a partir del estado clínico del paciente despues de la evaluación médica.

3.2 Variables

El conjunto de datos tiene 47 columnas, agrupadas en la Tabla 3.2 según su contenido. Tipos: **C** = numérica continua, **D** = numérica discreta, **B** = binaria, **N** = categórica nominal, **O** = categórica ordinal.

Tabla 3.2. Variables del conjunto de datos SUPPORT2, tipo y uso en el análisis

Grupo	Variables (tipo)	Uso
Demográficas	`age` (C), `sex` (N), `race` (N), `edu` (D), `income` (O)	Predictores
Enfermedad y comorbilidades	`dzgroup` (N), `num.co` (D), `diabetes` (B), `dementia` (B), `ca` (O)	Predictores
Escalas clínicas (día 3)	`scoma` (D), `sps` (C), `aps` (C), `adlsc` (C), `hday` (D)	Predictores

Grupo	Variables (tipo)	Uso
Signos vitales (día 3)	`meanbp` , `hrt` , `resp` , `temp` (C)	Predictores
Laboratorio (día 3)	`wblc` , `pafi` , `alb` , `bili` , `crea` , `sod` , `ph` , `glucose` , `bun` , `urine` (C)	Predictores
Órdenes médicas	`dnr` (N)	Predictor transformado (sección 3.5)
Pronósticos (día 3)	`prg2m` , `prg6m` (médico); `surv2m` , `surv6m` (modelo SUPPORT) (C, 0–1)	Excluidas de los predictores; referencia externa (sección 10)
Desenlace clinico	`hospdead` (B) / `death` (B), `d.time` (D)	Objetivo principal / construcción de la ventana temporal
Posteriores al día 3	`slos` , `sfdm2` , `charges` , `totcst` , `totmcst` , `avtisst` , `dnrday`	Excluidas (fuga de datos)
Redundantes	`dzclass` , `adlp` , `adls`	Excluidas

Abreviaturas:

- `scoma` : escala de coma basada en la escala de Glasgow.
- `sps` y `aps` : puntajes fisiológicos de SUPPORT y de APACHE III.
- `adlsc` : índice calibrado de actividades de la vida diaria.
- `hday` : día de hospitalización en que el paciente ingresó al estudio.
- `pafi` : relación PaO_2/FiO_2, un indicador de la oxigenación.
- `prg` y `surv` : probabilidades de supervivencia a 2 y 6 meses.

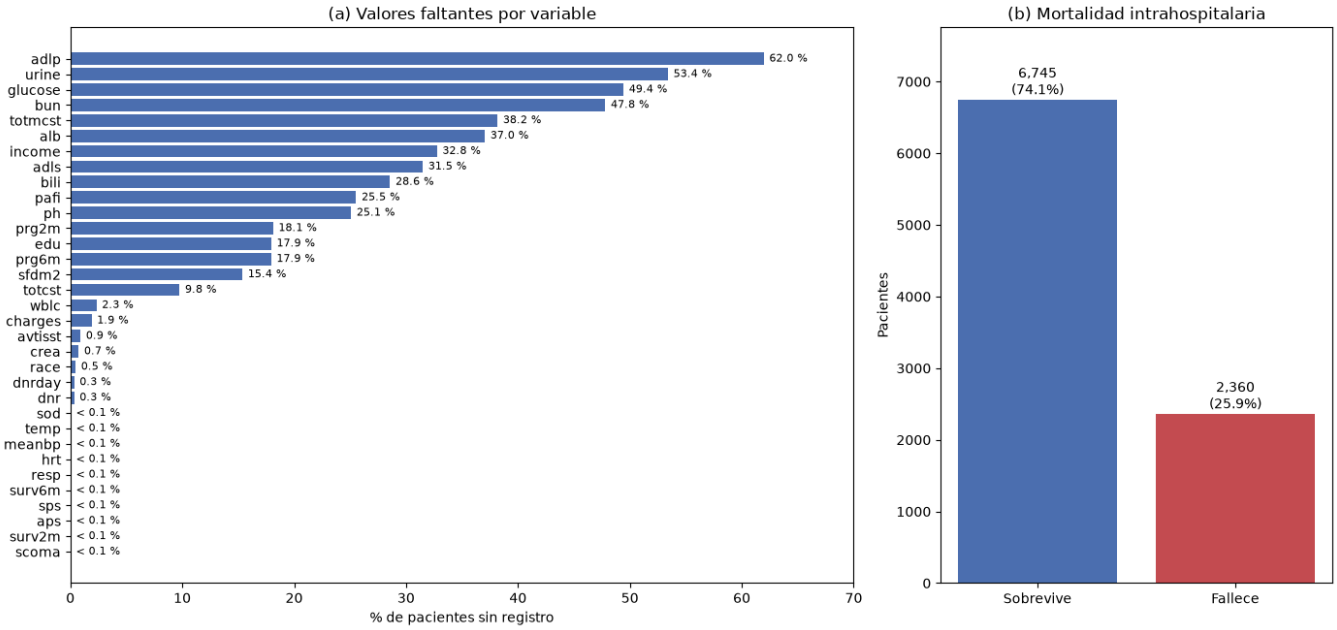
3.3 Verificación de calidad

La ficha del repositorio UCI indica que el conjunto de datos no tiene valores faltantes. Sin embargo, en los registros clínicos es habitual que no a todos los pacientes se les realicen todos los estudios de laboratorio, por lo que se verificó la integridad de los datos de forma independiente. La Tabla 3.3 resume la estructura del conjunto. La Figura 3.1 muestra el porcentaje de valores faltantes por variable (a) y el balance de la variable objetivo (b).

Tabla 3.3. Resumen de la verificación de calidad

	Valor
Pacientes	9,105
Columnas	47
Registros duplicados	0
Columnas numéricas	39
Columnas de texto	8
Columnas con valores faltantes	33

Figura 3.1. Valores faltantes por variable y balance de la variable objetivo



Tras el analísis, se concluye que no hay registros duplicados. De las 47 columnas, 39 son numéricas y 8 son de texto. Estas últimas corresponden a las variables categóricas y deberán codificarse según sean nominales u ordinales.

Valores faltantes.

Contrario a lo que indica la ficha del repositorio, 33 columnas tienen al menos un valor faltante. En la mayoría la proporción es mínima, pero varios estudios de laboratorio no se registraron en una fracción importante de los pacientes, por ejemplo el gasto urinario (`urine` , 53.4 %), la glucosa (`glucose` , 49.4 %), el nitrógeno ureico (`bun` , 47.8 %) y la albúmina (`alb` , 37.0 %). También faltan en una proporción considerable el ingreso (`income` , 32.8 %) y la escolaridad (`edu` , 17.9 %). Las variables con más faltantes de toda la tabla (`adlp` , `totmcst` , `adls` , `sfdm2`) no requieren tratamiento, porque serán excluidas del análisis posteriormente.

Balance de clases.

El 25.9 % de los pacientes (2,360) falleció durante la hospitalización y el 74.1 % (6,745) fue dado de alta con vida (Figura 3.1b). El desbalance es moderado, aproximadamente 3 a 1. Por lo tanto, la exactitud no basta como métrica de desempeño, pues un clasificador que siempre predijera "sobrevive" alcanzaría una exactitud del 74.1 % sin detectar un solo fallecimiento. Por esta razón, la evaluación se centra en *recall*, F1 y AUC-ROC, y la partición train-test se realiza de forma estratificada.

También es importante mencionar que el hecho de que un estudio de laboratorio no se registre no siempre es aleatorio, puede reflejar una decisión clínica. Para evaluarlo, la Tabla 3.4 compara la mortalidad intrahospitalaria entre los pacientes con y sin registro de cada variable que tiene más del 2 % de faltantes y que se usa como predictor.

Tabla 3.4. Mortalidad intrahospitalaria según si la variable fue registrada

Variable	% faltante	Mortalidad sin registro (%)	Mortalidad con registro (%)	Diferencia (pp)
wblc	2.3	13.7	26.2	-12.5
pafi	25.5	17.1	28.9	-11.8
ph	25.1	17.2	28.8	-11.6
bili	28.6	24.3	26.6	-2.2
alb	37.0	26.0	25.9	0.1
bun	47.8	26.6	25.3	1.4
urine	53.4	26.6	25.1	1.4
glucose	49.4	26.7	25.1	1.6
income	32.8	30.0	23.9	6.1
edu	17.9	37.5	23.4	14.1

La Tabla 3.4 muestra tres comportamientos distintos:

- **El % faltante que se asocia con menor mortalidad.** Los pacientes sin registro de leucocitos (`wblc`), relación PaO_2/FiO_2 (`pafi`) o pH arterial (`ph`) tienen una mortalidad entre 11.6 y 12.5 puntos porcentuales menor que los que sí tienen registro. Esto es consistente con que estos estudios, en particular la gasometría arterial, se solicitan sobre todo a los pacientes más graves. Su ausencia indica, por sí misma, que el dato proviene de un paciente más estable.
- **El % faltante que se asocia con mayor mortalidad.** Los pacientes sin registro de escolaridad (`edu`) o de ingreso (`income`) tienen una mortalidad 14.1 y 6.1 puntos porcentuales mayor, respectivamente. Como son datos que se obtienen por entrevista, esto es consistente con que los pacientes más graves que no pudieron responderla.
- **El % faltante que no es informativo.** En la bilirrubina, la albúmina, el nitrógeno ureico, el gasto urinario y la glucosa, la diferencia es menor a 2.5 puntos porcentuales, a pesar de que en algunas de ellas falta casi la mitad de los registros.

Por lo tanto, la estrategia de imputación no puede ser la misma para todas las variables. En las variables con faltantes informativos, la ausencia del dato contiene información sobre el desenlace que no debe perderse al imputar. Esta relación determinará el diseño del preprocesamiento de la sección 4.

3.4 Definición de las variables objetivo

3.4.1 Mortalidad intrahospitalaria (`hospdead`)

La variable objetivo principal es `hospdead`, que vale 1 si el paciente falleció durante la hospitalización y 0 si fue dado de alta con vida. Es una variable categórica binaria y se usa tal como viene en el conjunto de datos. Su distribución se muestra en la Figura 3.1b.

El problema se plantea como una tarea de clasificación por tres razones. Primero, el desenlace es un evento categórico, pues el paciente fallece o sobrevive a la hospitalización. Segundo, la decisión clínica que se busca apoyar también es categórica, pues consiste en identificar a los pacientes en riesgo para intensificar su vigilancia o iniciar la planeación de sus cuidados. Tercero, los clasificadores no solo asignan una clase, también estiman la probabilidad de fallecimiento, lo que permite ordenar a los pacientes según su riesgo y ajustar el umbral de alerta a las prioridades clínicas.

3.4.2 Ventana temporal de fallecimiento

Para la extensión multiclase se construye una nueva variable a partir de `death` (si el paciente falleció en algún momento del seguimiento) y `d.time` (días desde el ingreso al estudio hasta la muerte o hasta el último contacto). Estas dos variables solo se usan para construir la variable objetivo y nunca como predictores.

Predecir el número exacto de días hasta la muerte sería un problema de regresión, pero tiene dos dificultades. Por un lado, en los pacientes que seguían vivos al terminar el seguimiento, `d.time` no es un tiempo de muerte. Por otro, la precisión al día no es clínicamente necesaria, pues las decisiones se organizan, generalmente por rangos, tales como "el primer mes", "los seis meses" y "el año". Agrupar el tiempo en ventanas convierte la pregunta "¿cuándo?" en un problema de clasificación multiclase.

La construcción de los modelosdebe considerar el desconocimiento. Si un paciente seguía vivo al terminar el seguimiento, `d.time` indica el último día en que se supo de él, no el día de su muerte. Por ejemplo, un sobreviviente con 200 días de seguimiento no puede asignarse a la clase "sobrevive más de un año", porque se desconoce qué ocurrió después. Para elegir un horizonte sin desconocimiento, la Tabla 3.5 compara el tiempo hasta la muerte de los fallecidos con el tiempo de seguimiento de los sobrevivientes.

Tabla 3.5. Tiempo hasta la muerte y tiempo de seguimiento (días)

	Pacientes	Mínimo	P25	Mediana	P75	Máximo	Seguimiento < 365 días
Fallecidos (días hasta la muerte)	6,201	3	14	58	252	1,944	—
Sobrevivientes (días de seguimiento)	2,904	344	622	918	1,543	2,029	65

El seguimiento de los sobrevivientes es largo, pues el mínimo es de 344 días y la mediana de 918. Solo 65 sobrevivientes tienen menos de un año de seguimiento. Por lo tanto, un horizonte de un año prácticamente no tiene seguimiento de datos, y esos 65 pacientes se excluyen únicamente de la tarea multiclase.

Entre los 6,201 pacientes que fallecieron, la mediana del tiempo hasta la muerte fue de 58 días y el 25 % falleció en los primeros 14 días. Es decir, una parte importante de las muertes ocurre muy cerca del ingreso.

Con base en esto, se definen cuatro ventanas temporales:

- Muerte en los primeros 30 días (mortalidad a corto plazo).
- Muerte entre los días 31 y 180 (mediano plazo, que coincide con el horizonte de seis meses del modelo SUPPORT).
- Muerte entre los días 181 y 365.
- Supervivencia mayor a un año.

La Tabla 3.6 muestra la distribución resultante y la Tabla 3.7 su relación con `hospdead`.

Tabla 3.6. Distribución de la ventana temporal de fallecimiento

Ventana	Pacientes	%
Muerte ≤ 30 días	2,463	27.2
Muerte 31–180 días	1,802	19.9
Muerte 181–365 días	778	8.6
Sobrevive > 1 año	3,997	44.2
Total	9,040	100.0

Los 9,040 pacientes con ventana definida se distribuyen de forma desigual (Tabla 3.6). La supervivencia mayor a un año es la clase más frecuente (44.2 %), seguida de la muerte en los primeros 30 días (27.2 %) y despues por la muerte entre los 31 primeros días y los 6 meses. La muerte entre los días 181 y 365 es la

clase minoritaria (8.6 %) y, por lo tanto, la más difícil de predecir. Por esta razón, en la tarea multiclase se reportará el F1 de cada clase y no solo la exactitud global.

Tabla 3.7. Relación entre la mortalidad intrahospitalaria y la ventana temporal

Ventana hospdead	Muerte ≤ 30 días	Muerte 31–180 días	Muerte 181–365 días	Sobrevive > 1 año	Total
Fallece en el hospital	2,031	327	2	0	2,360
Sobrevive a la hospitalización	432	1,475	776	3,997	6,680
Total	2,463	1,802	778	3,997	9,040

La Tabla 3.7 muestra que las dos variables objetivo son complementarias y no redundantes:

- De los 2,360 pacientes que fallecieron en el hospital, 2,031 lo hicieron en los primeros 30 días y 329 después, en hospitalizaciones prolongadas.
- 432 pacientes fueron dados de alta con vida, pero fallecieron dentro de los primeros 30 días. `hospdead` los clasifica como sobrevivientes. Las ventanas temporales sí identifican que su riesgo era alto.

3.5 Variables excluidas por data leakage

Los modelos deben predecir el desenlace con la información disponible alrededor del tercer día de hospitalización. Cualquier variable que se registre después de ese momento, o que dependa del desenlace, produce fuga de datos, pues el modelo aprendería a "leer" el resultado en lugar de predecirlo. Tendría un desempeño artificialmente alto en la evaluación, pero sería inútil con un paciente nuevo. Por este motivo se excluyen las variables de la Tabla 3.8.

Tabla 3.8. Variables excluidas por fuga de información

Variable	Motivo de exclusión
`slos`	La duración de la estancia solo se conoce al alta o al fallecimiento.
`d.time` , `death`	Son información de seguimiento posterior al alta; solo se usan para construir la ventana temporal.
`sfdm2`	Describe el estado funcional a los dos meses, es decir, un desenlace.
`charges` , `totcst` , `totmcst`	Son costos acumulados durante toda la estancia, que dependen de su duración y de su desenlace.
`avtisst`	Promedia la intensidad del tratamiento de los días 3 a 25, por lo que incluye información futura.
`dnrday`	Las órdenes de no reanimar suelen darse poco antes de la muerte, así que su fecha anticipa el desenlace.

Variable	Motivo de exclusión
`dnr` (categoría "después del ingreso")	Por el mismo motivo, solo se conserva la información de si la orden existía **antes** del ingreso al estudio, como variable binaria `dnr_previo`.

El caso de `slos` ilustra la magnitud del problema. La Tabla 3.9 compara, para los pacientes que fallecieron en el hospital y para los que sobrevivieron, la proporción en la que la duración de la estancia coincide con los días de seguimiento.

Tabla 3.9. Coincidencia entre la duración de la estancia (slos) y los días de seguimiento (d.time)

Grupo	Pacientes	Pacientes con slos = d.time (%)
Fallece en el hospital	2,360	100.0
Sobrevive a la hospitalización	6,745	0.0

La duración de la estancia coincide con los días de seguimiento en el **100 %** de los pacientes que fallecieron en el hospital y en el **0 %** de los que sobrevivieron. La regla "si `slos` = `d.time`, el paciente murió en el hospital" clasifica correctamente a los 9,105 pacientes sin usar ninguna información clínica. Un modelo que recibiera estas variables alcanzaría un desempeño perfecto, pero sin ningún valor práctico, porque al tercer día de hospitalización ninguna de las dos se conoce todavía.

Además de las variables con fuga de información, se excluyen tres variables redundantes:

- **`dzclass`:** es una agrupación de `dzgroup`, por lo que no aporta información nueva.
- **`adlp` y `adls`:** son las variables con más valores faltantes (62.0 % y 31.5 %, Figura 3.1a), y su información ya está contenida en `adlsc`, la versión calibrada del índice de actividades de la vida diaria.

Por último, las estimaciones pronósticas `prg2m`, `prg6m`, `surv2m` y `surv6m` sí están disponibles al tercer día de hospitalización, así que no constituyen fuga de información. Sin embargo, no son mediciones clínicas del paciente, sino predicciones del médico y del modelo SUPPORT. Incluirlas mezclaría el desempeño de los modelos con el de esas fuentes externas. Como el objetivo es evaluar qué tanto pueden predecir los modelos a partir del estado clínico, se excluyen de los predictores. No obstante, se conservan por separado para comparar, en la sección 10, el desempeño del modelo final con el del modelo SUPPORT.

Con estas decisiones, el conjunto de predictores clínicos queda conformado como se muestra en la Tabla 3.10.

Tabla 3.10. Predictores clínicos finales por tipo de variable

Tipo	Número	Variables
Numéricas	22	age, num.co, edu, scoma, sps, aps, hday, meanbp, wblc, hrt, resp, temp, pafi, alb, bili, crea, sod, ph, glucose, bun, urine, adlsc
Binarias	3	diabetes, dementia, dnr_previo
Categóricas nominales	3	sex, race, dzgroup
Categóricas ordinales	2	income, ca
Total	30	

El análisis se realiza con 30 predictores clínicos, todos disponibles al tercer día de hospitalización: 22 numéricas, 3 binarias, 3 categóricas nominales y 2 categóricas ordinales. La heterogeneidad de tipos y los patrones de valores faltantes identificados en la Tabla 3.4 determinan el preprocesamiento que se describe en la sección 4.

4. Preparación del escenario experimental

Para que la comparación entre modelos sea justa, los seis clasificadores se entrenan y evalúan bajo exactamente las mismas condiciones: la misma partición de los pacientes en entrenamiento y prueba, el mismo preprocesamiento de las variables, el mismo esquema de validación cruzada y las mismas métricas. Así, cualquier diferencia de desempeño entre modelos se puede atribuir al modelo y no a diferencias en los datos que recibió.

4.1 Partición train-test

Los 9,105 pacientes se dividen una sola vez en un conjunto de **entrenamiento (80 %)** y un conjunto de **prueba (20 %)**. Esta partición es la única que se usa en todo el análisis, tanto para la tarea principal (`hospdead`) como para la extensión multiclase (ventana temporal).

La partición se **estratifica simultáneamente por grupo de enfermedad y por desenlace**. Es decir, cada combinación de enfermedad y desenlace (por ejemplo, "cirrosis, fallece en el hospital") conserva la misma proporción en ambos conjuntos. Estratificar solo por `hospdead` garantizaría la misma mortalidad global, pero no que cada enfermedad esté igualmente representada en el conjunto de prueba. Como la mortalidad varía hasta diez veces entre enfermedades (Tabla 3.1), un desbalance en su representación podría hacer que el conjunto de prueba fuera artificialmente más fácil o más difícil que la población.

Tabla 4.1. Tamaño y composición de los conjuntos de entrenamiento y prueba

Conjunto	Pacientes	% del total	Mortalidad intrahospitalaria (%)	Pacientes con ventana definida
Entrenamiento	7,284	80.0	25.9	7,228
Prueba	1,821	20.0	25.9	1,812

El conjunto de entrenamiento tiene 7,284 pacientes y el de prueba 1,821 (Tabla 4.1). La mortalidad intrahospitalaria es del 25.9 % en ambos, igual a la de la muestra completa (Figura 3.1b). Para la tarea multiclase quedan 7,228 pacientes en entrenamiento y 1,812 en prueba, una vez excluidos los 65 pacientes censurados (sección 3.4.2).

Tabla 4.2. Grupos de enfermedad y su mortalidad intrahospitalaria en cada conjunto

Grupo de enfermedad	Pacientes (entrenamiento)	Pacientes (prueba)	Mortalidad en entrenamiento (%)	Mortalidad en prueba (%)
Coma	477	119	60.8	60.5
Falla orgánica múltiple con cáncer	570	142	52.6	52.8
Falla respiratoria/orgánica con sepsis	2,812	703	33.7	33.7
Cirrosis	406	102	23.2	23.5
Cáncer de pulmón	727	181	11.3	11.0
EPOC	773	194	10.6	10.8
Insuficiencia cardiaca	1,110	277	6.3	6.1
Cáncer de colon	409	103	5.6	5.8

Tabla 4.3. Distribución de la ventana temporal de fallecimiento en cada conjunto

Ventana	Entrenamiento (%)	Prueba (%)	Diferencia (pp)
Muerte ≤ 30 días	27.5	26.2	1.3
Muerte 31–180 días	19.5	21.6	-2.1
Muerte 181–365 días	8.4	9.3	-0.9
Sobrevive > 1 año	44.5	42.9	1.7

La estratificación conserva la composición de la muestra en los tres niveles relevantes para el análisis:

- **Por enfermedad (Tabla 4.2):** la mortalidad de cada grupo difiere menos de medio punto porcentual entre entrenamiento y prueba, y cada grupo conserva el 80 % de sus pacientes en entrenamiento.
- **Por ventana temporal (Tabla 4.3):** la partición no se estratificó por esta variable, por lo que sus proporciones varían ligeramente entre conjuntos. La mayor diferencia es de 2.1 puntos porcentuales, en la ventana de 31 a 180 días (19.5 % en entrenamiento y 21.6 % en prueba). Las cuatro clases conservan el mismo orden de frecuencia en ambos conjuntos, y la clase minoritaria (muerte entre 181 y 365 días) mantiene una proporción similar (8.4 % y 9.3 %). Estas diferencias no comprometen la evaluación de la tarea multiclase, porque se reporta el F1 de cada clase por separado.
- **Global:** la proporción de fallecimientos es idéntica en los dos conjuntos.

Por lo tanto, el conjunto de prueba es representativo de la población completa en las dos tareas.

4.2 Preprocesamiento

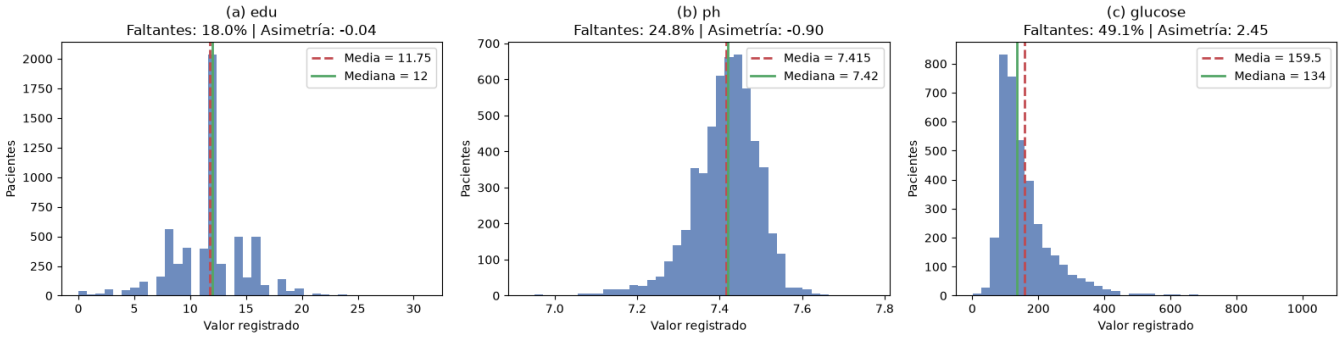
El preprocesamiento responde a los dos retos identificados en la sección 3 debido a los valores faltantes, que en algunas variables son informativos (Tabla 3.4), y la heterogeneidad de tipos de variables (Tabla 3.10).

Imputación de datos

- **Laboratorios con valor de referencia.** Para siete estudios de laboratorio (`alb` , `pafi` , `bili` , `crea` , `bun` , `wblc` y `urine`), los autores del conjunto de datos recomiendan imputar un valor fisiológico normal (Harrell, 1995), porque si un estudio no se solicitó, lo más probable es que el médico no esperara un valor anormal. Estos valores son fijos y provienen de la documentación del estudio, no de los datos, así que no aprenden nada del conjunto de prueba.
- **Resto de variables numéricas y ordinales.** Se imputan con la mediana del conjunto de entrenamiento, que es robusta ante las distribuciones asimétricas de las variables clínicas.
- **Variables nominales.** Se imputan con la moda del conjunto de entrenamiento. Solo `race` tiene faltantes, en 42 pacientes.

La Figura 4.1 muestra la distribución, en el conjunto de entrenamiento, de las variables numéricas imputadas con la mediana que tienen valores faltantes, junto con su media y su mediana.

Figura 4.1. Distribución de las variables numéricas imputadas con la mediana (conjunto de entrenamiento)



Indicadores de faltante informativo.

La imputación sustituye el valor ausente, pero también borra la información de que estaba ausente. Para las cinco variables en las que la Tabla 3.4 mostró una diferencia de mortalidad mayor a 5 puntos porcentuales entre pacientes con y sin registro (`wblc` , `pafi` , `ph` , `edu` e `income`), se agrega una variable binaria que vale 1 cuando el dato no estaba registrado. Así, los modelos pueden aprovechar la ausencia del dato como señal clínica.

Transformación de variables

- **Variables ordinales.** `income` y `ca` se codifican como enteros que respetan su orden natural, de menor a mayor ingreso, y de sin cáncer a cáncer metastásico.
- **Variables nominales.** `sex` , `race` y `dzgroup` se codifican con one-hot encoding, porque sus categorías no tienen orden. `sex` , al ser binaria, se representa con una sola columna.

Escalamiento.

Las variables numéricas y ordinales se estandarizan, con media 0 y desviación estándar 1, usando la media y la desviación estándar del conjunto de entrenamiento. El escalamiento es indispensable para tres de los modelos:

- **SVM:** clasifica a partir de distancias entre observaciones mediante *kernel*, así que una variable con valores grandes dominaría la distancia.
- **Red neuronal:** su entrenamiento por gradiente descendiente converge mal cuando las variables tienen escalas muy distintas.
- **Regresión logística:** la regularización penaliza la magnitud de los coeficientes, por lo que solo trata a todas las variables por igual si están en la misma escala. Además, con variables estandarizadas sus coeficientes se pueden comparar entre sí.

LDA y los modelos basados en árboles no dependen de la escala de las variables. LDA porque su frontera de decisión no cambia ante transformaciones lineales de los predictores, y los árboles porque dividen por umbrales. Aun así, se les aplica el mismo preprocesamiento para que los seis modelos reciban exactamente la misma información.

La Tabla 4.4 resume la estrategia para cada grupo de variables.

Tabla 4.4. Estrategia de preprocesamiento por grupo de variables

Grupo	Variables	Imputación	Transformación
Laboratorio con valor de referencia	alb, pafi, bili, crea, bun, wblc, urine	Valor fisiológico normal	Estandarización
Numéricas restantes	age, num.co, edu, scoma, sps, aps, hday, meanbp, hrt, resp, temp, sod, ph, glucose, adlsc	Mediana de entrenamiento	Estandarización
Ordinales	income, ca	Mediana de entrenamiento	Codificación ordinal + estandarización
Nominales	sex, race, dzgroup	Moda de entrenamiento	One-hot
Binarias	diabetes, dementia, dnr_previo	No requiere	Ninguna
Faltante informativo	wblc, pafi, ph, edu, income	—	Indicador binario de faltante (1 = sin registro)

4.3 Verificación de la adecuación del conjunto de datos

Para confirmar que los datos son adecuados para los seis modelos, el preprocesamiento se ajusta con el conjunto de entrenamiento y se aplica a ambos conjuntos. La Tabla 4.5 verifica el resultado.

Tabla 4.5. Verificación de las matrices de entrenamiento y prueba procesadas

Verificación	Entrenamiento	Prueba
Pacientes	7,284	1,821
Variables tras el preprocesamiento	46	46
Valores faltantes	0	0
Variables no numéricas	0	0
Máximo |media| de las variables estandarizadas	0.000	0.041
Desviación estándar promedio de las variables estandarizadas	1.000	1.015

Los 30 predictores clínicos se transforman en **46 variables**:

- 22 numéricas y 2 ordinales, estandarizadas.
- 14 columnas one-hot encoding: 1 de sexo, 5 de raza y 8 de grupo de enfermedad.
- 3 variables binarias.
- 5 indicadores de faltante.

Ninguna de las dos matrices tiene valores faltantes ni variables no numéricas (Tabla 4.5).

La verificación del escalamiento también confirma que el preprocesamiento se ajustó solo con el conjunto de entrenamiento. En entrenamiento, las variables estandarizadas tienen media 0 y desviación estándar 1 exactas. En prueba, se desvían ligeramente (media de hasta 0.041 en valor absoluto y desviación estándar promedio de 1.015), porque se transformaron con los parámetros aprendidos en entrenamiento y no con los suyos propios.

En cuanto al tamaño, el conjunto de entrenamiento tiene más de 150 pacientes por variable (7,284 pacientes para 46 variables). A diferencia de los escenarios con más variables que observaciones, esta proporción permite entrenar modelos flexibles, como los ensambles y la red neuronal, con un riesgo de sobreajuste controlable. También es suficiente para los modelos lineales. En la regresión logística, la regla habitual es contar con al menos 10 eventos por variable para que los coeficientes se estimen de forma estable (Peduzzi et al., 1996). Con 1,888 fallecimientos en entrenamiento hay 41 eventos por variable, cuatro veces ese mínimo. Junto con el desbalance moderado de clases (Figura 3.1b), esto confirma que el conjunto de datos es adecuado para los seis modelos.

4.4 Validación cruzada

Todas las decisiones de modelado (la elección de hiperparámetros, la comparación entre modelos y la selección del modelo final) se toman exclusivamente con el conjunto de entrenamiento, mediante validación cruzada estratificada de $k = 5$ *folds*. El conjunto de entrenamiento se divide en cinco subconjuntos con la misma proporción de fallecimientos. En cada iteración, el modelo se entrena con cuatro de ellos y se valida con el restante, de modo que cada paciente se usa exactamente una vez para

validación. El desempeño se reporta como la media y la desviación estándar de las cinco iteraciones, pues la media estima el desempeño esperado y la desviación estándar, su estabilidad.

En cada iteración, el preprocesamiento completo de la sección 4.2 se vuelve a ajustar usando solo los cuatro folds de entrenamiento.

Tabla 4.6. Composición de las iteraciones de validación cruzada dentro del conjunto de entrenamiento

Iteración	Pacientes para entrenar	Pacientes para validar	Mortalidad en validación (%)
Fold 1	5,827	1,457	25.9
Fold 2	5,827	1,457	25.9
Fold 3	5,827	1,457	25.9
Fold 4	5,827	1,457	25.9
Fold 5	5,828	1,456	25.9

En cada iteración se entrena con 5,827 o 5,828 pacientes y se valida con 1,456 o 1,457, y la mortalidad en cada *fold* de validación es del 25.9 %, igual a la del conjunto de entrenamiento (Tabla 4.6). Con alrededor de 377 fallecimientos por *fold*, las métricas de cada iteración se calculan sobre suficientes casos positivos para ser estables.

4.5 Data Leakage

Además de excluir las variables posteriores al desenlace del paciente (sección 3.5), el diseño experimental evita que la información del conjunto de prueba influya, directa o indirectamente, en el entrenamiento o en la selección de los modelos. Para ello se aplican las siguientes medidas:

1. **Partición única y previa.** El conjunto de prueba se separa antes de cualquier ajuste y solo se usa una vez, en la evaluación del modelo final (sección 8).
2. **Parámetros aprendidos solo en entrenamiento.** Las medianas, las modas y los parámetros de estandarización se calculan con el conjunto de entrenamiento y se aplican sin modificar al de prueba (Tabla 4.5).
3. **Preprocesamiento dentro de cada *fold*.** En la validación cruzada, el preprocesamiento se integra con el modelo en un mismo *pipeline*, que se ajusta de nuevo en cada iteración. Así, el *fold* de validación tampoco contamina la imputación ni el escalamiento.
4. **Selección de modelos sin el conjunto de prueba.** Los hiperparámetros, la arquitectura de la red neuronal, el criterio de *early stopping* y la elección del modelo final se definen con validación cruzada o con una fracción de validación tomada del conjunto de entrenamiento, nunca con los resultados en prueba. Elegir un modelo porque obtuvo mejores resultados en prueba convertiría a ese conjunto en parte del entrenamiento e inflaría artificialmente el desempeño reportado.

5. **Valores de referencia externos.** Los valores fisiológicos normales usados en la imputación provienen de la documentación del estudio, no de los datos, así que no pueden filtrar información de ningún conjunto.

4.6 Métricas de evaluación

En la tarea principal, la clase positiva es el **fallecimiento intrahospitalario** (`hospdead` = 1). Las métricas se obtienen a partir de la matriz de confusión, verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN).

Las métricas usadas para evaluar los modelos son:

- **Exactitud**
- **Precisión**
- ***Recall* (sensibilidad)**
- **F1**
- **AUC-ROC**

La **AUC-ROC** es la métrica principal de comparación por dos razones. Primero, no depende del umbral de clasificación, así que compara la capacidad de los modelos para distinguir entre pacientes que fallecen y que sobreviven, independientemente de qué tan conservador sea cada uno al clasificar. Segundo, la ponderación de clases (sección 5) desplaza el umbral efectivo de cada modelo de forma distinta, lo que hace que la precisión y el *recall* varíen entre modelos aunque su capacidad de discriminación sea la misma.

En la clasificación multiclase, la precisión, el *recall* y el F1 se calculan para cada ventana temporal. Además, se reporta el **F1 macro**, el promedio simple del F1 de las cuatro clases. A diferencia de la exactitud, el F1 macro da el mismo peso a la clase minoritaria (muerte entre 181 y 365 días, 8.6 %) que a la mayoritaria. Como métrica de discriminación se usa el **AUC macro uno contra el resto**, que calcula el AUC de cada ventana frente a las otras tres y las promedia.

Significancia de las diferencias entre modelos. Una diferencia de AUC entre dos modelos podría deberse solo a qué pacientes quedaron en cada partición de validación. Para distinguir las diferencias reales de las debidas al azar, en la comparación entre modelos (sección 6) la validación cruzada de 5 *folds* se repite cinco veces, con las mismas 25 particiones para los seis modelos, y se aplican dos pruebas de hipótesis con un nivel de significancia de 0.05:

- **Estadístico F**, de un análisis de varianza de medidas repetidas, para probar si los seis modelos tienen el mismo AUC esperado.
- **Pruebas t pareadas** entre cada par de modelos, para identificar cuáles difieren. Se usa la corrección de Nadeau y Bengio (2003), que compensa el hecho de que las particiones comparten pacientes, y el ajuste de Holm por realizar 15 comparaciones.

5. Construcción de modelos

Se entrenan seis modelos para predecir la mortalidad intrahospitalaria (`hospdead`): regresión logística, LDA, Random Forest, Boosting, SVM y una red neuronal. Todos reciben las mismas 46 variables preprocesadas (sección 4.2) y se entrenan únicamente con el conjunto de entrenamiento. Tres decisiones son comunes a los seis modelos.

Ponderación de clases. Con una proporción de aproximadamente 3 sobrevivientes por cada fallecimiento (Figura 3.1b), un modelo que minimiza el error global tiende a favorecer la clase mayoritaria y a pasar por alto a los pacientes que fallecen, que es justamente el error clínicamente más costoso (sección 4.6). Para compensarlo, cada observación se pondera de forma inversamente proporcional a la frecuencia de su clase, de modo que ambas clases contribuyan por igual al entrenamiento. La Tabla 5.1 muestra los pesos resultantes.

Selección de hiperparámetros. No se realiza una búsqueda exhaustiva. Para cada modelo se fijan los hiperparámetros secundarios con criterios teóricos y se compara, con validación cruzada de 5 folds (sección 4.4), un número reducido de valores del hiperparámetro que más controla su complejidad.

Regla de decisión. Diferencias de AUC menores a la variabilidad entre folds no son confiables. Por eso, entre las configuraciones cuyo AUC de validación está a menos de una desviación estándar del mejor, se elige la que tiene menor brecha entre el AUC de entrenamiento y el de validación. Es decir, ante un desempeño equivalente, se prefiere el modelo que menos sobreajusta.

Tabla 5.1. Pesos de clase aplicados en el entrenamiento

Clase	Pacientes en entrenamiento	Peso
Sobrevive (0)	5,396	0.67
Fallece (1)	1,888	1.93

5.1 Regresión logística

La regresión logística estima directamente la probabilidad de que un paciente fallezca a partir de sus variables clínicas. Para ello, asigna a cada variable un peso que indica cuánto aumenta o disminuye el riesgo, suma las contribuciones de todas las variables y transforma el resultado en una probabilidad entre 0 y 1. Cada peso se traduce en una **razón de momios**, es decir, el factor por el que se multiplica la probabilidad relativa de fallecer cuando la variable aumenta.

Es un modelo especialmente útil en este problema por tres razones:

- **Es interpretable.** Cada razón de momios tiene una lectura clínica directa, que el médico puede contrastar con su experiencia.
- **Es el estándar de la predicción clínica.** Comparte con el modelo SUPPORT el supuesto de que las variables contribuyen al riesgo de forma aditiva, así que sirve como punto de referencia, puesto que si los modelos más flexibles no lo superan, su complejidad adicional no se justifica.
- **Es estable con el tamaño de muestra disponible.** Con 47 coeficientes para más de 7,000 pacientes y 41 fallecimientos por variable (sección 4.3), sus estimaciones son confiables y el riesgo de sobreajuste es bajo.

Su limitación es que solo puede representar relaciones aditivas, por lo que si el efecto de una variable dependiera del valor de otra, no lo capturaría a menos que esa interacción se especificara de antemano.

Hiperparámetros fijos:

- **Regularización L2 (*ridge*).** Penaliza los pesos grandes y los encoge hacia cero sin eliminarlos. Esto evita que el modelo dependa en exceso de una sola variable y garantiza una solución única aunque las columnas *one-hot* de `race` y `dzgroup` sean redundantes entre sí (las de cada grupo suman 1).
- **Ponderación de clases** inversa a la frecuencia (Tabla 5.1).

Hiperparámetro comparado: C. Controla qué tan fuerte es la regularización. Un C pequeño encoge mucho los pesos y produce un modelo más simple y conservador; un C grande prácticamente no penaliza y deja que los pesos se ajusten libremente a los datos. La Tabla 5.2 compara cinco valores en escala logarítmica.

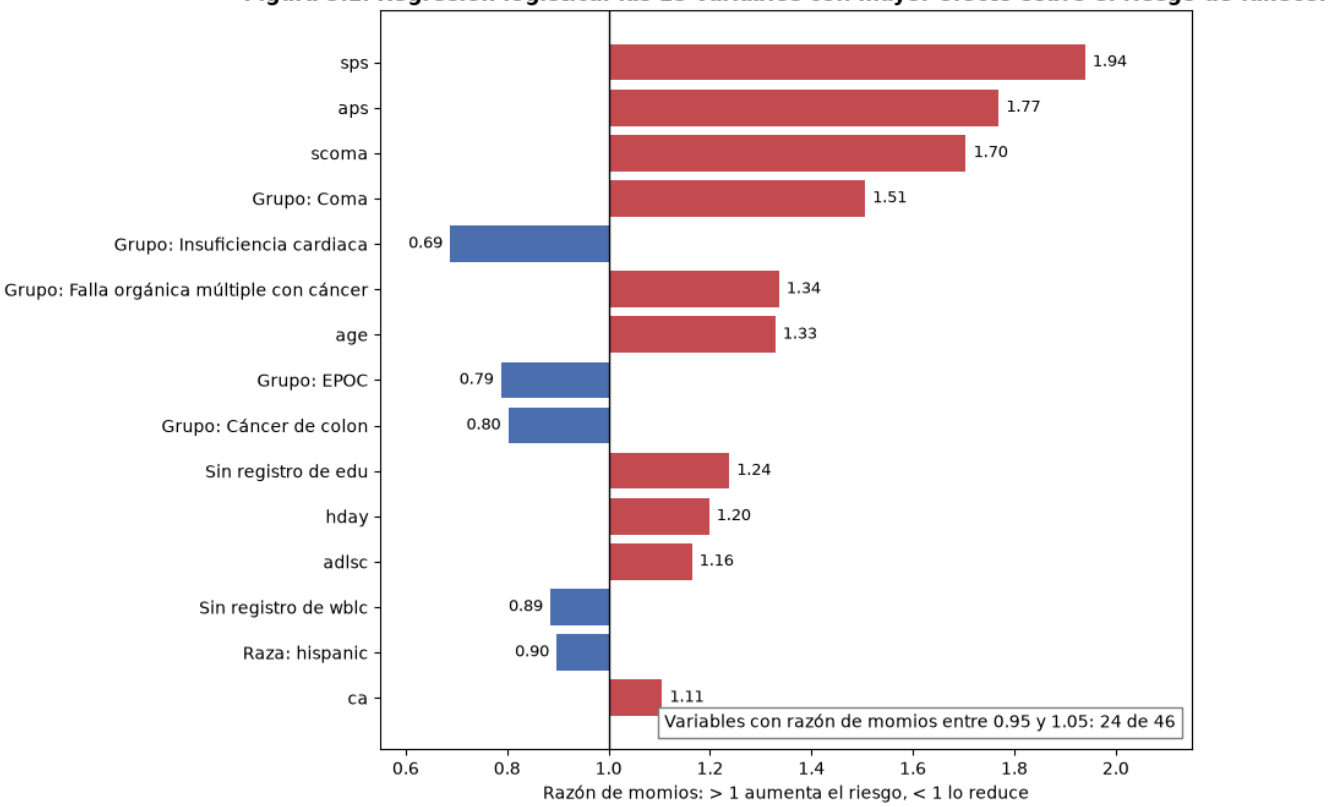
Tabla 5.2. Regresión logística: desempeño en validación cruzada según el parámetro C

C (inverso de la regularización)	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
0.001	0.8557	0.8529	0.0068	0.0028	0.6370	0.7278	0.5664	No
0.01	0.8627	0.8584	0.0061	0.0043	0.6422	0.7495	0.5619	Sí
0.1	0.8657	0.8602	0.0073	0.0055	0.6420	0.7622	0.5547	Sí
1	0.8659	0.8600	0.0077	0.0059	0.6400	0.7611	0.5522	Sí
10	0.8659	0.8598	0.0079	0.0060	0.6409	0.7622	0.5530	Sí

El AUC de validación prácticamente no cambia entre C = 0.01 y C = 10 (0.8584–0.8602), y la brecha entre entrenamiento y validación es menor a 0.007 en todas las configuraciones (Tabla 5.2), la regresión logística casi no tiene capacidad de memorizar a los pacientes de entrenamiento. Solo la regularización más fuerte la perjudica: con C = 0.001, el AUC baja a 0.8529 y el *recall* a 0.728, y queda fuera de una desviación estándar del mejor. Entre las configuraciones restantes, la de menor brecha es C **= 0.01** (0.0043), que es la que se selecciona.

La Figura 5.1 muestra las razones de momios del modelo final para las 15 variables con mayor efecto. Como las variables numéricas están estandarizadas, su razón de momios indica cuánto se multiplican los momios de fallecer por cada desviación estándar que aumenta la variable. En las variables binarias y *one-hot*, indica el efecto de tener esa característica.

Figura 5.1. Regresión logística: las 15 variables con mayor efecto sobre el riesgo de fallecer



La Figura 5.1 permite leer directamente en qué se apoya el modelo:

Los efectos más fuertes corresponden a la gravedad fisiológica y al estado neurológico, cada desviación estándar adicional del puntaje de SUPPORT (`sps`) multiplica los momios de fallecer por 1.94, la del puntaje APACHE III (`aps`) por 1.77 y la de la escala de coma (`scoma`) por 1.70 (Figura 5.1). Le siguen el grupo de enfermedad, que aumenta el riesgo en coma (1.51) y en falla orgánica múltiple con cáncer (1.34) y lo reduce en insuficiencia cardiaca (0.69), EPOC (0.79) y cáncer de colon (0.80), y la edad (1.33). Los indicadores de faltante también intervienen en la dirección que anticipaba la Tabla 3.4: no tener registro de escolaridad aumenta el riesgo (1.24) y no tener registro de leucocitos lo reduce (0.89). En cambio, 24 de las 46 variables modifican el riesgo en menos de 5 %. Como la regularización encoge los pesos, estas razones de momios son conservadoras, es decir, están más cerca de 1 de lo que estarían sin ella.

La regularización encoge los coeficientes hacia cero, así que estas razones de momios son conservadoras, es decir están más cerca de 1 de lo que estarían sin penalización, y como todas las categorías de `dzgroup` y `race` tienen su propia columna, sus razones de momios deben leerse como contribuciones relativas entre grupos y no frente a un grupo de referencia.

5.2 Linear Discriminant Analysis

LDA aborda la clasificación desde la dirección opuesta a la regresión logística. En lugar de estimar directamente la probabilidad de fallecer, primero asigna al paciente típico de cada clase, calcula el perfil promedio de los pacientes que sobreviven y el de los que fallecen, junto con la forma en que las variables varían y se relacionan entre sí. Después, para un paciente nuevo, evalúa a cuál de los dos perfiles se parece más. Si es positivo, el paciente se parece más al perfil de los que fallecen.

Para lograrlo, LDA supone que las variables siguen una distribución normal dentro de cada clase y que ambas clases tienen la misma variabilidad. Con estos supuestos, la frontera entre clases es lineal, igual que en la regresión logística, pero se estima de otra manera.

En este problema, LDA es útil como segundo modelo lineal de referencia:

- **Es igual de sencillo e interpretable** que la regresión logística, y sus pesos indican qué variables separan más a las dos clases.
- **Contrasta dos formas de estimar una frontera lineal.** Cuando sus supuestos se cumplen, LDA aprovecha mejor los datos que la regresión logística. Cuando no se cumplen, como ocurre con las variables binarias, las columnas *one-hot* y los laboratorios asimétricos como la glucosa (Figura 4.1), la regresión logística debería ser más robusta. Comparar ambos modelos permite comprobar cuánto pesa ese incumplimiento.

Hiperparámetros fijos:

- **Probabilidades a priori iguales para ambas clases (0.5 y 0.5).** LDA no admite ponderación de clases, pero cumple la misma función con su probabilidad a priori, es decir, con qué tan frecuente supone que es cada clase antes de ver los datos del paciente. Con probabilidades iguales, la frontera no favorece a la clase mayoritaria, lo que equivale a la ponderación de la Tabla 5.1.
- **Estimación por mínimos cuadrados** (`solver="lsqr"`), que permite regularizar la forma en que el modelo estima las relaciones entre variables.
- Se compara el **encogimiento,** λ, que simplifica la forma en que el modelo estima las relaciones entre las 46 variables: con $\lambda = 0$ se usan tal como se observan en los datos, y conforme λ aumenta, se suavizan. El encogimiento además es necesario porque las columnas *one-hot* son redundantes entre sí y, sin él, la estimación sería inestable.

La Tabla 5.3 compara cuatro valores.

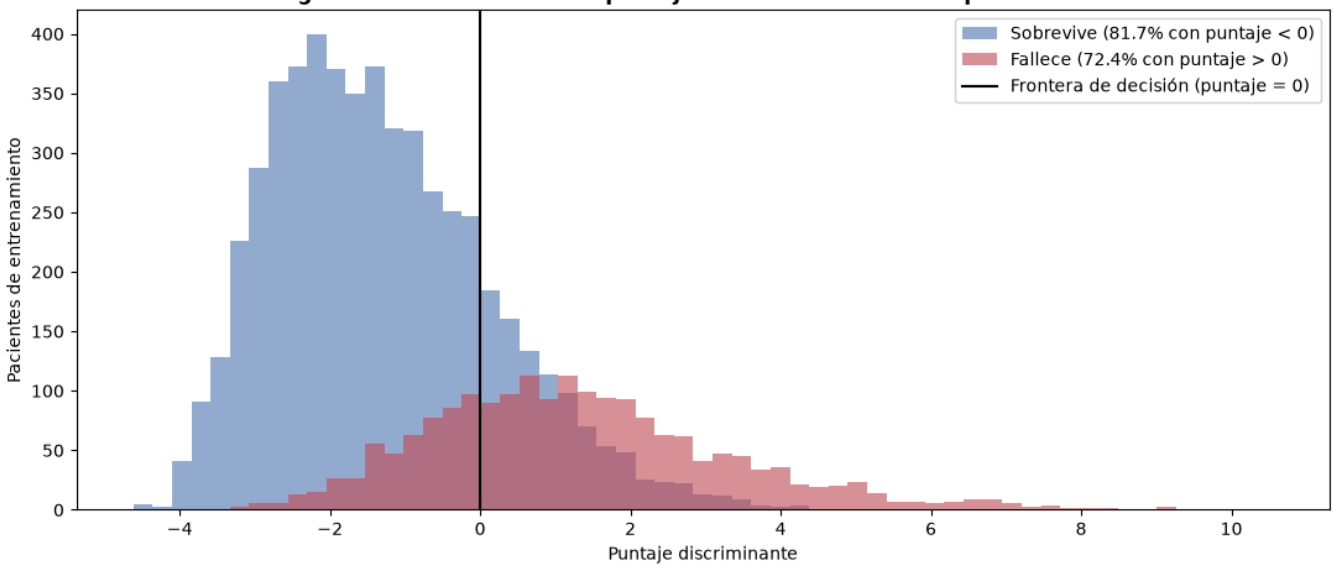
Tabla 5.3. LDA: desempeño en validación cruzada según el encogimiento

Encogimiento (λ)	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
0	0.8619	0.8563	0.0050	0.0056	0.6416	0.7558	0.5576	Sí
0.1	0.8620	0.8576	0.0040	0.0045	0.6432	0.7383	0.5699	Sí
0.3	0.8592	0.8555	0.0045	0.0037	0.6397	0.7182	0.5768	Sí
0.5	0.8566	0.8535	0.0056	0.0031	0.6399	0.7150	0.5791	No

Como en la regresión logística, el AUC de validación varía muy poco (0.8535–0.8576) y la brecha entre entrenamiento y validación es menor a 0.006 en todas las configuraciones (Tabla 5.3). El encogimiento excesivo perjudica al modelo, se observa que con λ = 0.5, el AUC baja a 0.8535 y queda fuera de una desviación estándar del mejor (λ = 0.1, con 0.8576 ± 0.0040). Entre las tres configuraciones restantes, la de menor brecha es λ **= 0.3** (0.0037), que es la que se selecciona.

Como LDA reduce a cada paciente a un solo número, su puntaje discriminante, es posible ver directamente cómo separa a las dos clases (Figura 5.2).

Figura 5.2. Distribución del puntaje discriminante de LDA por desenlace



El 81.7 % de los sobrevivientes queda del lado negativo de la frontera y el 72.4 % de los fallecidos del lado positivo (Figura 5.2). La figura también muestra por qué el supuesto de covarianza común no se cumple del todo. Los sobrevivientes se concentran en una distribución compacta, en torno a −2, mientras que los fallecidos se dispersan mucho más, con una cola larga que llega hasta valores cercanos a 10. Las dos clases no tienen la misma variabilidad. LDA sigue funcionando como clasificador lineal, pero este incumplimiento es una de las razones por las que la regresión logística, que no lo supone, puede ser

preferible. Por último, entre −1 y 2 las dos distribuciones se superponen. Este grupo de pacientes de pronóstico incierto podría repetirse con la SVM (sección 5.5).

5.3 Random Forest

Random Forest es un ensamble de B árboles de decisión. Cada árbol se entrena con un *bootstrap* del conjunto de entrenamiento y, en cada división, solo puede elegir entre un subconjunto aleatorio de m de los p predictores. Esta restricción reduce la correlación entre los árboles: si todos pudieran usar siempre el predictor más fuerte, serían casi idénticos y promediarlos aportaría poco. La predicción final es el voto mayoritario de los B árboles.

Hiperparámetros fijos:

- **Número de árboles, B = 500.** Aumentar B no produce sobreajuste; solo estabiliza el voto. Con 500 árboles el voto ya es estable y el costo computacional sigue siendo bajo.
- **Predictores por división, $m = \sqrt{p}$.** Es el valor estándar para clasificación. Con p = 46, cada división considera 6 predictores.

El hiperparámetro comparado es el mínimo de observaciones por hoja (`min_samples_leaf`). Controla qué tan profundo crece cada árbol. Con un mínimo de 1, cada árbol crece hasta aislar pacientes individuales y memoriza el conjunto de entrenamiento. Valores mayores producen árboles más simples, con un efecto equivalente al de la poda. La Tabla 5.4 compara cuatro valores.

Tabla 5.4. Random Forest: desempeño en validación cruzada según el mínimo de observaciones por hoja

Mínimo de observaciones por hoja	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
1	1.000	0.857	0.010	0.143	0.637	0.649	0.627	Sí
5	0.985	0.859	0.009	0.126	0.642	0.715	0.583	Sí
10	0.950	0.859	0.009	0.091	0.644	0.747	0.567	Sí
20	0.915	0.858	0.009	0.056	0.639	0.762	0.550	Sí

El AUC de validación es prácticamente igual en los cuatro valores (0.858–0.859), así que la capacidad de discriminación del modelo no depende de este hiperparámetro (Tabla 5.4). En cambio, la brecha entre entrenamiento y validación se reduce de forma sostenida, de 0.143 a 0.059. Con hojas de una sola observación, el modelo alcanza un AUC de entrenamiento de 1.000, lo que significa que memoriza a los pacientes sin ganar nada en validación. La brecha de Random Forest es, además, mucho mayor que la de los modelos lineales (Tablas 5.2 y 5.3), incluso en su configuración más simple.

Este hiperparámetro tiene también un efecto clínico relevante. Con hojas de una observación, el *recall* es el más bajo de las cuatro configuraciones, lo que significa que los árboles tan profundos dejan pasar a una gran parte de los pacientes que fallecen, a pesar de la ponderación de clases. Conforme las hojas crecen, el *recall* aumenta de forma considerable, a cambio de una menor precisión.

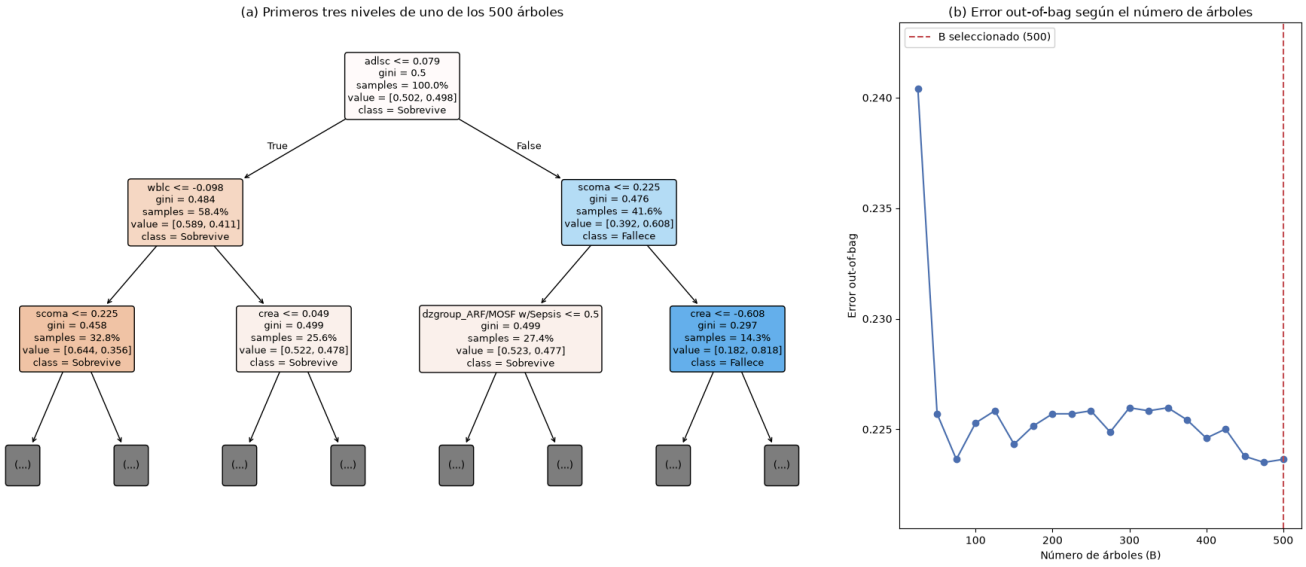
Aplicando la regla de decisión, todas las configuraciones están dentro de una desviación estándar del mejor AUC, y la de menor brecha es **`min_samples_leaf` = 20**, que es la que se selecciona.

Tabla 5.5. Random Forest final entrenado con el conjunto de entrenamiento completo

	Valor
Número de árboles (B)	500
Predictores por división (m)	6 de 46
Mínimo de observaciones por hoja	20
Profundidad promedio de los árboles	16.0
Hojas promedio por árbol	150.7
Exactitud out-of-bag	0.776

El modelo final tiene árboles con una profundidad promedio de 16 niveles y alrededor de 150 hojas (Tabla 5.5). La exactitud *out-of-bag* evalúa a cada paciente solo con los árboles que no lo usaron en su muestra *bootstrap*, así que funciona como una estimación interna de su desempeño fuera de la muestra, sin usar el conjunto de prueba.

Figura 5.3. Estructura y convergencia del Random Forest



La Figura 5.3 (a) presenta los tres primeros niveles de uno de los 500 árboles del bosque. Cada nodo indica la variable y el umbral de la división, el Gini Index del nodo, el porcentaje de pacientes que llegan a él y la proporción de cada clase. Los umbrales están en unidades estandarizadas, porque el árbol recibe las variables ya preprocesadas. A diferencia de la regresión logística, donde cada variable tiene un solo

coeficiente, aquí el efecto de una variable depende del camino que recorre cada paciente y cambia de un árbol a otro.

La Figura (b) muestra el error *out-of-bag* del bosque conforme se agregan árboles, de 25 en 25. El error disminuye con los primeros árboles y, a partir de unos 200, solo oscila ligeramente alrededor de un mismo valor, agregar árboles ya no cambia el voto del bosque, lo que confirma que B = 500 es suficiente.

5.4 Boosting

A diferencia de Random Forest, donde los árboles se entrenan de forma independiente, en Boosting los árboles se construyen secuencialmente. Cada árbol nuevo se ajusta a los residuales (los errores) del conjunto de árboles anteriores, y su contribución se reduce por un factor λ (*learning rate*). El modelo aprende de forma lenta y gradual, corrigiendo en cada paso los errores que aún no se han resuelto. Se usa la implementación de *gradient boosting* basada en histogramas (`HistGradientBoostingClassifier`), que agrupa los valores de cada variable en intervalos para acelerar la búsqueda de divisiones y admite ponderación de clases.

Hiperparámetros fijos:

- **Tasa de aprendizaje, λ = 0.05.** Un valor pequeño hace que cada árbol corrija solo una fracción del error. El aprendizaje es más lento y estable, y menos propenso a sobreajustar que con λ cercano a 1.
- **Profundidad de cada árbol, d = 3.** En Boosting se usan árboles pequeños, porque cada uno solo necesita capturar una parte del patrón restante. La profundidad 3 permite interacciones de hasta tres variables por árbol.

El hiperparámetro comparado es el número de árboles, B. A diferencia de Random Forest, en Boosting un B excesivo sí produce sobreajuste, pues los árboles finales terminan ajustando el ruido del conjunto de entrenamiento. La Tabla 5.6 compara tres valores.

Tabla 5.6. Boosting: desempeño en validación cruzada según el número de árboles

Número de árboles (B)	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
100	0.883	0.857	0.009	0.025	0.633	0.763	0.541	Sí
300	0.911	0.857	0.008	0.054	0.636	0.753	0.551	Sí
600	0.942	0.852	0.010	0.090	0.635	0.727	0.564	Sí

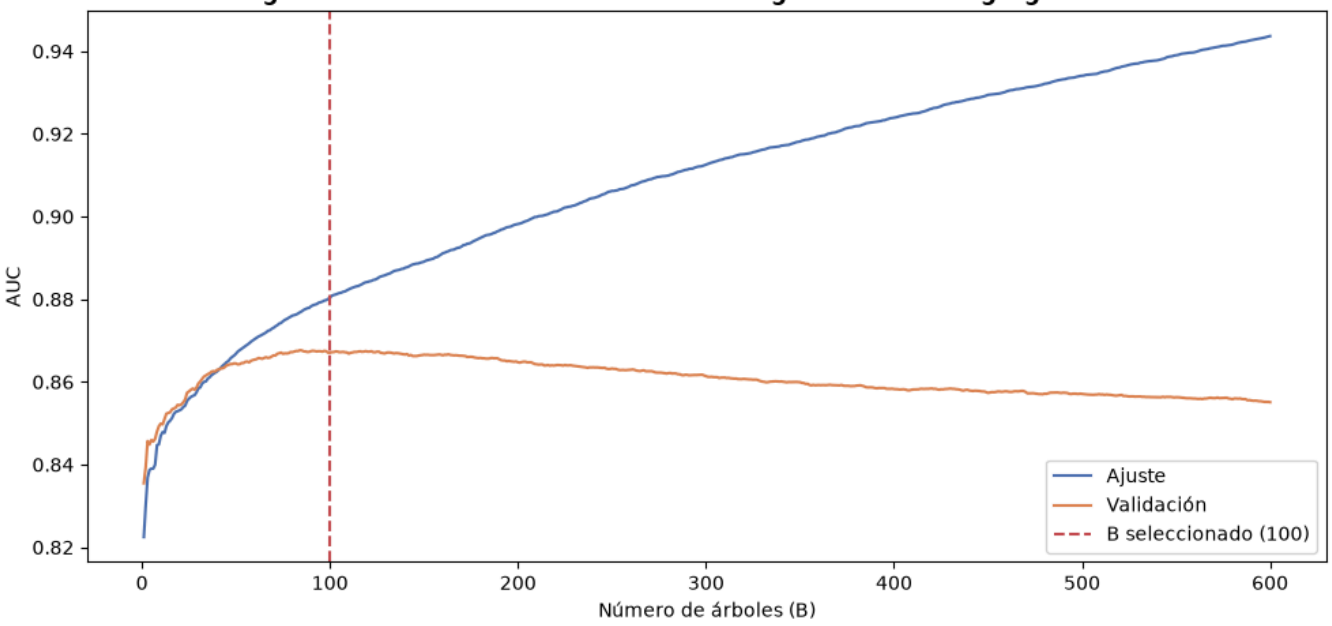
La Tabla 5.6 muestra el comportamiento esperado de Boosting. Al aumentar B, el AUC de entrenamiento crece de forma continua (de 0.883 a 0.941), mientras que el de validación se mantiene en 0.858 con 100

árboles y en 0.857 con 300, y baja a 0.852 con 600. A partir de cierto punto, los árboles adicionales solo ajustan el ruido del conjunto de entrenamiento, y la brecha se multiplica por más de tres (de 0.025 a 0.089).

Las tres configuraciones están dentro de una desviación estándar del mejor AUC. La de menor brecha es B **= 100**, que además tiene el *recall* más alto, así que es la que se selecciona.

Como Boosting construye sus árboles en secuencia, es posible observar cómo cambia el desempeño del modelo con cada árbol que se agrega. Para ello, el conjunto de entrenamiento se divide una vez en una parte de **ajuste** (80 %) y una de **validación interna** (20 %), estratificadas por enfermedad y desenlace. La Figura 5.4 muestra el AUC en ambas partes para un modelo con los mismos hiperparámetros, entrenado hasta 600 árboles. Esta misma partición interna se usa después para el *early stopping* de la red neuronal (sección 5.6).

Figura 5.4. Evolución del AUC de Boosting conforme se agregan árboles



La Figura 5.4 muestra cómo funciona Boosting. Los primeros árboles corrigen los errores más grandes, así que el AUC sube rápidamente en ambas partes. El AUC de validación alcanza su máximo, cercano a 0.867, entre los 75 y los 100 árboles, y a partir de ahí desciende de forma gradual hasta alrededor de 0.856 con 600. En cambio, el AUC de ajuste sigue subiendo de forma continua, de alrededor de 0.881 con 100 árboles a 0.944 con 600. Cada árbol nuevo corrige errores cada vez más específicos de los pacientes de ajuste, así que la brecha entre ambas curvas crece mientras el desempeño en validación empeora. Este es el sobreajuste de Boosting cuando B es excesivo, y la figura confirma la elección de B = 100 hecha con validación cruzada (Tabla 5.6). Los valores absolutos de AUC difieren ligeramente de los de la Tabla 5.6, porque aquí se usa una sola partición de validación en lugar del promedio de cinco.

5.5 Support Vector Machine

La SVM clasifica a cada paciente según el lado de un hiperplano en el que cae. Este hiperplano se construye de modo que el margen entre las clases sea lo más amplio posible. En la formulación de margen suave, se permite que algunas observaciones violen el margen o queden del lado incorrecto del hiperplano; las observaciones que están sobre el margen o lo violan son los **vectores de soporte** (S), y son las únicas que definen la frontera de decisión. La función *kernel* K permite que la frontera no sea lineal.

Hiperparámetros fijos:

- **Kernel radial.** Mide la similitud entre dos pacientes según su distancia en el espacio de las 46 variables, y permite fronteras de decisión no lineales sin suponer de antemano qué forma tienen. Es el *kernel* más flexible de los habituales y el adecuado cuando no hay razones para esperar una frontera lineal.
- γ **= 1 / (**p **· varianza de los datos).** Es el valor de referencia de la librería. Como las variables están estandarizadas, γ toma un valor cercano a 1/46. Controla qué tan local es la influencia de cada vector de soporte.

Hiperparámetro comparado: parámetro de regularización C**.** En la formulación teórica del *support vector classifier*, C es un **presupuesto** de violaciones del margen, de modo que un C mayor permite más violaciones y produce un margen más suave. En la implementación usada, `C` es en cambio una **penalización** por cada violación, con el efecto inverso: un `C` pequeño produce un margen suave, con muchos vectores de soporte, y un `C` grande, un margen estricto que se ajusta más al conjunto de entrenamiento. La Tabla 5.7 compara tres valores.

Tabla 5.7. SVM: desempeño en validación cruzada según el parámetro C

C (penalización)	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
0.1	0.869	0.849	0.007	0.020	0.628	0.785	0.524	Sí
1	0.932	0.846	0.007	0.086	0.637	0.733	0.563	Sí
10	0.996	0.803	0.004	0.194	0.573	0.574	0.573	No

La SVM es el modelo más sensible a su hiperparámetro de complejidad (Tabla 5.7). Con `C` = 10, el margen estricto lleva a un AUC de entrenamiento de 0.997, pero el de validación cae a 0.803, con una brecha de 0.194, la mayor de todas los modelos ejecutados, esto es un caso claro de sobreajuste. Al suavizar el margen, el AUC de validación mejora y la brecha se reduce.

Las configuraciones `C` = 0.1 y `C` = 1 están dentro de una desviación estándar del mejor AUC, y la de menor brecha es **`C` = 0.1**, que además tiene el AUC de validación (0.849) y el *recall* (0.785) más altos. Esa es la que se selecciona.

El modelo final se entrena con estimación de probabilidades. La clasificación de cada paciente sigue dependiendo del lado del hiperplano en que cae, pero las probabilidades permiten expresar su salida en la misma escala que los demás modelos (una probabilidad de fallecimiento entre 0 y 1).

Tabla 5.8. SVM final entrenada con el conjunto de entrenamiento completo

	Valor
Kernel	Radial
C (penalización)	0.1
γ	0.0363
Vectores de soporte, clase sobrevive	3,287
Vectores de soporte, clase fallece	1,212
Vectores de soporte (% del entrenamiento)	61.8 %

El modelo final usa 4,499 vectores de soporte, el 61.8 % de los pacientes de entrenamiento (Tabla 5.8). Una proporción tan alta es la consecuencia ocasionada por un margen suave, pues muchos pacientes quedan dentro del margen y participan en la frontera de decisión. Esto indica que las clases se traslapan considerablemente en el espacio de las variables clínicas y que no existe una frontera nítida entre los pacientes que sobreviven y los que fallecen. Al mismo tiempo, es lo que hace robusto al modelo, porque la frontera no depende de unos pocos pacientes extremos.

La SVM decide a partir del valor de la función de decisión $f(x)$, los pacientes con $f(x) > 0$ quedan del lado del hiperplano correspondiente a "fallece", y los que tienen $|f(x)| \leq 1$ quedan dentro del margen. Aunque el hiperplano existe en un espacio de 46 dimensiones y no se puede dibujar, la distribución de $f(x)$ muestra dónde quedan los pacientes respecto a él (Figura 5.5).

Figura 5.5. Posición de los pacientes respecto al hiperplano de la SVM

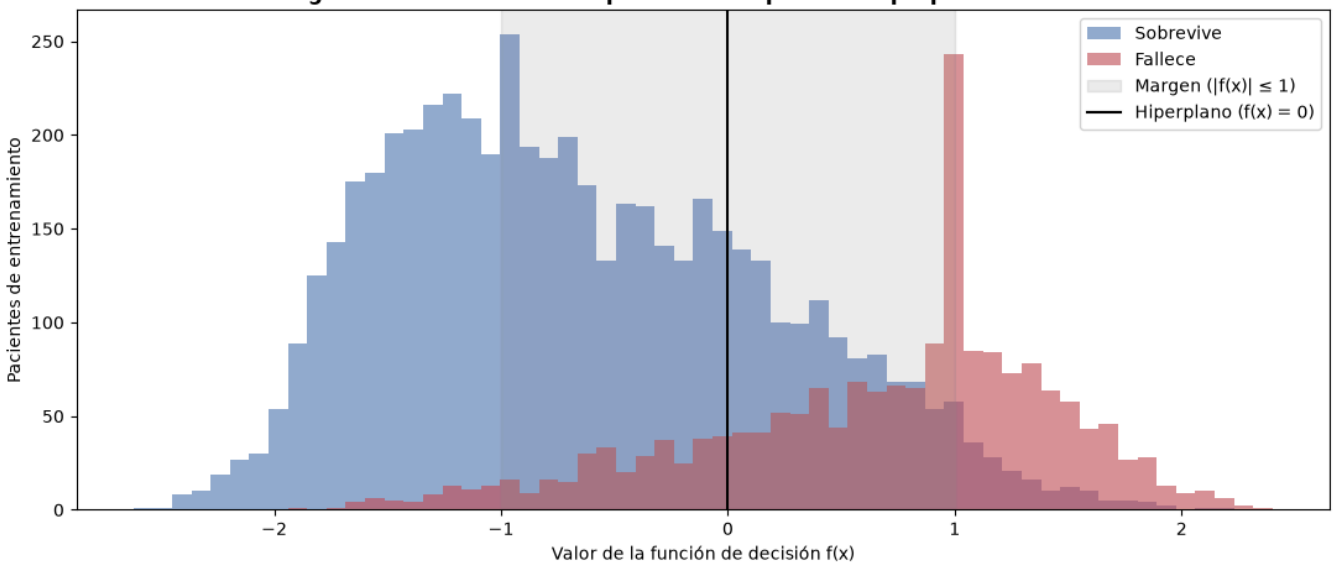


Tabla 5.9. Posición de los pacientes de entrenamiento respecto al hiperplano

	Valor
Pacientes dentro del margen (|f(x)| ≤ 1)	57.0 %
Pacientes que fallecen con f(x) > 0	80.8 %
Pacientes que sobreviven con f(x) < 0	76.4 %

La Figura 5.5 hace visible el traslape entre clases que sugería el número de vectores de soporte. La mayoría de los sobrevivientes queda del lado negativo del hiperplano y la mayoría de los fallecidos del lado positivo, determina que el 80.8 % de los pacientes que fallecen y el 76.4 % de los que sobreviven quedan del lado correcto (Tabla 5.9). Sin embargo, las dos distribuciones se superponen ampliamente, y el 57.0 % de los pacientes queda dentro del margen. Estos pacientes, junto con los que quedan del lado incorrecto, son los vectores de soporte que definen la frontera.

La acumulación de pacientes que fallecen justo en $f(x) = 1$ corresponde a los vectores de soporte que quedan exactamente sobre el borde del margen. En términos clínicos, la figura confirma lo que ya mostraba el LDA (Figura 5.2), existe un grupo de pacientes cuyo estado al tercer día no permite distinguir con claridad si sobrevivirán o no. Ningún modelo, con los datos disponibles, podrá clasificarlos con certeza, y ese grupo marcará el límite de desempeño de los seis clasificadores.

5.6 Red neuronal

La red neuronal procesa la información del paciente en capas sucesivas de neuronas. Cada neurona combina las salidas de la capa anterior con distintos pesos y les aplica una función que le permite representar relaciones no lineales. Las primeras capas aprenden combinaciones de variables, como un patrón de signos vitales y laboratorios propio de un paciente en deterioro, y la última las traduce en una probabilidad de fallecer. Los pesos se ajustan de forma iterativa, es decir, en cada época, la red compara sus predicciones con los desenlaces reales y corrige los pesos para reducir el error.

- Es el modelo más flexible de los seis: puede aprender relaciones no lineales e interacciones complejas sin especificarlas de antemano y produce directamente una probabilidad de fallecimiento y se extiende de forma natural a la clasificación multiclase de la sección 9.

Hiperparámetros

Se fijan dos capas ocultas con activación ReLU y una neurona de salida con activación sigmoide, así como la entropía cruzada binaria como función de costo; se usa el optimizador Adam (*learning rate* de 0.001, *batches* de 32 pacientes); la ponderación de clases; y un ***early stopping*** que detiene el entrenamiento cuando el AUC de la parte de validación interna (sección 5.4) no mejora durante 10 épocas, y conserva los pesos de la mejor época. Se compara el **número de neuronas de las capas ocultas**, que controla la capacidad de la red. En cada fold, la parte de entrenamiento se divide a su vez para el *early stopping*. La Tabla 5.7 compara tres tamaños.

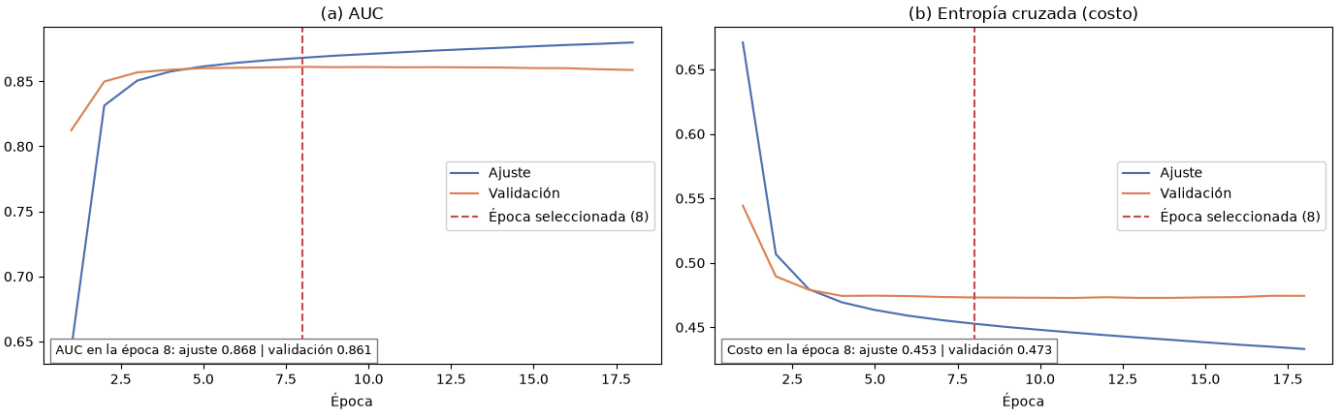
Tabla 5.10. Red neuronal: desempeño en validación cruzada según el número de neuronas

Neuronas en las capas ocultas	AUC entrenamiento	AUC validación	DE AUC validación	Brecha de AUC	F1	Recall	Precisión	Dentro de 1 DE del mejor
16 → 8	0.874	0.852	0.009	0.022	0.635	0.752	0.550	Sí
32 → 16	0.886	0.856	0.006	0.030	0.639	0.752	0.556	Sí
64 → 32	0.881	0.853	0.008	0.028	0.636	0.755	0.549	Sí

El AUC de validación es prácticamente igual en las tres arquitecturas (0.852–0.856), con desviaciones estándar de 0.006 a 0.009, así que las tres quedan dentro de una desviación estándar del mejor (Tabla 5.7). Lo que cambia con el tamaño de la red es el sobreajuste. Al pasar de 16 → 8 a 32 → 16 neuronas, el AUC de entrenamiento sube de 0.874 a 0.886, pero el de validación apenas pasa de 0.852 a 0.856, y la brecha aumenta de 0.022 a 0.030. La red más grande, de 64 → 32 neuronas, no mejora a ninguna de las dos (0.853 en validación, con una brecha de 0.028). Las métricas que dependen del umbral tampoco distinguen a las arquitecturas: las tres tienen un *recall* cercano a 0.75, una precisión cercana a 0.55 y un F1 de 0.635 a 0.639. Aplicando la regla de decisión, se selecciona la red de **16 → 8 neuronas**, la de menor brecha.

La Figura 5.6 muestra el entrenamiento del modelo final en la partición interna de ajuste y validación: la evolución del AUC y de la función de costo en cada época, y la época cuyos pesos se conservan.

Figura 5.6. Entrenamiento de la red neuronal final (16 → 8 neuronas, 18 épocas ejecutadas)



El entrenamiento se detuvo en la época 18, pues el AUC de validación alcanzó su máximo en la época 8 (0.861) y no mejoró durante las 10 épocas siguientes (Figura 5.6). En esa época, el AUC de ajuste (0.868) y el de validación difieren en menos de 0.01, y el costo de ajuste (0.453) es apenas menor que el de validación (0.473).

La figura muestra dos fases:

- **Primeras épocas.** El AUC de validación sube rápidamente y alcanza alrededor de 0.86 desde la cuarta época; a partir de ahí se mantiene prácticamente constante. En las primeras épocas, el AUC de ajuste queda por debajo del de validación porque se calcula como el promedio de toda la época, incluidos los primeros *batches*, cuando los pesos todavía no se habían ajustado.
- **Después de la época 8.** El AUC de ajuste sigue subiendo hasta cerca de 0.88 y su costo sigue bajando hasta cerca de 0.43, mientras que en validación el AUC deja de mejorar e incluso desciende ligeramente, y el costo se estanca alrededor de 0.47. Es el mismo comportamiento de Boosting al agregar árboles (Figura 5.4), pasado cierto punto, la capacidad adicional de la red se usa para memorizar a los pacientes de ajuste.

Que la red alcance su mejor desempeño en pocas épocas, y que las redes más grandes no mejoren la validación (Tabla 5.7), indica que el patrón que puede extraer de estos datos se aprende rápidamente y no es especialmente complejo.

6. Comparación de modelos en validación cruzada

Los seis modelos, con los hiperparámetros seleccionados en la sección 5, se comparan con el esquema de validación cruzada repetida descrito en la sección 4.6, la validación cruzada estratificada de 5 *folds* se repite cinco veces, lo que produce 25 particiones del conjunto de entrenamiento, idénticas para todos los modelos. El conjunto de prueba no se usa en esta sección; se reserva para evaluar únicamente al modelo final (sección 8).

En la red neuronal, cada partición repite el procedimiento completo de la sección 5.6, una partición interna para el *early stopping*, un preprocesamiento ajustado solo con la parte de ajuste y el entrenamiento hasta la detención temprana. En la SVM, la clase de cada paciente se obtiene con el lado del hiperplano en el que cae y no con la probabilidad estimada, porque la calibración de esas probabilidades las reajusta a la prevalencia real de fallecimientos y anularía el efecto de la ponderación de clases. Además de las métricas, se registra el tiempo de entrenamiento como indicador del costo computacional de cada modelo.

6.1 Métricas de desempeño

Tabla 6.1. Desempeño en validación cruzada repetida (media ± desviación estándar de 25 particiones)

Modelo	Exactitud	Precisión	Recall	F1	AUC	Tiempo de entrenamiento (s)
Regresión logística	0.782 ± 0.007	0.560 ± 0.011	0.749 ± 0.014	0.640 ± 0.009	0.858 ± 0.007	0.334 ± 0.149
LDA	0.790 ± 0.008	0.577 ± 0.013	0.720 ± 0.016	0.640 ± 0.011	0.856 ± 0.007	0.190 ± 0.049
Random Forest	0.775 ± 0.011	0.548 ± 0.016	0.763 ± 0.023	0.638 ± 0.013	0.858 ± 0.008	4.046 ± 1.139
Boosting	0.772 ± 0.009	0.543 ± 0.013	0.766 ± 0.018	0.636 ± 0.011	0.858 ± 0.009	1.146 ± 0.120
SVM	0.759 ± 0.009	0.523 ± 0.012	0.783 ± 0.017	0.627 ± 0.009	0.849 ± 0.008	6.236 ± 0.913
Red neuronal	0.779 ± 0.012	0.556 ± 0.019	0.743 ± 0.021	0.636 ± 0.013	0.852 ± 0.008	8.124 ± 0.741

Las medias de la Tabla 6.1 no muestran si un modelo es superior de forma consistente o solo en promedio. Para verlo, la Figura 6.1 muestra el AUC de cada modelo en cada una de las 25 particiones.

Cuatro de los seis modelos obtienen prácticamente el mismo AUC promedio, la regresión logística, Random Forest y Boosting 0.858, y LDA 0.856. La red neuronal (0.852) y la SVM (0.849) quedan por

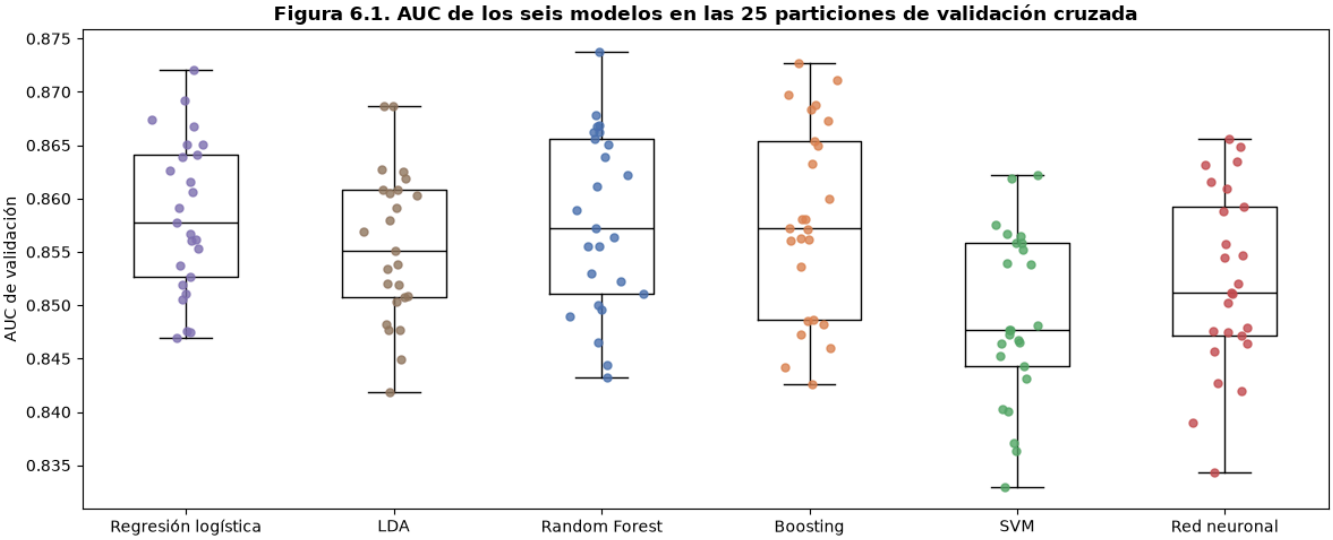
debajo (Tabla 6.1). Es decir, los dos modelos lineales, con 47 coeficientes cada uno, discriminan igual que los ensambles y mejor que los dos modelos más flexibles.

6.2 Estabilidad entre particiones

En las métricas que dependen del umbral, los modelos se diferencian más por el tipo de errores que cometen que por su calidad general. SVM tiene el *recall* más alto (0.783) y la precisión más baja (0.523), lo que indica que detecta a más pacientes que fallecen, a cambio de más falsas alarmas. LDA ocupa el extremo opuesto, con la mayor exactitud (0.790) y precisión (0.577) y el menor *recall* (0.720), porque sus probabilidades a priori iguales desplazan la frontera de forma distinta a la ponderación de clases. La red neuronal por otro lado, se ubica por encima del SVM en precisión (0.556) y con un recall mayor que LDA (0.743). Estos perfiles se compensan entre sí, pues el F1 de los seis modelos se mantiene en un rango estrecho, de 0.627 a 0.640.

El costo computacional, en cambio, sí difiere de forma marcada. Los dos modelos lineales se entrenan en menos de medio segundo por partición (0.19 y 0.33 s), mientras que Boosting requiere 1.1 s, Random Forest 4.0 s, la SVM 6.2 s y la red neuronal 8.1 s (Tabla 6.1).

Figura 6.1. AUC de los seis modelos en las 25 particiones de validación cruzada



La Figura 6.1 muestra que las distribuciones de la regresión logística, LDA, Random Forest y Boosting se superponen casi por completo, mientras que las de la red neuronal y la SVM quedan ligeramente desplazadas hacia abajo. Para un mismo modelo, el AUC cambia de forma considerable solo por los pacientes con los que se evalúa: el de la regresión logística, por ejemplo, va de 0.847 a 0.872 según la partición (Tabla 8.1). Esa variación es mucho mayor que la diferencia de AUC promedio entre los cuatro mejores modelos. Los modelos lineales son los más estables, con una desviación estándar de 0.007, seguidos de los demás, con 0.008 a 0.009 (Tabla 6.1). Que la diferencia entre modelos sea menor que la variación entre particiones no basta, por sí solo, para concluir que son equivalentes. Por eso se aplican las pruebas de hipótesis de la sección 6.3.

6.3 Estadístico F y pruebas t pareadas

Primero se prueba si los seis modelos tienen el mismo AUC esperado mediante un **análisis de varianza de medidas repetidas**. Cada partición se trata como un sujeto evaluado con los seis modelos, lo que permite separar dos fuentes de variación, la que se debe a que unas particiones son más fáciles que otras, que afecta a todos los modelos por igual, y la que se debe a diferencias reales entre modelos. El estadístico F compara la variación entre modelos con la variación aleatoria que queda después de descontar la dificultad de cada partición. Un valor de F grande indica que los modelos difieren más de lo que se esperaría por azar.

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_6 \qquad F = \frac{SC_{\text{modelos}} \,/\, (k-1)}{SC_{\text{error}} \,/\, \left[(k-1)(n-1)\right]}$$

donde k = 6 es el número de modelos y n = 25 el número de particiones. El numerador mide cuánto difieren los AUC promedio de los modelos, y el denominador, la variación que queda después de descontar la diferencia de dificultad entre particiones.

Tabla 6.2. Estadístico F: análisis de varianza de medidas repetidas sobre el AUC

	Valor
Hipótesis nula	Los seis modelos tienen el mismo AUC esperado
Particiones (n) × modelos (k)	25 × 6
Estadístico F	51.36
Grados de libertad	(5, 120)
Valor p	< 0.001
Decisión (α = 0.05)	Se rechaza H_0

El estadístico F es de 51.36, con 5 y 120 grados de libertad y un valor *p* menor a 0.001 (Tabla 6.2), así que se rechaza la hipótesis de que los seis modelos tienen el mismo AUC esperado. Sin embargo, la prueba F solo indica que al menos un modelo difiere, no cuál.

Tabla 6.3. Pruebas t pareadas corregidas entre pares de modelos (AUC de 25 particiones)

Comparación	Diferencia media de AUC	t	p	p ajustado (Holm)	¿Diferencia significativa?
Regresión logística − SVM	0.010	6.095	< 0.001	< 0.001	Sí
Random Forest − SVM	0.009	5.885	< 0.001	< 0.001	Sí
Boosting − SVM	0.009	3.801	< 0.001	0.011	Sí
LDA − SVM	0.007	3.639	0.001	0.016	Sí
Regresión logística − Red neuronal	0.006	3.435	0.002	0.024	Sí
Regresión logística − LDA	0.003	2.983	0.006	0.065	No
Random Forest − Red neuronal	0.006	2.188	0.039	0.348	No
LDA − Red neuronal	0.003	2.012	0.056	0.444	No
Boosting − Red neuronal	0.006	1.927	0.066	0.462	No
SVM − Red neuronal	-0.004	-1.430	0.166	0.993	No
LDA − Random Forest	-0.002	-1.047	0.305	1.000	No
LDA − Boosting	-0.002	-0.913	0.370	1.000	No
Regresión logística − Random Forest	0.001	0.295	0.770	1.000	No
Regresión logística − Boosting	0.000	0.227	0.823	1.000	No
Random Forest − Boosting	-0.000	-0.039	0.969	1.000	No

Las pruebas t muestran de dónde viene el rechazo de la prueba F (Tabla 6.3):

- **La SVM es significativamente inferior a los cuatro mejores modelos.** La regresión logística, Random Forest, Boosting y LDA la superan por entre 0.007 y 0.010 de AUC, con valores *p* ajustados de 0.016 o menores. Una diferencia de 0.010 equivale a que, de cada mil pares de pacientes (uno que fallece y uno que sobrevive), el otro modelo ordena correctamente diez pares más.
- **La red neuronal es significativamente inferior a la regresión logística**, por 0.006 de AUC (*p* ajustado de 0.024). Frente a Random Forest, Boosting y LDA, su desventaja (0.003 a 0.006) no alcanza la significancia después del ajuste por comparaciones múltiples.
- **La regresión logística, LDA, Random Forest y Boosting son equivalentes.** Ninguna de sus seis comparaciones es significativa. Las diferencias entre la regresión logística, Random Forest y Boosting

son de 0.001 o menos, con valores *p* superiores a 0.7. La comparación más cercana a la significancia es la de la regresión logística frente a LDA (0.003, $p = 0.006$ antes del ajuste y 0.065 después).

En conclusión, la flexibilidad adicional de los ensambles no se traduce en una mejora detectable sobre los modelos lineales, y los dos modelos más flexibles, la SVM y la red neuronal, obtienen incluso un AUC menor.

6.4 Costo computacional e interpretabilidad

Como cuatro modelos discriminan igual, la comparación debe considerar también lo que cuesta obtener esa discriminación y qué tan comprensible es. La Tabla 6.4 resume para cada modelo el número de elementos que definen su predicción, su tiempo de entrenamiento promedio en la validación cruzada repetida, su brecha de AUC entre entrenamiento y validación (sección 5) y su interpretabilidad.

Tabla 6.4. Complejidad, costo computacional e interpretabilidad de los modelos

Modelo	Elementos que definen la predicción	Tiempo de entrenamiento (s)	Brecha de AUC (sección 5)	Interpretabilidad
Regresión logística	47 coeficientes	0.334	0.004	Alta: cada coeficiente es una razón de momios
LDA	47 coeficientes	0.190	0.004	Alta: coeficientes de una función lineal
Random Forest	150,210 nodos en 500 árboles	4.046	0.056	Baja: voto de 500 árboles distintos
Boosting	790 hojas en 100 árboles	1.146	0.025	Baja: suma de 100 árboles secuenciales
SVM	4,499 vectores de soporte	6.236	0.020	Muy baja: similitud con miles de pacientes
Red neuronal	897 pesos	8.124	0.007	Muy baja: pesos sin significado individual

La Tabla 6.4 muestra que los modelos equivalentes en discriminación difieren enormemente en complejidad. La regresión logística y LDA definen su predicción con 47 coeficientes, mientras que Random Forest necesita 150,210 nodos repartidos en 500 árboles, la SVM 4,499 vectores de soporte y la red neuronal 897 pesos. Esta complejidad adicional tiene tres costos:

- **Costo computacional.** Los modelos lineales son los más rápidos de entrenar (Tabla 6.4).
- **Sobreajuste.** Los modelos lineales tienen las menores brechas entre entrenamiento y validación (0.004), mientras que Random Forest tiene la mayor (0.056) y Boosting y la SVM se ubican en un punto intermedio (0.025 y 0.020). La complejidad adicional se usa en buena parte para ajustarse a los pacientes de entrenamiento, no para discriminar mejor a los nuevos.

- **Interpretabilidad.** En la regresión logística, cada coeficiente se traduce en una razón de momios con significado clínico directo (Figura 5.1), y en LDA los coeficientes de la función discriminante tienen una lectura similar. Random Forest y Boosting combinan cientos de árboles: cada uno es una regla fácil de seguir (Figura 5.3a), pero la predicción final no se puede explicar con una regla única. La SVM decide según la similitud del paciente con miles de vectores de soporte en un espacio transformado por el *kernel*, y los pesos de la red neuronal no tienen un significado individual. Estos dos últimos son esencialmente black boxes.

7. Selección del modelo final

La selección del modelo final combina evidencia cuantitativa y cualitativa en dos pasos:

1. **Desempeño.** Se descartan los modelos cuyo AUC es significativamente inferior al del modelo con mayor AUC promedio, según las pruebas t corregidas de la sección 6.3.
2. **Criterios cualitativos.** Entre los modelos estadísticamente equivalentes, se prefiere el más interpretable, estable y sencillo, porque una ventaja de desempeño que no puede distinguirse del azar no justifica renunciar a esas propiedades.

La Tabla 7.1 reúne los criterios para los seis modelos.

Tabla 7.1. Criterios de selección del modelo final (mejor AUC media: Regresión logística)

Modelo	AUC media	DE del AUC	p ajustado frente al mejor	¿Equivalente al mejor?	Brecha de AUC	Tiempo de entrenamiento (s)	Interpretabilidad
Regresión logística	0.858	0.007	—	Sí	0.004	0.334	Alta
LDA	0.856	0.007	0.065	Sí	0.004	0.190	Alta
Random Forest	0.858	0.008	1.000	Sí	0.056	4.046	Baja
Boosting	0.858	0.009	1.000	Sí	0.025	1.146	Baja
SVM	0.849	0.008	< 0.001	No	0.020	6.236	Muy baja
Red neuronal	0.852	0.008	0.024	No	0.007	8.124	Muy baja

La regresión logística obtiene el mayor AUC promedio (0.858), y el primer paso descarta a la SVM y a la red neuronal, los dos únicos modelos con un AUC significativamente inferior al suyo (Tabla 7.1). Los otros tres modelos, LDA, Random Forest y Boosting, son estadísticamente equivalentes a ella, así que la elección se basa en el segundo paso.

Se selecciona la regresión logística como modelo final, por las siguientes razones:

- **Desempeño.** Su AUC promedio (0.858) es igual al de los ensambles y está entre los más altos de los seis modelos, Tiene el AUC promedio más alto (0.858), empatado con Random Forest y Boosting.
- **Estabilidad.** Junto con LDA, tiene la menor variabilidad entre particiones (desviación estándar de 0.007, Figura 6.1).
- **Bajo sobreajuste.** Su brecha entre entrenamiento y validación (0.004) es 14 veces menor que la de Random Forest (0.056) y seis veces menor que la de Boosting (0.025) (Tabla 6.4).

- **Interpretabilidad.** Cada coeficiente se traduce en una razón de momios que un médico puede verificar con su conocimiento clínico (Figura 5.1). En un contexto en el que la predicción puede influir en decisiones como la intensidad del tratamiento o el inicio de cuidados paliativos, poder explicar en qué se basa es un requisito, no una ventaja adicional.
- **Coherencia con el problema.** El modelo SUPPORT original también es aditivo (sección 1), y este análisis confirma que, con estas variables, las relaciones no lineales que pueden capturar los modelos flexibles no aportan una mejora detectable. Este resultado coincide con la evidencia de que, en predicción clínica con datos tabulares, el aprendizaje automático rara vez supera de forma significativa a la regresión logística (Christodoulou et al., 2019).

Entre los dos modelos lineales, se prefiere la regresión logística sobre LDA por tres motivos. Primero, no supone que las variables sigan una distribución normal con covarianza común, un supuesto que estos datos no cumplen (Figuras 4.1 y 5.2). Segundo, su AUC es ligeramente mayor (0.858 frente a 0.856), en la comparación más cercana a la significancia de las diez entre modelos equivalentes (p ajustado de 0.065, Tabla 6.3). Tercero, modela directamente la probabilidad de fallecer, lo que facilita su uso en el tablero interactivo (sección 11).

La selección no considera las métricas que dependen del umbral (exactitud, precisión, *recall* y F1), porque reflejan dónde coloca cada modelo su umbral de decisión más que su capacidad de discriminación (sección 4.6), y porque el F1 de los modelos equivalentes es prácticamente igual (Tabla 6.1).

8. Evaluación del modelo final en el conjunto de prueba

La regresión logística, entrenada con los 7,284 pacientes del conjunto de entrenamiento y con C = 0.01, se evalúa una sola vez en los 1,821 pacientes del conjunto de prueba, que no participaron en ninguna decisión del análisis.

8.1 Métricas de desempeño con intervalo de confianza

Además de las métricas de la sección 4.6, se reportan dos métricas útiles para interpretar el modelo en la práctica clínica, la **especificidad**, que representa la proporción de sobrevivientes que el modelo clasifica correctamente, y el **valor predictivo negativo**, la proporción de pacientes clasificados como "sobrevive" que efectivamente sobreviven. La incertidumbre de cada métrica se estima con un intervalo de confianza del 95 % por bootstrap; Se generan 2,000 muestras con reemplazo del conjunto de prueba, se recalcula la métrica en cada una y se toman los percentiles 2.5 y 97.5. Como referencia, se incluyen el desempeño del mismo modelo en la validación cruzada repetida y el de un clasificador mayoritario, que predice "sobrevive" para todos los pacientes.

Tabla 8.1. Desempeño de la regresión logística en el conjunto de prueba (1,821 pacientes)

Métrica	Prueba	IC 95 % inferior	IC 95 % superior	Validación cruzada (media)	Validación cruzada (mín. – máx.)	Clasificador mayoritario
Exactitud	0.793	0.775	0.812	0.782	0.765 – 0.795	0.741
Precisión	0.573	0.534	0.610	0.560	0.532 – 0.580	0.000
Recall	0.788	0.752	0.824	0.749	0.714 – 0.777	0.000
F1	0.664	0.630	0.694	0.640	0.625 – 0.655	0.000
AUC	0.872	0.854	0.889	0.858	0.847 – 0.872	0.500
Especificidad	0.795	0.773	0.816	—	—	1.000
Valor predictivo negativo	0.915	0.898	0.931	—	—	0.741

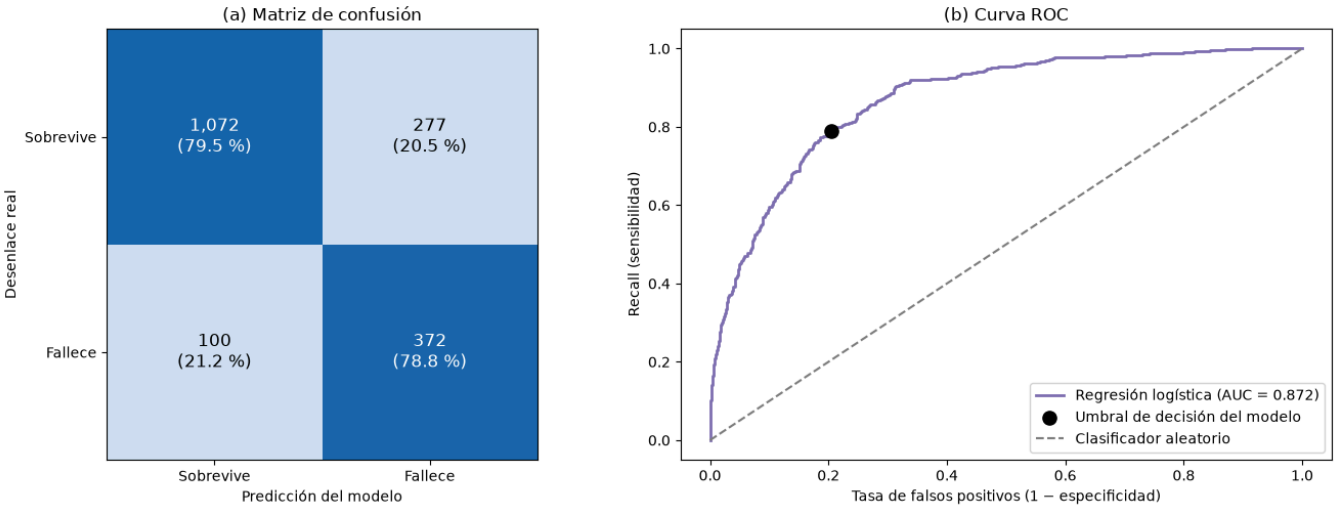
En el conjunto de prueba, la regresión logística alcanza un AUC de 0.872, con un intervalo de confianza del 95 % de 0.854 a 0.889 (Tabla 8.1). Su exactitud (0.793) supera a la del clasificador mayoritario (0.741), pero la diferencia importante está en las demás métricas, pues el clasificador mayoritario no detecta a un solo paciente que fallece, mientras que el modelo detecta al 78.8 % (*recall* de 0.788, IC de 0.752 a 0.824).

Los resultados en prueba son coherentes con los de la validación cruzada. El AUC de prueba coincide con el valor más alto observado entre las 25 particiones (0.872), y el promedio de la validación cruzada (0.858) queda dentro del intervalo de confianza del AUC de prueba. Lo mismo ocurre con la exactitud y la precisión. El *recall* y el F1 de prueba quedan ligeramente por encima del rango de la validación

cruzada, lo que indica que el conjunto de prueba resultó algo más favorable que el promedio. En ningún caso el desempeño en prueba es inferior al esperado, así que no hay evidencia de que la selección de hiperparámetros o del modelo haya producido sobreajuste.

8.2 Matriz de confusión y curva ROC

Figura 8.1. Matriz de confusión y curva ROC del modelo final en el conjunto de prueba



De los 472 pacientes de prueba que fallecieron en el hospital, el modelo identificó a 372 (78.8 %) y dejó sin detectar a 100 (21.2 %) (Figura 8.1a). De los 1,349 que sobrevivieron, clasificó correctamente a 1,072 (79.5 %) y generó 277 falsas alarmas (20.5 %). El modelo comete, en proporción, el mismo error en ambas clases, alrededor de uno de cada cinco pacientes de cada desenlace se clasifica mal. Este equilibrio es la consecuencia directa de la ponderación de clases. Sin ella, el modelo habría favorecido a la clase mayoritaria y dejado pasar a muchos más pacientes que fallecen.

La curva ROC (Figura 8.1b) muestra el desempeño del modelo en todos los umbrales posibles, y el punto negro marca el umbral con el que clasifica. Ese punto no es una propiedad fija del modelo, desplazándolo sobre la curva se puede aumentar el *recall* a cambio de más falsas alarmas, o al revés. Por ejemplo, en un contexto de tamizaje, donde una alerta solo implica una revisión clínica adicional, convendría mover el umbral hacia la derecha para detectar a más pacientes en riesgo.

8.3 Interpretación de los resultados

En términos accesibles, los resultados de la Tabla 8.1 y la Figura 8.1 significan lo siguiente para un paciente nuevo evaluado al tercer día de hospitalización:

- **Capacidad de detección.** De cada 10 pacientes que fallecerán durante la hospitalización, el modelo identifica alrededor de 8 (*recall* de 0.788).
- **Confiabilidad de una alerta.** De cada 10 pacientes que el modelo señala como en riesgo, casi 6 fallecen (precisión de 0.573). Los otros 4 son pacientes graves que sobreviven, por lo que se interpreta como una alerta indica un riesgo alto, no un desenlace seguro.

- **Confiabilidad de un pronóstico favorable.** Cuando el modelo indica que el paciente sobrevivirá, acierta en 9 de cada 10 casos (valor predictivo negativo de 0.915).
- **Capacidad de ordenar por riesgo.** Si se toma al azar un paciente que fallece y uno que sobrevive, el modelo asigna mayor riesgo al que fallece en 87 de cada 100 pares (AUC de 0.872).

Como el modelo produce una probabilidad y no solo una clase, también puede usarse para agrupar a los pacientes por nivel de riesgo. La Tabla 8.2 divide a los pacientes de prueba en cinco grupos del mismo tamaño según la probabilidad estimada, y compara la mortalidad observada en cada uno.

Tabla 8.2. Mortalidad observada en el conjunto de prueba según el grupo de riesgo asignado por el modelo

Grupo de riesgo (quintil)	Pacientes	Probabilidad estimada (rango)	Fallecimientos	Mortalidad observada (%)
Muy bajo	365	0.02 – 0.14	7	1.9
Bajo	364	0.14 – 0.25	16	4.4
Medio	364	0.25 – 0.45	56	15.4
Alto	364	0.45 – 0.70	140	38.5
Muy alto	364	0.70 – 1.00	253	69.5

La mortalidad observada aumenta de forma constante con el grupo de riesgo, se observa un incremento del 1.9 % en el grupo de riesgo muy bajo, 4.4 % en el bajo, 15.4 % en el medio, 38.5 % en el alto y 69.5 % en el muy alto (Tabla 8.2). Entre los grupos extremos hay una diferencia de más de 35 veces. En los dos grupos de menor riesgo, que reúnen a 729 pacientes, solo fallecieron 23. En el grupo de riesgo muy alto fallecieron 253 de 364 pacientes. Esta es probablemente la forma más útil de presentar el modelo en la práctica, determinando más que una predicción binaria, ofreciendo una clasificación del paciente en un nivel de riesgo, con una mortalidad esperada para cada nivel.

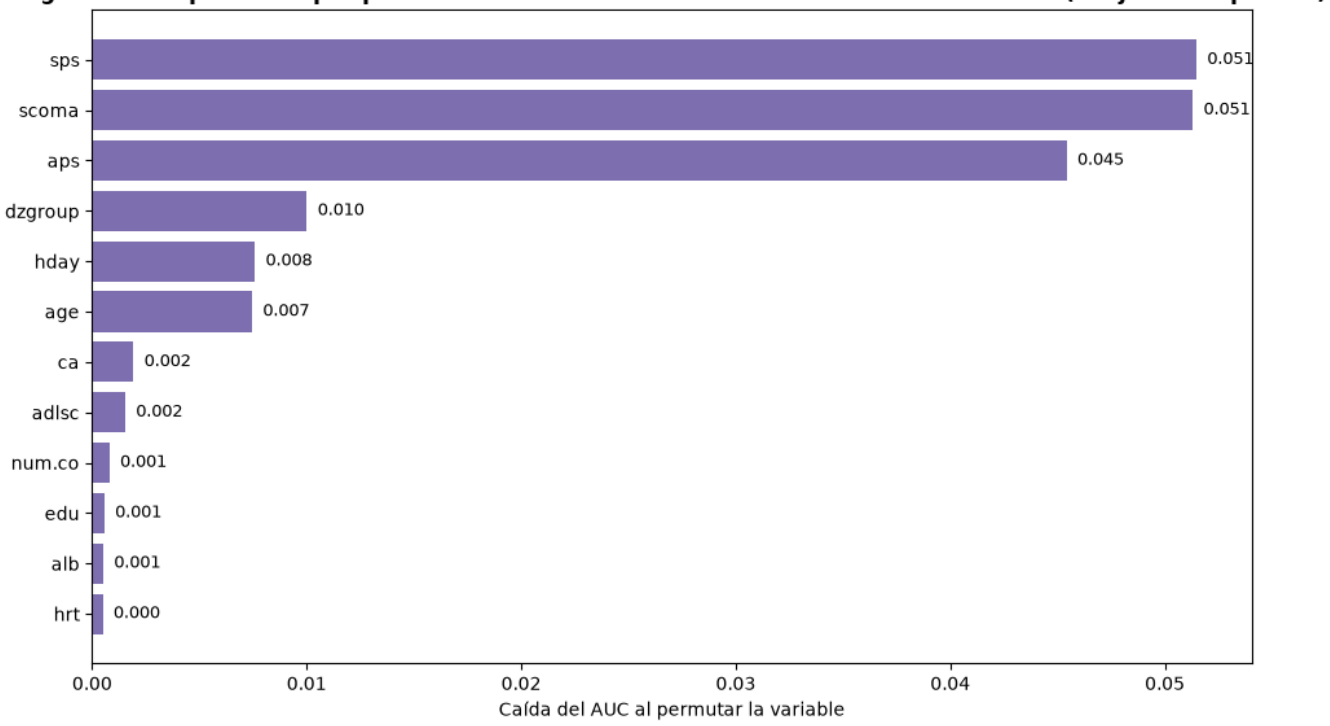
La tabla también revela una limitación importante. Las probabilidades estimadas son mayores que la mortalidad real, por ello en el grupo de riesgo alto, el modelo estima probabilidades de 0.45 a 0.70, pero falleció solo el 38.5 % de los pacientes. Esto es consecuencia de la ponderación de clases, que entrena al modelo como si la mitad de los pacientes falleciera. Por lo tanto, se propone que la probabilidad del modelo debe leerse como una **puntuación de riesgo relativa**, útil para ordenar a los pacientes, y no como la probabilidad literal de fallecer.

En cuanto a su comportamiento con datos nuevos, la coincidencia entre la validación cruzada y el conjunto de prueba indica que, en pacientes de una población similar, puede esperarse un AUC de alrededor de 0.86, con un intervalo plausible de 0.85 a 0.89. Esta expectativa se limita a pacientes comparables a los del estudio SUPPORT, hospitalizados en Estados Unidos entre 1989 y 1994. En otros hospitales o épocas, con otros tratamientos y perfiles de pacientes, el modelo tendría que validarse de nuevo.

8.4 Variables que sostienen la predicción

Los coeficientes de la Figura 5.1 indican la dirección y la magnitud del efecto de cada variable transformada. Para medir cuánto depende el desempeño del modelo de cada variable clínica original, se permutan por importancia, desordenando aleatoriamente los valores de una variable en el conjunto de prueba, lo que rompe su relación con el desenlace, y se mide cuánto disminuye el AUC. Se usan cinco repeticiones por variable y se reporta la caída promedio. Como se permutan las 30 variables originales, y no las 46 transformadas, `dzgroup` se evalúa como una sola variable y no como ocho columnas binarias.

Figura 8.2. Importancia por permutación de las 12 variables clínicas más relevantes (conjunto de prueba)



Tres variables concentran casi toda la capacidad predictiva del modelo (Figura 8.2). Permutar el puntaje fisiológico de SUPPORT (`sps`) o la escala de coma (`scoma`) reduce el AUC en 0.051, y permutar el puntaje APACHE III (`aps`), en 0.045. Les siguen, con una importancia mucho menor, el grupo de enfermedad (0.010), el día de ingreso al estudio (0.008) y la edad (0.007). Las demás variables tienen una importancia individual de 0.002 o menos.

Junto con la Figura 5.1, esto permite resumir el modelo en términos clínicos. El riesgo de fallecer durante la hospitalización depende sobre todo de la **gravedad fisiológica** del paciente al tercer día y de su **estado neurológico**, se determina entonces que, a mayor puntaje fisiológico y mayor grado de coma, mayor riesgo. El tipo de enfermedad, la edad y el momento de ingreso al estudio ajustan ese riesgo de forma secundaria. Que las predicciones se apoyen en variables con un significado clínico tan claro, y en la dirección esperada, es un argumento adicional a favor de confiar en el modelo.

9. Predicción de la ventana temporal de fallecimiento

La mortalidad intrahospitalaria responde si un paciente fallecerá durante su hospitalización, pero no cuándo. Esta sección extiende el análisis a una pregunta más estricta, en qué ventana de tiempo ocurrirá el fallecimiento, o si el paciente sobrevivirá más de un año. Como se mostró en la Tabla 3.7, ambas preguntas son complementarias, pues 432 pacientes fueron dados de alta con vida pero fallecieron en los primeros 30 días, un riesgo que `hospdead` no capta.

9.1 Adaptación de los modelos a clasificación multiclase (*softmax*)

Las ventanas se definieron en la sección 3.4.2 a partir de `death` y `d.time`, con cortes en 30, 180 y 365 días, y se excluyó a los 65 pacientes con seguimiento incompleto. Para esta sección, se mantiene la misma partición train-test de la sección 4.1, los pacientes de cada conjunto son los mismos que en la tarea principal, salvo esos 65. Así, ningún paciente de prueba participa en el entrenamiento de ninguna de las dos tareas.

Las clases están desbalanceadas, así que se aplica la misma ponderación inversa a la frecuencia que en la tarea principal. La Tabla 9.1 muestra el número de pacientes y el peso de cada clase.

Tabla 9.1. Pacientes y peso de cada clase en la tarea multiclase

Ventana	Pacientes (entrenamiento)	Pacientes (prueba)	Peso de clase
Muerte ≤ 30 días	1,988	475	0.91
Muerte 31–180 días	1,411	391	1.28
Muerte 181–365 días	609	169	2.97
Sobrevive > 1 año	3,220	777	0.56

La ponderación asigna a la clase minoritaria, la muerte entre 181 y 365 días, un peso de 2.97, cada uno de esos 609 pacientes cuenta en el entrenamiento como casi tres pacientes de una clase de frecuencia promedio. La supervivencia mayor a un año, la clase más frecuente, recibe un peso de 0.56 (Tabla 9.1).

Los seis modelos se adaptan a las cuatro clases con los mismos hiperparámetros de la sección 5. No se repite la selección de hiperparámetros, para que las diferencias entre ambas tareas se deban al problema y no a la configuración de los modelos. Cada modelo resuelve el problema multiclase a su manera:

- **Regresión logística:** se generaliza a la **regresión logística multinomial**, que estima un vector de coeficientes por clase y convierte las cuatro combinaciones lineales en probabilidades mediante la función *softmax*.
- **LDA:** maneja varias clases de forma natural, pues estima una media por clase y una covarianza común, y asigna a cada paciente la clase con mayor función discriminante. Las probabilidades a priori se fijan en 0.25 para cada ventana.

- **Random Forest:** cada hoja almacena la proporción de pacientes de cada clase, la impureza se mide con el índice de Gini sobre las cuatro clases y la predicción final es el voto de los 500 árboles.
- **Boosting:** en cada iteración se construye un árbol por clase, y la salida se transforma en probabilidades con *softmax*. Con B = 100 iteraciones y cuatro clases, el modelo combina 400 árboles.
- **SVM:** el hiperplano separa solo dos clases, así que se usa la estrategia **uno contra uno**, por lo que el modelo entrena una SVM para cada par de clases (seis en total), y cada paciente se asigna a la clase que gana más enfrentamientos.
- **Red neuronal:** la capa de salida pasa de una neurona sigmoide a **cuatro neuronas con activación *softmax***, una por ventana, cuyas salidas suman 1. La función de costo pasa a ser la entropía cruzada categórica (`sparse_categorical_crossentropy`). Como no existe una AUC única para cuatro clases durante el entrenamiento, el *early stopping* monitorea el costo de validación, con la misma paciencia de 10 épocas.

Métricas. Se reportan la exactitud, el F1 macro (sección 4.6) y el **AUC macro uno contra el resto**, que calcula el AUC de cada ventana frente a las otras tres y las promedia. Como en la tarea principal, el AUC macro es la métrica principal de comparación. En la SVM, el AUC se calcula con los valores de su función de decisión para cada clase.

9.2 Comparación en validación cruzada y selección del modelo

Los seis modelos se comparan con el mismo esquema de la sección 6: 25 particiones (5 *folds* × 5 repeticiones) del conjunto de entrenamiento, estratificadas por ventana, con el estadístico F y las pruebas t pareadas corregidas aplicadas al AUC macro.

Tabla 9.2. Ventana temporal: desempeño en validación cruzada repetida (media ± desviación estándar de 25 particiones)

Modelo	Exactitud	F1 macro	AUC macro (OvR)	Tiempo de entrenamiento (s)
Regresión logística	0.519 ± 0.012	0.443 ± 0.012	0.740 ± 0.012	0.332 ± 0.106
LDA	0.512 ± 0.013	0.443 ± 0.013	0.736 ± 0.012	0.150 ± 0.022
Random Forest	0.545 ± 0.012	0.449 ± 0.014	0.740 ± 0.011	6.609 ± 0.750
Boosting	0.518 ± 0.014	0.440 ± 0.014	0.734 ± 0.012	2.463 ± 0.305
SVM	0.511 ± 0.012	0.429 ± 0.012	0.712 ± 0.011	9.771 ± 2.516
Red neuronal	0.501 ± 0.015	0.429 ± 0.015	0.722 ± 0.012	8.922 ± 1.460

Tabla 9.3. Ventana temporal: pruebas t pareadas corregidas sobre el AUC macro (estadístico F = 194.30, gl = (5, 120), p < 0.001)

Comparación	Diferencia media de AUC	t	p	p ajustado (Holm)	¿Diferencia significativa?
Regresión logística − SVM	0.027	11.030	< 0.001	< 0.001	Sí
LDA − SVM	0.024	9.689	< 0.001	< 0.001	Sí
Random Forest − SVM	0.028	8.352	< 0.001	< 0.001	Sí
Boosting − SVM	0.021	6.133	< 0.001	< 0.001	Sí
Random Forest − Red neuronal	0.018	5.098	< 0.001	< 0.001	Sí
Regresión logística − Red neuronal	0.018	4.851	< 0.001	< 0.001	Sí
Regresión logística − LDA	0.004	4.046	< 0.001	0.004	Sí
LDA − Red neuronal	0.014	3.567	0.002	0.012	Sí
Boosting − Red neuronal	0.012	2.959	0.007	0.048	Sí
Regresión logística − Boosting	0.006	2.728	0.012	0.070	No
Random Forest − Boosting	0.007	2.665	0.014	0.070	No
SVM − Red neuronal	-0.010	-2.305	0.030	0.120	No
LDA − Random Forest	-0.004	-1.775	0.089	0.266	No
LDA − Boosting	0.002	0.926	0.364	0.727	No
Regresión logística − Random Forest	-0.001	-0.265	0.793	0.793	No

Predecir la ventana temporal es considerablemente más difícil que predecir la mortalidad intrahospitalaria. El AUC macro de los modelos va de 0.712 a 0.740 y el F1 macro de 0.429 a 0.449 (Tabla 9.2), muy por debajo del AUC de 0.86 de la tarea binaria (Tabla 6.1). La regresión logística y Random Forest obtienen el mayor AUC macro (0.740), seguidos de LDA (0.736) y Boosting (0.734), mientras que la red neuronal (0.722) y la SVM (0.712) quedan claramente por debajo. Random Forest tiene la mayor exactitud (0.545) y F1 macro (0.449), aunque su F1 macro apenas supera al de la regresión logística (0.443).

El estadístico F rechaza la hipótesis de que los seis modelos tienen el mismo AUC macro (F = 194.30, p < 0.001; Tabla 9.3), y las pruebas t identifican dónde están las diferencias:

- **La SVM y la red neuronal son significativamente inferiores a los otros cuatro modelos**, con diferencias de 0.021 a 0.028 la SVM y de 0.012 a 0.018 la red neuronal. Entre ellas dos, la diferencia no es significativa. En esta tarea, los dos modelos más flexibles son los que peor ordenan a los pacientes en cada ventana.
- **La regresión logística supera a LDA** por 0.004, una diferencia pequeña pero significativa (p_value ajustado de 0.004). Con cuatro clases, LDA necesita estimar cuatro medias con una sola covarianza común, y el incumplimiento de ese supuesto (Figura 5.2) pesa más que en la tarea binaria.
- **La regresión logística, Random Forest y Boosting son equivalentes.** Ninguna de sus comparaciones es significativa, pues la diferencia entre la regresión logística y Random Forest es de apenas 0.001 (p_value ajustado de 0.793).

Aplicando el mismo criterio de la sección 7, **se selecciona la regresión logística multinomial** como modelo final para la ventana temporal. Tiene el AUC macro más alto entre los modelos de , empatado con Random Forest; es equivalente a los mejores modelos y conserva la interpretabilidad y el bajo costo que justificaron su elección en la tarea principal. Usar el mismo tipo de modelo en ambas tareas tiene, además, una ventaja práctica: el tablero interactivo puede explicar las dos predicciones con la misma lógica de coeficientes.

9.3 Evaluación en el conjunto de prueba

La regresión logística multinomial se entrena con los 7,228 pacientes de entrenamiento con ventana definida y se evalúa una sola vez en los 1,812 pacientes de prueba. Como en la sección 8, la incertidumbre se estima con 2,000 réplicas *bootstrap*, y se incluye como referencia un clasificador mayoritario que asigna a todos los pacientes la clase más frecuente (supervivencia mayor a un año).

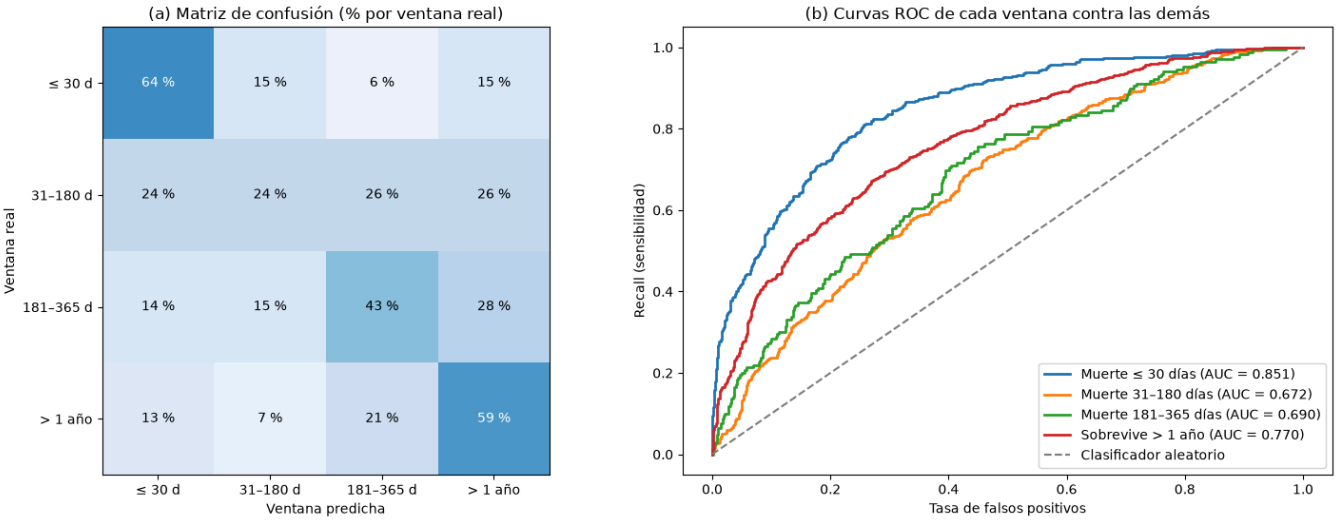
Tabla 9.4. Desempeño de la regresión logística en la ventana temporal (conjunto de prueba, 1,812 pacientes)

Métrica	Prueba	IC 95 % inferior	IC 95 % superior	Validación cruzada (media)	Clasificador mayoritario
Exactitud	0.513	0.490	0.536	0.519	0.429
F1 macro	0.452	0.429	0.474	0.443	0.150
AUC macro (OvR)	0.746	0.730	0.762	0.740	0.500
F1 Muerte ≤ 30 días	0.607	0.568	0.641	—	0.000
F1 Muerte 31–180 días	0.298	0.252	0.344	—	0.000
F1 Muerte 181–365 días	0.270	0.221	0.318	—	0.000
F1 Sobrevive > 1 año	0.631	0.603	0.660	—	0.600

En el conjunto de prueba, el modelo alcanza un AUC macro de 0.746 (con un Intervalo de Confianza de 95 %: 0.730 a 0.762), un F1 macro de 0.452 y una exactitud de 0.513 (Tabla 9.4). Supera con claridad al clasificador mayoritario, que tiene una exactitud de 0.429 y un F1 macro de 0.150. Los valores de prueba son coherentes con los de la validación cruzada (AUC macro de 0.740 y F1 macro de 0.443), así que no hay evidencia de sobreajuste.

El F1 de cada clase muestra de dónde viene la dificultad. El modelo predice razonablemente bien las dos ventanas extremas, la muerte en los primeros 30 días (F1 de 0.607) y la supervivencia mayor a un año (0.631). En cambio, falla en las dos ventanas intermedias, ocasionando que el F1 es de 0.298 para la muerte entre 31 y 180 días y de 0.270 para la muerte entre 181 y 365 días. La Figura 9.1 desglosa estos errores.

Figura 9.1. Matriz de confusión y curvas ROC de la ventana temporal en el conjunto de prueba



La matriz de confusión (Figura 9.1a) confirma el patrón de la Tabla 9.4. El modelo identifica correctamente al 64 % de los pacientes que fallecen en los primeros 30 días y al 59 % de los que sobreviven más de un año. En la ventana de 181 a 365 días acierta en el 43 % de los casos, un resultado favorecido por el peso de casi 3 que recibe esa clase (Tabla 9.1), pero a costa de asignarle también al 21 % de los sobrevivientes a un año y al 26 % de los fallecidos entre 31 y 180 días. La ventana de 31 a 180 días es la más difícil, pues sus pacientes se reparten casi por igual entre las cuatro ventanas predichas (24 % a 26 % en cada una).

Las curvas ROC (Figura 9.1b) muestran lo mismo desde la perspectiva de la discriminación. La muerte en los primeros 30 días se distingue de las demás ventanas casi tan bien como la mortalidad intrahospitalaria (AUC de 0.851), y la supervivencia mayor a un año también se distingue razonablemente (0.770). Las dos ventanas intermedias, en cambio, apenas se separan del resto (0.672 y 0.690).

La explicación es clínica. Las variables del tercer día describen la gravedad del paciente en ese momento, y esa gravedad distingue bien a los pacientes que fallecerán en pocas semanas de los que se recuperarán por completo. Pero la muerte meses después del ingreso depende de factores que ocurren después de la hospitalización, como la evolución de la enfermedad crónica, el tratamiento ambulatorio o las complicaciones posteriores, y ninguno de ellos está en los datos.

El error clínicamente más grave, clasificar como sobreviviente a más de un año a un paciente que fallecerá en el primer mes, ocurre en el 15 % de esos pacientes (Figura 9.1a). La predicción de la ventana temporal con la información del tercer día sirve como orientación complementaria a `hospdead`, sobre todo para identificar el riesgo de muerte temprana, pero no tiene la confiabilidad necesaria para precisar cuándo ocurrirá el fallecimiento en los horizontes intermedios.

10. Comparación con el modelo pronóstico SUPPORT y la estimación médica

El conjunto de datos incluye, para cada paciente, dos estimaciones de su probabilidad de sobrevivir 6 meses hechas al tercer día de hospitalización: la del **modelo pronóstico SUPPORT** (`surv6m`), desarrollado con regresión de Cox por Knaus et al. (1995), y la del **médico tratante** (`prg6m`). Estas variables se excluyeron de los predictores (sección 3.5), lo que permite usarlas ahora como referencias externas para contextualizar el desempeño del modelo de este análisis.

La comparación se hace en el horizonte de 6 meses, que coincide con uno de los cortes de la ventana temporal. El riesgo de fallecer en los primeros 180 días según el modelo es la suma de las probabilidades de las dos primeras ventanas, $P(\leq 30 \text{ días}) + P(31\text{–}180 \text{ días})$, estimadas por la regresión logística multinomial de la sección 9. Para el modelo SUPPORT y el médico, el riesgo es $1-$ la probabilidad de supervivencia estimada. Las tres fuentes se comparan en los mismos pacientes de prueba, los que tienen las tres estimaciones disponibles.

Tabla 10.1. Pronóstico de fallecimiento a 6 meses en los 1,481 pacientes de prueba con las tres estimaciones

Fuente del pronóstico	AUC	IC 95 % inferior	IC 95 % superior	Supervivencia a 6 meses estimada (media, %)	Supervivencia a 6 meses observada (%)
Modelo (regresión logística)	0.788	0.765	0.812	51.804	53.342
Modelo SUPPORT	0.776	0.752	0.799	52.844	53.342
Médico tratante	0.779	0.757	0.803	49.755	53.342

Tabla 10.2. Diferencias de AUC entre las fuentes de pronóstico (bootstrap pareado, 2,000 réplicas)

Comparación	Diferencia de AUC	IC 95 % inferior	IC 95 % superior	¿Diferencia significativa?
Modelo (regresión logística) – Modelo SUPPORT	0.013	0.002	0.023	Sí
Modelo (regresión logística) – Médico tratante	0.009	-0.015	0.035	No
Modelo SUPPORT – Médico tratante	-0.003	-0.028	0.021	No

De los 1,812 pacientes de prueba con ventana definida, 1,481 tienen las tres estimaciones; a los demás les falta la estimación del médico. En ellos, el modelo de este análisis obtiene un AUC de 0.788 (IC 95 %: 0.765 a 0.812), el modelo SUPPORT de 0.776 y el médico tratante de 0.779 (Tabla 10.1). Las diferencias pareadas (Tabla 10.2) muestran que:

- **El modelo supera al modelo SUPPORT** por 0.013 de AUC, con un intervalo de 0.002 a 0.023 que no incluye el 0. Es una diferencia significativa.
- **El modelo y el médico tratante son equivalentes.** La diferencia de 0.009 a favor del modelo tiene un intervalo de −0.015 a 0.035, que incluye el 0.
- **El modelo SUPPORT y el médico también son equivalentes** (diferencia de −0.003, de −0.028 a 0.021).

El resultado frente al modelo SUPPORT es notable, porque el modelo SUPPORT se desarrolló con pacientes de este mismo estudio (Knaus et al., 1995), así que una parte del conjunto de prueba formó parte de sus datos de construcción, lo que le da una ventaja en esta comparación. El modelo de este análisis no se entrenó para el horizonte de 6 meses, sino para cuatro ventanas, y aun así su estimación combinada discrimina mejor.

En promedio, las tres fuentes estiman una supervivencia a 6 meses cercana a la observada, con 51.8 % el modelo, 52.8 % el modelo SUPPORT y 49.8 % el médico, frente al 53.3 % real (Tabla 10.1). Sin embargo, el promedio puede ocultar errores que se compensan entre pacientes de riesgo bajo y alto. La Figura 10.1 compara las curvas ROC y la calibración de las tres fuentes, es decir, qué tanto coincide el riesgo estimado con la mortalidad observada en cada nivel de riesgo.

Figura 10.1. Discriminación y calibración del pronóstico a 6 meses según su fuente

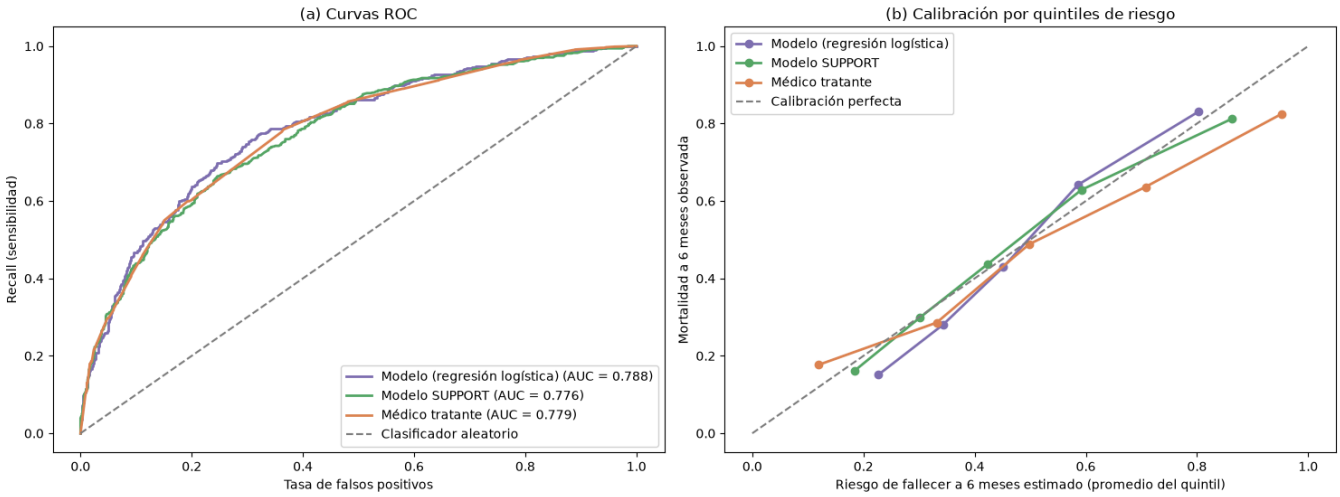


Tabla 10.3. Riesgo de fallecer a 6 meses estimado / mortalidad observada, por quintil de riesgo estimado

Fuente del pronóstico	Quintil 1	Quintil 2	Quintil 3	Quintil 4	Quintil 5
Modelo (regresión logística)	0.23 / 0.15	0.34 / 0.28	0.45 / 0.43	0.59 / 0.64	0.80 / 0.83
Modelo SUPPORT	0.18 / 0.16	0.30 / 0.30	0.42 / 0.44	0.59 / 0.63	0.86 / 0.81
Médico tratante	0.12 / 0.18	0.33 / 0.29	0.50 / 0.49	0.71 / 0.64	0.95 / 0.83

Las curvas ROC de las tres fuentes se superponen en casi todo su recorrido (Figura 10.1a), y la ventaja del modelo se concentra en la zona de tasas de falsos positivos de 0.1 a 0.4. Donde las fuentes se distinguen con claridad es en la calibración (Figura 10.1b y Tabla 10.3):

- **El modelo SUPPORT es el mejor calibrado.** En los cinco quintiles, su riesgo estimado difiere de la mortalidad observada en 0.05 o menos.
- **El modelo de este análisis sobreestima el riesgo de los pacientes de menor riesgo.** En el primer quintil estima un riesgo de 0.23, cuando la mortalidad observada es de 0.15, y en el segundo, de 0.34 frente a 0.28. Es la misma consecuencia de la ponderación de clases observada en la sección 8.3, el modelo ordena bien a los pacientes, pero sus probabilidades no deben leerse de forma literal sin recalibrarlas.
- **Los médicos son demasiado extremos.** A los pacientes que consideran de menor riesgo les asignan un riesgo promedio de 0.12, pero fallece el 18 %; a los que consideran de mayor riesgo les asignan 0.95, pero fallece el 82 %. Es decir, son optimistas con los pacientes que ven estables y pesimistas con los que ven graves.

Este último hallazgo matiza la evidencia citada en la introducción. Christakis y Lamont (2000) encontraron que los médicos tienden a sobrestimar la supervivencia de pacientes terminales. En este estudio, el error de los médicos no es un optimismo generalizado, pues su estimación promedio es incluso algo pesimista (49.8 % frente a 53.3 %), sino un exceso de confianza en los extremos. En los pacientes que el médico considera fuera de peligro, casi uno de cada cinco fallece en los siguientes seis meses.

En conjunto, la comparación muestra que una regresión logística construida solo con la información clínica rutinaria del tercer día discrimina tan bien como el juicio del médico tratante y ligeramente mejor que el modelo pronóstico SUPPORT, aunque este último sigue siendo superior en calibración. El modelo no sustituye al juicio clínico, pero puede servir como una segunda opinión , especialmente útil en los pacientes en los que el médico tiende a ser más optimista.

11. Tablero interactivo

Para comunicar los resultados a un público no técnico, como médicos, pacientes o familiares, se desarrolló el tablero interactivo **Pronóstico al Día 3**, disponible en github. El usuario ingresa el estado clínico de un paciente al tercer día de hospitalización, o elige uno de cuatro pacientes de ejemplo, y el tablero muestra tres resultados:

- **Riesgo de muerte durante la hospitalización.** La probabilidad estimada por la regresión logística de la sección 7, el grupo de riesgo de la Tabla 8.2 en el que cae el paciente y la mortalidad que se observó en ese grupo en el conjunto de prueba.
- **Fecha estimada de fallecimiento.** A partir de una fecha de ingreso, la regresión logística multinomial de la sección 9 traduce las cuatro ventanas temporales a fechas de calendario. La fecha estimada es el día en que el riesgo acumulado de fallecer alcanza 50 %, suponiendo que dentro de cada ventana el riesgo se reparte de forma uniforme. Si ese riesgo no llega a 50 % en el primer año, el tablero lo indica y muestra la probabilidad de sobrevivir más de un año.
- **Variables que mueven el riesgo.** Las variables que más aumentan o reducen el riesgo de ese paciente, comparado con el paciente promedio del estudio, expresadas como el factor por el que multiplican los momios de fallecer.

El tablero no modifica la metodología ni los modelos. Usa los coeficientes y los parámetros de preprocesamiento de los dos modelos finales, exportados desde este análisis, y reproduce sus predicciones con una diferencia máxima de una millonésima. Solo se agrega un ajuste para presentar los resultados, pues la ponderación de clases infla las probabilidades estimadas (sección 8.3), así que el tablero las corrige a la frecuencia real de cada desenlace. Para ello divide la probabilidad de cada clase entre su peso (Tablas 5.1 y 9.1) y vuelve a normalizar. Así, el modelo conserva exactamente el mismo orden de los pacientes y la misma AUC, pero sus probabilidades se pueden leer de forma literal. Las Tablas 11.1 y 11.2 verifican el efecto de esta corrección con validación cruzada dentro del conjunto de entrenamiento, sin usar el conjunto de prueba.

Tabla 11.1. Mortalidad intrahospitalaria: probabilidad estimada antes y después de la corrección (validación cruzada en entrenamiento)

Quintil de riesgo	Probabilidad sin corregir (media)	Probabilidad corregida (media)	Mortalidad observada
Quintil 1	0.099	0.037	0.019
Quintil 2	0.199	0.080	0.066
Quintil 3	0.344	0.156	0.170
Quintil 4	0.562	0.315	0.344
Quintil 5	0.852	0.690	0.697
Total	0.411	0.256	0.259

Tabla 11.2. Mortalidad intrahospitalaria: probabilidad estimada antes y después de la corrección (validación cruzada en entrenamiento)

Quintil de riesgo	Probabilidad sin corregir (media)	Probabilidad corregida (media)	Mortalidad observada
Quintil 1	0.099	0.037	0.019
Quintil 2	0.199	0.080	0.066
Quintil 3	0.344	0.156	0.170
Quintil 4	0.562	0.315	0.344
Quintil 5	0.852	0.690	0.697
Total	0.411	0.256	0.259

Sin corrección, el modelo sobreestima el riesgo en todos los niveles, en promedio estima una probabilidad de 0.411, cuando la mortalidad real del entrenamiento es de 0.259 (Tabla 11.1). Después de la corrección, la probabilidad promedio es de 0.256, y en cada quintil la probabilidad estimada queda cerca de la mortalidad observada: por ejemplo, 0.690 frente a 0.697 en el quintil de mayor riesgo y 0.156 frente a 0.170 en el intermedio. En la ventana temporal ocurre lo mismo (Tabla 11.2): sin corrección, el modelo reparte la probabilidad casi por igual entre las cuatro ventanas (0.237 a 0.274), y después de la corrección reproduce casi exactamente la frecuencia real de cada una (por ejemplo, 0.083 frente a 0.084 en la muerte entre 181 y 365 días).

El tablero hereda las limitaciones del análisis. Sus estimaciones solo son válidas para pacientes comparables a los del estudio SUPPORT, la fecha estimada es una aproximación basada en cuatro ventanas y no en una curva de supervivencia completa, y no está diseñado para tomar decisiones

clínicas. Su propósito es mostrar, de forma concreta, cómo cambia el pronóstico de un paciente cuando cambia su estado clínico, y cuáles son las variables que más pesan en ese pronóstico.

12. Conclusión y reflexión final

12.1 Aprendizajes sobre la problemática

Con el presente modelo y la información clínica disponible al tercer día de hospitalización es posible anticipar con buena precisión qué pacientes gravemente enfermos fallecerán durante su hospitalización, el modelo final alcanza un AUC de 0.872 en pacientes nuevos y detecta a casi 8 de cada 10 fallecimientos (Tabla 8.1). El riesgo depende sobre todo de la gravedad fisiológica (`sps` , `aps`) y del estado neurológico (`scoma`); el tipo de enfermedad, la edad y el momento de ingreso lo ajustan de forma secundaria (Figuras 5.1 y 8.2). El análisis también mostró que en los registros clínicos la ausencia de un dato es informativa, porque refleja decisiones médicas (Tabla 3.4), y que variables aparentemente inocentes, como la duración de la estancia, pueden producir una predicción perfecta pero inútil (Tabla 3.9).

Anticipar cuándo ocurrirá el fallecimiento es mucho más difícil. Los modelos distinguen bien la muerte en el primer mes y la supervivencia mayor a un año, pero no las ventanas intermedias (Tabla 9.4), que dependen de lo que ocurre después de la hospitalización. Aun así, a 6 meses, el modelo discrimina tan bien como el médico tratante y mejor que el modelo SUPPORT (Tabla 10.2), y la comparación reveló que los médicos son excesivamente confiados en los extremos de riesgo (Tabla 10.3).

12.2 Modelo más adecuado

La **regresión logística** resultó el modelo más adecuado. Obtuvo el mayor AUC promedio, estadísticamente equivalente al de Random Forest, Boosting y LDA, y significativamente superior al de la SVM y la red neuronal (Tabla 6.3), con la menor variabilidad entre particiones, el menor sobreajuste y el menor costo computacional (Tabla 6.4). Sobre todo, es el único modelo cuyas predicciones se pueden explicar en términos clínicos directos, mediante razones de momios. En este problema, el aumento de complejidad no se tradujo en mejores predicciones: los dos modelos más flexibles fueron los de menor desempeño, en la tarea principal y en la ventana temporal. El límite de desempeño lo imponen la información disponible al tercer día y el grupo de pacientes de pronóstico incierto (Figuras 5.2 y 5.5), no el algoritmo.

12.3 Limitaciones

- **Validez externa.** Los datos provienen de cinco hospitales universitarios de Estados Unidos entre 1989 y 1994. Los tratamientos, los perfiles de pacientes y las prácticas clínicas han cambiado, por lo que el desempeño reportado no se puede trasladar sin una nueva validación a hospitales actuales ni a otros sistemas de salud.
- **Una sola partición de prueba.** El modelo final se evaluó en un único conjunto de 1,821 pacientes. Los intervalos de confianza cuantifican la incertidumbre del muestreo, pero no sustituyen a una validación en una cohorte independiente.

- **Probabilidades no calibradas.** La ponderación de clases mejora la detección de fallecimientos, pero infla las probabilidades estimadas (Tabla 8.2 y Tabla 10.3). Sin recalibración, deben interpretarse como puntuaciones de riesgo relativo.
- **Umbral de decisión no optimizado.** El umbral de clasificación quedó definido por la ponderación de clases y no por un análisis del costo clínico de cada tipo de error.
- **Búsqueda de hiperparámetros limitada.** Para cada modelo se comparó un solo hiperparámetro con pocos valores, pues en la red neuronal, solo tres tamaños de una misma arquitectura de dos capas. En la tarea multiclase se reutilizaron los hiperparámetros de la tarea binaria sin volver a ajustarlos.
- **Supuestos de las pruebas estadísticas.** La corrección de Nadeau y Bengio es una aproximación a la dependencia entre particiones, y el estadístico F no la incorpora, por lo que se interpretó solo como una prueba general.
- **Imputación de valores faltantes.** La imputación con valores fisiológicos normales supone que un estudio no solicitado habría resultado normal, un supuesto razonable pero no verificable.
- **Definición de las ventanas temporales.** Los cortes en 30, 180 y 365 días son una decisión de diseño. Las ventanas se trataron como categorías sin orden, aunque tienen un orden natural, y se excluyó a los 65 pacientes con seguimiento incompleto.
- **Comparación con fuentes externas.** El modelo SUPPORT se desarrolló con parte de los pacientes de este estudio, y la estimación del médico falta en el 18 % de los pacientes de prueba, por lo que la comparación se limitó a 1,481 pacientes (Tabla 10.1).

12.4 Trabajo futuro

- **Validación externa y temporal** del modelo en hospitales actuales, incluidos hospitales mexicanos, para evaluar si el desempeño se mantiene en otra población y con prácticas clínicas actuales.
- **Recalibración de las probabilidades** (por ejemplo, con escalamiento de Platt o regresión isotónica) y **análisis de curvas de decisión** para elegir el umbral según el costo clínico de cada tipo de error.
- **Clasificación ordinal** de la ventana temporal, que aproveche el orden natural de las clases.
- **Análisis por grupo de enfermedad**, para identificar en qué enfermedades el modelo funciona mejor o peor y si conviene un modelo específico para algunas de ellas.
- **Combinación del modelo con la estimación del médico**, para evaluar si ambas fuentes, con errores distintos, se complementan.
- **Modelos dinámicos** que actualicen el pronóstico con las mediciones de días posteriores, en lugar de usar solo las del tercer día.
- **Explicaciones individuales** de cada predicción, que muestren al médico qué variables elevaron o redujeron el riesgo de un paciente específico.

12.5 Reflexión final

El estudio partió de un problema clínico concreto, el pronóstico de los pacientes gravemente enfermos guía decisiones como la intensidad del tratamiento, la asignación de camas de terapia intensiva, la transición a cuidados paliativos y la comunicación con la familia, pero depende de un juicio médico poco preciso (Christakis y Lamont, 2000). Los resultados muestran que una regresión logística construida solo

con la información rutinaria del tercer día de hospitalización puede apoyar esas decisiones. Su mayor valor no está en sustituir al juicio clínico, sino en complementarlo como una segunda opinión objetiva y explicable. Esa segunda opinión es especialmente útil en los pacientes que el médico considera estables, de los cuales casi uno de cada cinco fallece en los siguientes seis meses (Tabla 10.3). Para llevarlo a la práctica, el modelo tendría que recalibrarse y validarse en hospitales actuales.

Referencias

- Christakis, N. A., & Lamont, E. B. (2000). Extent and determinants of error in doctors' prognoses in terminally ill patients: Prospective cohort study. *BMJ, 320*(7233), 469–472. https://doi.org/10.1136/bmj.320.7233.469
- Harrell, F. (1995). *SUPPORT2* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.3886/ICPSR02957.v2
- Knaus, W. A., Harrell, F. E., Lynn, J., Goldman, L., Phillips, R. S., Connors, A. F., Dawson, N. V., Fulkerson, W. J., Califf, R. M., Desbiens, N., Layde, P., Oye, R. K., Bellamy, P. E., Hakim, R. B., & Wagner, D. P. (1995). The SUPPORT prognostic model: Objective estimates of survival for seriously ill hospitalized adults. *Annals of Internal Medicine, 122*(3), 191–203. https://doi.org/10.7326/0003-4819-122-3-199502010-00007
- Bouckaert, R. R., & Frank, E. (2004). Evaluating the replicability of significance tests for comparing learning algorithms. En H. Dai
- R. Srikant, & C. Zhang (Eds.), Advances in Knowledge Discovery and Data Mining (pp. 3–12). Springer. https://doi.org/10.1007978-3-540-24775-3_3
- Nadeau, C., & Bengio, Y. (2003). Inference for the generalization error. Machine Learning, 52(3), 239–281. https://doi.org/10.1023/A:1024068626366
- Peduzzi, P., Concato, J., Kemper, E., Holford, T. R., & Feinstein, A. R. (1996). A simulation study of the number of events per variable in logistic regression analysis. Journal of Clinical Epidemiology, 49(12), 1373–1379. https://doi.org/10.1016/S0895-4356(96)00236-3