Aprendizaje estadistico-automatico sobre el nivel de obesidad en Latinoamerica

Jorge Tello

Lenguajes utilizado en el analisis: Python

Índice

1. Introducción

2. Metodología

    - 2.1 Proceso de exploración inicial de los datos
    - 2.2 Proceso de reflexión sobre el diseño del estudio
    - 2.3 Proceso de definición de una variable de interés para la inferencia
    - 2.4 Proceso de análisis gráfico enfocado en una subpoblación

3. Resultados

    - 3.1 Exploración inicial de datos
    - 3.2 Reflexión sobre el diseño del estudio
    - 3.3 Definición de una variable de interés para inferencia
    - 3.4 Análisis gráfico enfocado en una subpoblación

4. Conclusiones

Referencias

---

1. Introducción

Los niveles de obesidad en la población constituyen un problema relevante de salud pública, particularmente en países latinoamericanos. En este contexto, investigadores de la Universidad de la Costa en Colombia recopilaron información de individuos provenientes de Colombia, Perú y México con el propósito de estudiar factores asociados con distintos niveles de obesidad.

La base de datos utilizado contiene información demográfica, hábitos y características relacionadas con la salud de los individuos, además de una variable categórica que clasifica el nivel de obesidad de cada observación a partir del índice de masa corporal (MC).

El análisis de esta información permite explorar las características de la población estudiada, identificar patrones relevantes en las variables disponibles y establecer una base para un análisis de inferencia

sobre una variable de respuesta seleccionada.

Objetivo general

El objetivo del presente reporte es documentar de manera sistemática el proceso de análisis exploratorio e inferencia realizado sobre el conjunto de datos de obesidad.

El análisis busca caracterizar inicialmente la estructura y calidad de los datos, reflexionar sobre variables adicionales que podrían mejorar el diseño del estudio, seleccionar una variable de salida adecuada para un análisis de inferencia y explorar gráficamente su relación con una variable cuantitativa dentro de una subpoblación específica.

Objetivos específicos

1. Explorar y caracterizar la estructura, naturaleza y calidad de la base de datos.
2. Seleccionar y justificar una variable adicional que podría complementar el estudio, así como una variable de salida adecuada para el análisis de inferencia.
3. Analizar la relación entre la variable de salida y una variable cuantitativa dentro de una subpoblación, interpretando su coherencia con el contexto del problema.

---

2. Metodología

El análisis se desarrollará mediante un enfoque cuantitativo basado en la exploración estadística de la base de datos y en el estudio de la relación entre variables.

2.1 Proceso de exploración inicial de los datos

Inicialmente se examinará la estructura de la base de datos, considerando su dimensión, tipos de variables y calidad de la información. Se verificará la presencia de valores faltantes y otros aspectos que puedan afectar el análisis posterior.

Las variables serán clasificadas de acuerdo con su naturaleza cuantitativa o cualitativa y se emplearán procedimientos descriptivos acordes con cada tipo.

2.2 Proceso de reflexión sobre el diseño del estudio

A partir de la exploración inicial se propondrá una variable que no se encuentre disponible en la base de datos y que pudiera aportar información relevante al estudio, en este caso, NumeroDePasos.

2.3 Proceso de definición de una variable de interés para inferencia

Se seleccionará una variable existente en el conjunto de datos que pueda funcionar como variable de salida o respuesta para un estudio de inferencia.

La selección se realizará considerando cuál de las variables representa de manera más directa el fenómeno central estudiado. Particularmente, se evaluará la variable NivelDeObesidad, la cual constituye una clasificación categórica del nivel de obesidad de los individuos y se encuentra relacionada con el índice de masa corporal.

2.4 Proceso de análisis gráfico enfocado en una subpoblación

Se seleccionará una subpoblación específica a partir de la variable Sexo y estudiar dentro de ella la relación entre NivelDeObesidad y una variable cuantitativa de interés.

Se trabajará con la subpoblación masculina y se utilizará Peso como variable cuantitativa para el análisis. Esta elección permitirá examinar visualmente cómo se distribuye el peso corporal entre las distintas categorías de NivelDeObesidad dentro de una misma subpoblación.

La relación será representada mediante un diagrama de caja (boxplot).

Resultados

3.1 Exploración inicial de datos

El conjunto de datos analizado contiene información de 2,111 individuos y 10 variables relacionadas con características demográficas, hábitos y condiciones asociadas al nivel de obesidad.

La información incluye variables relacionadas con sexo, edad, estatura y peso, así como indicadores sobre antecedentes familiares de sobrepeso, hábitos alimenticios, tabaquismo, consumo de vegetales y consumo de agua. El conjunto incorpora además una variable categórica que clasifica a cada individuo según su nivel de obesidad.

Tabla 1. Categorización de datos

Variable	Tipo de dato	Naturaleza	Descripción
`Sexo`	Categórico	Cualitativa	Sexo del individuo
`Edad`	Numérico	Cuantitativa	Edad en años
`Estatura`	Numérico	Cuantitativa	Estatura en metros
`Peso`	Numérico	Cuantitativa	Peso corporal en kg
`FamiliarConSobrepeso`	Categórico	Cualitativa	Antecedentes familiares de sobrepeso
`ComeMuchasCalorias`	Categórico	Cualitativa	Indicador de consumo elevado de calorías

Variable	Tipo de dato	Naturaleza	Descripción
`ComeVegetales`	Numérico	Cuantitativa	Nivel registrado de consumo de vegetales
`Fumador`	Categórico	Cualitativa	Indicador de tabaquismo
`ConsumoDeAgua`	Numérico	Cuantitativa	Nivel registrado de consumo de agua
`NivelDeObesidad`	Categórico	Cualitativa	Clasificación del nivel de obesidad

Una vez identificada la naturaleza técnica de cada variable, es fundamental evaluar la integridad del conjunto de datos antes de proceder con los análisis inferenciales. A continuación, se ejecuta la verificación para validar los datos presentes en la base de datos y confirmar la presencia o ausencia de valores nulos o faltantes en el total de los registros.

Tabla 2. Estructura y calidad de los datos

	Variable	Tipo de dato	Valores faltantes	Porcentaje de faltantes (%)
0	Sexo	object	0	0.0
1	Edad	float64	0	0.0
2	Estatura	float64	0	0.0
3	Peso	float64	0	0.0
4	FamiliarConSobrepeso	object	0	0.0
5	ComeMuchasCalorias	object	0	0.0
6	ComeVegetales	float64	0	0.0
7	Fumador	object	0	0.0
8	ConsumoDeAgua	float64	0	0.0
9	NivelDeObesidad	object	0	0.0

No se identifica ningun valor faltante en la base de datos en ninguna de las 10 variables presentadas, por lo que no se requiere de imputación previa al análisis.

Tabla 3. Descripción de datos cuantitativos

	Edad	Estatura	Peso	ComeVegetales	ConsumoDeAgua
count	2111.00	2111.00	2111.00	2111.00	2111.00
mean	24.31	1.70	86.59	2.42	2.01
std	6.35	0.09	26.19	0.53	0.61
min	14.00	1.45	39.00	1.00	1.00
25%	19.95	1.63	65.47	2.00	1.58
50%	22.78	1.70	83.00	2.39	2.00
75%	26.00	1.77	107.43	3.00	2.48
max	61.00	1.98	173.00	3.00	3.00

La base de datos contiene una muestra que incluye personas de entre 14 y 61 años, con una edad promedio de aproximadamente 24 años, por lo que predominan los adultos jóvenes. En cuanto a las características físicas, la estatura promedio es de 1.70 m y el peso promedio es de 86.6 kg. El peso presenta bastante variación entre las personas, con una desviación estándar cercana a 26 kg, lo cual tiene sentido, porque los datos incluyen diferentes niveles de obesidad.

En las variables ComeVegetales y ConsumoDeAgua se encontraron algunos valores decimales, aunque ambas deberían manejarse en una escala del 1 al 3. Esto puede indicar que la base de datos combina información real con datos generados para lograr una mejor distribución entre las diferentes categorías.

```
=== Tabla 4. Sexo ===
```

Sexo	Conteo	Porcentaje (%)
Male	1068	50.59
Female	1043	49.41

```
=== Tabla 5. FamiliarConSobrepeso ===
```

FamiliarConSobrepeso	Conteo	Porcentaje (%)
yes	1726	81.76
no	385	18.24

```
=== Tabla 6. ComeMuchasCalorias ===
```

ComeMuchasCalorias	Conteo	Porcentaje (%)
yes	1866	88.39
no	245	11.61

```
=== Tabla 7. Fumador ===
```

Fumador	Conteo	Porcentaje (%)
no	2067	97.92
yes	44	2.08

Al examinar la composición cualitativa de la muestra, destaca una distribución sumamente equitativa en la variable Sexo, con una representación del 50.6% de hombres (1,068 individuos) y 49.4% de mujeres (1,043 individuos). Por otro lado, los indicadores de hábitos y factores de riesgo muestran una concentración: el 81.8% de los participantes reporta antecedentes familiares de exceso de peso (1,726 personas) y el 88.4% admite un consumo frecuente de alimentos con alta densidad calórica (1,866 personas). Por su parte, la prevalencia de consumo de tabaco es marginal, alcanzando apenas al 2.1% del total analizado (44 fumadores).

Esta configuración refleja una selección muestral intencionada, orientada a agrupar a individuos con alta exposición a determinantes genéticos y dietéticos vinculados con el desarrollo de obesidad.

3.2 Reflexión sobre el diseño del estudio

Si yo formase parte del equipo, propondría, desde una perspectiva analítica sobre los determinantes del equilibrio energético y la composición corporal, s la incorporación de la variable "Número diario de pasos".

- Justificación: Aunque la base de datos contempla aspectos dietéticos y de consumo, no cuenta con una medición continua del gasto calórico derivado de la actividad física cotidiana no estructurada (conocida como *NEAT* o termogénesis por actividad no vinculada al ejercicio). La medición del número de pasos aportaría un indicador preciso del nivel de sedentarismo o movilidad del participante. Esta variable permitiría diferenciar de manera objetiva si parte del sobrepeso en los individuos es consecuencia directa y prioritaria al exceso calorias o a la falta de actividad física diaria, ofreciendo un control cuantitativo más sólido al momento de modelar e inferir las causas del exceso de peso en la población estudiada.
- Naturaleza de la variable: Se trata de una variable de tipo cuantitativo discreto, correspondiente al recuento o conteo acumulado de pasos efectuados por el individuo durante un lapso de 24 horas.

3.2 Definición de una variable de interés para inferencia

Como líder del proyecto, seleccionaría la variable NivelDeObesidad como la variable de salida del estudio.

Justificación: Esta variable sintetiza de manera directa la finalidad del estudio para determinar el estado de la población observada. En un análisis de inferencia estadística, NivelDeObesidad actúa como el resultado de interés que se busca explicar o predecir en función de los factores demográficos, genéticos y comportamentales registrados en los participantes.

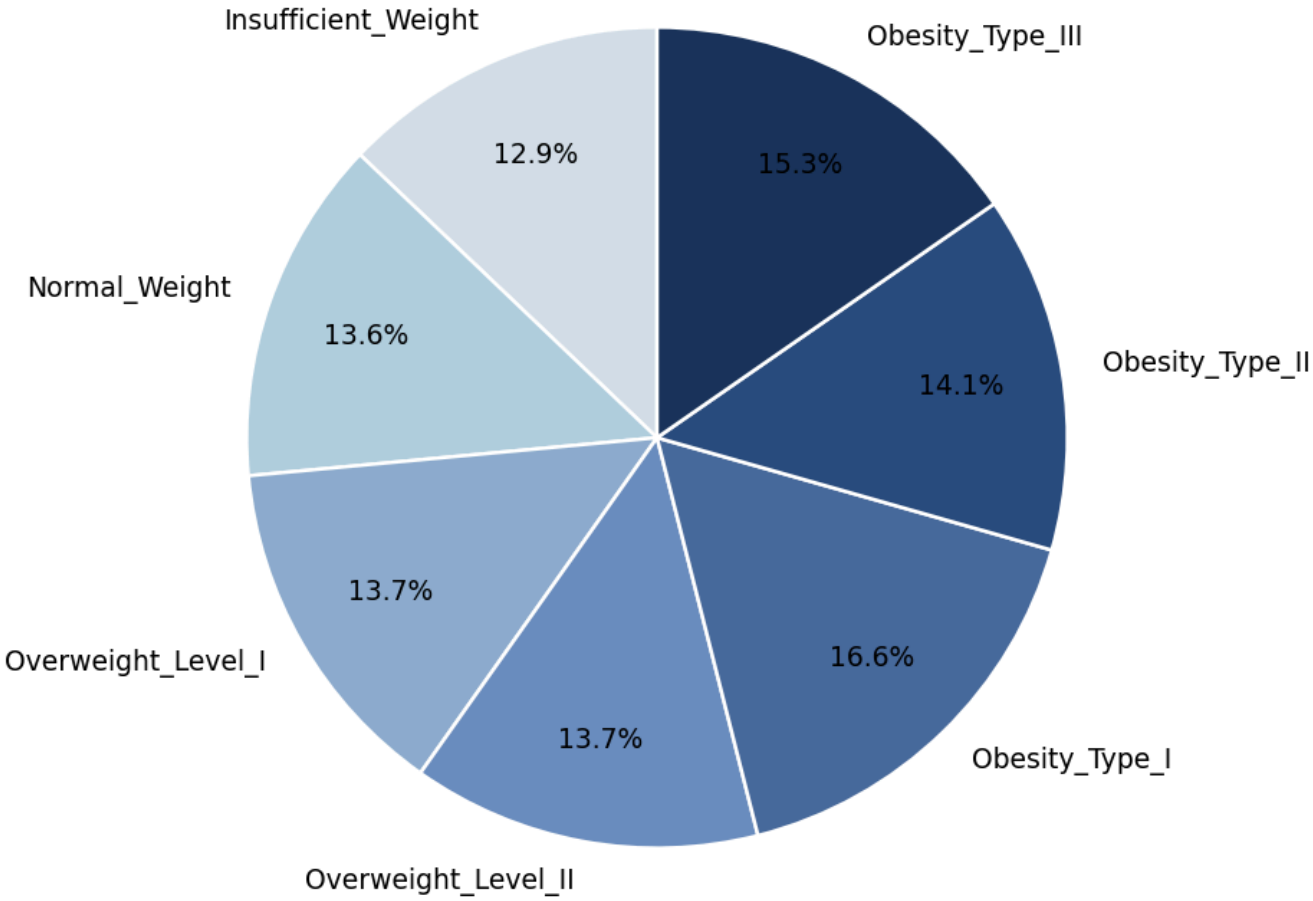
Naturaleza de la variable: Es una variable cualitativa ordinal, la cual clasifica a los individuos en siete niveles ponderados de acuerdo con su Índice de Masa Corporal (IMC): Insufficient_Weight, Normal_Weight, Overweight_Level_I, Overweight_Level_II, Obesity_Type_I, Obesity_Type_II y Obesity_Type_III.

```
--- Tabla 8. Distribución de frecuencias para NivelDeObesidad ---
```

NivelDeObesidad	Cantidad de personas	Porcentaje (%)
Obesity_Type_I	351	16.63
Obesity_Type_III	324	15.35
Obesity_Type_II	297	14.07
Overweight_Level_I	290	13.74
Overweight_Level_II	290	13.74
Normal_Weight	287	13.60
Insufficient_Weight	272	12.88

Al examinar la distribución de NivelDeObesidad, se aprecia un notable balance entre las siete categorías que la integran.

La clase con mayor frecuencia es Obesity_Type_I representando un 16.63% de los casos (351 registros), mientras que la categoría con menor frecuencia es Insufficient_Weight con un 12.88% (272 registros). La diferencia entre la clase más representada y la menos representada es de apenas 3.75 puntos porcentuales. Esta homogeneidad confirma una muestra adecuadamente balanceada, lo que resulta altamente propicio para tareas de inferencia y clasificación, ya que evita sesgos hacia una categoría predominante.

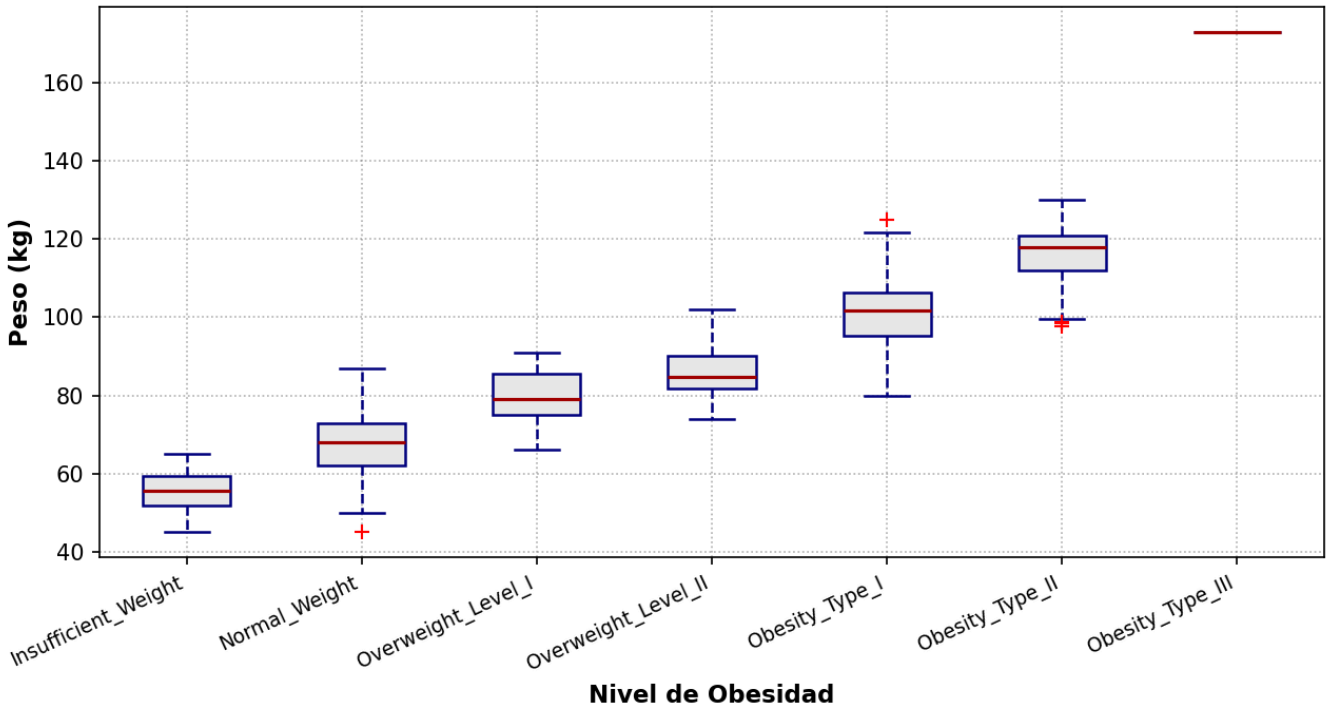


Gráfica 1. Distribución porcentual del nivel de obesidad

3.4 Análisis gráfico enfocado en una subpoblación

A continuación se selecciona la subpoblación masculina. Dentro de esta subpoblación, se explora la relación entre la variable de salida NivelDeObesidad (categórica ordinal) y la variable cuantitativa Peso (en kilogramos).

A continuación, se ejecutan las visualizaciones en Python mediante un diagrama de cajas (boxplot) para evaluar la posición, dispersión y presencia de valores atípicos, y un gráfico de barras para comparar la media del peso a lo largo de cada nivel de obesidad.



Gráfica 2. Distribución del peso por nivel de obesidad en la subpoblación masculina

El diagrama de caja revela patrones claros y coherentes sobre la distribución de la masa corporal en los hombres a través de las distintas categorías:

Tendencia ascendente: Se observa un incremento monótono y sostenido en la mediana del peso a medida que se avanza en la escala ordinal de obesidad. La mediana parte de aproximadamente 55.5 kg en la categoría Insufficient_Weight y se eleva de forma continua hasta superar los 117.8 kg en Obesity_Type_II (y alcanzando 173 kg en el registro aislado de Obesity_Type_III).

Dispersión: En la mayoría de los niveles, los rangos son relativamente estrechos y homogéneos, situándose entre 6 kg y 8 kg de desviación estándar. Esto indica una variabilidad moderada dentro de una misma clasificación, reflejando que la estatura del individuo modula en qué punto exacto dentro de la categoría de IMC se ubica determinado peso.

Observaciones atípicas y distribución: Se aprecian muy pocos valores atípicos fuera de las cajas (como un caso inferior cercano a 45 kg en Normal_Weight y observaciones puntuales en Obesity_Type_I y Obesity_Type_II). Por su parte, la categoría Obesity_Type_III cuenta únicamente con un individuo masculino en la muestra (173 kg), lo que evidencia que en esta población los casos severos de obesidad de tipo III se concentran casi en su totalidad en el sexo femenino.

---

4. Conclusiones

El análisis exploratorio e inferencial realizado sobre el conjunto de datos de obesidad en la población latinoamericana permite establecer las siguiente conclusion:

El análisis exploratorio de la base de datos reveló una completitud del 100% sobre sus 2,111 registros y 10 variables. La incorporación propuesta de la variable Número de pasos diarios aportaría un indicador cuantitativo clave para evaluar el impacto del sedentarismo de manera independiente a la dieta.

Por su parte, la distribución homogénea de NivelDeObesidad (entre 12.88% y 16.63%) la consolida como una variable solida para estudios de inferencia sin riesgos de sesgo por desbalance. Finalmente, el análisis en la subpoblación masculina mostró un crecimiento monótono y constante del peso a través de los niveles de obesidad, con variabilidad controlada dentro de cada clase y muy poca presencia de hombres en la categoría *Obesity_Type_III*.

Referencias

UCI Machine Learning Repository - base de datos de obesidad

OpenAI. (2026). ChatGPT (Versión de 10 de agosto) "Genera un diagrama en base a estos datos...". https://chatgpt.com

OpenAI. (2026). ChatGPT (Versión de 10 de agosto) "Genera un boxplot en base a estos datos...". https://chatgpt.com