Análisis del malestar psicológico condicionado por consumo de sustancias y factores sociodemográficos en México

Jorge Tello

Lenguaje Utilizado: Python

Indíce

1. Introducción y planteamiento del problema

2. Objetivos

3. Metodología

4. Exploración y comprensión del conjunto de datos

5. Preparación y tratamiento de los datos

6. Selección de características

7. Construcción y comparación de modelos de regresión

8. Evaluación del desempeño del modelo

9. Análisis de inferencia

10. Conclusiones

11. Referencias

1. Introducción y planteamiento del problema

El consumo de alcohol y sustancias es uno de los principales factores de riesgo para la salud pública, los efectos están asociados a enfermedades crónicas, accidentes, violencia y, de manera menos visible pero igualmente relevante, a la salud mental de quienes lo consumen, (OMS, 2024). La relación entre alcohol y bienestar psicológico rara vez es unidireccional, pues mientras algunos marcos teóricos sugieren que el malestar psicológico lleva al consumo como forma de automedicación, otros documentan que el consumo problemático de alcohol puede, a su vez, deteriorar la salud mental.

Este proyecto busca caracterizar qué sustancias se asocian con el malestar psicologico en la población mexicana, considerando no solo variables demográficas básicas, sino tambien el consumo de alcohol, tabaco y de otras sustancias, y la edad de inicio del consumo. El objetivo no es afirmar relaciones causales, sino identificar si existen asociaciones que aporten evidencia útil para entender el fenómeno.

Los datos utilizados fueron recopilados de la Encuesta Nacional de Consumo de Drogas, Alcohol y Tabaco (ENCODAT, 2025), levantada por la Secretaría de Salud a través de la Comisión Nacional de Salud Mental y Adicciones (CONASAMA), el Instituto Nacional de Psiquiatría Ramón de la Fuente Muñiz (INPRFM) y el Instituto Nacional de Salud Pública (INSP). Es una encuesta probabilística con representatividad nacional y regional, con información individual sobre consumo de sustancias y salud mental recabada en el mismo cuestionario.

En el presente estudio, la variable a predecir es el estado de salud mental, medido mediante la escala Kessler-10 (K-10), construida a partir de la suma de sus diez reactivos y disponible para la totalidad de la muestra encuestada, independientemente de si la persona ha consumido o no alguna sustancia.

2. Objetivos

Objetivo general

Analizar en qué medida el consumo de alcohol, el consumo de drogas, la exposición a estas sustancias y un conjunto de variables sociodemográficas de control se asocian con el malestar psicológico de la población mexicana de entre 12 y 65 años, medido mediante la escala Kessler 10, utilizando los datos de la Encuesta Nacional de Consumo de Drogas, Alcohol y Tabaco 2025.

Objetivos específicos:

- Caracterizar la estructura, calidad y cobertura del conjunto de datos de ENCODAT 2025 relevante para el análisis.
- Construir un puntaje continuo de malestar psicológico a partir de la escala Kessler 10, así como las variables categóricas de consumo de alcohol, edad de inicio de consumo de drogas y exposición a drogas, a partir de las observaciones disponibles en la encuesta.
- Seleccionar el subconjunto de variables más relevante para predecir el malestar psicológico, evitando redundancia.
- Construir y comparar un modelo de regresión lineal y un modelo de regresión no lineal basado en KNN, evaluando su desempeño mediante métricas interpretables.
- Construir un modelo con fines de inferencia que permita cuantificar la asociación (con márgenes de error) entre cada predictor y el malestar psicológico, reconociendo el alcance y las limitaciones de su diseño.

3. Metodología

3.1 Exploración inicial de datos

Para este estudio se utiliza la muestra completa de personas de 12 a 65 años entrevistadas en el cuestionario individual (19,200 registros), sin restringirla a ningún subgrupo de consumo, ya que la variable de interés (malestar psicológico) se mide en la totalidad de la muestra.

3.2 Variables

Variable de interés

Malestar psicológico, medido mediante la escala Kessler-10 (K-10): un puntaje continuo (rango 10-50) construido como la suma de sus 10 reactivos, disponible para el 100% de la muestra. Se investiga en qué medida este malestar está condicionado por el consumo de alcohol, el consumo de drogas y la exposición a estas sustancias.

Variables independientes candidatas

- Consumo de alcohol. Variable categórica de cuatro niveles, construida a partir de la frecuencia de consumo en el último año y la presencia de dificultades asociadas al consumo (problemas de salud, relaciones o trabajo atribuidos al alcohol): "Nunca ha bebido", "Bebió, no en el último año", "Consumo reciente sin dificultades" y "Consumo reciente con dificultades".
- Edad de inicio de consumo de drogas. Variable categórica de cuatro niveles ("No consumió", 12-18, 18-30, 30-65 años), que combina el consumo de drogas ilegales y el uso no médico de medicamentos controlados, siguiendo la definición operacional "cualquier droga" del informe ENCODAT 2025.
- Exposición a drogas. Variable binaria que indica si a la persona alguna vez le han ofrecido drogas, un proxy reconocido en la literatura de influencia del entorno y de pares sobre el consumo de sustancias.
- Edad. Variable de control continua, disponible para el 100% de la muestra.
- Variables sociodemográficas de control: sexo, urbanidad (rural / urbano / metropolitano, clasificación oficial por tamaño de localidad de INEGI) y nivel escolar (4 categorías: primaria o menos, secundaria, bachillerato, licenciatura o posgrado). Se incluyen para controlar heterogeneidad estructural y evitar atribuir a las variables de interés (salud mental, consumo de drogas) efectos que en realidad correspondan a diferencias socioeconómicas o geográficas de fondo.

3.3 Tratamiento de datos.

Se documentarán y resolverán explícitamente los problemas de codificación identificados relacionados a la base de datos, ya sean huecos, outliers, variables con interacciones o colinealidad, o variables sin significancia para nuestro modelo.

3.4 Modelado

Se construirán al menos dos modelos de regresión, uno lineal (regresión lineal múltiple) y uno no lineal (mediante KNN), posteriormente se comparará su desempeño mediante métricas como R^2, RMSE y MAE, para determinar qué modelo es mejor para predecir la variable de interés. Se opta por KNN en lugar de splines dado que la totalidad de las variables predictoras candidatas son categóricas o binarias, con la única excepción de la edad, lo cual limita la utilidad de una técnica pensada para modelar curvas suaves sobre variables continuas. Por último, se construirá un modelo con fines de inferencia (regresión lineal con intervalos de confianza) para cuantificar el margen de error de las asociaciones encontradas.

4. Exploración y comprensión del conjunto de datos

La base de datos completa, correspondiente al cuestionario individual de ENCODAT 2025, contiene 19,200 registros y 937 variables. Estas variables cubren una gran diversidad de temas más allá de los que se usaran para este estudio, entre ellos, tabaquismo, videojuegos problemáticos y ciudad de procedencia, además de los identificadores propios del diseño muestral de la encuesta, como el ponderador de expansión, el estrato y la unidad primaria de muestreo. Dado que la inmensa mayoría de estas 937 variables queda fuera del alcance de este estudio, el primer paso consiste en importar únicamente el subconjunto de reactivos necesarios para construir las variables definidas en la metodología.

```
Dimensiones de la base completa: 19200 registros, 937 variables
```

4.2 Importación de las variables de interés

Se seleccionan de forma explícita los siguientes grupos, cada uno correspondiente a una variable o a un conjunto de variables de la metodología. El primer grupo corresponde a las variables sociodemográficas de control, sexo, edad, urbanidad y nivel escolar. El segundo grupo corresponde a los diez reactivos individuales de la escala Kessler 10, que más adelante se suman para construir el puntaje de malestar psicológico. El tercer grupo corresponde al módulo de alcohol, e incluye tanto el reactivo de consumo alguna vez en la vida como el de frecuencia de consumo en el último año, además de los cinco reactivos que registran dificultades relacionadas con el consumo de alcohol, como problemas de salud, de relaciones o laborales atribuidos a la bebida. El cuarto grupo corresponde al módulo de drogas, e incluye por separado los reactivos de consumo de drogas ilegales, los de uso de medicamentos controlados, los que indican si ese uso fue con receta médica o sin ella, y los que registran la edad en que la persona consumió cada sustancia por primera vez. El quinto y último grupo corresponde a un único reactivo binario que indica si a la persona alguna vez le han ofrecido drogas. En conjunto, de las 937 variables originales se importan 59, un subconjunto reducido pero suficiente para construir la totalidad de las variables necesarias para el análisis.

```
Variables importadas: 59 de 937 originales
```

4.3 Naturaleza de las variables

Antes de examinar la calidad de los datos, conviene identificar la naturaleza estadística de cada variable, ya que esta determina tanto las operaciones que pueden aplicarse válidamente sobre ella como las decisiones de codificación que se tomarán más adelante, en la sección de tratamiento de datos.

Variable	Naturaleza	Justificación
Sexo	Cualitativa nominal (binaria)	No existe un orden natural entre "hombre" y "mujer"
Edad	Cuantitativa discreta	Medida en años completos, con orden y magnitud interpretable

Variable	Naturaleza	Justificación
Urbanidad	Cualitativa ordinal	Rural < Urbano < Metropolitano refleja un orden creciente en tamaño de localidad
Nivel escolar	Cualitativa ordinal	Existe una jerarquía clara (primaria < secundaria < bachillerato < licenciatura/posgrado)
Reactivos K-10 (10 ítems)	Cuantitativa discreta (Likert 1-5)	Se suman en un puntaje total (10-50), tratado como cuantitativa continua
Consumo de alcohol	Cualitativa nominal (4 categorías)	Combina recencia y presencia de dificultades; no existe un orden único evidente entre sus categorías
Edad de inicio de drogas	Cualitativa nominal (4 categorías)	Incluye "No consumió" como categoría estructural, no solo tramos de edad
Exposición a drogas	Cualitativa nominal (binaria)	Respuesta dicotómica que indica si a la persona alguna vez le han ofrecido drogas

4.4 Exploración de huecos

Para cada una de las variables anteriores se revisó cuántos registros cuentan con una respuesta válida frente al total de la muestra, de 19,200 personas. Sexo, edad, urbanidad, el puntaje completo de la escala Kessler 10 y exposición a drogas están completos al 100%, es decir, ninguna persona entrevistada dejó de responder alguno de estos reactivos.

Tabla 1b. Completitud — variables categóricas construidas

	Variable	n_valido	n_hueco	%_hueco
0	**Sexo**	19,200	0	0.00%
1	**Edad**	19,200	0	0.00%
2	**Urbanidad**	19,200	0	0.00%
3	**Nivel escolar**	18,911	289	1.51%
4	**K-10 (10 reactivos completos)**	19,200	0	0.00%
5	**Exposición a drogas**	19,200	0	0.00%

Nivel escolar presenta un hueco de 1.51 por ciento, equivalente a 289 personas sin una respuesta válida en el reactivo original de escolaridad. Además de estas seis variables de respuesta directa, se revisaron también las dos variables categóricas que se construyen a partir de varios reactivos combinados, consumo de alcohol y edad de inicio de drogas, ya que su completitud no puede evaluarse hasta que están ensambladas. Consumo de alcohol presenta un hueco de 0.58 por ciento, equivalente a 111 personas cuya respuesta de frecuencia de consumo resultó ambigua, y edad de inicio de drogas presenta un hueco de 2.03 por ciento, equivalente a 390 personas, que combina tanto respuestas de "no

sabe o no contesta" en el tamizaje de drogas como casos en los que la persona reportó haber consumido pero no proporcionó una edad de inicio válida. En ningún caso el hueco de una variable individual supera el 2.1 por ciento de la muestra total, lo cual confirma que el análisis puede construirse sobre prácticamente la totalidad de la población encuestada, sin necesidad de restringir el estudio a ningún subgrupo particular de consumo.

4.5 Variables consideradas y descartadas

Durante la exploración inicial de la base completa se revisaron varios módulos que finalmente no forman parte del conjunto de variables de este estudio:

- Consumo de drogas en el último año (di6*, dm6*): Descartado por alcance y cantidad de huecos, sus respuestas eran para un subgrupo muy pequeño, se descarta para priorizar el consumo independientemente del año con mayor cobertura muestral.
- Región geográfica (region): se descartó al presentar 9 categorías sin un orden natural entre sí y una relevancia conceptual limitada para la pregunta de investigación planteada, incluirla habría incrementado la dimensionalidad del modelo en gran medida.
- Dificultades relacionadas al consumo de drogas: solo 843 de 19,200 registros (4.4%) tienen respuesta válida, al aplicarse únicamente a un subgrupo muy acotado bajo un patrón de filtro, se consideran demasiados huecos para ser una variable de control útil.
- Campos de texto libre (nombre de medicamento u otra sustancia,): respuestas abiertas no estandarizadas (ej. "TRAMADOL", "MORFINA", "PARACETAMOL") que requerirían una categorización manual extensa antes de poder usarse cuantitativamente.
- Módulos de seguimiento detallado por sustancia específica: presentan estructuras de filtro anidadas y códigos de respuesta sin una correspondencia clara y verificable con las variables agregadas oficiales ya utilizadas, por lo que no aportan información adicional confiable.

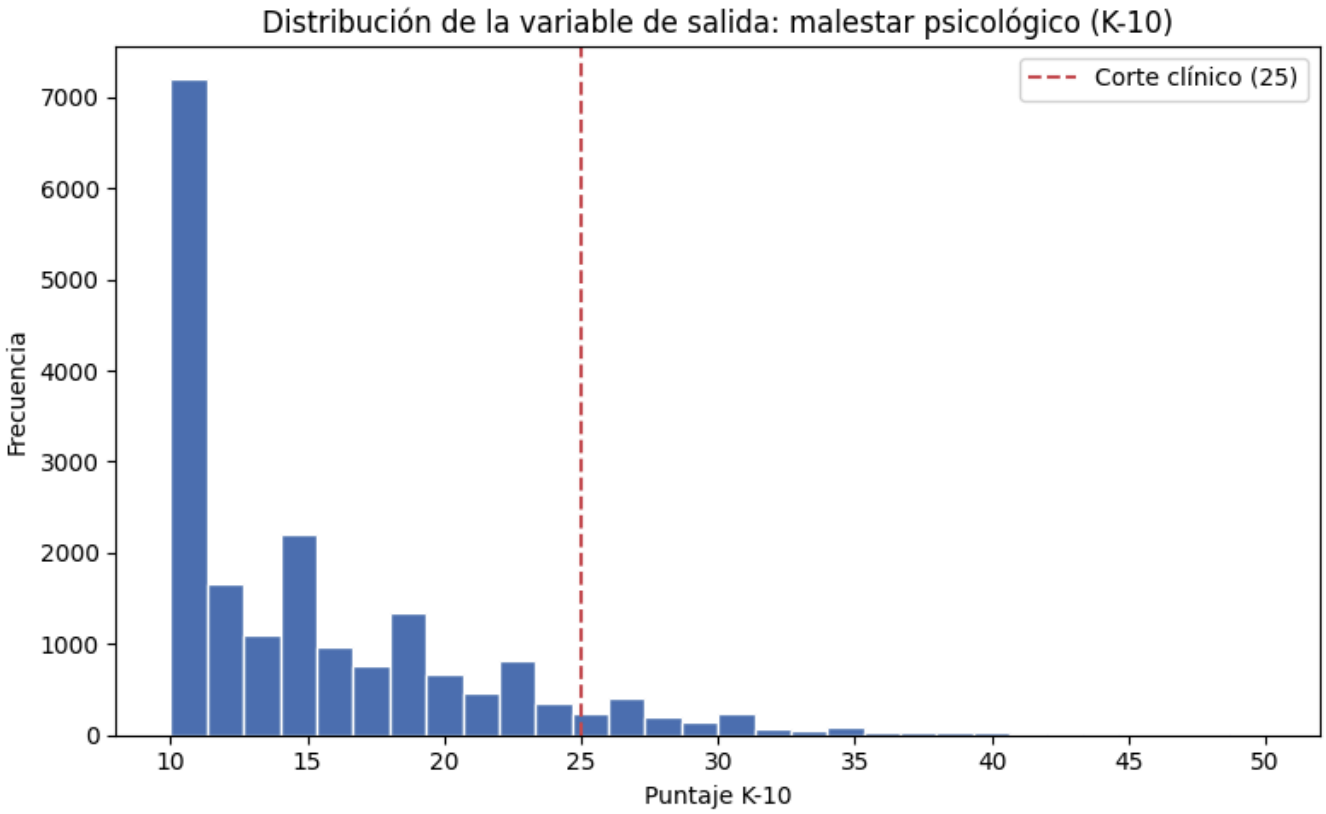
5. Preparación y tratamiento de los datos

En esta sección se construyen, a partir de los reactivos importados en la sección anterior, todas las variables que se emplean en el resto del estudio; se examina el comportamiento de la variable de salida y de las principales predictoras, se resuelve cada uno de los huecos documentados en la sección 4, distinguiendo entre los que admiten una imputación razonable y los que deben excluirse; se codifican las variables categóricas para que puedan incorporarse a un modelo de regresión, y finalmente, se revisa la presencia de valores atípicos en las variables cuantitativas.

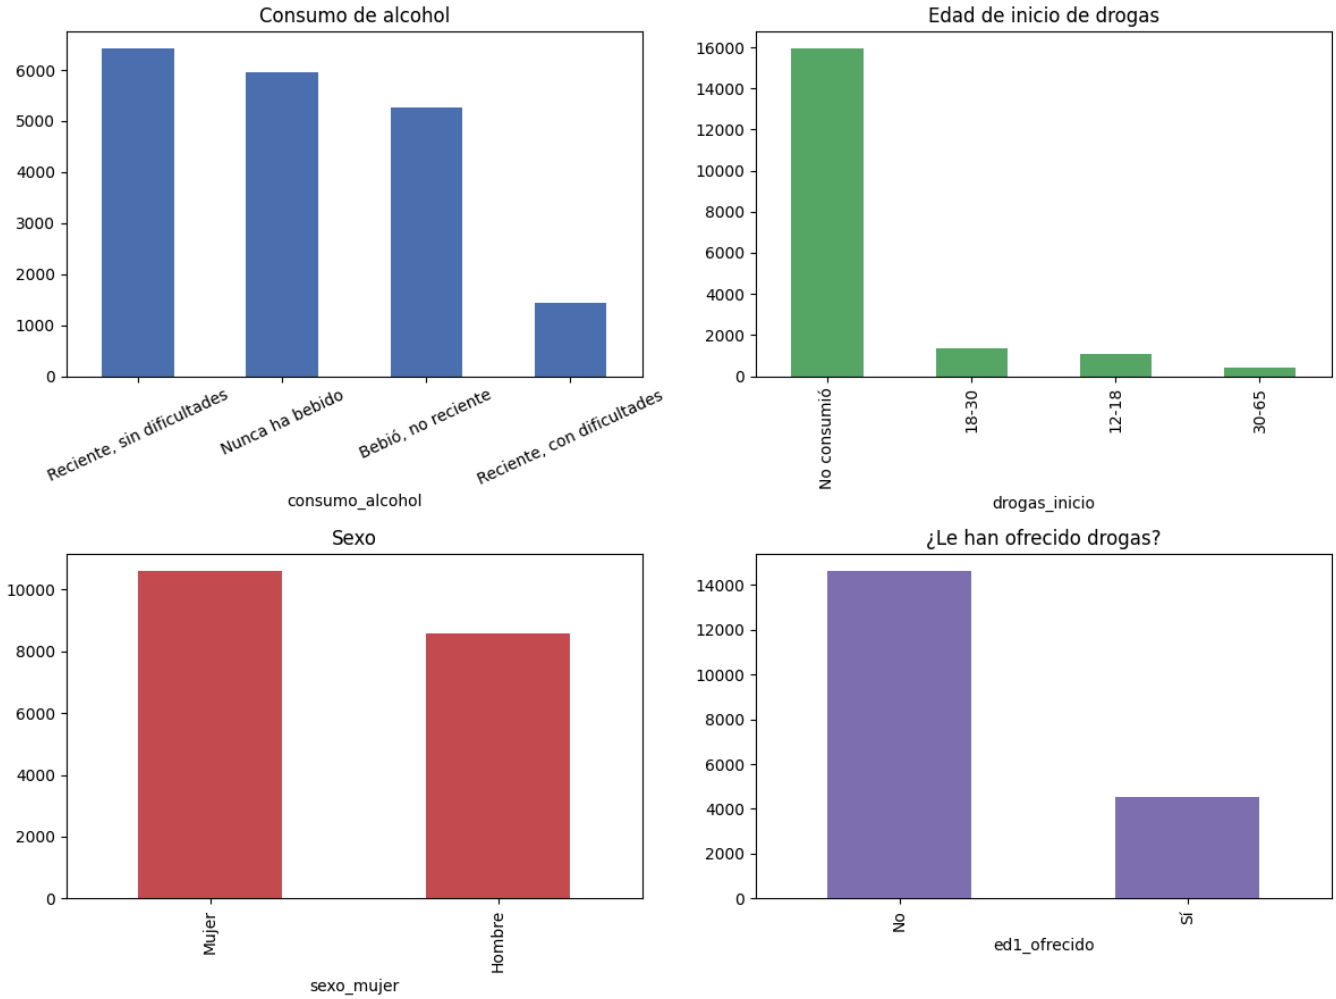
5.1 Comportamiento de las variables.

Las variables sociodemográficas se construyen de forma directa a partir de sus reactivos originales. Sexo se recodifica como una variable binaria que vale uno cuando la persona es mujer y cero cuando es hombre. Edad se conserva tal cual, como variable continua. Urbanidad se conserva en su codificación original de tres categorías, rural, urbano y metropolitano. Nivel escolar se recodifica a partir de las nueve categorías originales del cuestionario, agrupándolas en cuatro niveles, primaria o menos, secundaria, bachillerato, y licenciatura o posgrado, siguiendo la agrupación oficial documentada en el instrumento.

El puntaje de malestar psicológico se construye como la suma simple de los diez reactivos de la escala Kessler 10, cada uno de los cuales se responde en una escala de uno a cinco puntos según la frecuencia con que la persona experimentó cierto síntoma en el periodo de referencia, de modo que el puntaje resultante puede tomar cualquier valor entero entre 10 y 50, siendo 10 la ausencia total de síntomas y 50 la severidad máxima posible en esta escala.



La distribución de K-10 está fuertemente sesgada a la derecha, 37% de la muestra se ubica exactamente en el mínimo posible (10 puntos, ausencia total de síntomas), con una cola larga hacia valores más altos y solo una fracción menor por encima del corte clínico de malestar moderado-grave (25 puntos). Es el patrón esperado en una escala de tamizaje poblacional: la mayoría de las personas no reporta síntomas relevantes, y una minoría concentra el malestar más severo.



Respecto a las variables predictoras, las cuatro categorías de consumo de alcohol tienen un tamaño razonablemente balanceado entre sí, como ya se describió en la sección anterior. La variable de edad de inicio de drogas está dominada por la categoría "No consumió", que agrupa al 83.1 por ciento de la muestra. La variable de sexo está razonablemente balanceada, con un 52 por ciento de mujeres y un 48 por ciento de hombres. Y un 23.7 por ciento de la muestra reporta haber sido expuesta alguna vez a una oferta de drogas.

5.3 Tratamiento de huecos

Los huecos documentados en la sección 4 no son homogéneos en su naturaleza, y por lo tanto se tratan de forma distinta según su origen. El hueco de nivel escolar, de 1.51 por ciento, no tiene ninguna razón conceptual para sospechar que esté relacionado con una categoría de respuesta en particular, es decir, no hay motivo para pensar que quienes no respondieron esta pregunta tengan sistemáticamente un nivel escolar más alto o más bajo que el resto. Por esta razón, se trata como un hueco apto para imputación mediante KNN, donde el parecido se calcula usando un conjunto de variables de apoyo que sí están completas al 100% para toda la muestra, en este caso edad, sexo, urbanidad y el propio puntaje de malestar psicológico. De esta manera, el nivel escolar de una persona sin respuesta se estima observando el nivel escolar típico de otras personas con una edad, un sexo, una urbanidad y un nivel de

malestar psicológico similares a los suyos, en lugar de asignarle arbitrariamente el valor más frecuente de toda la muestra.

```
Nivel escolar — huecos antes: 289  después: 0
```

Los huecos de consumo de alcohol, 111 casos, y de edad de inicio de drogas, 496 casos, se tratan de manera distinta. Estos huecos no representan información faltante al azar, sino respuestas inconsistentes, como un código de frecuencia de consumo que no sigue el patrón esperado, o ambiguas por diseño del propio cuestionario, como una respuesta de "no sabe o no contesta" en el tamizaje de drogas. En ambos casos, imputar un valor implicaría estimar una respuesta para una pregunta que, por su propia naturaleza, no tiene un valor verdadero comparable al resto de la escala, por lo que estos registros se excluyen del conjunto final de modelado en lugar de imputarse. Tras aplicar esta exclusión, el conjunto final de modelado queda en 18,704 registros, equivalentes al 97.4 por ciento de la muestra total, sin ningún hueco pendiente en ninguna de las variables seleccionadas para el análisis

```
Registros excluidos: 496
Tamaño final del conjunto de modelado: 18704 de 19200 (97.4%)
```

El conjunto final de modelado queda en 18,704 registros (97.4% de la muestra total), sin huecos pendientes en ninguna de las variables seleccionadas.

**5.4 Transformación de variables

Todas las variables categóricas de este estudio, sexo, urbanidad, nivel escolar, consumo de alcohol y edad de inicio de drogas, se codifican mediante one-hot encoding, que consiste en crear una columna binaria independiente por cada categoría de la variable, con la excepción de una categoría que se designa como referencia y que no recibe una columna propia. Se optó por esta técnica en lugar de conservar las variables como números enteros ordenados, aun en el caso de urbanidad y nivel escolar, que sí tienen un orden natural, porque tratarlas como enteros en una regresión lineal impondría que el peso de pasar de una categoría a la siguiente es idéntico en magnitud entre todos los pares de categorías consecutivas, un supuesto que no hay ninguna razón para asumir de antemano y que, de ser falso, distorsionaría la estimación del modelo.

Las categorías elegidas como referencia, son Rural para urbanidad, Primaria o menos para nivel escolar, "Nunca ha bebido" para consumo de alcohol, y "No consumió" para edad de inicio de drogas. Es importante subrayar que estas categorías de referencia no quedan fuera del análisis en ningún sentido, siguen siendo una categoría plena de su variable, y su ausencia como columna independiente es únicamente una convención para evitar que las columnas de una misma variable sean una combinación lineal exacta entre sí, es decir, que X3 sea el resultado de X1+X2, lo cual generaría un problema de colinealidad perfecta si se incluyeran todas las categorías simultáneamente.

5.5 Valores atipícos

Como último paso de esta sección, se examinó la presencia de valores atípicos en las dos variables cuantitativas continuas del estudio, edad y el puntaje de malestar psicológico, utilizando el criterio del rango interquantil, que considera atípico cualquier valor que se ubique por debajo del primer cuartil

menos una vez y media el rango interquantil, o por encima del tercer cuartil más una vez y media ese mismo rango.

El IQR se obtiene mediante:

$$IQR = Q_3 - Q_1$$

donde Q_1 corresponde al primer cuartil y Q_3 al tercer cuartil.

Se considera inicialmente como posible valor atípico cualquier observación que se encuentre fuera del intervalo:

$$[Q_1 - 1.5(IQR),\ Q_3 + 1.5(IQR)]$$

```
Edad: límites=[-22.5, 93.5], atípicos=0
K-10: límites=[-2.0, 30.0], atípicos=461
```

Edad no presenta ningún valor atípico bajo este criterio, ya que sus límites naturales de 12 y 65 años quedan cómodamente dentro del rango intercuartílico ampliado. El puntaje de malestar psicológico sí presenta 461 valores por encima del límite superior calculado, todos ellos correspondientes a puntajes altos dentro de la escala. Estos valores no se eliminan ni se modifican, ya que no representan errores de captura, sino casos genuinos de malestar psicológico severo dentro de una escala clínica acotada entre 10 y 50 puntos, y son precisamente la población de mayor interés para los objetivos de este estudio. Eliminar estos registros por el simple hecho de ser estadísticamente atípicos introduciría un sesgo que excluiría sistemáticamente a las personas con mayor severidad de síntomas, contradiciendo el propósito mismo del análisis.

6. Selección de características

En esta sección se determina, de entre las siete variables candidatas identificadas en la metodología, cuáles mantienen una asociación estadísticamente significativa con el malestar psicológico una vez controlado por el resto, y se descarta cualquier variable que resulte redundante o irrelevante para el modelo.

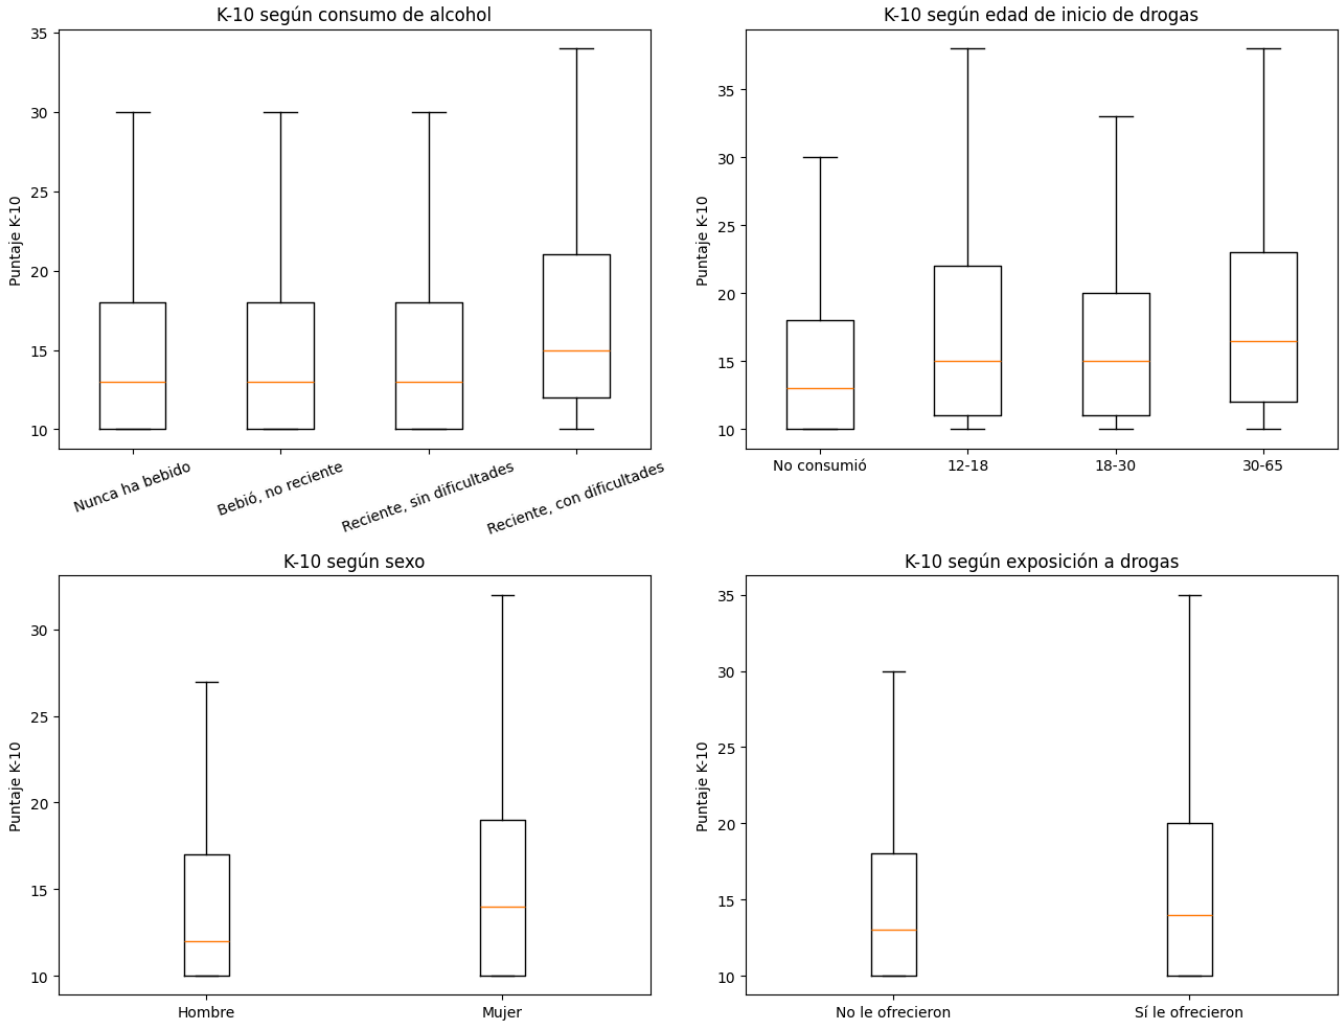
Todo el análisis de esta sección, la revisión de correlaciones, el cálculo de colinealidad y la prueba de significancia, se realiza exclusivamente sobre el conjunto de entrenamiento, reservando el conjunto de prueba para la evaluación final del modelo en la sección 8. Esta separación no es un detalle menor, si el proceso de selección de variables se realizara sobre la totalidad de los datos, la información del conjunto de prueba estaría influyendo indirectamente en la construcción del modelo, lo cual produciría una fuga de datos.

```
Entrenamiento: 14963 registros — Prueba: 3741 registros
```

Se divide el conjunto total de forma aleatoria en una porción de entrenamiento y una de prueba, en una proporción de 80 por ciento y 20 por ciento respectivamente. El conjunto de variables predictoras incluye, en esta etapa inicial, las siete variables candidatas de la metodología ya codificadas en sus columnas dummy correspondientes, sexo, edad, exposición a drogas, urbanidad, nivel escolar, consumo de alcohol y edad de inicio de drogas, lo cual suma trece columnas predictoras en total, ya que cuatro de estas siete variables son categóricas y se representan mediante más de una columna dummy cada una. Con esta partición, el conjunto de entrenamiento queda constituido por 14,963 registros y el conjunto de prueba por 3,741 registros, ambos con un tamaño más que suficiente para sostener los análisis estadísticos que siguen.

6.2 Comportamiento de la variable de salida frente a cada predictora

Antes de aplicar cualquier prueba estadística formal, se examina de manera visual cómo se distribuye el malestar psicológico dentro de cada categoría de las principales variables predictoras, mediante box-plot's que muestran la mediana y la dispersión del puntaje de Kessler 10 en cada grupo.

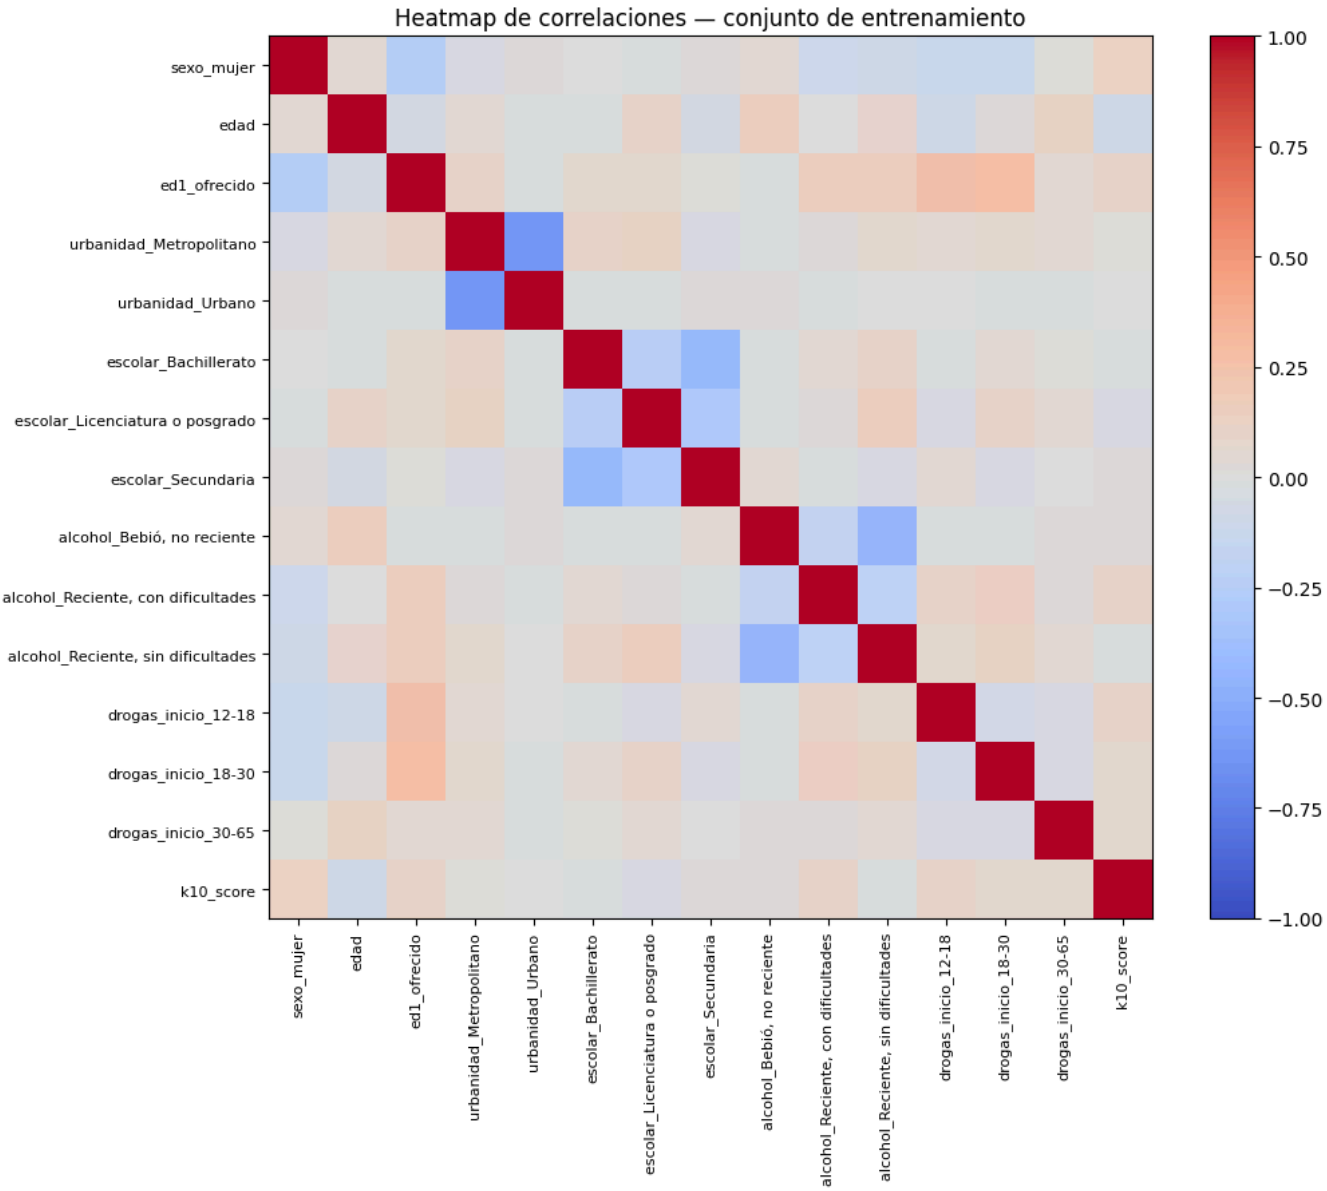


En el panel de consumo de alcohol, quienes reportan un consumo reciente acompañado de dificultades muestran una mediana de malestar psicológico visiblemente más alta que el resto de las categorías de esa misma variable, las cuales, entre sí, apenas se distinguen unas de otras, un indicio de que no es el consumo de alcohol en sí lo que importa, sino específicamente que ese consumo haya generado consecuencias reconocibles. En el panel de edad de inicio de drogas, la mediana de malestar psicológico aumenta de forma progresiva en cada uno de los tres tramos de edad de inicio, en comparación con la categoría de referencia "No consumió". En el panel de sexo, las mujeres muestran una mediana de malestar psicológico más alta que los hombres. Y en el panel de exposición a drogas, quienes alguna vez recibieron una oferta de drogas muestran una mediana ligeramente más alta que quienes nunca la recibieron.

6.3 Heatmap de correlaciones y Factor de Inflación de Varianza

El primer análisis cuantitativo consiste en calcular la matriz de correlaciones entre todas las variables predictoras y la variable de interés, únicamente sobre el conjunto de entrenamiento, y representarla mediante un mapa de calor que permite identificar de un vistazo tanto las asociaciones más fuertes con el malestar psicológico como cualquier par de variables predictoras que estén fuertemente correlacionadas entre sí. Las correlaciones más notables con el puntaje de malestar psicológico corresponden a sexo, con un valor de 0.13, exposición a drogas, con 0.10, la categoría de consumo de

alcohol reciente con dificultades, con 0.09, y la categoría de edad de inicio de drogas en la adolescencia, también con 0.09.



El mapa de calor, sin embargo, solo permite detectar colinealidad entre pares de variables, y no es capaz de identificar un caso en el que una variable quede casi perfectamente explicada por una combinación de varias otras variables al mismo tiempo. Para cubrir esta limitación, se calcula también el Factor de Inflación de Varianza de cada variable predictora, un indicador que cuantifica en qué medida la varianza de una variable puede explicarse mediante una combinación lineal del resto de las variables del modelo, y que convencionalmente se considera motivo de preocupación cuando supera un valor de entre 5 y 10.

```
urbanidad_Metropolitano              1.765775
urbanidad_Urbano                     1.692232
alcohol_Reciente, sin dificultades   1.661438
escolar_Bachillerato                 1.603998
escolar_Secundaria                   1.585021
alcohol_Bebió, no reciente           1.501388
escolar_Licenciatura o posgrado      1.449113
ed1_ofrecido                         1.306525
alcohol_Reciente, con dificultades   1.295222
drogas_inicio_18-30                  1.165470
drogas_inicio_12-18                  1.142523
edad                                 1.097617
sexo_mujer                           1.092529
drogas_inicio_30-65                  1.028360
dtype: float64
```

En este caso, ninguna de las trece columnas predictoras presenta un Factor de Inflación de Varianza mayor a 2, siendo el valor más alto 1.77, correspondiente a la categoría metropolitana de urbanidad. Este resultado confirma que no existe colinealidad múltiple relevante entre ninguna de las variables candidatas, cada variable aporta información que no está ya contenida en el resto.

6.4 Selección stepwise mixta mediante prueba F parcial por bloques

Cuatro de las siete variables candidatas, urbanidad, nivel escolar, consumo de alcohol y edad de inicio de drogas, son variables categóricas representadas mediante varias columnas dummy cada una. Evaluar la significancia de estas variables columna por columna sería metodológicamente incorrecto, ya que las categorías de una misma variable no son independientes entre sí, y una variable podría parecer irrelevante si se juzga por una sola de sus categorías, aun cuando el conjunto completo de sus categorías sí aporte información significativa al modelo. Por esta razón, la significancia de cada variable se evalúa en bloque, es decir, considerando de manera conjunta todas las columnas dummy que le corresponden, en lugar de una por una.

Se aplica un procedimiento stepwise evaluando cada iteración, mediante una prueba F parcial, si conviene agregar el bloque no incluido que más reduce el error del modelo ($p < 0.05$), o retirar el bloque ya incluido que menos aporta ($p > 0.05$), hasta que ninguna de las dos condiciones se cumpla.

```
Prueba F final (modelo completo, controlando simultáneamente por el resto):
  sexo_mujer     F=501.569  p=0.000000  -> Se incluye
  edad           F=139.627  p=0.000000  -> Se incluye
  ed1_ofrecido   F=108.953  p=0.000000  -> Se incluye
  escolar        F=29.909  p=0.000000  -> Se incluye
  alcohol        F=45.264  p=0.000000  -> Se incluye
  drogas_inicio  F=59.729  p=0.000000  -> Se incluye
  urbanidad      F=0.140  p=0.869651  -> Se descarta
```

	Variable	F	p-valor	Decisión
0	sexo_mujer	501.568517	2.697808e-109	Se incluye
1	edad	139.627008	4.461717e-32	Se incluye
2	ed1_ofrecido	108.952887	2.032204e-25	Se incluye
3	escolar	29.908884	2.859077e-19	Se incluye
4	alcohol	45.263910	4.129604e-29	Se incluye
5	drogas_inicio	59.728516	2.239311e-38	Se incluye
6	urbanidad	0.139664	8.696512e-01	Se descarta

Al aplicar este procedimiento sobre las siete variables candidatas, seis de ellas, sexo, edad, exposición a drogas, edad de inicio de drogas, consumo de alcohol y nivel escolar, resultan estadísticamente significativas, con valores p muy por debajo de 0.05 en todos los casos, una vez controlado simultáneamente por el resto de las variables incluidas en el modelo final. Urbanidad es la única variable que el procedimiento descarta, con un valor F cercano a cero y un valor p de 0.87, muy por encima del umbral de significancia. Esto indica que el tamaño de la localidad en la que vive una persona, sea rural, urbana o metropolitana, no guarda una asociación distinguible de cero con su nivel de malestar psicológico, una vez que se controla por su sexo, su edad, su nivel escolar, su exposición a drogas y su historial de consumo de alcohol y de drogas.

6.5 Reflexión final sobre redundancia e irrelevancia

El proceso de selección de características descrito en esta sección se apoyó en dos criterios distintos y complementarios. El primero, evaluado mediante el Factor de Inflación de Varianza, busca identificar redundancia entre variables, es decir, casos en los que una variable no aporta ninguna información que no esté ya contenida en otra. En este estudio, ninguna de las siete variables candidatas presentó este problema.

El segundo criterio, evaluado mediante el procedimiento stepwise con pruebas F por bloques, busca identificar irrelevancia estadística, es decir, variables cuya asociación con la variable de interés no puede distinguirse de la ausencia total de asociación una vez controlado por el resto del modelo. Bajo este segundo criterio, únicamente la variable de urbanidad resultó descartada.

El conjunto final de variables que resulta de este proceso de selección, y que se utiliza para construir los modelos de regresión en la sección siguiente, queda integrado por sexo, edad, exposición a drogas, nivel escolar, consumo de alcohol y edad de inicio de drogas, lo cual equivale a doce columnas predictoras en total, una vez descontada la variable de urbanidad y sus dos columnas dummy asociadas.

Si nuestro modelo contase con alguna variable insignificante solo empobreceria su rendimiento al quitar valor a la predicción hecha, además de causar un mayor ruido en los datos, del mismo modo, tener variables redundantes ocasionaría aportar esencialmente la misma información dos veces, se generan estimaciones más inestables y se gastan recursos de cómputo e interpretación en columnas que no añaden nada nuevo al modelo.

7. Construcción y comparación de modelos

En esta sección se construyen dos modelos de regresión para predecir el malestar psicológico medido por la escala K 10, uno lineal y uno no lineal, siguiendo las variables seleccionadas en la sección anterior, es decir, sexo, edad, exposición a drogas, nivel escolar, consumo de alcohol y edad de inicio de drogas. Para el modelo no lineal se utiliza un enfoque basado en KNN, en lugar de un enfoque paramétrico como los splines, ya que la totalidad de las variables candidatas son categóricas o binarias, con la única excepción de la edad, lo cual limita la utilidad de una técnica pensada específicamente para capturar curvas suaves sobre variables continuas. Un modelo basado en vecinos más cercanos, en cambio, puede capturar de forma natural relaciones no lineales e interacciones entre combinaciones de categorías, sin necesidad de especificarlas de antemano, lo cual resulta más adecuado dada la naturaleza de nuestras variables predictoras.

7.1 Modelo lineal, regresión lineal múltiple

El modelo lineal se construye únicamente con las variables que resultaron significativas en la sección 6, es decir, sexo, edad, exposición a drogas, nivel escolar, consumo de alcohol y edad de inicio de drogas, todas ellas codificadas mediante variables dummy con su categoría de referencia correspondiente, salvo edad, que se mantiene como variable continua.

```
                            OLS Regression Results
==============================================================================
Dep. Variable:              k10_score   R-squared:                       0.070
Model:                            OLS   Adj. R-squared:                  0.069
Method:                 Least Squares   F-statistic:                     93.05
Date:                Fri, 04 Sep 2026   Prob (F-statistic):          4.52e-223
Time:                        01:44:40   Log-Likelihood:                -47489.
No. Observations:               14963   AIC:                          9.500e+04
Df Residuals:                   14950   BIC:                          9.510e+04
Df Model:                          12
Covariance Type:            nonrobust
==============================================================================

R cuadrada: 0.070    R cuadrada ajustada: 0.069
Observaciones: 14963    Estadístico F: 93.1    Valor p del modelo: 4.52e-223
```

	Coeficiente	Error estándar	Valor p	Límite inf. 95%	Límite sup. 95%
Intercepto	14.722	0.157	0.0	14.415	15.029
Escolar: Bachillerato	-1.053	0.138	0.0	-1.323	-0.783
Escolar: Licenciatura o posgrado	-1.389	0.165	0.0	-1.713	-1.064
Escolar: Secundaria	-0.684	0.123	0.0	-0.926	-0.443
Alcohol: Bebió, no reciente	0.859	0.130	0.0	0.605	1.113
Alcohol: Reciente, con dificultades	2.244	0.203	0.0	1.846	2.641
Alcohol: Reciente, sin dificultades	0.506	0.129	0.0	0.254	0.759
Drogas, inicio: 12-18	1.827	0.219	0.0	1.398	2.255
Drogas, inicio: 18-30	1.419	0.197	0.0	1.032	1.805
Drogas, inicio: 30-65	3.034	0.318	0.0	2.411	3.656
Sexo (mujer)	2.225	0.099	0.0	2.030	2.420
Edad	-0.036	0.003	0.0	-0.042	-0.030
Exposición a drogas	1.320	0.126	0.0	1.072	1.568

Todas las variables incluidas muestran una asociación estadísticamente significativa con el malestar psicológico, con valores p muy por debajo del umbral convencional de 0.05, lo cual indica que ninguna de estas asociaciones puede atribuirse razonablemente al azar dado el tamaño de la muestra utilizada. El patrón más relevante desde el punto de vista sustantivo se observa dentro de la variable de consumo de alcohol, donde el salto entre haber bebido recientemente sin dificultades y haber bebido recientemente con dificultades es considerablemente mayor que cualquier otro salto dentro de esa misma variable, lo cual sugiere que no es tanto el hecho de consumir alcohol lo que se asocia con mayor malestar psicológico, sino específicamente el hecho de que ese consumo haya generado consecuencias negativas reconocibles para la persona. De manera similar, dentro de edad de inicio de drogas, el consumo iniciado en la edad adulta tardía, entre los 30 y 65 años, muestra el coeficiente más alto de toda la tabla, un hallazgo que merece explorarse con cautela en la sección de conclusiones, ya que el tamaño de este subgrupo es considerablemente menor que el de los demás y podría estar reflejando un patrón particular, como el consumo de sustancias como una forma de afrontar un malestar psicológico ya existente en la vida adulta, en lugar de que el consumo sea la causa de dicho malestar.

7.2 Modelo no lineal, K Vecinos Más Cercanos

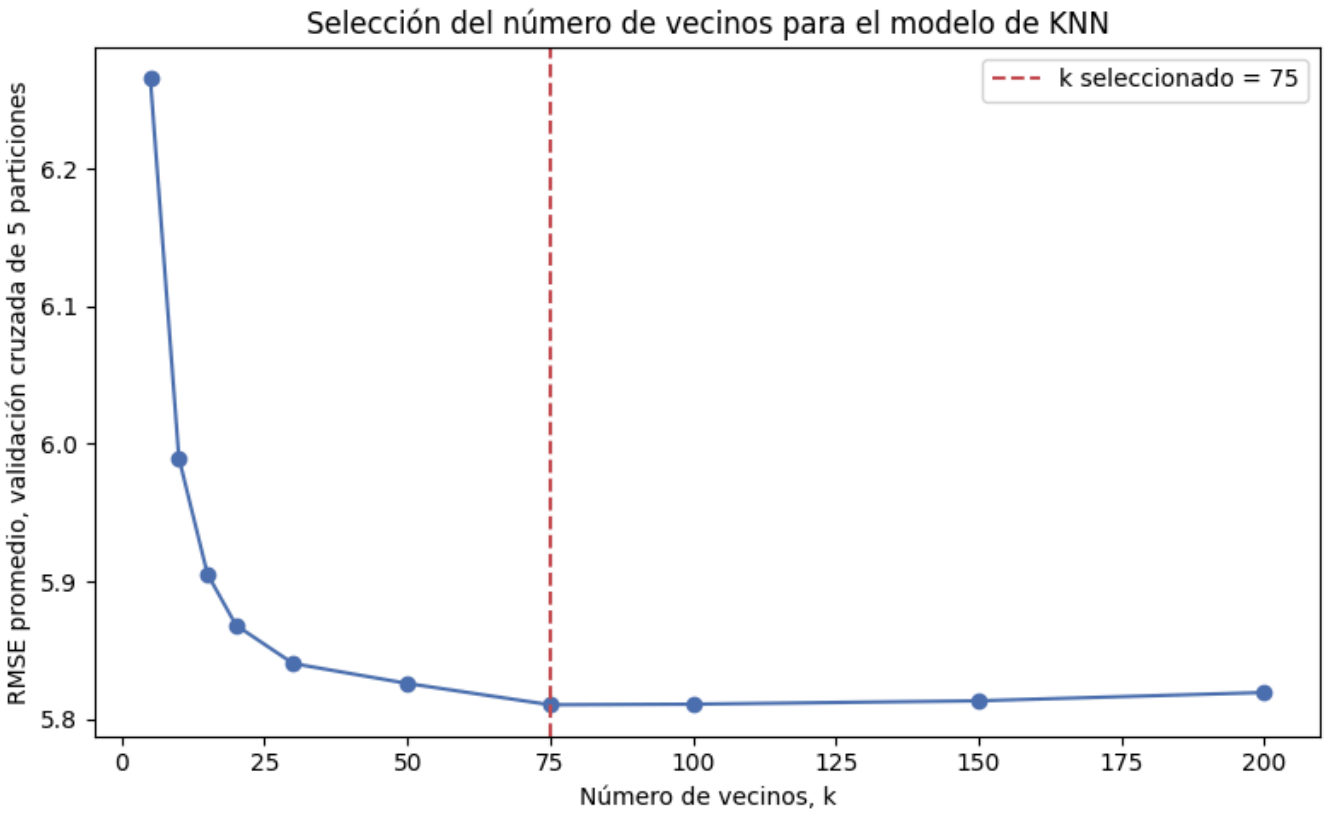
El modelo de KNN predice el valor de K 10 de una persona como el promedio del valor de K 10 de las personas más similares a ella dentro del conjunto de entrenamiento, de acuerdo con la distancia entre sus variables predictoras. Dado que este algoritmo se basa en distancias, es indispensable estandarizar las variables antes de ajustarlo, ya que de lo contrario la variable edad, con un rango mucho mayor que el de las variables dummy, dominaría por completo el cálculo de la distancia y las variables categóricas prácticamente no tendrían ninguna influencia sobre el resultado.

```
Valores nulos en X_train: 0
Valores nulos en X_test: 0
```

El número de vecinos, es el parámetro más importante de este modelo, y su elección implica un compromiso entre sesgo y varianza, ya que valores muy pequeños de k generan un modelo que se ajusta demasiado al ruido de cada observación individual, mientras que valores muy grandes de k generan un modelo excesivamente suavizado que pierde capacidad de distinguir patrones reales. Para seleccionar el valor óptimo, se evaluó el error del modelo mediante validación cruzada de cinco particiones sobre el conjunto de entrenamiento, probando distintos valores de k.

```
k = 5, RMSE promedio de validación cruzada = 6.2657
k = 10, RMSE promedio de validación cruzada = 5.9900
k = 15, RMSE promedio de validación cruzada = 5.9055
k = 20, RMSE promedio de validación cruzada = 5.8683
k = 30, RMSE promedio de validación cruzada = 5.8405
k = 50, RMSE promedio de validación cruzada = 5.8260
k = 75, RMSE promedio de validación cruzada = 5.8105
k = 100, RMSE promedio de validación cruzada = 5.8109
k = 150, RMSE promedio de validación cruzada = 5.8134
k = 200, RMSE promedio de validación cruzada = 5.8194

El valor de k con menor error de validación cruzada es 75
```



La curva de error muestra el comportamiento esperado para este tipo de modelo, con un error alto para valores pequeños de k, una disminución rápida conforme k aumenta, y una zona relativamente plana entre k igual a 50 y k igual a 150, donde el error se mantiene estable antes de comenzar a incrementarse nuevamente para valores de k muy grandes. El valor seleccionado, k igual a 75, se ubica precisamente en el punto de menor error dentro de esta zona estable.

A diferencia del modelo lineal, el modelo de KNN no genera coeficientes ni valores p asociados a cada variable, ya que no asume ninguna forma funcional específica entre las variables predictoras y la variable de interés, sino que construye sus predicciones directamente a partir de la similitud entre observaciones. Por esta razón, no es posible interpretar el efecto individual de cada variable de la misma manera que en el modelo lineal, aunque sí es posible comparar el desempeño global de ambos modelos, lo cual se realiza a continuación.

7.3 Comparación de modelos y justificación del modelo más adecuado

```
X_train_escalado: (14963, 12)  X_test_escalado: (3741, 12)
y_train: (14963,)  pred_train_lineal: (14963,)  pred_train_knn: (14963,)
y_test: (3741,)  pred_test_lineal: (3741,)  pred_test_knn: (3741,)
```

	Modelo	Conjunto	R2	RMSE	MAE
0	Lineal	Entrenamiento	0.069501	5.782248	4.455933
1	Lineal	Prueba	0.085650	5.856850	4.518957
2	K Vecinos Más Cercanos	Entrenamiento	0.084745	5.734689	4.394528
3	K Vecinos Más Cercanos	Prueba	0.085857	5.856187	4.515395

En el conjunto de entrenamiento, el modelo de K NN muestra un ajuste ligeramente mejor que el modelo lineal, con una R cuadrada más alta y errores más bajos, lo cual sugiere que existe cierta estructura no lineal en los datos que el modelo lineal no logra capturar del todo. Sin embargo, en el conjunto de prueba, que es el que realmente importa para juzgar la capacidad de generalización de un modelo, ambos modelos obtienen resultados prácticamente idénticos, con una diferencia en R cuadrada menor a 0.001 y diferencias igualmente mínimas en RMSE y MAE. Esto indica que la ligera ventaja del modelo de KNN sobre el conjunto de entrenamiento no se traduce en una mejor capacidad predictiva sobre datos nuevos, sino que refleja simplemente una mayor flexibilidad del algoritmo para ajustarse a las particularidades del propio conjunto de entrenamiento.

Dado que ambos modelos generalizan de forma prácticamente equivalente, se considera que el modelo lineal es el más adecuado para este problema, ya que ofrece exactamente el mismo desempeño predictivo sobre datos nuevos que el modelo de KNN, con la ventaja adicional de ser completamente interpretable, permitiendo cuantificar la dirección, magnitud y significancia estadística de cada asociación, algo que el modelo de KNN no puede ofrecer por su propia naturaleza. El modelo de KNN resulta útil como verificación de que no existe una estructura no lineal importante que el modelo lineal esté pasando por alto, pero no aporta una ventaja predictiva que justifique renunciar a la interpretabilidad del modelo lineal para los fines de este estudio.

8. Evaluación del desempeño del modelo

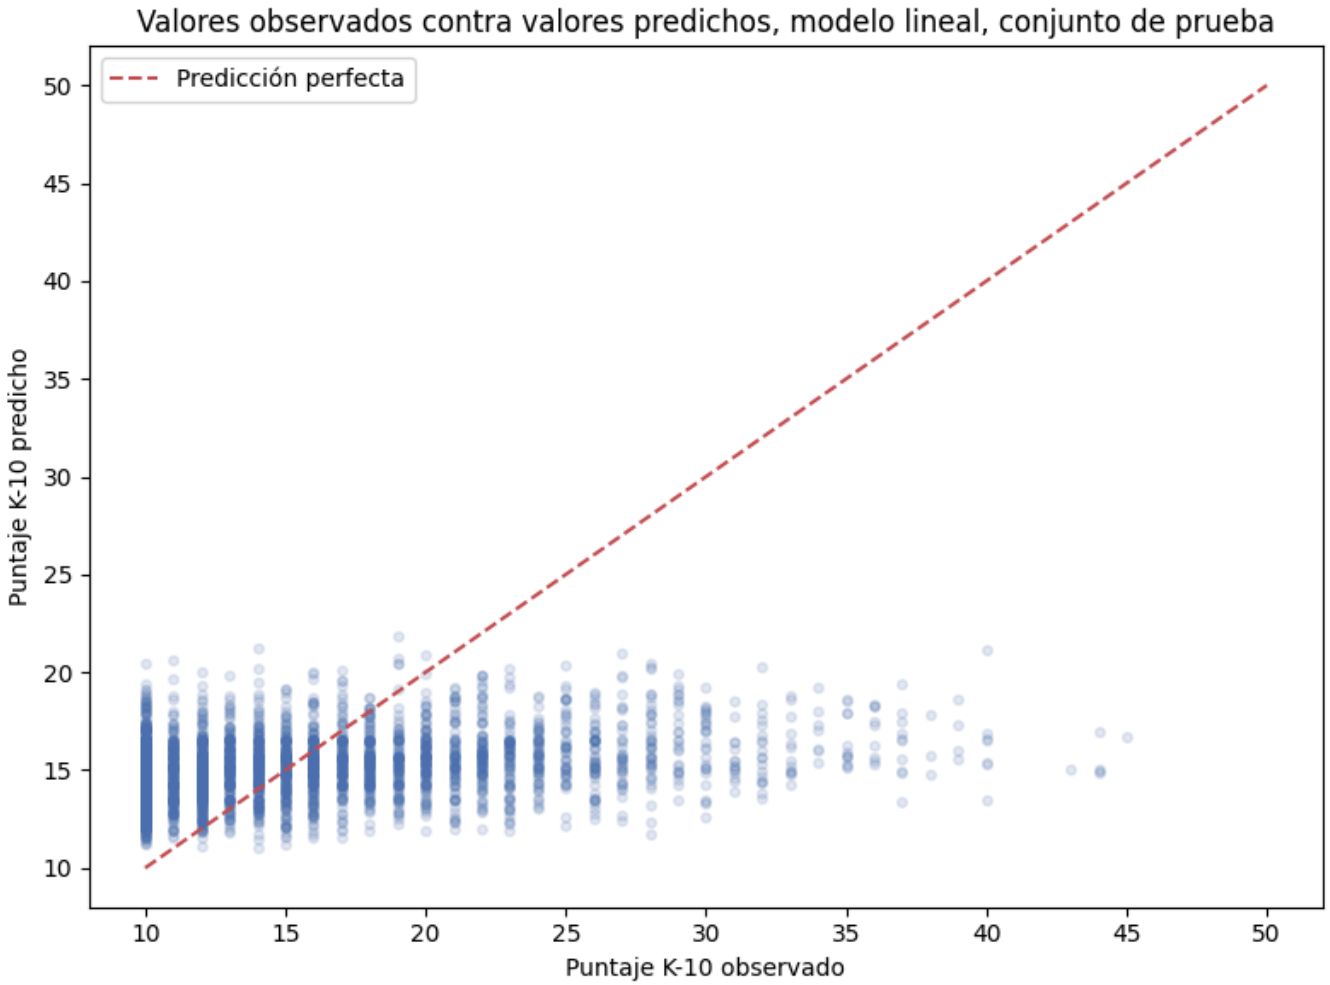
Habiendo determinado que el modelo lineal es el más adecuado para este problema, esta sección profundiza en la interpretación de sus métricas de desempeño, así como en el comportamiento esperado de sus predicciones al enfrentarse a datos que el modelo no ha observado durante su entrenamiento.

8.1 Interpretación de las métricas en lenguaje accesible

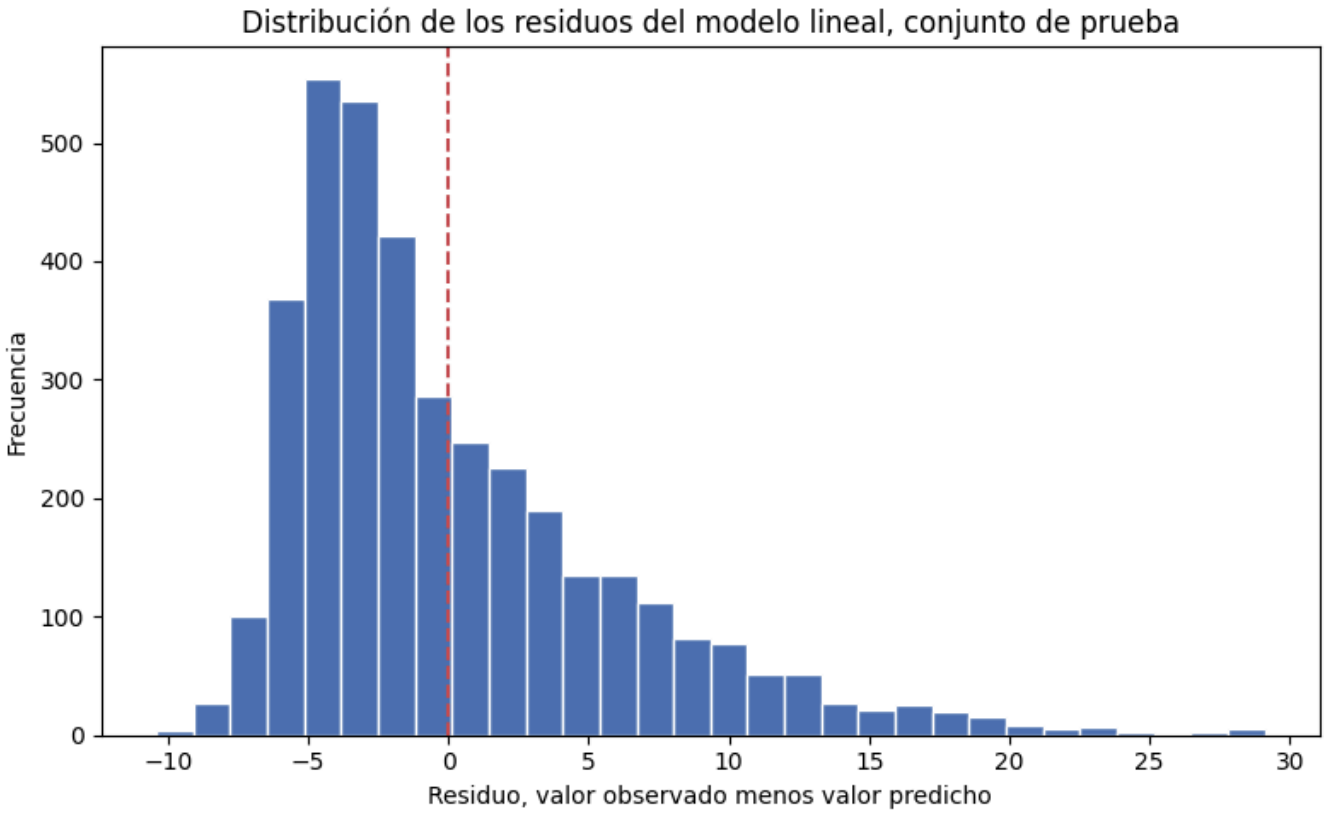
La R cuadrada obtenida en el conjunto de prueba es de 0.086, lo cual significa que las variables incluidas en el modelo, es decir, sexo, edad, exposición a drogas, nivel escolar, consumo de alcohol y edad de inicio de drogas, en conjunto logran explicar apenas el 8.6 por ciento de toda la variación individual que existe en el malestar psicológico dentro de la muestra. Esto no significa que estas variables no estén relacionadas con el malestar psicológico, ya que todas ellas mostraron una asociación estadísticamente muy significativa en la sección anterior, sino que el malestar psicológico de una persona depende de una enorme cantidad de factores adicionales que esta encuesta no captura, como la historia familiar, los eventos de vida recientes, el apoyo social disponible o factores biológicos individuales, entre muchos otros.

El RMSE, o raíz del error cuadrático medio, obtenido en el conjunto de prueba es de 5.86 puntos, y el MAE, o error absoluto medio, es de 4.52 puntos. En términos prácticos, esto significa que, en promedio, la predicción del modelo se equivoca por poco más de cuatro puntos y medio respecto al puntaje real de K 10 de una persona, en una escala que va de 10 a 50 puntos. Dado que buena parte de la muestra se concentra en los valores más bajos de esta escala, un error promedio de esta magnitud es considerable en términos relativos, aunque sigue siendo útil para distinguir tendencias generales entre grupos, como la diferencia consistente observada entre hombres y mujeres o entre quienes han tenido dificultades relacionadas con el alcohol y quienes no.

8.2 Comportamiento esperado del modelo frente a nuevos datos



La gráfica revela un comportamiento importante que las métricas resumidas por sí solas no muestran con la misma claridad, y es que las predicciones del modelo se concentran en un rango relativamente angosto, aproximadamente entre 11 y 22 puntos, sin importar qué tan alto sea el valor real observado. Para las personas con malestar psicológico severo, es decir, con puntajes reales de K 10 por encima de 30 o 35 puntos, el modelo sistemáticamente predice valores mucho más bajos que los observados, lo cual se refleja como una nube de puntos que se aleja cada vez más por debajo de la línea de predicción perfecta conforme el valor observado aumenta.



La distribución de los residuos confirma este patrón, mostrando una cola larga hacia valores positivos, es decir, casos en los que el valor observado fue considerablemente más alto que el valor predicho, mientras que prácticamente no existen residuos igual de extremos hacia el lado negativo. En términos prácticos, esto significa que, al aplicar este modelo sobre nuevas personas, se puede confiar en que ofrecerá una estimación razonable del nivel general de malestar psicológico esperado para alguien con ciertas características sociodemográficas y de consumo de sustancias, siempre que esa persona se encuentre dentro del rango típico de la escala, pero el modelo tenderá sistemáticamente a subestimar el malestar psicológico de las personas que en realidad se encuentran en una situación de mayor severidad clínica. Esta limitación es coherente con la naturaleza del modelo, que promedia el comportamiento de grandes grupos de personas que comparten ciertas características, y no está diseñado para identificar a los individuos más extremos dentro de cada grupo, algo que debe tenerse presente si el objetivo futuro de un modelo similar fuera, por ejemplo, la detección temprana de casos de malestar psicológico severo, para lo cual harían falta variables adicionales capaces de capturar esa heterogeneidad individual que el conjunto actual de predictoras no alcanza a representar.

9. Análisis de inferencia

Esta sección utiliza el modelo lineal como modelo de inferencia, ya que es el único de los dos modelos construidos que permite cuantificar tanto la dirección como el margen de error de cada asociación encontrada, algo que el modelo de KNN no puede ofrecer por su propia naturaleza no paramétrica. El objetivo de esta sección no es predecir con precisión el malestar psicológico de una persona en particular, para lo cual ya se documentó la capacidad limitada del modelo en la sección anterior, sino establecer con qué grado de certeza estadística se puede afirmar que cada una de las variables estudiadas se asocia con el malestar psicológico dentro de la población representada por esta muestra.

9.1 Intervalos de confianza de las asociaciones encontradas

	Coeficiente	Límite inferior, 95 por ciento	Límite superior, 95 por ciento
Intercepto	14.722	14.415	15.029
sexo_mujer	2.225	2.030	2.420
edad	-0.036	-0.042	-0.030
ed1_ofrecido	1.320	1.072	1.568
escolar_Secundaria	-0.684	-0.926	-0.443
escolar_Bachillerato	-1.053	-1.323	-0.783
escolar_Licenciatura o posgrado	-1.389	-1.713	-1.064
alcohol_Bebió, no reciente	0.859	0.605	1.113
alcohol_Reciente, sin dificultades	0.506	0.254	0.759
alcohol_Reciente, con dificultades	2.244	1.846	2.641
drogas_inicio_12-18	1.827	1.398	2.255
drogas_inicio_18-30	1.419	1.032	1.805
drogas_inicio_30-65	3.034	2.411	3.656

Ninguno de los intervalos de confianza de las variables incluidas en el modelo cruza el valor cero, lo cual confirma, con un nivel de confianza del 95 por ciento, que la dirección de cada una de estas asociaciones es consistente y no puede atribuirse al azar dentro de esta muestra. Es interesante notar que el intervalo más amplio corresponde a la categoría de edad de inicio de drogas entre los 30 y 65 años, que va de 2.411 a 3.656 puntos, un rango considerablemente más ancho que el de las demás categorías de esa misma variable, lo cual es consistente con el hecho de que este subgrupo cuenta con muchas menos observaciones que el resto, y por lo tanto su estimación es naturalmente menos precisa aunque su dirección siga siendo clara.

9.2 Inferencias sobre la problemática estudiada

Con base en estos resultados, se puede afirmar con razonable certeza estadística que, dentro de la población mexicana de entre 12 y 65 años representada por esta encuesta, el sexo femenino se asocia con un mayor malestar psicológico, con una diferencia esperada de entre 2.03 y 2.42 puntos respecto a

los hombres. De manera similar, se puede afirmar que haber sido expuesto a una oferta de drogas, haber consumido drogas en algún momento de la vida, y particularmente el haber tenido dificultades relacionadas con el consumo de alcohol, se asocian de forma consistente con un mayor malestar psicológico dentro de esta población, con márgenes de error que en ningún caso ponen en duda la dirección positiva de estas asociaciones.

También es posible inferir, con el mismo nivel de confianza, que la escolaridad actúa como un factor asociado a un menor malestar psicológico, de forma gradual, es decir, entre mayor es el nivel educativo alcanzado, menor es el malestar psicológico esperado, con una diferencia de hasta 1.37 puntos entre quienes tienen licenciatura o posgrado y quienes tienen primaria o menos. Esta gradiente es coherente con explicaciones basadas en el acceso diferenciado a recursos económicos, sociales y de afrontamiento asociados a la escolaridad, aunque esta encuesta no permite determinar si la escolaridad protege directamente contra el malestar psicológico o si ambas están explicadas por un tercer factor no medido, como el nivel socioeconómico general del hogar de origen.

9.3 Alcance y limitaciones de las conclusiones

Estas conclusiones deben interpretarse con límites claros. En primer lugar, el diseño de este estudio es transversal, es decir, todas las variables se midieron en un único punto en el tiempo, por lo que ninguna de las asociaciones aquí reportadas puede interpretarse como una relación de causa y efecto, ni en una dirección ni en la otra. Es igualmente posible, por ejemplo, que el consumo problemático de alcohol contribuya a un mayor malestar psicológico, que un malestar psicológico preexistente lleve a un mayor consumo de alcohol como forma de afrontamiento, o que ambos fenómenos sean consecuencia de un tercer factor no medido en este estudio, y los datos disponibles no permiten distinguir entre estas posibilidades.

En segundo lugar, como se documentó en la sección de evaluación del desempeño, el modelo utilizado explica una fracción reducida de la variación total en el malestar psicológico, por lo que estas inferencias son válidas únicamente a nivel de tendencias poblacionales generales, y no deben utilizarse para predecir o diagnosticar el nivel de malestar psicológico de una persona en particular. Finalmente, algunas de las categorías analizadas, en especial edad de inicio de drogas entre los 30 y 65 años, están basadas en un número relativamente reducido de observaciones dentro de la muestra, lo cual se refleja en intervalos de confianza más amplios y sugiere que estos hallazgos específicos deberían tratarse con mayor cautela que aquellos basados en categorías con mayor representación muestral.

10. Conclusiones

Este estudio se propuso caracterizar en qué medida el malestar psicológico, medido mediante la escala Kessler 10, se asocia con el consumo de alcohol, el consumo de drogas y la exposición a estas sustancias en la población mexicana de entre 12 y 65 años, utilizando los datos de la Encuesta Nacional de Consumo de Drogas, Alcohol y Tabaco 2025. Los resultados muestran que todas las variables finalmente incluidas en el modelo, es decir, sexo, edad, exposición a drogas, nivel escolar, consumo de alcohol y edad de inicio de drogas, presentan una asociación estadísticamente significativa con el malestar psicológico, con márgenes de error suficientemente bajos para no dudar de las asociaciones dentro de la muestra estudiada.

El hallazgo más consistente a lo largo de todo el análisis fue que no es simplemente el hecho de consumir sustancias lo que se asocia con un mayor malestar psicológico, sino específicamente el haber experimentado dificultades reconocibles derivadas de ese consumo, ya que el salto en malestar psicológico esperado entre consumir alcohol recientemente sin dificultades y consumirlo con dificultades fue considerablemente mayor que cualquier otro salto dentro de esa misma variable. Esto sugiere que las intervenciones de salud pública dirigidas a esta problemática podrían obtener un mayor beneficio si se enfocan en identificar y atender tempranamente las consecuencias negativas del consumo de alcohol y otras sustancias, en lugar de dirigirse de manera indiferenciada a toda la población que consume alcohol de forma ocasional y sin consecuencias aparentes.

En términos de relevancia para el contexto real del problema, estos hallazgos son consistentes con marcos teóricos ya establecidos en la literatura sobre salud mental y adicciones (OMS, 2024), particularmente aquellos que reconocen una relación entre el malestar psicológico y el consumo de sustancias, en la que el consumo puede tanto derivar de un malestar preexistente como agravarlo con el tiempo. La magnitud modesta pero consistente de estas asociaciones, junto con la capacidad predictiva limitada del modelo en su conjunto, refuerza la idea de que el malestar psicológico es un fenómeno determinado por muchos factores, en el que el consumo de sustancias es un factor relevante pero parcial dentro de un panorama mucho más amplio de determinantes sociales, familiares y biológicos, por lo que nuestro modelo no explica ni un 10% de su varianza, reflejando su gran limitación.

Como posibles líneas de trabajo futuro, sería valioso complementar este tipo de análisis con encuestas que incorporen variables adicionales sobre entorno familiar, apoyo social percibido, eventos de vida recientes y antecedentes de salud mental en la familia, factores que la literatura señala como determinantes relevantes y que no forman parte del instrumento utilizado en este estudio. También sería de interés explorar diseños longitudinales, que permitan observar a las mismas personas a lo largo del tiempo y así aproximarse con mayor solidez a la dirección temporal de la relación entre consumo de sustancias y malestar psicológico, superando la limitación transversal del diseño aquí empleado. Finalmente, dado que la variable de edad de inicio de drogas entre los 30 y 65 años mostró el efecto más grande de todo el modelo pero con el menor número de observaciones, un estudio dirigido específicamente a esta subpoblación podría aportar información valiosa sobre un patrón de consumo tardío que este estudio solo pudo documentar de manera preliminar.

11. Referencias

- Sistema de control de encuestas - repositorio. (s. f.). ENSANUT. https://encuestas.insp.mx/repositorio/encuestas/ENCODAT2025/descargas.php
- World Health Organization: WHO. (2024, 28 junio). Alcohol. https://www.who.int/es/news-room/fact-sheets/detail/alcohol
- Anthropic. (2026). Claude [Modelo de lenguaje grande], Usado en codigo de gráficas. https://claude.ai/
- Comisión Nacional de Salud Mental y Adicciones. (s. f.). Informe sobre la situación de la salud mental y el consumo de sustancias en México. Gobierno de México. https://www.gob.mx/conasama/documentos/informe-sobre-la-situacion-de-la-salud-mental-y-el-consumo-de-sustancias-en-mexico
- Patrones y medidas de consumo de alcohol en adultos mexicanos: hallazgos de la Encodat 2025. (2026). PubMed. https://pubmed.ncbi.nlm.nih.gov/42536907/